

Théorie de la mesure et probabilités

Cours de 4^e année de licence – ZFAI (Institut Sino-Français de l'Aviation)

Livret de cours

Benoit Duvocelle

29 septembre 2026

Public visé : 4^e année de licence (L4, les licences chinoises durant quatre ans), dans le cadre du programme de mathématiques du ZFAI (Institut Sino-Français de l'Aviation).

Objectif général : Ce livret construit rigoureusement la théorie des probabilités à partir de la théorie de la mesure. Il prolonge les probabilités élémentaires vues en licence (probabilités discrètes, variables à densité, calcul d'espérance) en leur donnant un cadre unifié, capable de traiter à la fois le discret et le continu, et de manipuler rigoureusement des objets comme les limites de variables aléatoires.

Programme couvert : Ce livret suit la structure des deux unités d'enseignement du ZFAI, MA 7002 (Théorie de la mesure) et MA 7003 (Probabilités).

Partie I – Théorie de la mesure (MA 7002) :

- Chapitre 1 « Autour de la mesure extérieure de Lebesgue » (mesure extérieure, critère de Carathéodory, ensemble de Vitali) ;
- Chapitre 2 « Espace mesurable » (tribus, tribu engendrée, tribu borélienne, ensemble de Cantor) ;
- Chapitre 3 « Mesures » (mesure abstraite, mesure de Lebesgue sur $\mathbb{R}^n$, mesure de comptage) ;
- Chapitre 4 « Fonctions mesurables » ;
- Chapitre 5 « Intégrale de Lebesgue » (construction, propriétés, théorèmes de convergence, intégrales à paramètre) ;
- Chapitre 6 « Intégrales multiples » (théorème de Fubini, changement de variable) ;
- Chapitre 7 « Espaces L^p » (inégalités fondamentales, complétude et densité) ;
- Chapitre 8 « Décomposition des mesures » (densité et absolue continuité, théorème de Radon-Nikodym, mesure de Cantor, mesures étrangères, Théorème 8.22 « Décomposition de Lebesgue »).

Partie II – Probabilités (MA 7003) :

- Chapitre 9 « Variables aléatoires réelles » (discrètes et continues, moments, caractérisation de la loi, changement de variables, indépendance, fonctions génératrices) ;
- Chapitre 10 « Vecteurs aléatoires » (loi jointe et lois marginales, moments, indépendance, somme de variables aléatoires) ;
- Chapitre 11 « Lois et espérance conditionnelles » ;
- Chapitre 12 « Vecteurs aléatoires gaussiens » ;
- Chapitre 13 « Convergence de suites de variables aléatoires » (modes de convergence, lois des grands nombres, fonctions caractéristiques, théorème central limite).

Mots clés : Tribus, mesures, intégrale de Lebesgue, décomposition de Lebesgue, espaces L^p , variables et vecteurs aléatoires, indépendance, vecteurs gaussiens, espérance conditionnelle, convergence, fonctions caractéristiques, théorèmes limites.

Table des matières

I	Théorie de la mesure	4
1	Autour de la mesure extérieure de Lebesgue	4
1.1	Rappels et compléments sur la théorie des ensembles	4
1.2	La mesure extérieure de Lebesgue	8
1.3	Ensembles Lebesgue-mesurables : le critère de Carathéodory	13
1.4	L'ensemble de Vitali : une partie non mesurable	15
2	Espace mesurable	17
2.1	Vers la notion de tribu	17
2.2	La tribu borélienne sur $\mathbb{R}$	21
2.3	L'ensemble triadique de Cantor	27
3	Mesures	28
3.1	Définitions et exemples	29
3.2	Le théorème π - λ (Dynkin)	31
3.3	Propriétés élémentaires	34
4	Fonctions mesurables	37
4.1	Image réciproque et tribus	37
4.2	Définition et premières propriétés	40
4.3	Complément : mesure image	44
5	Intégrale de Lebesgue	44
5.1	Fonctions étagées et approximation	45
5.2	Construction de l'intégrale de Lebesgue	48
5.3	Propriétés de l'intégrale	55
5.4	Les trois théorèmes de convergence	59
5.5	Intégrales dépendant d'un paramètre	64
6	Intégrales multiples	66
6.1	Mesure produit et théorèmes de Tonelli–Fubini	66
6.2	Changement de variables	69
7	Espaces L^p	76
7.1	Définition et norme	76
7.2	Inégalités fondamentales	77
7.3	Complétude et densité dans les espaces L^p	81
7.4	Le cas $p = 2$: espaces de Hilbert et théorème de représentation de Riesz	81
8	Décomposition des mesures	83
8.1	Densité et mesures absolument continues	84
8.2	Mesures étrangères	86
8.3	La mesure de Cantor	87
8.4	Le théorème de Radon-Nikodym	89
8.5	Le théorème de décomposition de Lebesgue	89
II	Probabilités	92
9	Variables aléatoires réelles	92
9.1	Rappels : événements, mesure de probabilité, formules classiques	92
9.2	Probabilités conditionnelles et indépendance des événements	94
9.3	Variable aléatoire, loi, fonction de répartition	96

9.4	Variables discrètes et variables à densité	101
9.5	Espérance, moments, variance	103
9.6	Rappel : les inégalités fondamentales du Chapitre 7 « Espaces L^p », en version probabiliste	106
9.7	Lois usuelles	108
9.8	Indépendance	110
9.9	Compléments : fonction génératrice et paradoxe de Bertrand	113
10	Vecteurs aléatoires	116
10.1	Vecteur aléatoire et loi jointe	116
10.2	Lois marginales	117
10.3	Indépendance des composantes	118
10.4	Covariance et matrice de covariance	119
10.5	Somme de variables aléatoires indépendantes	122
11	Lois et espérance conditionnelles	123
11.1	Construction de l'espérance conditionnelle	124
11.2	Lois conditionnelles	128
11.3	Régression linéaire	132
12	Vecteurs aléatoires gaussiens	136
12.1	Définition et exemples	137
12.2	Propriétés	138
12.3	Lois et fonctions caractéristiques	140
12.4	Définition et fonction caractéristique	141
12.5	Existence : construction d'un vecteur gaussien de paramètres donnés	142
12.6	Densité dans le cas non dégénéré	143
12.7	Indépendance et décorrélation : le théorème clé	144
12.8	Stabilité par combinaison linéaire	145
13	Convergence de suites de variables aléatoires	146
13.1	Modes de convergence	146
13.2	Lois des grands nombres	150
13.3	Applications aux théorèmes limites	152
13.4	Vecteurs gaussiens et convergence	155

Théorie de la mesure

1 Autour de la mesure extérieure de Lebesgue

Objectifs

- Comprendre le *problème de la mesure* et la solution qu'y apporte Lebesgue.
- Savoir manipuler la mesure extérieure et le critère de Carathéodory.
- Comprendre, à travers l'exemple de Vitali, pourquoi on ne peut pas mesurer toutes les parties de $\mathbb{R}$.
- Manipuler les indicatrices et les opérations logiques (union, intersection, complémentaire) sur les ensembles.

Introduction

On présente dans ce chapitre les tout premiers éléments de théorie de la mesure, en travaillant uniquement sur $\mathbb{R}$: cette théorie mathématique fournit un cadre unifié pour la théorie des probabilités moderne, le calcul intégral et l'étude des séries. On part d'une question concrète – peut-on attacher à *toute* partie de $\mathbb{R}$ un nombre, sa mesure, qui généralise la longueur et soit additive ? – pour découvrir qu'elle n'a pas de solution en toute généralité (Théorème 1.31 « Ensemble de Vitali »). Cette difficulté, une fois bien comprise sur l'exemple concret de $\mathbb{R}$, motivera au Chapitre 2 « Espace mesurable » la notion générale d'**espace mesurable**.

De la théorie de la mesure aux probabilités : quatre briques




Figure 1: Les notions centrales du livret : une tribu $\mathcal{T}$ (Chapitre 2 « Espace mesurable ») décrit les parties que l'on autorise à mesurer, une mesure μ (Chapitre 3 « Mesures ») leur attribue un poids, et l'intégrale (Chapitre 5 « Intégrale de Lebesgue ») permet de moyenner une fonction par rapport à μ . Les probabilités (Chapitre 9 « Variables aléatoires réelles ») correspondent au cas particulier où la mesure considérée est de masse totale 1.

1.1 Rappels et compléments sur la théorie des ensembles

1.1.1 Langage de la théorie des ensembles et des probabilités

Le langage des probabilités a son propre vocabulaire ; on prendra l'habitude, tout au long de ce livret, de traduire les énoncés dans les deux langues. On rappelle ici la correspondance de base, qui sera complétée au Chapitre 3 « Mesures » une fois que la notion de mesure aura été introduite.

Théorie des probabilités	Théorie des ensembles
Univers Ω	Un ensemble Ω
Événement A	Une partie A de Ω
Événement contraire de A	Le complémentaire de A (noté A^c ou A^c)
Événement impossible	L'ensemble vide $\emptyset$
Événement certain	L'ensemble Ω tout entier
A et B incompatibles	A et B disjoints
Événement élémentaire	Un singleton
Système complet d'événements	Partition de Ω (nombre dénombrable de parts)

Rappel de L1 1.1 – dénombrement, ensembles

On rappelle qu'une **partition** d'un ensemble Ω est une famille $(A_i)_{i \in I}$ de parties de Ω , deux à deux disjointes, et dont la réunion vaut Ω . En probabilités, un système complet d'événements est exactement une partition de l'univers : chaque issue ω appartient à exactement une des parts.

1.1.2 Dénombrabilité

Définition 1.2 – Ensemble dénombrable

Soit E un ensemble. On dit que E est **dénombrable** s'il existe $\varphi : E \rightarrow \mathbb{N}$ injective.

Remarque 1.3

Si l'on peut de plus choisir φ bijective, on dit que E est **infini dénombrable**. Dans le cas contraire (i.e. E est dénombrable et fini), on dit simplement que E est **fini**. Par abus de langage très répandu, on qualifie souvent de « dénombrable » un ensemble infini dénombrable ; le contexte lève l'ambiguïté.

Exemple 1.4 – Ensembles dénombrables et non dénombrables

Les ensembles $\mathbb{Z}$, $\mathbb{Q}$, $\mathbb{N} \times \mathbb{N}$ sont dénombrables : pour $\mathbb{N} \times \mathbb{N}$, on peut par exemple utiliser le codage de Cantor $\varphi(p, q) = \frac{(p+q)(p+q+1)}{2} + q$, qui est une bijection vers $\mathbb{N}$. Sa bijection réciproque s'exprime également explicitement : pour $n \in \mathbb{N}$, en posant

$$s := \left\lfloor \frac{\sqrt{8n+1} - 1}{2} \right\rfloor, \quad q := n - \frac{s(s+1)}{2}, \quad p := s - q,$$

on a $\varphi^{-1}(n) = (p, q)$ (l'entier s retrouve la diagonale $p+q$ contenant n , et q la position sur cette diagonale). Il existe en revanche des ensembles qui ne sont pas dénombrables, par exemple $\mathcal{P}(\mathbb{N})$ et $\mathbb{R}$.

Propriété 1.5 – Non-dénombrabilité de $\mathbb{R}$: argument diagonal de Cantor

L'intervalle $]0, 1[$, et donc $\mathbb{R}$, n'est pas dénombrable.

Démonstration. Supposons par l'absurde que $]0, 1[$ soit dénombrable et écrivons ses éléments sous la forme d'une liste

$$x_0, x_1, x_2, \dots$$

On choisit pour chaque x_n son développement décimal qui ne se termine pas par une suite infinie de 9 :

$$x_n = 0, a_{n,1}a_{n,2}a_{n,3} \dots$$

Définissons alors

$$y = 0, b_1b_2b_3 \dots, \quad b_n = \begin{cases} 1, & \text{si } a_{n,n} \neq 1, \\ 2, & \text{si } a_{n,n} = 1. \end{cases}$$

Le nombre y appartient à $]0, 1[$. Pour tout n , son n -ième chiffre décimal diffère du n -ième chiffre décimal de x_n ; ainsi $y \neq x_n$. Le nombre y n'apparaît donc nulle part dans la liste, contradiction. Ainsi $]0, 1[$ n'est pas dénombrable, et a fortiori $\mathbb{R}$ ne l'est pas non plus. ■

Remarque 1.6 – Deux comparaisons utiles de cardinalité

On dispose d'une bijection très simple entre $] - 1, 1[$ et $\mathbb{R}$:

$$f(x) = \tan\left(\frac{\pi x}{2}\right), \quad f^{-1}(y) = \frac{2}{\pi} \arctan(y).$$

On peut aussi injecter simplement $]0, 1[$ dans $\mathcal{P}(\mathbb{N})$. Fixons une énumération $(q_n)_{n \in \mathbb{N}}$ de $\mathbb{Q} \cap]0, 1[$ et posons

$$\Phi(x) := \{n \in \mathbb{N} \mid q_n < x\}.$$

Si $x < y$, la densité de $\mathbb{Q}$ fournit un rationnel $q_n \in]x, y[$; alors $n \in \Phi(y) \setminus \Phi(x)$, donc $\Phi(x) \neq \Phi(y)$. L'application Φ est donc injective.

Ce fait est la source de nombreuses subtilités en théorie de la mesure : on ne pourra pas, par exemple, décrire un borélien quelconque de $\mathbb{R}$ comme réunion dénombrable de singletons.

	14	19	25	32	40
	9	13	18	24	31
	5	8	12	17	23
	2	4	7	11	16
q	0	1	3	6	10
	p				

Figure 2: Numérotation diagonale de Cantor : la case (p, q) reçoit le numéro $\varphi(p, q) = \frac{(p+q)(p+q+1)}{2} + q$. On parcourt ainsi $\mathbb{N} \times \mathbb{N}$ diagonale par diagonale, ce qui donne une bijection avec $\mathbb{N}$.

Méthode 1.7 – Montrer qu'un ensemble est dénombrable

Pour montrer qu'un ensemble E est dénombrable, deux stratégies reviennent très souvent :

1. **Exhiber directement une injection** $\varphi : E \rightarrow \mathbb{N}$ (ou une bijection si l'on veut préciser qu'il est infini) ;
2. **Écrire E comme réunion dénombrable d'ensembles dénombrables**, ou comme image d'un ensemble dénombrable par une application quelconque : ces deux opérations préservent la dénombrabilité.

Pour montrer qu'un ensemble n'est *pas* dénombrable, l'argument diagonal de Cantor est le grand classique (utilisé pour $\mathcal{P}(\mathbb{N})$ et pour $\mathbb{R}$ via son développement décimal).

1.1.3 Limite supérieure et limite inférieure d'une suite d'ensembles

Cette notion, un peu abstraite au premier abord, est omniprésente en théorie des probabilités dès que l'on s'intéresse à des événements asymptotiques (« tel événement se produit une infinité de fois », « tel événement finit toujours par se produire »).

Définition 1.8 – Limite supérieure et limite inférieure d'une suite d'ensembles

Soit $(A_n)_{n \in \mathbb{N}}$ une suite de parties d'un ensemble Ω . On appelle :

- **limite supérieure** de $(A_n)_{n \in \mathbb{N}}$ l'ensemble des éléments qui appartiennent à une infinité de A_n :

$$\limsup_{n \in \mathbb{N}} A_n = \{\omega \in \Omega \mid \omega \in A_n \text{ pour une infinité d'indices } n\} = \{\omega \in \Omega \mid \forall i \in \mathbb{N}, \exists j \geq i, \omega \in A_j\};$$

- **limite inférieure** de $(A_n)_{n \in \mathbb{N}}$ l'ensemble des éléments qui appartiennent à tous les A_n sauf un nombre fini d'entre eux :

$$\liminf_{n \in \mathbb{N}} A_n = \{\omega \in \Omega \mid \omega \in A_n \text{ pour tout } n \text{ assez grand}\} = \{\omega \in \Omega \mid \exists i \in \mathbb{N}, \forall j \geq i, \omega \in A_j\}.$$

Exemple 1.9 – Pile ou face répété

On lance une pièce une infinité de fois ; on modélise l'univers par $\Omega = \{P, F\}^{\mathbb{N}}$. On souhaite décrire l'événement « la pièce tombe deux fois de suite sur Face une infinité de fois ». Pour $i \geq 1$, on pose $A_i = \{\omega \in \Omega \mid \omega_i = F, \omega_{i+1} = F\}$ (deux Face consécutifs à partir du rang i). L'événement recherché est alors, très naturellement,

$$\limsup_{n \geq 1} A_n,$$

puisque'il s'agit précisément des issues ω pour lesquelles une infinité des A_i se réalisent.

Remarque 1.10

On a toujours $\liminf_n A_n \subset \limsup_n A_n$: si ω appartient à tous les A_n à partir d'un certain rang, il appartient en particulier à une infinité d'entre eux.

Propriété 1.11 – Description par réunion et intersection

Soit $(A_n)_{n \in \mathbb{N}}$ une suite de parties de Ω . Alors :

$$\limsup_{n \in \mathbb{N}} A_n = \bigcap_{n \in \mathbb{N}} \left(\bigcup_{m \geq n} A_m \right), \quad \liminf_{n \in \mathbb{N}} A_n = \bigcup_{n \in \mathbb{N}} \left(\bigcap_{m \geq n} A_m \right).$$

Démonstration. On démontre d'abord l'égalité pour la limite supérieure. Pour tout $\omega \in \Omega$,

$$\begin{aligned} \omega \in \limsup_{n \in \mathbb{N}} A_n &\iff \forall i \in \mathbb{N}, \exists j \geq i, \omega \in A_j \\ &\iff \forall i \in \mathbb{N}, \omega \in \bigcup_{j \geq i} A_j \\ &\iff \omega \in \bigcap_{i \in \mathbb{N}} \left(\bigcup_{j \geq i} A_j \right). \end{aligned}$$

Ainsi,

$$\limsup_{n \in \mathbb{N}} A_n = \bigcap_{i \in \mathbb{N}} \left(\bigcup_{j \geq i} A_j \right).$$

De même, pour la limite inférieure, pour tout $\omega \in \Omega$,

$$\begin{aligned}\omega \in \liminf_{n \in \mathbb{N}} A_n &\iff \exists i \in \mathbb{N}, \forall j \geq i, \omega \in A_j \\ &\iff \exists i \in \mathbb{N}, \omega \in \bigcap_{j \geq i} A_j \\ &\iff \omega \in \bigcup_{i \in \mathbb{N}} \left(\bigcap_{j \geq i} A_j \right).\end{aligned}$$

On obtient donc également

$$\liminf_{n \in \mathbb{N}} A_n = \bigcup_{i \in \mathbb{N}} \left(\bigcap_{j \geq i} A_j \right).$$

■

Exercice 1.12 – Passage au complémentaire

Soit $(A_n)_{n \in \mathbb{N}}$ une famille de parties de Ω . Montrer que :

$$\left(\limsup_{n \in \mathbb{N}} A_n \right)^c = \liminf_{n \in \mathbb{N}} A_n^c \quad \text{et} \quad \left(\liminf_{n \in \mathbb{N}} A_n \right)^c = \limsup_{n \in \mathbb{N}} A_n^c.$$

Solution

On utilise la Proposition 1.11 « Description par réunion et intersection » et les lois de De Morgan : en passant au complémentaire dans $\limsup_n A_n = \bigcap_n \bigcup_{m \geq n} A_m$, on obtient $\bigcup_n \bigcap_{m \geq n} A_m^c = \liminf_n A_n^c$. Le second point s'obtient de façon symétrique.

Méthode 1.13 – Manipuler des lim sup/lim inf d'ensembles

Pour démontrer une inclusion ou une égalité portant sur des lim sup/lim inf d'ensembles, deux approches se complètent :

1. Travailler directement avec la définition « quantifiée » ($\forall i, \exists j \geq i, \dots$ pour la lim sup) : c'est souvent le plus rapide pour une inclusion simple.
2. Passer par la description en réunion/intersection dénombrable (Proposition 1.11 « Description par réunion et intersection ») pour se ramener aux propriétés usuelles des réunions et intersections (stabilité par tribu, De Morgan, etc.), en particulier lorsqu'on veut montrer qu'un tel ensemble est un événement (cf. Proposition 3.25 « Stabilité par lim sup/lim inf »).

1.2 La mesure extérieure de Lebesgue

1.2.1 Le problème de la mesure

L'idée de Lebesgue pour attaquer le problème de la mesure est la suivante : on sait, sans ambiguïté, mesurer un intervalle ; on sait donc aussi mesurer une réunion *dénombrable* d'intervalles, en sommant leurs longueurs (si les intervalles sont disjoints). L'idée est alors d'approcher *n'importe quelle* partie A de $\mathbb{R}$ « par l'extérieur », à l'aide de réunions dénombrables d'intervalles ouverts qui la recouvrent, et de prendre la plus petite longueur totale possible parmi tous ces recouvrements.

Définition 1.14 – Longueur d'un intervalle

Si I est un intervalle borné de $\mathbb{R}$ ayant pour extrémités $a \leq b$ (qu'elles appartiennent ou non à I), on note

$$\ell(I) := b - a.$$

Pour un intervalle non borné, on pose $\ell(I) := +\infty$.

Définition 1.15 – Mesure extérieure de Lebesgue

Pour toute partie $A \subset \mathbb{R}$, on pose

$$\lambda^*(A) := \inf \left\{ \sum_{i \in \mathbb{N}} \ell(I_i) \mid A \subset \bigcup_{i \in \mathbb{N}} I_i, I_i \text{ intervalle ouvert} \right\},$$

la borne inférieure étant prise sur tous les recouvrements **dénombrables** de A par des intervalles ouverts. Le nombre $\lambda^*(A) \in [0, +\infty]$ est appelé **mesure extérieure** de A .

Remarque 1.16

Un tel recouvrement existe toujours (par exemple $\mathbb{R} = \bigcup_{n \in \mathbb{Z}}]n-1, n+1[$), donc $\lambda^*(A)$ est bien défini pour toute partie A ; en particulier, λ^* est une application de $\mathcal{P}(\mathbb{R})$ tout entier dans $[0, +\infty]$ – c'est bien la générale que l'on cherchait au départ.

Propriété 1.17 – Premières propriétés de λ^*

La mesure extérieure de Lebesgue vérifie :

1. $\lambda^*(\emptyset) = 0$;
2. **croissance** : $A \subset B \Rightarrow \lambda^*(A) \leq \lambda^*(B)$;
3. **σ -sous-additivité** : pour toute suite $(A_n)_{n \in \mathbb{N}}$ de parties de $\mathbb{R}$,

$$\lambda^*\left(\bigcup_n A_n\right) \leq \sum_n \lambda^*(A_n).$$

Démonstration. Le point 1 est immédiat sur la définition. Pour le point 2, supposons $A \subset B$ et fixons un recouvrement dénombrable $(I_i)_{i \in \mathbb{N}}$ de B par des intervalles ouverts. Ce recouvrement couvre aussi A . Par définition de la borne inférieure qui définit $\lambda^*(A)$, on a donc, dans un premier temps,

$$\lambda^*(A) \leq \sum_{i \in \mathbb{N}} \ell(I_i).$$

Cette inégalité étant vraie pour tout recouvrement dénombrable de B , on prend, dans un second temps, la borne inférieure du membre de droite sur tous ces recouvrements ; on obtient

$$\lambda^*(A) \leq \inf_{B \subset \bigcup_i I_i} \sum_i \ell(I_i) = \lambda^*(B).$$

Pour le point 3 : soit $\varepsilon > 0$. Pour chaque n , on choisit un recouvrement $(]a_i^{(n)}, b_i^{(n)}[)_{i \in \mathbb{N}}$ de A_n tel que $\sum_i (b_i^{(n)} - a_i^{(n)}) \leq \lambda^*(A_n) + \varepsilon 2^{-n}$ (possible par définition de la borne inférieure). La famille $(]a_i^{(n)}, b_i^{(n)}[)_{n,i}$, qui est encore dénombrable (réunion dénombrable de familles dénombrables), recouvre $\bigcup_n A_n$; donc

$$\lambda^*\left(\bigcup_n A_n\right) \leq \sum_n \sum_i (b_i^{(n)} - a_i^{(n)}) \leq \sum_n \lambda^*(A_n) + \varepsilon.$$

On conclut en faisant $\varepsilon \rightarrow 0$. ■

Propriété 1.18 – Invariance de λ^* par translation et par homothétie

Pour toute partie $E \subset \mathbb{R}$:

1. pour tout $x \in \mathbb{R}$, en notant $x + E := \{x + y \mid y \in E\}$, on a $\lambda^*(x + E) = \lambda^*(E)$;
2. pour tout $a \in \mathbb{R}^*$ et tout $b \in \mathbb{R}$, en notant $aE + b := \{ay + b \mid y \in E\}$, on a $\lambda^*(aE + b) = |a| \lambda^*(E)$.

Idée de preuve. Un recouvrement de E par des intervalles ouverts $(]a_i, b_i[)_i$ se transporte, via l'application affine $y \mapsto ay + b$, en un recouvrement de $aE + b$ par les intervalles ouverts $(]aa_i + b, ab_i + b[)_i$ si $a > 0$ (ou leurs symétriques si $a < 0$), dont la longueur totale vaut $|a|$ fois celle du recouvrement de départ. Pour obtenir l'inégalité entre les deux bornes inférieures, on procède en deux temps : pour un recouvrement de

E fixé, on prend d'abord la borne inférieure sur les recouvrements de $aE + b$ dans le membre de gauche ; puis, l'inégalité obtenue étant vraie pour tout recouvrement de E , on prend la borne inférieure sur ces recouvrements dans le membre de droite. On recommence avec l'application affine réciproque pour obtenir l'inégalité inverse.

Démonstration. Le point 1 est le cas particulier $a = 1$ du point 2 ; montrons directement le point 2, en supposant d'abord $a > 0$. Soit $(]a_i, b_i[)_{i \in \mathbb{N}}$ un recouvrement de E par des intervalles ouverts. Alors $(]aa_i + b, ab_i + b[)_{i \in \mathbb{N}}$ est un recouvrement de $aE + b$ par des intervalles ouverts (car $y \in]a_i, b_i[\iff ay + b \in]aa_i + b, ab_i + b[$ lorsque $a > 0$), de longueur totale

$$\sum_i \ell(aI_i + b) = a \sum_i \ell(I_i).$$

Pour ce recouvrement fixé de E , la famille transformée est un recouvrement admissible de $aE + b$. Par définition de la borne inférieure, on a donc d'abord

$$\lambda^*(aE + b) \leq a \sum_i \ell(I_i).$$

Le membre de gauche ne dépend plus du recouvrement choisi de E . Comme l'inégalité vaut pour tout recouvrement dénombrable $(I_i)_i$ de E , on prend maintenant la borne inférieure du membre de droite sur tous ces recouvrements :

$$\lambda^*(aE + b) \leq a \inf_{E \subset \bigcup_i I_i} \sum_i \ell(I_i) = a \lambda^*(E).$$

Réciproquement, fixons un recouvrement $(J_i)_i$ de $aE + b$. Par l'application réciproque $z \mapsto \frac{z - b}{a}$, on obtient un recouvrement de E dont la longueur totale vaut $\frac{1}{a} \sum_i \ell(J_i)$. En prenant d'abord la borne inférieure sur les recouvrements de E dans le membre de gauche,

$$\lambda^*(E) \leq \frac{1}{a} \sum_i \ell(J_i).$$

Cette inégalité valant pour tout recouvrement $(J_i)_i$ de $aE + b$, on prend ensuite la borne inférieure du membre de droite sur tous ces recouvrements :

$$\lambda^*(E) \leq \frac{1}{a} \lambda^*(aE + b).$$

Ainsi $a \lambda^*(E) \leq \lambda^*(aE + b)$, et l'égalité suit.

Si $a < 0$, le même calcul vaut en échangeant les rôles de a_i et b_i (l'application $y \mapsto ay + b$ renverse l'orientation), et l'on obtient $\lambda^*(aE + b) = |a| \lambda^*(E) = -a \lambda^*(E)$. ■

Remarque 1.19

C'est cette propriété, utilisée dès la construction de l'ensemble de Vitali (translation des classes d'équivalence), qui garantit que tous les translatés $q + F$ ont la même mesure extérieure que F .

Remarque 1.20 – Pourquoi la dénombrabilité est essentielle

La σ -sous-additivité ci-dessus n'est valable que pour une réunion **dénombrable** $(A_n)_{n \in \mathbb{N}}$; rien de tel ne tient pour une réunion non dénombrable. Un exemple frappant : $[0, 1]$ est la réunion (non dénombrable) de tous ses singletons $\{x\}$, $x \in [0, 1]$, chacun de mesure extérieure nulle. Si la sous-additivité s'étendait aux familles non dénombrables, on en déduirait $\lambda^*([0, 1]) \leq \sum_{x \in [0, 1]} \lambda^*({x}) = \sum_{x \in [0, 1]} 0$, une somme de zéros que l'on serait tenté de croire nulle – alors que $\lambda^*([0, 1]) = 1$. Il n'y a pas de contradiction : une somme non dénombrable de termes nuls n'est simplement **pas définie** par les outils usuels. Autrement dit, cela n'a pas de sens de faire une somme usuelle sur un ensemble non dénombrable (contrairement à une série, indexée par $\mathbb{N}$, qui converge en un sens parfaitement rigoureux). C'est précisément parce que toute la construction de λ^* ne fait intervenir que des familles *dénombrables* (recouvrements, réunions) que ce paradoxe ne se produit jamais dans ce qui précède.

Attention 1.21

On aimerait bien sûr que λ^* soit *additive* sur les réunions disjointes : $\lambda^*(A \cup B) = \lambda^*(A) + \lambda^*(B)$ si $A \cap B = \emptyset$. On n'a établi ci-dessus que l'inégalité $\leq$ (sous-additivité) ; l'inégalité inverse est *fausse en général* sur $\mathcal{P}(\mathbb{R})$ tout entier. C'est précisément le nœud du problème de la mesure, et il va falloir s'y attaquer.

Théorème 1.22 – Valeur de λ^* sur les intervalles

Pour tous réels $a \leq b$, $\lambda^*([a, b]) = \lambda^*([a, b[) = b - a$.

Rappel. Le **théorème de Borel–Lebesgue** affirme que tout recouvrement ouvert d'un compact de $\mathbb{R}$ admet un sous-recouvrement fini. En particulier, si une famille d'intervalles ouverts recouvre $[a, b]$, on peut en extraire un nombre fini qui recouvre encore tout $[a, b]$.

Démonstration. Le cas $a = b$ est immédiat. Supposons donc $a < b$.

Inégalité $\leq$. Pour tout $\varepsilon > 0$, l'intervalle $]a - \varepsilon, b + \varepsilon[$ recouvre $[a, b]$. Ainsi

$$\begin{aligned}\lambda^*([a, b]) &\leq (b + \varepsilon) - (a - \varepsilon) \\ &= b - a + 2\varepsilon.\end{aligned}$$

Comme cette majoration vaut pour tout $\varepsilon > 0$, on obtient $\lambda^*([a, b]) \leq b - a$.

Inégalité $\geq$. Soit $(]a_i, b_i[)_{i \in \mathbb{N}}$ un recouvrement dénombrable de $[a, b]$. Par Borel–Lebesgue, il existe des indices $i_1, \dots, i_N$ tels que

$$[a, b] \subset \bigcup_{k=1}^N]a_{i_k}, b_{i_k}[.$$

À partir de cette famille finie, construisons une chaîne d'intervalles qui progresse de a vers b . Parmi les intervalles contenant a , choisissons-en un, noté $]u_1, v_1[$, dont l'extrémité droite v_1 est maximale. Si $v_1 > b$, la chaîne est terminée. Sinon, le point $v_1 \in [a, b]$ est recouvert ; il existe donc un intervalle de la famille finie qui contient v_1 , et son extrémité droite est strictement supérieure à v_1 . Parmi tous ces intervalles, choisissons-en un $]u_2, v_2[$ d'extrémité droite maximale. En répétant ce procédé, on obtient, après un nombre fini d'étapes, des intervalles

$$]u_1, v_1[, \dots,]u_m, v_m[$$

tels que

$$u_1 < a, \quad u_{k+1} < v_k \quad (1 \leq k < m), \quad v_m > b.$$

La longueur totale de cette chaîne vérifie alors

$$\begin{aligned}\sum_{k=1}^m \ell([u_k, v_k]) &> (v_1 - a) + \sum_{k=2}^m (v_k - v_{k-1}) \\ &= v_m - a \\ &> b - a.\end{aligned}$$

La somme des longueurs de tous les intervalles du sous-recouvrement fini est donc au moins aussi grande, puis celle du recouvrement dénombrable initial également. Ainsi

$$\sum_{i \in \mathbb{N}} \ell([a_i, b_i]) \geq \ell([a, b]) = b - a.$$

Cette inégalité vaut pour tout recouvrement dénombrable de $[a, b]$. Le membre de droite étant indépendant du recouvrement, on prend la borne inférieure du membre de gauche sur tous les recouvrements admissibles :

$$\lambda^*([a, b]) = \inf_{[a, b] \subset \bigcup_i I_i} \sum_i \ell(I_i) \geq b - a.$$

D'où $\lambda^*([a, b]) = b - a$.

Pour l'intervalle ouvert, la croissance donne d'abord $\lambda^*([a, b]) \leq b - a$. Réciproquement, pour tout $\eta \in]0, \frac{b-a}{2}[$,

$$[a + \eta, b - \eta] \subset]a, b[,$$

donc

$$\lambda^*([a, b]) \geq \lambda^*([a + \eta, b - \eta]) = b - a - 2\eta.$$

En faisant tendre η vers 0, on obtient $\lambda^*([a, b]) \geq b - a$. Ainsi $\lambda^*([a, b]) = b - a$. ■

Propriété 1.23 – Régularité intérieure des ouverts de $\mathbb{R}$

Soit $O \subset \mathbb{R}$ un ouvert. Alors

$$\lambda(O) = \sup\{\lambda(K) ; K \subset O, K \text{ compact}\}.$$

Autrement dit, un ouvert de $\mathbb{R}$ peut être approché de l'intérieur par des compacts, au sens de la mesure de Lebesgue.

Idée de preuve. Lorsque O est un intervalle ouvert, on l'approche par des intervalles fermés strictement inclus. Pour un ouvert général de $\mathbb{R}$, on utilise le fait qu'il s'écrit comme réunion dénombrable disjointe d'intervalles ouverts, puis on approche chacun de ces intervalles par des compacts en ne perdant qu'une masse arbitrairement petite. La preuve détaillée est proposée dans le TD n°1. Le même principe se généralise à $\mathbb{R}^n$: les ouverts de $\mathbb{R}^n$ s'approchent de l'intérieur par des compacts.

Exemple 1.24 – La mesure extérieure de $\mathbb{Q}$ est nulle

Comme $\mathbb{Q}$ est dénombrable, écrivons

$$\mathbb{Q} = \{q_0, q_1, q_2, \dots\}.$$

Fixons $\varepsilon > 0$ et, pour chaque $i \in \mathbb{N}$, posons

$$I_i = \left] q_i - \frac{\varepsilon}{2^{i+2}}, q_i + \frac{\varepsilon}{2^{i+2}} \right[.$$

Chaque rationnel q_i appartient à I_i , donc

$$\mathbb{Q} \subset \bigcup_{i=0}^{\infty} I_i.$$

La longueur de I_i vaut

$$\ell(I_i) = \left(q_i + \frac{\varepsilon}{2^{i+2}} \right) - \left(q_i - \frac{\varepsilon}{2^{i+2}} \right) = \frac{\varepsilon}{2^{i+1}}.$$

La longueur totale du recouvrement est donc

$$\begin{aligned} \sum_{i=0}^{\infty} \ell(I_i) &= \sum_{i=0}^{\infty} \frac{\varepsilon}{2^{i+1}} \\ &= \varepsilon \sum_{i=0}^{\infty} \frac{1}{2^{i+1}} \\ &= \varepsilon. \end{aligned}$$

Par définition de la mesure extérieure,

$$0 \leq \lambda^*(\mathbb{Q}) \leq \varepsilon.$$

Cette inégalité étant vraie pour tout $\varepsilon > 0$, on en déduit nécessairement

$$\boxed{\lambda^*(\mathbb{Q}) = 0}.$$

Le même argument montre plus généralement que **tout sous-ensemble dénombrable de $\mathbb{R}$ est de mesure extérieure nulle** : il suffit d'énumérer ses éléments et de les recouvrir par des intervalles dont les longueurs forment une série de somme arbitrairement petite.

Remarque 1.25

Définition 1.26 – Ensemble négligeable

Une partie $N \subset \mathbb{R}$ est dite **négligeable** si sa mesure extérieure de Lebesgue est nulle, c'est-à-dire si $\lambda^*(N) = 0$. En particulier, les singletons, $\mathbb{Q}$ et plus généralement toutes les parties dénombrables de $\mathbb{R}$ sont négligeables.

On retrouve donc bien, sur les intervalles, la longueur usuelle : λ^* prolonge la notion de longueur à *toutes* les parties de $\mathbb{R}$. Reste à savoir sur quelle famille de parties elle se comporte comme une vraie mesure additive.

1.3 Ensembles Lebesgue-mesurables : le critère de Carathéodory

On a vu que λ^* n'est, en toute généralité, que sous-additive. L'idée de Carathéodory est de repérer les parties B de $\mathbb{R}$ qui « découpent proprement » n'importe quel ensemble : si l'on teste B contre une partie arbitraire A , le découpage de A selon B et son complémentaire ne doit ni perdre ni créer de mesure.

Définition 1.27 – Ensembles Lebesgue-mesurables

Une partie $B \subset \mathbb{R}$ est dite **Lebesgue-mesurable** si

$$\forall A \subset \mathbb{R}, \quad \lambda^*(A) = \lambda^*(A \cap B) + \lambda^*(A \cap B^c).$$

On note $\mathcal{M}(\lambda^*)$ l'ensemble des parties Lebesgue-mesurables de $\mathbb{R}$.

Remarque 1.28

Par sous-additivité (Proposition 1.17 « Premières propriétés de λ^* »), l'inégalité $\lambda^*(A) \leq \lambda^*(A \cap B) + \lambda^*(A \cap B^c)$ est *toujours* vraie, quel que soit B . C'est donc uniquement l'inégalité inverse $\geq$ qu'il faut vérifier pour montrer que B est Lebesgue-mesurable.




Figure 3: B est Lebesgue-mesurable si, pour *tout* ensemble test A , le découpage de A en $A \cap B$ et $A \cap B^c$ conserve exactement la masse : $\lambda^*(A) = \lambda^*(A \cap B) + \lambda^*(A \cap B^c)$.

Théorème 1.29 – Théorème de Carathéodory

$\mathcal{M}(\lambda^*)$ contient $\emptyset$, est stable par complémentation et par réunion dénombrable ; il contient également toute partie de mesure extérieure nulle. De plus, la restriction de λ^* à $\mathcal{M}(\lambda^*)$ est **additive** sur les réunions dénombrables disjointes : si $(B_n)_{n \in \mathbb{N}}$ sont des éléments de $\mathcal{M}(\lambda^*)$ deux à deux disjoints, alors $\lambda^*(\bigcup_n B_n) = \sum_n \lambda^*(B_n)$.

Idée de preuve. La stabilité par complémentation est immédiate : la définition est symétrique en B, B^c . La stabilité par réunion se montre en deux temps : d'abord pour deux ensembles (calcul direct en écrivant deux fois la définition), puis par récurrence pour une réunion finie ; on passe ensuite à une réunion dénombrable d'ensembles *disjoints* grâce à une identité clé, obtenue en découpant A successivement selon $B_0, \dots, B_m$, puis en faisant tendre $m \rightarrow \infty$.

Démonstration. Notons $\mathcal{M} = \mathcal{M}(\lambda^*)$.

Mesure nulle. Si $\lambda^*(B) = 0$, alors pour tout A (car $\lambda^*(A \cap B) \leq \lambda^*(B) = 0$ par croissance) :

$$\lambda^*(A \cap B^c) \leq \lambda^*(A) \leq \lambda^*(A \cap B) + \lambda^*(A \cap B^c) = \lambda^*(A \cap B^c);$$

les deux membres extrêmes sont égaux, donc $B \in \mathcal{M}$.

$\emptyset \in \mathcal{M}$ en découle (mesure nulle), et $\mathcal{M}$ est stable par complémentation (la définition est symétrique en B, B^c).

Réunion finie. Soient $B_1, B_2 \in \mathcal{M}$. Pour tout $A \subset \mathbb{R}$, en utilisant $B_1 \in \mathcal{M}$:

$$\lambda^*(A \cap (B_1 \cup B_2)) = \lambda^*(A \cap (B_1 \cup B_2) \cap B_1) + \lambda^*(A \cap (B_1 \cup B_2) \cap B_1^c) = \lambda^*(A \cap B_1) + \lambda^*(A \cap B_2 \cap B_1^c).$$

En ajoutant $\lambda^*(A \cap (B_1 \cup B_2)^c) = \lambda^*(A \cap B_1^c \cap B_2^c)$ et en utilisant successivement $B_2 \in \mathcal{M}$ puis $B_1 \in \mathcal{M}$:

$$\lambda^*(A \cap (B_1 \cup B_2)) + \lambda^*(A \cap (B_1 \cup B_2)^c) = \lambda^*(A \cap B_1) + \lambda^*(A \cap B_1^c) = \lambda^*(A),$$

donc $B_1 \cup B_2 \in \mathcal{M}$. Par récurrence, $\mathcal{M}$ est stable par réunion finie, donc (en repassant au complémentaire, via les lois de De Morgan) par intersection finie.

Réunion dénombrable disjointe. Soit $(B_k)_{k \in \mathbb{N}}$ une famille de $\mathcal{M}$, deux à deux disjointes. Montrons par récurrence sur m que, pour tout $A \subset \mathbb{R}$,

$$\lambda^*(A) = \sum_{k=0}^m \lambda^*(A \cap B_k) + \lambda^*\left(A \cap \left(\bigcap_{k=0}^m B_k^c\right)\right). \quad (*)$$

Pour $m = 0$, c'est la définition de $B_0 \in \mathcal{M}$. En supposant $(*)$ vraie au rang m , on applique la définition de $B_{m+1} \in \mathcal{M}$ à l'ensemble test $A \cap \bigcap_{k=0}^m B_k^c$: comme les B_k sont disjointes, $(A \cap \bigcap_{k=0}^m B_k^c) \cap B_{m+1} = A \cap B_{m+1}$, ce qui donne $(*)$ au rang $m + 1$. En particulier, $(*)$ donne, en minorant l'intersection finie par l'intersection infinie (λ^* étant croissante) :

$$\lambda^*(A) \geq \sum_{k=0}^m \lambda^*(A \cap B_k) + \lambda^*\left(A \cap \left(\bigcap_{k=0}^{\infty} B_k^c\right)\right).$$

En faisant $m \rightarrow +\infty$, puis en utilisant la sous-additivité dénombrable (Proposition 1.17 « Premières propriétés de λ^* ») :

$$\lambda^*(A) \geq \sum_{k=0}^{\infty} \lambda^*(A \cap B_k) + \lambda^*\left(A \cap \left(\bigcap_k B_k^c\right)\right) \geq \lambda^*\left(A \cap \bigcup_k B_k\right) + \lambda^*\left(A \cap \left(\bigcup_k B_k\right)^c\right).$$

Comme l'inégalité inverse est toujours vraie, $\bigcup_k B_k \in \mathcal{M}$: $\mathcal{M}$ est stable par réunion dénombrable disjointe. Le cas d'une réunion dénombrable quelconque s'y ramène en posant $C_0 = B_0$, $C_k = B_k \setminus \bigcup_{j < k} B_j$ (disjoints, dans $\mathcal{M}$ par les stabilités déjà établies, et de même réunion que les B_k).

Additivité. En prenant $A = \bigcup_k B_k$ dans l'inégalité ci-dessus (avec les B_k disjointes), on obtient $\lambda^*(\bigcup_k B_k) \geq \sum_k \lambda^*(B_k)$; l'inégalité inverse étant la sous-additivité, on a égalité. ■

Remarque 1.30

On vient donc de construire, à force de travail, une famille $\mathcal{M}(\lambda^*)$ de parties de $\mathbb{R}$ qui contient $\emptyset$, est stable par complémentation et par réunion dénombrable, et sur laquelle λ^* se comporte enfin comme une vraie mesure additive. On peut montrer (nous l'admettrons) que $\mathcal{M}(\lambda^*)$ contient tous les intervalles, donc tous les ensembles usuels que l'on souhaite mesurer. On a donc résolu le problème de la mesure... pour les parties de $\mathcal{M}(\lambda^*)$. Reste une question, cruciale : a-t-on $\mathcal{M}(\lambda^*) = \mathcal{P}(\mathbb{R})$, c'est-à-dire a-t-on réussi à mesurer toutes les parties de $\mathbb{R}$?

1.4 L'ensemble de Vitali : une partie non mesurable

La réponse à la question précédente est négative, et c'est un résultat profond dû à Giuseppe Vitali (1905).

Théorème 1.31 – Ensemble de Vitali

Il existe une partie F de $[0, 1]$ qui n'est pas Lebesgue-mesurable, c'est-à-dire $F \notin \mathcal{M}(\lambda^*)$. En particulier, $\mathcal{M}(\lambda^*) \subsetneq \mathcal{P}(\mathbb{R})$.

Idée de preuve. On construit F en choisissant, dans chaque classe d'équivalence de la relation « différer d'un rationnel », un unique représentant dans $[0, 1]$. Si F était mesurable, on pourrait paver un intervalle borné par une infinité dénombrable de translatés disjoints de F , tous de même mesure : c'est absurde, qu'on suppose cette mesure nulle (la réunion serait alors négligeable, ce qu'elle n'est pas) ou strictement positive (la réunion serait alors de mesure infinie, ce qui contredit qu'elle est bornée).

Démonstration. On considère la relation d'équivalence sur $\mathbb{R}$ définie par $x \sim y \iff x - y \in \mathbb{Q}$. Par l'axiome du choix, on peut former un ensemble $F \subset [0, 1]$ contenant exactement **un** représentant de chaque classe d'équivalence intersectant $[0, 1]$ (un tel F existe car chaque classe d'équivalence, étant de la forme $x + \mathbb{Q}$, est dense dans $\mathbb{R}$ et rencontre donc $[0, 1]$).

Posons $Q := \mathbb{Q} \cap [-1, 1]$, dénombrable, et considérons la famille de translatés $(q + F)_{q \in Q}$.

Ces translatés sont deux à deux disjoints. Si $(q_1 + F) \cap (q_2 + F) \neq \emptyset$ avec $q_1 \neq q_2$, il existe $x, y \in F$ avec $q_1 + x = q_2 + y$, donc $x - y = q_2 - q_1 \in \mathbb{Q} \setminus \{0\}$: ainsi $x \sim y$ avec $x \neq y$, ce qui contredit le fait que F contient un *unique* représentant par classe.

Encadrement. D'une part, $F \subset [0, 1]$ donc $\bigcup_{q \in Q} (q + F) \subset [-1, 2]$. D'autre part, tout $x \in \mathbb{R}$ vérifie $x \sim y$ pour un (unique) $y \in F$, donc $x - y \in \mathbb{Q}$; comme $y \in [0, 1]$, si l'on choisit x dans un borné, $x - y$ reste dans un borné, donc en particulier $[0, 1] \subset \bigcup_{q \in Q} (q + F)$ (tout $x \in [0, 1]$ s'écrit $x = q + y$ avec $y \in F$ et $q = x - y \in [-1, 1] \cap \mathbb{Q} = Q$).

Supposons $F \in \mathcal{M}(\lambda^)$.* Par le Théorème 1.29 « Théorème de Carathéodory », chaque $q + F$ est encore Lebesgue-mesurable (translation d'un mesurable – la mesurabilité se transporte par translation exactement comme λ^* elle-même, Proposition 1.18 « Invariance de λ^* par translation et par homothétie »), et $\lambda^*(q + F) = \lambda^*(F)$ pour tout q (Proposition 1.18 « Invariance de λ^* par translation et par homothétie », point 1). Par additivité dénombrable sur les translatés disjoints (Théorème 1.29 « Théorème de Carathéodory ») :

$$\lambda^*\left(\bigcup_{q \in Q} (q + F)\right) = \sum_{q \in Q} \lambda^*(F).$$

Or, par l'encadrement précédent et la croissance de λ^* (en utilisant le Théorème 1.22 « Valeur de λ^* sur les intervalles ») :

$$1 = \lambda^*([0, 1]) \leq \sum_{q \in Q} \lambda^*(F) \leq \lambda^*([-1, 2]) = 3.$$

Mais Q est dénombrable infini : si $\lambda^*(F) = 0$, la somme $\sum_{q \in Q} \lambda^*(F)$ vaut 0, ce qui contredit $\sum_{q \in Q} \lambda^*(F) \geq 1$; et si $\lambda^*(F) > 0$, la somme d'une infinité dénombrable de termes égaux à $\lambda^*(F) > 0$ vaut $+\infty$, ce qui contredit $\sum_{q \in Q} \lambda^*(F) \leq 3$. Dans les deux cas, on obtient une contradiction. Donc $F \notin \mathcal{M}(\lambda^*)$. ■

Remarque 1.32

Cette construction repose de façon essentielle sur l'axiome du choix (pour choisir un représentant par classe d'équivalence, il y en a une infinité non dénombrable). C'est un résultat typique de théorie des ensembles : on ne peut pas exhiber F « à la main », on ne peut que prouver son existence.

Attention 1.33 – Le problème de la mesure n’a pas de solution sur $\mathcal{P}(\mathbb{R})$

Le Théorème 1.31 « Ensemble de Vitali » montre qu’**aucune** mesure additive sur les réunions dénombrables disjointes, valant $b - a$ sur les intervalles $]a, b[$, ne peut être définie sur $\mathcal{P}(\mathbb{R})$ tout entier. Autrement dit, il faut nécessairement **sacrifier** quelque chose : soit l’additivité, soit l’invariance par translation, soit – c’est le choix retenu – le fait de mesurer *toutes* les parties de $\mathbb{R}$. On cherche donc à se restreindre au plus grand sous-ensemble possible de $\mathcal{P}(\mathbb{R})$ qui évite ce genre de pathologie – assez grand pour contenir tous les ensembles usuels, mais assez raisonnable pour que λ^* s’y comporte enfin comme une vraie mesure. La famille $\mathcal{M}(\lambda^*)$ construite ci-dessus en est un candidat naturel : est-ce le candidat *idéal*, le plus grand possible ? Presque !

2 Espace mesurable

Objectifs

- Définir une tribu (ou σ -algèbre) sur un ensemble quelconque, et une tribu engendrée.
- Comprendre pourquoi cette structure est exactement celle qui permet de faire des probabilités.
- Connaître la tribu borélienne, sur $\mathbb{R}$ et plus généralement sur un espace vectoriel normé.
- Connaître l'ensemble triadique de Cantor comme exemple non trivial de borélien.

Introduction

Le Chapitre 1 « Autour de la mesure extérieure de Lebesgue » a mis en évidence, sur l'exemple concret de $\mathbb{R}$, un phénomène général : on ne peut pas espérer mesurer *toutes* les parties d'un ensemble tout en gardant les propriétés naturelles d'une mesure. La solution – se restreindre à une famille de parties suffisamment riche mais strictement plus petite que $\mathcal{P}(\Omega)$ – ne dépend en réalité pas de la structure particulière de $\mathbb{R}$: c'est une notion purement ensembliste, valable sur un ensemble Ω *quelconque*. Ce chapitre en donne la définition générale : celle d'**espace mesurable** $(\Omega, \mathcal{T})$, la brique de base sur laquelle repose toute la suite de ce livret (mesure, intégrale, probabilités).

2.1 Vers la notion de tribu

2.1.1 Ce qu'on attend d'une famille d'événements

On vient de construire, par la voie de Carathéodory, un exemple concret de famille $\mathcal{M}(\lambda^*)$ de parties « raisonnables » de $\mathbb{R}$: elle contient $\emptyset$, est stable par complémentation et par réunion dénombrable. Prenons un instant de recul, et demandons-nous *pourquoi* ce sont précisément ces propriétés-là qui comptent – y compris en dehors de tout contexte de mesure de longueur.

Important. Faisons un aparté sur les probabilités. Supposons que l'on veuille modéliser une expérience aléatoire dont les issues sont des réels (par exemple, la durée de vie d'une ampoule, ou la position d'une fléchette sur une cible modélisée par $\mathbb{R}$), et que l'on cherche à attribuer à certains événements $A \subset \mathbb{R}$ une probabilité $\mathbb{P}(A) \in [0, 1]$. On voudrait, tout naturellement, pouvoir écrire et manipuler des expressions comme

$$\mathbb{P}(A \cap B), \quad \mathbb{P}(A \cup B), \quad \mathbb{P}(A^c)$$

pour deux événements A, B – par exemple pour calculer la probabilité que *deux* conditions soient réalisées simultanément, qu'*au moins une* des deux le soit, ou que *A ne se produise pas*. Mais pour que ces expressions aient seulement un *sens*, il faut d'abord que $A \cap B$, $A \cup B$ et A^c soient, eux aussi, des événements auxquels on a décidé d'attribuer une probabilité ! Si l'on part d'une collection de parties de $\mathbb{R}$ auxquelles on sait attribuer une probabilité, il faut donc que cette collection soit stable par intersection, par réunion et par passage au complémentaire – et, pour les mêmes raisons que dans la construction de λ^* (on voudra faire des passages à la limite, par exemple pour calculer $\mathbb{P}(X \leq a) = \mathbb{P}(\bigcap_n \{X < a + \frac{1}{n}\})$), stable par réunion et intersection *dénombrables*, pas seulement finies.

Autrement dit : la bonne structure sur laquelle on peut espérer construire une théorie des probabilités cohérente est exactement celle que l'on a rencontrée avec $\mathcal{M}(\lambda^*)$ – une famille de parties stable par complémentation et par réunion dénombrable. Cette structure a un nom.

2.1.2 Définition abstraite

Définition 2.1 – Tribu ou σ -algèbre

Soit Ω un ensemble. Une partie $\mathcal{T}$ de $\mathcal{P}(\Omega)$ est appelée **tribu** (ou **σ -algèbre**) sur Ω si :

- $\emptyset \in \mathcal{T}$;
- si $A \in \mathcal{T}$, alors $A^c \in \mathcal{T}$ (stabilité par complémentation) ;
- si $(A_n)_{n \in \mathbb{N}}$ est une famille d'éléments de $\mathcal{T}$, alors $\bigcup_{n \in \mathbb{N}} A_n \in \mathcal{T}$ (stabilité par réunion dénombrable).

Le couple $(\Omega, \mathcal{T})$ est appelé **espace mesurable**, ou, dans un contexte probabiliste, **espace probabilisable**. Les éléments de $\mathcal{T}$ sont appelés parties **mesurables**, ou, dans un contexte probabiliste, **événements**.

Propriété 2.2 – Propriétés élémentaires d’une tribu

Soit $\mathcal{T}$ une tribu sur Ω . Alors :

1. $\Omega \in \mathcal{T}$;
2. $\mathcal{T}$ est stable par intersection dénombrable ;
3. $\mathcal{T}$ est stable par réunion et intersection finies ;
4. si $A, B \in \mathcal{T}$, alors

$$A \setminus B \in \mathcal{T} \quad \text{et} \quad A \Delta B \in \mathcal{T}.$$

Démonstration. Comme $\emptyset \in \mathcal{T}$, on a $\Omega = \emptyset^c \in \mathcal{T}$. Si $(A_n)_{n \in \mathbb{N}} \subseteq \mathcal{T}$, les lois de De Morgan donnent

$$\bigcap_{n \in \mathbb{N}} A_n = \left(\bigcup_{n \in \mathbb{N}} A_n^c \right)^c \in \mathcal{T}.$$

Les unions et intersections finies sont des cas particuliers des opérations dénombrables. Enfin, si $A, B \in \mathcal{T}$,

$$A \setminus B = A \cap B^c \in \mathcal{T},$$

puis

$$A \Delta B = (A \setminus B) \cup (B \setminus A) \in \mathcal{T}.$$

■

Remarque 2.3

Une tribu est donc exactement la structure motivée ci-dessus : elle est stable par complémentation, réunion et intersection dénombrables, et par les opérations finies usuelles. Cela donne un sens à $\mathbb{P}(A \cap B)$, $\mathbb{P}(A \cup B)$, $\mathbb{P}(A^c)$, $\mathbb{P}(A \setminus B)$ et, plus généralement, à toute combinaison dénombrable de ces opérations.

Exemple 2.4 – Le théorème de Carathéodory, relu

Le Théorème 1.29 « Théorème de Carathéodory » affirme exactement que $\mathcal{M}(\lambda^*)$ est une tribu sur $\mathbb{R}$: c’est notre premier exemple non trivial de tribu, et il est bâti sur mesure – ce qui n’est pas un hasard, puisque c’est précisément la structure qui rend l’additivité possible.

Exemple 2.5 – Les deux tribus extrêmes

Pour Ω un ensemble quelconque :

- $\{\emptyset, \Omega\}$ est une tribu, appelée **tribu grossière** : c’est la plus petite tribu (au sens de l’inclusion) que l’on puisse construire sur Ω ;
- $\mathcal{P}(\Omega)$ est également une tribu (la plus grande) ; c’est la seule tribu raisonnable lorsque Ω est dénombrable, mais on vient de voir (Théorème 1.31 « Ensemble de Vitali ») qu’elle est hors de portée dès que $\Omega = \mathbb{R}$ si l’on veut de plus une mesure additive invariante par translation.

Exercice 2.6 – Tribus sur un ensemble à 3 éléments

Donner l’ensemble des tribus possibles pour $\Omega = \{0, 1, 2\}$.

Solution

On rappelle que $\mathcal{P}(\Omega) = \{\emptyset, \{0\}, \{1\}, \{2\}, \{0, 1\}, \{0, 2\}, \{1, 2\}, \{0, 1, 2\}\}$.

- Toute tribu contient $\{\emptyset, \Omega\}$, qui est elle-même une tribu (la tribu grossière).
- On peut ensuite ajouter un singleton, ce qui impose d'ajouter son complémentaire : on obtient les tribus $\{\emptyset, \Omega, \{0\}, \{1, 2\}\}$, $\{\emptyset, \Omega, \{1\}, \{0, 2\}\}$, $\{\emptyset, \Omega, \{2\}, \{0, 1\}\}$.
- Si l'on ajoute encore un élément à l'une de ces tribus, on est contraint (par stabilité par complémentation et réunion) de retomber sur $\mathcal{P}(\Omega)$ tout entier.

Il y a donc 5 tribus sur $\Omega = \{0, 1, 2\}$.

2.1.3 Tribu engendrée

Comment construire des tribus intéressantes, entre les deux extrêmes ci-dessus ? En partant d'une famille de parties que l'on souhaite absolument pouvoir mesurer (par exemple, les intervalles de $\mathbb{R}$), et en lui ajoutant le strict minimum nécessaire pour satisfaire les axiomes d'une tribu.

Définition 2.7 – Tribu engendrée par une famille de parties

Soit Ω un ensemble, $\mathcal{G} \subset \mathcal{P}(\Omega)$. On appelle **tribu engendrée** par $\mathcal{G}$, notée $\sigma(\mathcal{G})$, la plus petite tribu (au sens de l'inclusion) contenant $\mathcal{G}$.

Propriété 2.8 – Intersection de tribus

Soit Ω un ensemble et soit $(\mathcal{T}_i)_{i \in I}$ une famille non vide de tribus sur Ω . Alors

$$\bigcap_{i \in I} \mathcal{T}_i$$

est encore une tribu sur Ω .

Démonstration. Posons

$$\mathcal{T} := \bigcap_{i \in I} \mathcal{T}_i.$$

Par définition d'une intersection, un ensemble $A \subset \Omega$ appartient à $\mathcal{T}$ si et seulement s'il appartient à *toutes* les tribus $\mathcal{T}_i$. Vérifions successivement les trois axiomes d'une tribu.

- **L'ensemble vide appartient à $\mathcal{T}$.** Pour tout $i \in I$, $\mathcal{T}_i$ est une tribu, donc $\emptyset \in \mathcal{T}_i$. Ainsi $\emptyset$ appartient à toutes les $\mathcal{T}_i$, donc

$$\emptyset \in \bigcap_{i \in I} \mathcal{T}_i = \mathcal{T}.$$

- **$\mathcal{T}$ est stable par complémentaire.** Soit $A \in \mathcal{T}$. Alors, par définition de $\mathcal{T}$, on a $A \in \mathcal{T}_i$ pour tout $i \in I$. Comme chaque $\mathcal{T}_i$ est une tribu, on a donc $A^c \in \mathcal{T}_i$ pour tout $i \in I$. Par conséquent A^c appartient à leur intersection :

$$A^c \in \bigcap_{i \in I} \mathcal{T}_i = \mathcal{T}.$$

- **$\mathcal{T}$ est stable par réunion dénombrable.** Soit $(A_n)_{n \in \mathbb{N}}$ une suite d'éléments de $\mathcal{T}$. Pour chaque n et pour chaque $i \in I$, on a $A_n \in \mathcal{T}_i$. Fixons $i \in I$. Puisque $\mathcal{T}_i$ est une tribu, elle est stable par réunion dénombrable, donc

$$\bigcup_{n \in \mathbb{N}} A_n \in \mathcal{T}_i.$$

Cette conclusion est vraie pour tout $i \in I$. Ainsi $\bigcup_{n \in \mathbb{N}} A_n$ appartient à toutes les $\mathcal{T}_i$, donc

$$\bigcup_{n \in \mathbb{N}} A_n \in \bigcap_{i \in I} \mathcal{T}_i = \mathcal{T}.$$

Les trois axiomes étant vérifiés, $\mathcal{T}$ est une tribu sur Ω . ■

Propriété 2.9 – Description de la tribu engendrée

Soit Ω un ensemble, $\mathcal{G} \subset \mathcal{P}(\Omega)$. Alors

$$\sigma(\mathcal{G}) = \bigcap_{\substack{\mathcal{T}' \text{ tribu} \\ \mathcal{G} \subset \mathcal{T}'}} \mathcal{T}'.$$

Idée de preuve. On considère toutes les tribus qui contiennent $\mathcal{G}$ et on garde uniquement les ensembles qui appartiennent à chacune d'elles. La Proposition 2.8 « Intersection de tribus » garantit que cette intersection est encore une tribu. Elle contient $\mathcal{G}$, et elle est incluse dans toute tribu contenant $\mathcal{G}$: c'est donc exactement la plus petite tribu contenant $\mathcal{G}$.

Démonstration. Notons

$$\mathcal{C} := \{\mathcal{T}' \subset \mathcal{P}(\Omega) ; \mathcal{T}' \text{ est une tribu sur } \Omega \text{ et } \mathcal{G} \subset \mathcal{T}'\}.$$

Cette famille n'est pas vide : en effet, $\mathcal{P}(\Omega)$ est une tribu sur Ω et contient évidemment $\mathcal{G}$. On peut donc considérer l'intersection de toutes les tribus appartenant à $\mathcal{C}$:

$$\mathcal{S} := \bigcap_{\mathcal{T}' \in \mathcal{C}} \mathcal{T}'.$$

Nous allons vérifier pas à pas que $\mathcal{S}$ est précisément la tribu engendrée par $\mathcal{G}$.

1. $\mathcal{S}$ est une tribu. Toutes les familles $\mathcal{T}' \in \mathcal{C}$ sont des tribus sur le même ensemble Ω . D'après la Proposition 2.8 « Intersection de tribus », leur intersection $\mathcal{S}$ est donc elle-même une tribu sur Ω .

2. $\mathcal{S}$ contient $\mathcal{G}$. Soit $A \in \mathcal{G}$. Par définition de $\mathcal{C}$, chaque tribu $\mathcal{T}' \in \mathcal{C}$ contient toute la famille $\mathcal{G}$; en particulier, elle contient A . Ainsi A appartient à toutes les tribus $\mathcal{T}' \in \mathcal{C}$. Par définition d'une intersection,

$$A \in \bigcap_{\mathcal{T}' \in \mathcal{C}} \mathcal{T}' = \mathcal{S}.$$

Comme ceci vaut pour tout $A \in \mathcal{G}$, on a bien $\mathcal{G} \subset \mathcal{S}$.

3. $\mathcal{S}$ est la plus petite tribu contenant $\mathcal{G}$. Soit $\mathcal{U}$ une tribu quelconque sur Ω telle que $\mathcal{G} \subset \mathcal{U}$. Alors $\mathcal{U}$ satisfait exactement les conditions qui définissent $\mathcal{C}$, donc $\mathcal{U} \in \mathcal{C}$.

Or $\mathcal{S}$ est l'intersection de tous les éléments de $\mathcal{C}$. Un élément qui appartient à cette intersection doit appartenir à chacun des ensembles intersectés, et en particulier à $\mathcal{U}$. On obtient donc

$$\mathcal{S} \subset \mathcal{U}.$$

Autrement dit, $\mathcal{S}$ est incluse dans toute tribu $\mathcal{U}$ qui contient $\mathcal{G}$. Nous avons déjà montré que $\mathcal{S}$ est elle-même une tribu contenant $\mathcal{G}$; elle est donc la plus petite tribu contenant $\mathcal{G}$ au sens de l'inclusion.

Par définition de la tribu engendrée, cette plus petite tribu est $\sigma(\mathcal{G})$. Ainsi

$$\sigma(\mathcal{G}) = \bigcap_{\substack{\mathcal{T}' \text{ tribu} \\ \mathcal{G} \subset \mathcal{T}'}} \mathcal{T}'.$$

■

Propriété 2.10 – Monotonie de la tribu engendrée

Soit Ω un ensemble, soit $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ et soit $\mathcal{U}$ une tribu sur Ω . Si

$$\mathcal{A} \subseteq \mathcal{U},$$

alors

$$\sigma(\mathcal{A}) \subseteq \mathcal{U}.$$

Autrement dit : dès qu'une tribu contient les générateurs, elle contient automatiquement toute la tribu engendrée par ces générateurs.

Démonstration. Par la Proposition 2.9 « Description de la tribu engendrée », $\sigma(\mathcal{A})$ est l'intersection de toutes les tribus sur Ω qui contiennent $\mathcal{A}$. Or $\mathcal{U}$ est précisément une de ces tribus, puisque $\mathcal{A} \subseteq \mathcal{U}$. Une intersection est toujours incluse dans chacun des ensembles que l'on intersecte ; on obtient donc

$$\sigma(\mathcal{A}) \subseteq \mathcal{U}.$$

■

Exemple 2.11 – Tribu engendrée par un seul ensemble

Soit $A \subseteq \Omega$. Si $A = \emptyset$ ou $A = \Omega$, alors

$$\sigma(\{A\}) = \{\emptyset, \Omega\}.$$

Si $\emptyset \neq A \neq \Omega$, toute tribu contenant A contient nécessairement A^c , $\emptyset$ et Ω . Réciproquement,

$$\{\emptyset, A, A^c, \Omega\}$$

est une tribu. Ainsi

$$\sigma(\{A\}) = \{\emptyset, A, A^c, \Omega\}.$$

C'est le cas le plus simple de tribu engendrée par une famille de parties.

Exemple 2.12

La tribu engendrée par les singletons de $\mathbb{N}$ est $\mathcal{P}(\mathbb{N})$ tout entier : toute partie de $\mathbb{N}$ est une réunion dénombrable de singletons. En revanche, si Ω est non dénombrable, la tribu engendrée par les singletons est strictement plus petite que $\mathcal{P}(\Omega)$: c'est la **tribu dénombrable–codénombrable**

$$\{A \subseteq \Omega : A \text{ est dénombrable ou } A^c \text{ est dénombrable}\}.$$

En particulier, sur $\mathbb{R}$, cette tribu ne contient pas l'intervalle $]0, 1[$. La **tribu discrète** sur un ensemble Ω désigne, elle, la tribu maximale $\mathcal{P}(\Omega)$.

2.2 La tribu borélienne sur $\mathbb{R}$

On a désormais deux exemples de tribus naturelles sur $\mathbb{R}$: la tribu dénombrable–codénombrable (trop petite : elle ne contient même pas $]0, 1[$) et $\mathcal{M}(\lambda^*)$ (obtenue de façon assez indirecte, via la mesure extérieure). On introduit maintenant la tribu de référence de ce livret, engendrée directement à partir des ouverts.

Définition 2.13 – Tribu borélienne, borélien

Soit $\mathcal{O}$ l'ensemble des ouverts de $\mathbb{R}$ (pour la valeur absolue). On appelle **tribu borélienne** de $\mathbb{R}$ la tribu $\mathcal{B}(\mathbb{R}) := \sigma(\mathcal{O})$ engendrée par $\mathcal{O}$. Les éléments de cette tribu sont appelés **boréliens**.

Remarque 2.14 – Premiers exemples de boréliens

Par construction même, $\mathcal{B}(\mathbb{R})$ contient :

- tous les **ouverts** de $\mathbb{R}$ (donc en particulier tous les intervalles ouverts $]a, b[$) ;
- donc aussi, par stabilité par complémentation, tous les **fermés** ;
- tous les intervalles **fermés** $[a, b]$ (on le vérifie dans l'Exercice 2.17 « Boréliens usuels de $\mathbb{R}$ ») ;
- tous les **singletons** (également dans l'Exercice 2.17 « Boréliens usuels de $\mathbb{R}$ ») ;
- $\mathbb{Q}$ tout entier (Exercice 2.17 « Boréliens usuels de $\mathbb{R}$ »).

Remarque 2.15

La même définition, avec $\mathcal{O}$ l'ensemble des ouverts, se transpose sans changement à $\mathbb{R}^n$, ou plus généralement à tout espace vectoriel normé E : on note alors $\mathcal{B}(E)$.

Rappel de L3 2.16 – Régularité de la mesure de Lebesgue

On utilisera plus tard le fait suivant, déjà vu au Chapitre 1 pour les ouverts de $\mathbb{R}$: la mesure de Lebesgue est régulière. En particulier, dans $\mathbb{R}^n$, les ouverts peuvent être approchés de l'intérieur par des compacts et les boréliens peuvent être encadrés par des compacts et des ouverts. La preuve en dimension 1 est donnée dans le TD n°1 ; l'adaptation à $\mathbb{R}^n$ repose sur les pavés et la construction de la mesure de Lebesgue, voir le TD n°2, partie 3.




Figure 4: La tribu borélienne est engendrée par les ouverts ; elle contient tous les ensembles usuels (intervalles, singletons, $\mathbb{Q}$, l'ensemble de Cantor, etc.) mais reste strictement plus petite que $\mathcal{P}(\mathbb{R})$.

Exercice 2.17 – Boréliens usuels de $\mathbb{R}$

1. Montrer que les singletons sont des boréliens.
2. Montrer que $\mathbb{R} \setminus \mathbb{Q}$ est un borélien.
3. Montrer que les intervalles $[a, b]$ (avec $a < b$) sont des boréliens, puis que $[a, b[$ l'est également.

Solution

1. Soit $a \in \mathbb{R}$. Pour tout $n \in \mathbb{N}$, $I_n =]a - \frac{1}{2^n}, a + \frac{1}{2^n}[$ est un ouvert contenant a , donc $\{a\} \subset \bigcap_n I_n$; réciproquement, si $x \neq a$, $x \notin I_n$ dès que $\frac{1}{2^n} < |x - a|$. Donc $\bigcap_n I_n = \{a\}$, borélien par stabilité par intersection dénombrable.
2. $\mathbb{Q}$ est dénombrable, donc réunion dénombrable de ses singletons, donc borélien ; par complémentarité, $\mathbb{R} \setminus \mathbb{Q}$ est également borélien.
3. Le complémentaire de $[a, b]$ est $] - \infty, a[\cup]b, +\infty[$, un ouvert ; donc $[a, b]$ est un fermé, donc un borélien. Ensuite $[a, b[= \bigcup_{n \geq 1} [a, b - \frac{b-a}{2^n}]$, réunion dénombrable de fermés, donc un borélien.

Méthode 2.18 – Montrer qu'une partie de $\mathbb{R}$ est un borélien

Trois outils suffisent dans l'écrasante majorité des cas :

1. Un ouvert (ou un fermé, complémentaire d'un ouvert) est un borélien – c'est le point de départ.
2. Les opérations dénombrables (réunion, intersection, complémentaire, différence) préservent le caractère borélien.
3. Un ensemble dénombrable est toujours un borélien (réunion dénombrable de singletons, eux-mêmes boréliens, Exercice 2.17 « Boréliens usuels de $\mathbb{R}$ »).

Propriété 2.19 – Génération de la tribu borélienne par les intervalles ouverts bornés

La tribu borélienne de $\mathbb{R}$ est engendrée par les intervalles ouverts bornés :

$$\mathcal{B}(\mathbb{R}) = \sigma(\{]a, b[: a < b\}).$$

Démonstration. Posons

$$\mathcal{G} := \{]a, b[: a < b\}.$$

D'après la Définition 2.13 « Tribu borélienne, borélien », chaque élément de $\mathcal{G}$ est un ouvert, donc

$$\sigma(\mathcal{G}) \subseteq \mathcal{B}(\mathbb{R}).$$

Montrons l'inclusion réciproque. Soit O un ouvert de $\mathbb{R}$ et soit $x \in O$.

Comme O est ouvert, il existe $r_x > 0$ tel que

$$]x - r_x, x + r_x[\subset O.$$

Comme $\mathbb{Q}$ est dense dans $\mathbb{R}$, on peut choisir

$$q_x \in \mathbb{Q} \cap \left]x - \frac{r_x}{2}, x + \frac{r_x}{2}\right[.$$

On a donc $|x - q_x| < r_x/2$.

Toujours par densité de $\mathbb{Q}$ dans $\mathbb{R}$, on choisit $\rho_x \in \mathbb{Q}_+^*$ tel que

$$|x - q_x| < \rho_x < r_x - |x - q_x|.$$

Alors

$$x \in]q_x - \rho_x, q_x + \rho_x[\subset]x - r_x, x + r_x[\subset O.$$

Ceci étant vrai pour tout $x \in O$, on obtient

$$O = \bigcup_{\substack{q \in \mathbb{Q}, \rho \in \mathbb{Q}_+^* \\]q - \rho, q + \rho[\subset O}}]q - \rho, q + \rho[.$$

La famille des couples $(q, \rho) \in \mathbb{Q} \times \mathbb{Q}_+^*$ est dénombrable ; cette réunion est donc dénombrable. Chaque intervalle qui intervient appartient à $\mathcal{G}$, donc $O \in \sigma(\mathcal{G})$. Ainsi tous les ouverts appartiennent à $\sigma(\mathcal{G})$ et, par la Définition 2.13 « Tribu borélienne, borélien »,

$$\mathcal{B}(\mathbb{R}) \subseteq \sigma(\mathcal{G}).$$

Avec l'inclusion réciproque obtenue au début de la preuve, on conclut

$$\mathcal{B}(\mathbb{R}) = \sigma(\{]a, b[: a < b\}).$$

■

Propriété 2.20 – Autres familles génératrices de la tribu borélienne

On a également

$$\mathcal{B}(\mathbb{R}) = \sigma(\{[a, b] : a < b\}) = \sigma(\{]-\infty, a] : a \in \mathbb{R}\}) = \sigma(\{]-\infty, a[: a \in \mathbb{R}\}).$$

Démonstration. D'après la Proposition 2.19 « Génération de la tribu borélienne par les intervalles ouverts bornés »,

$$\mathcal{B}(\mathbb{R}) = \sigma(\{]a, b[: a < b\}).$$

Intervalles fermés bornés. Soient $a < b$. Si $N \in \mathbb{N}^*$ est tel que $N > 2/(b - a)$, alors

$$]a, b[= \bigcup_{n \geq N} \left[a + \frac{1}{n}, b - \frac{1}{n} \right].$$

Donc

$$\sigma(\{]a, b[: a < b\}) \subseteq \sigma(\{[a, b] : a < b\}).$$

Réciproquement,

$$[a, b] = \bigcap_{n \geq 1} \left[a - \frac{1}{n}, b + \frac{1}{n} \right],$$

donc l'inclusion réciproque est vraie. Ainsi

$$\mathcal{B}(\mathbb{R}) = \sigma(\{[a, b] : a < b\}).$$

Demi-droites. Pour tout $a \in \mathbb{R}$,

$$]-\infty, a[= \bigcup_{n \in \mathbb{N}}]a - n - 2, a - n[,$$

donc les demi-droites ouvertes appartiennent à $\mathcal{B}(\mathbb{R})$. De même,

$$]-\infty, a] = \bigcup_{n \in \mathbb{N}} [a - n - 1, a - n],$$

donc les demi-droites fermées appartiennent également à $\mathcal{B}(\mathbb{R})$.

Par ailleurs,

$$]-\infty, a] = \bigcap_{n \geq 1}]-\infty, a + 1/n[,$$

d'où

$$\sigma(\{]-\infty, a] : a \in \mathbb{R}\}) \subseteq \sigma(\{]-\infty, a[: a \in \mathbb{R}\}).$$

Et

$$]-\infty, a[= \bigcup_{n \geq 1}]-\infty, a - 1/n],$$

d'où l'inclusion réciproque. Les deux tribus engendrées par les demi-droites ouvertes et fermées sont donc égales.

Enfin, pour $a < b$,

$$]a, b[=]-\infty, b[\cap (]-\infty, a])^c.$$

La tribu engendrée par les demi-droites contient donc tous les intervalles ouverts bornés ; par la Proposition 2.19 « Génération de la tribu borélienne par les intervalles ouverts bornés », elle contient $\mathcal{B}(\mathbb{R})$. Comme, réciproquement, toutes les demi-droites sont boréliennes, on conclut que

$$\mathcal{B}(\mathbb{R}) = \sigma(\{[a, b] : a < b\}) = \sigma(\{]-\infty, a] : a \in \mathbb{R}\}) = \sigma(\{]-\infty, a[: a \in \mathbb{R}\}).$$

■

Remarque 2.21 – Lien avec la fonction de répartition

Ces familles génératrices seront utilisées lorsque l'on caractérisera une loi de probabilité par sa fonction de répartition $F_X(a) = \mathbb{P}(X \leq a)$: c'est parce que les $]-\infty, a]$ engendrent $\mathcal{B}(\mathbb{R})$ que la donnée de F_X suffit à reconstruire toute la loi de X .

Propriété 2.22 – Les boréliens sont Lebesgue-mesurables

$\mathcal{B}(\mathbb{R}) \subset \mathcal{M}(\lambda^*)$: tout borélien est Lebesgue-mesurable.

Idée de preuve. Il suffit de vérifier le critère de Carathéodory sur une famille génératrice de $\mathcal{B}(\mathbb{R})$, par exemple les demi-droites $]-\infty, c]$: $\mathcal{M}(\lambda^*)$ étant une tribu contenant cette famille, elle contient la tribu qu'elle engendre, c'est-à-dire $\mathcal{B}(\mathbb{R})$ tout entier.

Démonstration. D'après la Proposition 2.20 « Autres familles génératrices de la tribu borélienne »,

$$\mathcal{B}(\mathbb{R}) = \sigma(\{]-\infty, c] : c \in \mathbb{R}\}).$$

Il suffit donc de montrer que, pour tout $c \in \mathbb{R}$, la demi-droite

$$B_c :=]-\infty, c]$$

appartient à $\mathcal{M}(\lambda^*)$.

Fixons $c \in \mathbb{R}$ et $E \subset \mathbb{R}$. D'après la Définition 1.27 « Ensembles Lebesgue-mesurables », il suffit de montrer

$$\lambda^*(E) \geq \lambda^*(E \cap B_c) + \lambda^*(E \cap B_c^c),$$

l'inégalité inverse découlant de la Proposition 1.17 « Premières propriétés de λ^* », par sous-additivité. Si $\lambda^*(E) = +\infty$, cette inégalité est immédiate ; on suppose donc désormais $\lambda^*(E) < +\infty$.

Soit $\varepsilon > 0$. Par la Définition 1.15 « Mesure extérieure de Lebesgue », il existe un recouvrement $(]a_i, b_i[)_{i \in \mathbb{N}}$ de E tel que

$$\sum_{i \in \mathbb{N}} (b_i - a_i) \leq \lambda^*(E) + \varepsilon.$$

Pour chaque $i \in \mathbb{N}$, l'intervalle

$$\left] \min(a_i, c), \min(b_i, c) + \frac{\varepsilon}{2^{i+1}} \right[$$

recouvre la partie de $]a_i, b_i[$ située dans $] - \infty, c]$. Par conséquent,

$$E \cap B_c \subseteq \bigcup_{i \in \mathbb{N}} \left] \min(a_i, c), \min(b_i, c) + \frac{\varepsilon}{2^{i+1}} \right[,$$

et donc

$$\lambda^*(E \cap B_c) \leq \sum_{i \in \mathbb{N}} \left(\min(b_i, c) - \min(a_i, c) + \frac{\varepsilon}{2^{i+1}} \right). \quad (1)$$

De même, en omettant les intervalles vides,

$$E \cap B_c^c \subseteq \bigcup_{i \in \mathbb{N}}] \max(a_i, c), \max(b_i, c)[,$$

d'où

$$\lambda^*(E \cap B_c^c) \leq \sum_{i \in \mathbb{N}} (\max(b_i, c) - \max(a_i, c)). \quad (2)$$

En sommant (1) et (2), puis en utilisant l'identité

$$\min(x, c) + \max(x, c) = x + c,$$

on obtient

$$\begin{aligned} \lambda^*(E \cap B_c) + \lambda^*(E \cap B_c^c) &\leq \sum_{i \in \mathbb{N}} (b_i - a_i) + \varepsilon \\ &\leq \lambda^*(E) + 2\varepsilon. \end{aligned}$$

Comme $\varepsilon > 0$ est arbitraire,

$$\lambda^*(E \cap B_c) + \lambda^*(E \cap B_c^c) \leq \lambda^*(E).$$

L'inégalité inverse étant donnée par la sous-additivité de λ^* , on a l'égalité du critère de Carathéodory. Ainsi $B_c \in \mathcal{M}(\lambda^*)$ pour tout $c \in \mathbb{R}$.

Enfin, le Théorème 1.29 « Théorème de Carathéodory » affirme que $\mathcal{M}(\lambda^*)$ est une tribu. Comme elle contient toutes les demi-droites $] - \infty, c]$, elle contient la tribu qu'elles engendrent, c'est-à-dire $\mathcal{B}(\mathbb{R})$. On conclut donc

$$\boxed{\mathcal{B}(\mathbb{R}) \subseteq \mathcal{M}(\lambda^*)}.$$

■

Remarque 2.23

Ce résultat permet de parler sans ambiguïté de « la mesure de Lebesgue sur $\mathcal{B}(\mathbb{R})$ » : c'est la restriction de λ^* à $\mathcal{B}(\mathbb{R})$, notée simplement λ . On peut montrer que $\mathcal{M}(\lambda^*)$ est en réalité strictement plus grande que $\mathcal{B}(\mathbb{R})$ (elle contient par exemple certaines parties non boréliennes de sous-ensembles négligeables de l'ensemble de Cantor, ci-dessous). Une démonstration guidée de l'inclusion stricte $\mathcal{B}(\mathbb{R}) \subsetneq \mathcal{M}(\lambda^*)$ est proposée dans le **TD n°2, partie 3**, exercice « Boréliens et Lebesgue-mesurables : une inclusion stricte ». Cette distinction ne jouera ensuite qu'un rôle secondaire dans le livret : on travaillera essentiellement avec $\mathcal{B}(\mathbb{R})$.

Théorème 2.24 – Tout ensemble Lebesgue-mesurable est un borélien à un ensemble négligeable près

Soit $E \in \mathcal{M}(\lambda^*)$. Il existe un borélien $B \in \mathcal{B}(\mathbb{R})$ et un ensemble $N \subset \mathbb{R}$ de mesure extérieure nulle tels que

$$E = B \sqcup N \quad (\text{réunion disjointe}), \quad B \subset E.$$

Idée de preuve. Dans le cas borné, on place E dans un intervalle borné I et on approche cette fois $I \setminus E$ par l'extérieur. Comme $I \setminus E$ est de mesure finie, la Définition 1.15 « Mesure extérieure de Lebesgue » fournit des ouverts $U_n \supset I \setminus E$ tels que $\lambda(U_n \setminus (I \setminus E)) \rightarrow 0$. L'intersection $H = \bigcap_n U_n$ est borélienne, contient $I \setminus E$ et ne lui ajoute qu'un ensemble négligeable. On pose alors $B := I \setminus H$: on a $B \subset E$ et $E \setminus B$ est négligeable. Le cas général s'obtient en découpant $\mathbb{R}$ en intervalles bornés.

Démonstration. Traitons d'abord le cas où E est borné. Choisissons un intervalle fermé borné I tel que $E \subset I$ et posons

$$A := I \setminus E.$$

Les ensembles I et E étant Lebesgue-mesurables, A l'est également ; de plus $\lambda(A) \leq \lambda(I) < +\infty$.

Pour $n \geq 1$, la Définition 1.15 « Mesure extérieure de Lebesgue » permet de choisir un recouvrement de A par des intervalles ouverts $(I_{n,k})_{k \in \mathbb{N}}$ tel que

$$\sum_{k \in \mathbb{N}} \ell(I_{n,k}) \leq \lambda(A) + \frac{1}{n}.$$

Posons

$$U_n := \bigcup_{k \in \mathbb{N}} I_{n,k}.$$

Alors U_n est ouvert, donc borélien et Lebesgue-mesurable par la Proposition 2.22 « Les boréliens sont Lebesgue-mesurables », et $A \subset U_n$. Par sous-additivité de λ^* ,

$$\lambda(U_n) \leq \sum_{k \in \mathbb{N}} \ell(I_{n,k}) \leq \lambda(A) + \frac{1}{n}.$$

Comme $A \subset U_n$ et $\lambda(A) < +\infty$, l'additivité sur la réunion disjointe $U_n = A \sqcup (U_n \setminus A)$ donne

$$0 \leq \lambda(U_n \setminus A) = \lambda(U_n) - \lambda(A) \leq \frac{1}{n}.$$

Posons maintenant

$$H := \bigcap_{n \geq 1} U_n.$$

L'ensemble H est borélien et contient A . De plus, pour tout n ,

$$H \setminus A \subset U_n \setminus A,$$

donc, par croissance de λ^* ,

$$0 \leq \lambda^*(H \setminus A) \leq \frac{1}{n}.$$

Ainsi $\lambda^*(H \setminus A) = 0$.

Définissons enfin

$$B := I \setminus H.$$

Comme I et H sont boréliens, B est borélien. Puisque $A = I \setminus E \subset H$, on a $B \subset E$. Enfin, comme $E \subset I$,

$$E \setminus B = E \cap H \subset H \setminus A,$$

donc $E \setminus B$ est de mesure extérieure nulle. En posant $N := E \setminus B$, on obtient bien

$$E = B \sqcup N, \quad B \in \mathcal{B}(\mathbb{R}), \quad \lambda^*(N) = 0.$$

Pour un ensemble E quelconque, posons $E_k := E \cap [k, k+1[$ pour $k \in \mathbb{Z}$. Chaque E_k est borné ; d'après le cas précédent, il existe un borélien $B_k \subset E_k$ tel que $N_k := E_k \setminus B_k$ soit de mesure extérieure nulle. En posant

$$B := \bigcup_{k \in \mathbb{Z}} B_k, \quad N := \bigcup_{k \in \mathbb{Z}} N_k,$$

on a $B \in \mathcal{B}(\mathbb{R})$, $B \subset E$ et $\lambda^*(N) = 0$ par sous-additivité dénombrable. Comme $E = B \sqcup N$, le résultat est démontré dans le cas général. ■

Remarque 2.25 – Le théorème le plus important de ce chapitre

Ce théorème est la vraie raison pour laquelle ce livret travaillera presque exclusivement avec la tribu borélienne $\mathcal{B}(\mathbb{R})$ plutôt qu'avec $\mathcal{M}(\lambda^*)$ tout entière : **tout** ensemble Lebesgue-mesurable ne diffère d'un borélien que par un ensemble négligeable, invisible du point de vue de la mesure. Se restreindre aux boréliens ne fait donc perdre, en un sens précis, strictement rien qui soit « mesurable » : c'est le sens dans lequel $\mathcal{M}(\lambda^*)$ n'était *presque* pas le plus grand candidat idéal évoqué à l'Attention 1.33 « Le problème de la mesure n'a pas de solution sur $\mathcal{P}(\mathbb{R})$ » – il ne l'est pas tout à fait ($\mathcal{M}(\lambda^*) \subsetneq \mathcal{B}(\mathbb{R})$) ; ce point est expliqué juste avant et repris dans le TD n°2, partie 3), mais l'écart entre les deux est, précisément, négligeable.

2.3 L'ensemble triadique de Cantor

On termine ce chapitre par un exemple qui va réunir, en un seul objet, toutes les notions rencontrées jusqu'ici : dénombrabilité, mesure, tribu borélienne.

Définition 2.26 – Ensemble de Cantor

On construit une suite $(C_n)_{n \in \mathbb{N}}$ de parties fermées de $[0, 1]$ par récurrence : $C_0 = [0, 1]$, et C_{n+1} s'obtient en retirant, au milieu de chaque intervalle constituant C_n , son tiers central ouvert. Ainsi

$$C_1 = \left[0, \frac{1}{3}\right] \cup \left[\frac{2}{3}, 1\right], \quad C_2 = \left[0, \frac{1}{9}\right] \cup \left[\frac{2}{9}, \frac{1}{3}\right] \cup \left[\frac{2}{3}, \frac{7}{9}\right] \cup \left[\frac{8}{9}, 1\right], \quad \dots$$

L'ensemble triadique de Cantor est $C := \bigcap_{n \in \mathbb{N}} C_n$.




Figure 5: Les quatre premières étapes de la construction de l'ensemble de Cantor : à chaque étape, on retire le tiers central ouvert de chaque segment restant.

Propriété 2.27 – L'ensemble de Cantor est fermé, non dénombrable, et négligeable

L'ensemble C vérifie :

1. C est un fermé de $\mathbb{R}$, donc $C \in \mathcal{B}(\mathbb{R})$;
2. C n'est pas dénombrable ;
3. $\lambda(C) = 0$.

Idée de preuve. Le point 1 est immédiat : C est une intersection (même dénombrable) de fermés. Pour le point 3, on calcule directement la mesure du complémentaire retiré à chaque étape, qui vaut $\sum_n \frac{2^n}{3^{n+1}} = 1$: tout a été retiré, au sens de la mesure. Pour le point 2, l'idée est d'identifier C aux suites infinies de choix « gauche/droite » à chaque étape de la construction, ce qui met C en bijection avec $\{0, 1\}^{\mathbb{N}}$, non dénombrable.

Démonstration. 1. *Fermé.* Chaque C_n est une réunion finie de segments fermés, donc un fermé ; $C = \bigcap_n C_n$ est donc une intersection de fermés, donc un fermé (stable par intersection quelconque). En particulier $C \in \mathcal{B}(\mathbb{R})$ (un fermé est le complémentaire d'un ouvert).

3. *Mesure nulle.* Pour tout n , l'ensemble C est contenu dans C_n , qui est réunion de 2^n segments de longueur 3^{-n} . En recouvrant chacun de ces segments par un intervalle ouvert de longueur arbitrairement proche de 3^{-n} , la définition de la mesure extérieure donne

$$0 \leq \lambda(C) = \lambda^*(C) \leq \lambda^*(C_n) \leq 2^n 3^{-n} = \left(\frac{2}{3}\right)^n.$$

Cette inégalité étant vraie pour tout n et $(2/3)^n \rightarrow 0$, on obtient directement

$$\lambda(C) = 0.$$

Cette preuve n'utilise que la définition de λ^* et sa monotonie, déjà établies au Chapitre 1 « Autour de la mesure extérieure de Lebesgue ».

2. *Non dénombrable.* Tout élément de C peut s'écrire, en base 3, avec uniquement des chiffres 0 et 2 (les nombres dont le développement triadique n'utilise jamais le chiffre 1) : à chaque étape $n \rightarrow n+1$, retirer le tiers central revient exactement à interdire le chiffre 1 en $(n+1)$ -ième position du développement en base 3. On obtient ainsi une bijection explicite $\varphi : \{0, 1\}^{\mathbb{N}} \rightarrow C$, en associant à une suite $(\omega_n)_{n \in \mathbb{N}} \in \{0, 1\}^{\mathbb{N}}$ le réel

$$\varphi((\omega_n)_{n \in \mathbb{N}}) := \sum_{n=0}^{+\infty} \frac{2\omega_n}{3^{n+1}} \in C$$

(chaque $\omega_n \in \{0, 1\}$ code le chiffre $2\omega_n \in \{0, 2\}$ en position $n+1$ du développement en base 3). Comme $\{0, 1\}^{\mathbb{N}}$ n'est pas dénombrable (argument diagonal de Cantor, ou bijection avec $\mathcal{P}(\mathbb{N})$), C n'est donc pas dénombrable. ■

Remarque 2.28 – Un exemple qui déjoue l'intuition

L'ensemble de Cantor est l'archétype de l'ensemble « gros » en cardinal (autant d'éléments que $\mathbb{R}$ tout entier) mais « petit » en mesure (mesure nulle, comme un point). Il montre que dénombrabilité et négligeabilité sont deux notions bien distinctes : on avait déjà noté que *dénombrable* $\Rightarrow$ *négligeable*, mais l'ensemble de Cantor prouve que la réciproque est fausse.

Exercice 2.29

Montrer que C ne contient aucun intervalle ouvert non vide (autrement dit, C est d'intérieur vide).

Solution

Supposons que $] \alpha, \beta[\subset C$ avec $\alpha < \beta$. Alors $] \alpha, \beta[\subset C_n$ pour tout n , donc $\beta - \alpha \leq \lambda(C_n) = (2/3)^n \rightarrow 0$: contradiction avec $\beta > \alpha$.

3 Mesures

Objectifs

- Définir une mesure, une mesure de probabilité, sur un espace mesurable.
- Connaître les propriétés élémentaires d'une mesure (croissance, continuité monotone, sous-additivité).
- Savoir former des combinaisons linéaires à coefficients positifs de mesures, et connaître la stabilité de la finitude et de la σ -finitude par somme finie.
- Connaître la mesure de Lebesgue sur $\mathbb{R}^n$ et la mesure de comptage.

Introduction

Le Chapitre 2 « Espace mesurable » a mis en place le vocabulaire permettant de dire *quels* ensembles on peut mesurer : les éléments d'une tribu $\mathcal{T}$ sur un ensemble Ω . Il reste à dire *quel poids* on leur donne : c'est l'objet de ce chapitre, avec la notion de **mesure**. On a déjà rencontré, au Chapitre 2 « Espace mesurable », un exemple fondamental de mesure – la mesure de Lebesgue sur $\mathbb{R}$, construite par la méthode de Carathéodory. On en donne ici la définition abstraite, valable sur n'importe quel espace mesurable, ce qui permettra de traiter dans un même cadre la mesure de Lebesgue, le comptage, et les mesures de probabilité.

3.1 Définitions et exemples

On dispose maintenant, avec la notion de tribu, du bon cadre pour définir une mesure sur un ensemble Ω *quelconque* – pas seulement sur $\mathbb{R}$ muni de $\mathcal{M}(\lambda^*)$ ou $\mathcal{B}(\mathbb{R})$.

Définition 3.1 – Mesure, mesure finie, mesure σ -finie, mesure de probabilité

Soit $(\Omega, \mathcal{T})$ un espace mesurable. Soit $\mu : \mathcal{T} \rightarrow \mathbb{R}^+ \cup \{+\infty\}$ une application. On dit que μ est une **mesure** si :

1. $\mu(\emptyset) = 0$;
2. pour toute famille $(A_n)_{n \in \mathbb{N}}$ d'éléments de $\mathcal{T}$ deux à deux incompatibles (i.e. disjoints), on a $\mu(\bigcup_{n \in \mathbb{N}} A_n) = \sum_{n \in \mathbb{N}} \mu(A_n)$ (**σ -additivité**).

On dit de plus que μ est :

- une **mesure finie** si $\mu(\Omega) < +\infty$;
- une **mesure σ -finie** s'il existe une famille $(A_n)_{n \in \mathbb{N}}$ d'éléments de $\mathcal{T}$ vérifiant $\bigcup_n A_n = \Omega$ et $\mu(A_n) < +\infty$ pour tout n ;
- une **mesure de probabilité** (ou **probabilité**) si $\mu(\Omega) = 1$.

Le triplet $(\Omega, \mathcal{T}, \mu)$ est appelé **espace mesuré** ; lorsque μ est une probabilité, on parle d'**espace probabilisé** et on note en général $\mathbb{P}$ plutôt que μ .

Remarque 3.2

Par abus de langage, on désigne souvent par « la mesure de A » la valeur $\mu(A)$. On adopte la convention usuelle $x + (+\infty) = +\infty$ pour tout $x \in \mathbb{R}^+$.

Propriété 3.3 – Somme et multiplication positive de mesures

Soient μ et ν deux mesures sur un même espace mesurable $(\Omega, \mathcal{T})$ et soient $a, b \geq 0$. En convenant que 0μ désigne la mesure nulle, l'application

$$a\mu + b\nu : A \mapsto a\mu(A) + b\nu(A)$$

est encore une mesure sur $(\Omega, \mathcal{T})$. De plus :

- si μ et ν sont finies, alors $a\mu + b\nu$ est finie ;
- si μ et ν sont σ -finies, alors $a\mu + b\nu$ est σ -finie.

En particulier, la somme $\mu + \nu$ est toujours une mesure.

Démonstration. On a $(a\mu + b\nu)(\emptyset) = 0$. Si $(A_n)_{n \in \mathbb{N}}$ sont deux à deux disjoints, la σ -additivité de μ et de

ν donne

$$\begin{aligned}(a\mu + b\nu)\left(\bigcup_n A_n\right) &= a\mu\left(\bigcup_n A_n\right) + b\nu\left(\bigcup_n A_n\right) \\ &= a\sum_n \mu(A_n) + b\sum_n \nu(A_n) = \sum_n (a\mu + b\nu)(A_n).\end{aligned}$$

Ainsi $a\mu + b\nu$ est une mesure. Si μ et ν sont finies, alors

$$(a\mu + b\nu)(\Omega) = a\mu(\Omega) + b\nu(\Omega) < +\infty.$$

Supposons maintenant μ et ν σ -finies. Il existe des suites (E_n) et (F_m) recouvrant Ω telles que $\mu(E_n) < +\infty$ et $\nu(F_m) < +\infty$. La famille doublement indexée

$$(E_n \cap F_m)_{(n,m) \in \mathbb{N}^2}$$

est encore dénombrable, recouvre Ω , et sur chacun de ses éléments

$$(a\mu + b\nu)(E_n \cap F_m) \leq a\mu(E_n) + b\nu(F_m) < +\infty.$$

Donc $a\mu + b\nu$ est σ -finie. ■

Remarque 3.4 – Les mesures positives ne forment pas un espace vectoriel

Les mesures positives sur $(\Omega, \mathcal{T})$ sont stables par addition et par multiplication par un scalaire positif : elles forment donc un **cône convexe**. Elles ne forment pas un espace vectoriel, car $-\mu$ n'est pas une mesure positive dès que $\mu \neq 0$. Pour obtenir un véritable espace vectoriel, il faut introduire les **mesures signées**, ce que l'on ne fera pas ici.

Théorie des probabilités	Théorie de la mesure
Espace probabilisable $(\Omega, \mathcal{T})$	Espace mesurable $(\Omega, \mathcal{T})$
Probabilité $\mathbb{P}$: mesure de masse totale 1	Mesure μ
Espace probabilisé $(\Omega, \mathcal{T}, \mathbb{P})$	Espace mesuré $(\Omega, \mathcal{T}, \mu)$
$\mathbb{P}(A)$, probabilité de l'événement A	$\mu(A)$, mesure de l'ensemble A

Exemple 3.5 – Mesure de comptage

La mesure de comptage a du sens sur tout espace mesurable $(\Omega, \mathcal{T})$: pour $A \in \mathcal{T}$, on pose $\mu(A) = \text{Card}(A)$, avec la valeur $+\infty$ si A est infini.

On peut aussi l'adapter à un sous-ensemble que l'on veut compter. Par exemple, sur l'espace mesurable $(\mathbb{R}, \mathcal{P}(\mathbb{R}))$, la fonction μ définie par $\mu(A) = \text{Card}(A \cap \mathbb{N})$ pour tout $A \subset \mathbb{R}$ est une mesure : elle « compte » les entiers présents dans A . Elle n'est pas finie, puisque $\mu(\mathbb{N}) = +\infty$, mais elle est σ -finie : la famille $([n, n+1])_{n \in \mathbb{Z}}$ recouvre $\mathbb{R}$, deux à deux disjoints, et $\mu([n, n+1]) \in \{0, 1\}$ est fini pour chaque n .

Définition 3.6 – Mesure de Dirac

Soit $(\Omega, \mathcal{T})$ un espace mesurable et soit $x \in \Omega$. La **mesure de Dirac** en x , notée δ_x , est définie par

$$\delta_x(A) := \begin{cases} 1 & \text{si } x \in A, \\ 0 & \text{si } x \notin A, \end{cases} \quad A \in \mathcal{T}.$$

Plus généralement, si $(x_i)_{i \in I}$ est une famille au plus dénombrable de points de Ω et $(p_i)_{i \in I}$ des réels positifs, $\mu := \sum_{i \in I} p_i \delta_{x_i}$ (c'est-à-dire $\mu(A) = \sum_{i \in I} p_i \mathbf{1}_A(x_i)$) est une mesure sur $(\Omega, \mathcal{T})$, dite **discrète** ; c'est une mesure de probabilité si et seulement si $\sum_i p_i = 1$. La notion plus générale de mesure purement atomique sera précisée au Chapitre 8 « Décomposition des mesures ».

Définition 3.7 – Atome et mesure diffuse

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré. Un élément $x \in \Omega$ est appelé **atome** de μ lorsque son singleton est mesurable et

$$\mu(\{x\}) > 0.$$

On dit que μ est **diffuse** si elle n'a aucun atome.

Remarque 3.8

δ_x est bien une mesure : $\delta_x(\emptyset) = 0$, et pour $(A_n)_n$ deux à deux disjoints, x appartient à au plus l'un des A_n , donc $\delta_x(\bigcup_n A_n) = \mathbf{1}_{\exists n, x \in A_n} = \sum_n \delta_x(A_n)$. C'est la mesure la plus simple possible : toute la masse (ici, 1) est concentrée sur le seul point x . C'est aussi le prototype même d'une mesure discrète (Chapitre 8 « Décomposition des mesures ») : δ_x n'a qu'un seul atome, le point x lui-même.

Exemple 3.9 – Ω fini

Si Ω est fini, $(\Omega, \mathcal{P}(\Omega))$ est un espace probabilisable et une mesure de probabilité sur Ω est simplement une mesure sur cet espace, de masse totale 1 : on retrouve exactement le cadre des probabilités « élémentaires » vu en licence.

3.2 Le théorème π - λ (Dynkin)

On aura, dans tout le reste de ce livret, besoin très régulièrement de montrer que **deux mesures sont égales**. Le vérifier directement sur *tous* les éléments de la tribu est en général hors de portée ; le Théorème 3.12 « Théorème π - λ (Dynkin) » permet de se contenter de le vérifier sur une famille bien plus restreinte, qui engendre la tribu.

Définition 3.10 – Système de Dynkin

Soit Ω un ensemble. Une partie $\mathcal{D}$ de $\mathcal{P}(\Omega)$ est appelée **système de Dynkin** (ou **λ -système**) si :

- $\Omega \in \mathcal{D}$;
- si $A, B \in \mathcal{D}$ avec $A \subset B$, alors $B \setminus A \in \mathcal{D}$ (stabilité par différence propre) ;
- si $(A_n)_{n \in \mathbb{N}}$ est une suite **croissante** d'éléments de $\mathcal{D}$, alors $\bigcup_{n \in \mathbb{N}} A_n \in \mathcal{D}$ (stabilité par réunion croissante).

Remarque 3.11

Toute tribu est un système de Dynkin (les trois propriétés se vérifient immédiatement à partir des axiomes d'une tribu). La réciproque est fautive : un système de Dynkin n'est stable par intersection *que dans des cas particuliers* – c'est précisément ce qui manque pour en faire une tribu, et c'est l'objet du Théorème 3.12 « Théorème π - λ (Dynkin) » que de montrer que cette stabilité supplémentaire se propage sous une hypothèse raisonnable.

Théorème 3.12 – Théorème π - λ (Dynkin)

Soit Ω un ensemble, $\mathcal{C} \subset \mathcal{P}(\Omega)$ une famille **stable par intersection finie** (on dit aussi que $\mathcal{C}$ est un **π -système**). Si $\mathcal{D}$ est un système de Dynkin contenant $\mathcal{C}$, alors $\mathcal{D}$ contient la tribu $\sigma(\mathcal{C})$ engendrée par $\mathcal{C}$.

Idée de preuve. [admise] On montre que le *plus petit* système de Dynkin contenant $\mathcal{C}$ (l'intersection de tous ceux qui contiennent $\mathcal{C}$, qui est encore un système de Dynkin, comme pour les tribus à la Proposition 2.9 « Description de la tribu engendrée ») est en réalité une tribu – ce qui suffit, puisqu'il est alors nécessairement égal à $\sigma(\mathcal{C})$ et contenu dans $\mathcal{D}$. L'unique point technique, assez calculatoire, est de vérifier que ce plus petit système de Dynkin est stable par intersection finie : on le montre d'abord pour l'intersection avec un élément fixé de $\mathcal{C}$ (en utilisant que $\mathcal{C}$ est un π -système), puis on étend l'argument à l'intersection avec un élément

quelconque du système de Dynkin lui-même. La preuve complète et détaillée est proposée dans le TD n°2, partie 3, exercice « Démonstration du théorème π - λ (Dynkin) ».

Corollaire 3.13 – Unicité d’une mesure déterminée par un π -système générateur

Soient μ, ν deux mesures sur un espace mesurable $(\Omega, \mathcal{T})$, telles que $\mu(\Omega) = \nu(\Omega) < +\infty$. Soit $\mathcal{C} \subset \mathcal{T}$ un π -système (stable par intersection finie) engendrant $\mathcal{T}$. Si μ et ν coïncident sur $\mathcal{C}$, alors $\mu = \nu$ sur $\mathcal{T}$ tout entier.

Démonstration. Posons $\mathcal{D} := \{A \in \mathcal{T} \mid \mu(A) = \nu(A)\}$. Montrons que $\mathcal{D}$ est un système de Dynkin :

- $\Omega \in \mathcal{D}$ par hypothèse ($\mu(\Omega) = \nu(\Omega)$) ;
- si $A, B \in \mathcal{D}$ avec $A \subset B$, alors, μ et ν étant *finies* (majorées par $\mu(\Omega) = \nu(\Omega) < +\infty$), $\mu(B \setminus A) = \mu(B) - \mu(A) = \nu(B) - \nu(A) = \nu(B \setminus A)$ (soustraction licite grâce à l’additivité et à la finitude), donc $B \setminus A \in \mathcal{D}$;
- si $(A_n)_n \subset \mathcal{D}$ est croissante, posons $B_0 = A_0$ et $B_k = A_k \setminus A_{k-1}$ pour $k \geq 1$: les B_k sont deux à deux disjoints (car (A_n) croissante), et $B_k \in \mathcal{D}$ pour $k \geq 1$ car $\mathcal{D}$ est stable par différence propre (point précédent, avec $A_{k-1} \subset A_k$ tous deux dans $\mathcal{D}$). Par σ -additivité de μ et de ν , et puisque $\bigcup_n A_n = \bigsqcup_k B_k$:

$$\mu\left(\bigcup_n A_n\right) = \sum_k \mu(B_k) = \sum_k \nu(B_k) = \nu\left(\bigcup_n A_n\right)$$

(chaque terme $\mu(B_k) = \nu(B_k)$ car $B_0 = A_0 \in \mathcal{D}$ et $B_k \in \mathcal{D}$ pour $k \geq 1$ comme on vient de le voir), donc $\bigcup_n A_n \in \mathcal{D}$.

Ainsi $\mathcal{D}$ est un système de Dynkin contenant le π -système $\mathcal{C}$; par le Théorème 3.12 « Théorème π - λ (Dynkin) », $\mathcal{D} \supset \sigma(\mathcal{C}) = \mathcal{T}$. Donc $\mathcal{D} = \mathcal{T}$, c’est-à-dire $\mu = \nu$ sur $\mathcal{T}$ tout entier. ■

Remarque 3.14

C’est cette dernière forme – **corollaire**, pas le théorème lui-même – que l’on utilisera systématiquement dans ce livret, presque toujours pour des mesures de probabilité ($\mu(\Omega) = \nu(\Omega) = 1 < +\infty$, l’hypothèse de finitude est donc automatique). On l’admettra sans plus de commentaire à chaque usage, en se contentant de vérifier que la famille génératrice invoquée est bien stable par intersection finie.

Résultat – Familles génératrices de $\mathcal{B}(\mathbb{R}^n)$. Pour $n \geq 1$, la tribu borélienne de $\mathbb{R}^n$ est engendrée aussi bien par les pavés ouverts bornés, par les pavés semi-ouverts, que par les pavés semi-infinis à gauche :

$$\begin{aligned} \mathcal{B}(\mathbb{R}^n) &= \sigma\left(\left\{\prod_{i=1}^n]a_i, b_i[\ ; \ a_i < b_i\right\}\right) \\ &= \sigma\left(\left\{\prod_{i=1}^n]a_i, b_i] \ ; \ a_i < b_i\right\}\right) \\ &= \sigma\left(\left\{\prod_{i=1}^n]-\infty, a_i] \ ; \ a_i \in \mathbb{R}\right\}\right). \end{aligned}$$

La première égalité se démontre comme en dimension 1, en recouvrant tout ouvert par une réunion dénombrable de pavés à extrémités rationnelles. Les autres égalités s’en déduisent par des opérations de tribu. La preuve détaillée est proposée dans le TD n°2, partie 3, exercice « Construction guidée de la mesure de Lebesgue sur $\mathbb{R}^n$ ».

Théorème 3.15 – Mesure de Lebesgue sur $\mathbb{R}^n$

Soit $n \geq 1$; on considère l'espace mesurable $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$. Il existe une unique mesure λ_n (notée simplement λ ou dx lorsque $n = 1$), appelée **mesure de Lebesgue**, vérifiant :

$$\forall P = [a_1, b_1] \times \cdots \times [a_n, b_n] \in \mathcal{B}(\mathbb{R}^n), \quad \lambda_n(P) = \prod_{i=1}^n (b_i - a_i),$$

où $a_1 < b_1, \dots, a_n < b_n$. Autrement dit, λ_n prolonge à tous les boréliens la notion usuelle de longueur, d'aire ou de volume d'un pavé.

Idée de preuve. [admise] Pour $n = 1$, l'existence est celle déjà construite à partir de la mesure extérieure de Lebesgue : on a $\mathcal{B}(\mathbb{R}) \subseteq \mathcal{M}(\lambda^*)$ et $\lambda^*([a, b]) = b - a$.

Pour $n \geq 2$, on reprend la construction de Carathéodory en remplaçant les intervalles par des pavés. Le résultat précédent garantit que les pavés utilisés engendrent bien toute la tribu $\mathcal{B}(\mathbb{R}^n)$; on admet ici que la construction fournit une mesure borélienne ayant le volume attendu sur les pavés.

Pour l'**unicité**, on utilise que les pavés semi-ouverts forment un π -système générateur de $\mathcal{B}(\mathbb{R}^n)$ et le corollaire d'unicité d'une mesure finie déterminée par un π -système générateur, après restriction à des cubes de mesure finie. La démonstration détaillée est proposée dans le TD n°3, partie 3, exercice « Unicité de la mesure de Lebesgue sur $\mathbb{R}^n$ ».

Exemple 3.16

Sur $\mathbb{R}$, $\lambda(\{a\}) = 0$ pour tout $a \in \mathbb{R}$ (un singleton est un pavé dégénéré $[a, a]$, de longueur nulle) ; par σ -additivité, $\lambda(A) = 0$ pour toute partie dénombrable A de $\mathbb{R}$ (en particulier $\lambda(\mathbb{Q}) = 0$). En revanche $\lambda(\mathbb{R}) = +\infty$: la mesure de Lebesgue n'est pas une mesure finie, mais elle est σ -finie grâce au recouvrement $\mathbb{R} = \bigcup_{n \in \mathbb{Z}} [n, n+1[$.

Définition 3.17 – Ensemble négligeable

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré. Soit $A \in \mathcal{T}$. On dit que A est **négligeable** (pour μ) si $\mu(A) = 0$.

Exemple 3.18

Pour la mesure de Lebesgue sur $\mathbb{R}$, toute partie dénombrable est négligeable (par exemple $\mathbb{Q}$) ; mais il existe aussi des ensembles négligeables non dénombrables (l'ensemble triadique de Cantor, Chapitre 1 « Autour de la mesure extérieure de Lebesgue »). On retiendra : négligeable $\neq$ dénombrable, seule l'implication « dénombrable $\Rightarrow$ négligeable » est vraie pour λ .

3.3 Propriétés élémentaires

Propriété 3.19 – Propriétés élémentaires d'une mesure

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré. Alors :

1. (additivité finie) pour $(A_i)_{1 \leq i \leq n}$ une famille finie d'événements deux à deux incompatibles, $\mu(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n \mu(A_i)$; en particulier, si A, B sont incompatibles, $\mu(A \cup B) = \mu(A) + \mu(B)$;
2. (croissance) si $A \subset B$ (avec $A, B \in \mathcal{T}$), alors $\mu(A) \leq \mu(B)$; en particulier si $\mu(B) < +\infty$ alors $\mu(A) < +\infty$;
3. (formule du crible à deux termes) si A, B sont de mesure finie, $A \cup B$ est de mesure finie et $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$;
4. (différence propre) si $A \subset B$, alors $\mu(B \setminus A) = \mu(B) - \mu(A)$ dès que $\mu(A) < +\infty$.

Démonstration. *Point 1.* On complète $(A_i)_{1 \leq i \leq n}$ en une suite infinie en posant $A_i = \emptyset$ pour $i \geq n+1$; la σ -additivité donne $\mu(\bigcup_{i \geq 1} A_i) = \sum_{i \geq 1} \mu(A_i)$, et il ne reste que les n premiers termes non nuls.

Point 2. On écrit $B = A \sqcup (B \setminus A)$ (réunion disjointe), d'où par additivité finie $\mu(B) = \mu(A) + \mu(B \setminus A) \geq \mu(A)$ par positivité de μ .

Point 3. On écrit $A \cup B = A \sqcup (B \setminus A)$, donc $\mu(A \cup B) = \mu(A) + \mu(B \setminus A)$; or $\mu(B \setminus A) = \mu(B) - \mu(A \cap B)$ par le point précédent appliqué à $A \cap B \subset B$.

Point 4. C'est exactement l'égalité utilisée dans la preuve du point 2, valable dès que $\mu(A)$ est finie (pour pouvoir soustraire). ■




Figure 6: La formule du crible $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$ corrige le double comptage de $A \cap B$, compté une fois dans $\mu(A)$ et une fois dans $\mu(B)$.

Propriété 3.20 – Continuité croissante et décroissante

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré.

1. Si $(A_n)_{n \in \mathbb{N}}$ est une suite **croissante** d'événements (i.e. $A_n \subset A_{n+1}$ pour tout n), alors

$$\mu\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \lim_{n \rightarrow +\infty} \mu(A_n).$$

2. Si $(B_n)_{n \in \mathbb{N}}$ est une suite **décroissante** d'événements et s'il existe m tel que $\mu(B_m) < +\infty$, alors

$$\mu\left(\bigcap_{n \in \mathbb{N}} B_n\right) = \lim_{n \rightarrow +\infty} \mu(B_n).$$

Démonstration. *Continuité croissante.* Posons $A_{-1} = \emptyset$ et

$$D_i := A_i \setminus A_{i-1} \quad (i \in \mathbb{N}).$$

Les D_i sont deux à deux disjoints, et

$$\bigcup_{i \in \mathbb{N}} A_i = \bigsqcup_{i \in \mathbb{N}} D_i.$$

Par σ -additivité,

$$\mu\left(\bigcup_{i \in \mathbb{N}} A_i\right) = \sum_{i \in \mathbb{N}} \mu(D_i) = \lim_{n \rightarrow +\infty} \sum_{i=0}^n \mu(D_i).$$

Mais, pour chaque n , $A_n = \bigsqcup_{i=0}^n D_i$; l'additivité finie donne donc, sans aucune soustraction de quantités éventuellement infinies,

$$\sum_{i=0}^n \mu(D_i) = \mu(A_n).$$

Ainsi

$$\mu\left(\bigcup_{i \in \mathbb{N}} A_i\right) = \lim_{n \rightarrow +\infty} \mu(A_n).$$

Continuité décroissante. On applique la continuité croissante à la suite croissante $(B_m \setminus B_n)_{n \geq m}$, en utilisant $\mu(B_m) < +\infty$ pour écrire $\mu(B_m \setminus B_n) = \mu(B_m) - \mu(B_n)$, puis on passe à la limite et on simplifie. ■

Rappel de L1 3.21 – suites numériques

On rappelle qu'une suite réelle (u_n) est dite **croissante** si $u_n \leq u_{n+1}$ pour tout n , et qu'une suite croissante et majorée converge vers sa borne supérieure. C'est exactement ce mécanisme qui est à l'œuvre dans la continuité croissante d'une mesure : la suite $(\mu(A_n))_n$ est croissante (par la Proposition 3.19 « Propriétés élémentaires d'une mesure »), donc converge (éventuellement vers $+\infty$), et la Proposition 3.20 « Continuité croissante et décroissante » identifie sa limite.

Exemple 3.22

Pour la mesure de Lebesgue sur $\mathbb{R}$, on retrouve avec la continuité croissante un résultat intuitif : $\lambda\left(\bigcup_{n \geq 1} [0, n - \frac{1}{n}]\right) = \lim_{n \rightarrow +\infty} \lambda([0, n - \frac{1}{n}]) = \lim_{n \rightarrow +\infty} (n - \frac{1}{n}) = +\infty = \lambda([0, +\infty[)$, ce qui est cohérent puisque $\bigcup_{n \geq 1} [0, n - \frac{1}{n}[= [0, +\infty[$.

Attention 3.23 – L'hypothèse de mesure finie est indispensable

Pour la continuité *décroissante*, l'hypothèse $\mu(B_m) < +\infty$ pour un certain m ne peut pas être supprimée. Prenons $B_n = [n, +\infty[$ pour la mesure de Lebesgue : la suite (B_n) est décroissante, d'intersection vide (donc de mesure 0), mais $\mu(B_n) = +\infty$ pour tout n : la limite des mesures vaut $+\infty \neq 0$. C'est un phénomène de « fuite de la masse à l'infini », qui réapparaîtra au Chapitre 13 « Convergence de suites de variables aléatoires » pour expliquer pourquoi le Théorème 5.31 « Lemme de Fatou » n'est, en général, qu'une inégalité.

Propriété 3.24 – Sous-additivité dénombrable, inégalité de Boole

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, soit $(A_n)_{n \in \mathbb{N}}$ une famille d'événements. Alors

$$\mu\left(\bigcup_{n \in \mathbb{N}} A_n\right) \leq \sum_{n \in \mathbb{N}} \mu(A_n).$$

Démonstration. Pour $n \in \mathbb{N}$, posons

$$B_n := \bigcup_{i=0}^n A_i.$$

On rend cette réunion disjointe en posant $D_0 := A_0$ et, pour $i \geq 1$,

$$D_i := A_i \setminus \bigcup_{j=0}^{i-1} A_j.$$

Alors $B_n = \bigsqcup_{i=0}^n D_i$ et $D_i \subseteq A_i$. D'après la Proposition 3.19 « Propriétés élémentaires d'une mesure » (additivité finie puis croissance),

$$\begin{aligned}\mu(B_n) &= \sum_{i=0}^n \mu(D_i) \\ &\leq \sum_{i=0}^n \mu(A_i) \\ &\leq \sum_{i \in \mathbb{N}} \mu(A_i).\end{aligned}$$

Or $B_n \uparrow \bigcup_{i \in \mathbb{N}} A_i$. Par la Proposition 3.20 « Continuité croissante et décroissante »,

$$\begin{aligned}\mu\left(\bigcup_{i \in \mathbb{N}} A_i\right) &= \lim_{n \rightarrow +\infty} \mu(B_n) \\ &\leq \sum_{i \in \mathbb{N}} \mu(A_i).\end{aligned}$$

C'est exactement l'inégalité de Boole. ■

Propriété 3.25 – Stabilité par $\limsup/\liminf$

Soit $(\Omega, \mathcal{T})$ un espace mesurable, soit $(A_n)_{n \in \mathbb{N}}$ une suite d'éléments de $\mathcal{T}$. Alors $\limsup_n A_n$ et $\liminf_n A_n$ appartiennent à $\mathcal{T}$.

Démonstration. D'après la Proposition 1.11 « Description par réunion et intersection », $\limsup_n A_n = \bigcap_n \bigcup_{m \geq n} A_m$: c'est une intersection dénombrable de réunions dénombrables d'éléments de $\mathcal{T}$, donc un élément de $\mathcal{T}$ par les stabilités usuelles d'une tribu. Même raisonnement pour $\liminf_n A_n$. ■

Théorème 3.26 – Lemme de Borel–Cantelli

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, soit $(A_n)_{n \in \mathbb{N}}$ une suite d'éléments de $\mathcal{T}$. Si

$$\sum_{n \in \mathbb{N}} \mu(A_n) < +\infty,$$

alors

$$\mu\left(\limsup_n A_n\right) = 0.$$

Démonstration. Pour tout entier N , on a

$$\limsup_n A_n = \bigcap_{N \in \mathbb{N}} \bigcup_{n \geq N} A_n \subseteq \bigcup_{n \geq N} A_n.$$

Par croissance de la mesure, puis par l'inégalité de Boole (Proposition 3.24 « Sous-additivité dénombrable, inégalité de Boole »),

$$\begin{aligned}\mu\left(\limsup_n A_n\right) &\leq \mu\left(\bigcup_{n \geq N} A_n\right) \\ &\leq \sum_{n \geq N} \mu(A_n).\end{aligned}$$

Comme la série à termes positifs $\sum_n \mu(A_n)$ converge, son reste $\sum_{n \geq N} \mu(A_n)$ tend vers 0 quand $N \rightarrow +\infty$. L'inégalité précédente étant vraie pour tout N , on obtient nécessairement $\mu(\limsup_n A_n) = 0$. ■

Remarque 3.27 – Cas probabiliste

Lorsque $\mu = \mathbb{P}$ est une probabilité, ce résultat se lit ainsi : si $\sum_n \mathbb{P}(A_n) < +\infty$, alors, presque sûrement, seul un nombre fini des événements A_n se réalisent. L'événement « une infinité de A_n se réalisent » est précisément $\limsup_n A_n$.

4 Fonctions mesurables

Objectifs

- Savoir manipuler l'image réciproque et son lien avec les tribus.
- Définir une fonction mesurable ; connaître les opérations qui préservent la mesurabilité.
- Connaître la tribu borélienne de $\mathbb{R}$ et les fonctions boréliennes usuelles.

Introduction

On dispose maintenant des deux premières briques : la tribu (Chapitre 2 « Espace mesurable ») et la mesure (Chapitre 3 « Mesures »). Avant de pouvoir intégrer une fonction par rapport à une mesure, il faut d'abord savoir quelles fonctions on a le droit d'intégrer : ce sont les fonctions **mesurables**, dont ce chapitre pose les bases.

4.1 Image réciproque et tribus

Rappel de L1 4.1 – applications

Pour $f : E \rightarrow F$ une application et $B \subset F$, on rappelle que l'**image réciproque** de B par f est $f^{-1}(B) = \{x \in E \mid f(x) \in B\}$. Il ne s'agit pas nécessairement d'une bijection réciproque : $f^{-1}(B)$ est bien défini même si f n'est ni injective ni surjective.

Propriété 4.2 – Propriétés algébriques de l'image réciproque

Soient E, F deux ensembles, $f : E \rightarrow F$ une application. Alors :

1. $f^{-1}(\emptyset) = \emptyset$ et $f^{-1}(F) = E$;
2. pour tout $B \subset F$, $f^{-1}(B^c) = (f^{-1}(B))^c$;
3. pour toute famille $(B_i)_{i \in I}$ de parties de F , $f^{-1}(\bigcup_{i \in I} B_i) = \bigcup_{i \in I} f^{-1}(B_i)$ et $f^{-1}(\bigcap_{i \in I} B_i) = \bigcap_{i \in I} f^{-1}(B_i)$.

De plus, si les B_i sont deux à deux disjoints, les $f^{-1}(B_i)$ le sont également.

Démonstration. Démontrons chacun des points.

1. Par définition d'une application, tout élément de E possède une image, donc aucun $x \in E$ ne vérifie $f(x) \in \emptyset$: $f^{-1}(\emptyset) = \emptyset$. De même, $f(x) \in F$ pour tout $x \in E$, donc $f^{-1}(F) = E$.

2. Soit $B \subset F$, soit $x \in E$. On raisonne par équivalences successives :

$$\begin{aligned} x \in f^{-1}(B^c) &\iff f(x) \in B^c \\ &\iff f(x) \notin B \\ &\iff x \notin f^{-1}(B) \\ &\iff x \in (f^{-1}(B))^c. \end{aligned}$$

Ceci étant vrai pour tout $x \in E$, on a bien $f^{-1}(B^c) = (f^{-1}(B))^c$.

3. Soit $(B_i)_{i \in I}$ une famille de parties de F , soit $x \in E$. D'une part :

$$\begin{aligned} x \in f^{-1}\left(\bigcup_{i \in I} B_i\right) &\iff f(x) \in \bigcup_{i \in I} B_i \\ &\iff \exists i \in I, f(x) \in B_i \\ &\iff \exists i \in I, x \in f^{-1}(B_i) \\ &\iff x \in \bigcup_{i \in I} f^{-1}(B_i). \end{aligned}$$

D'autre part, de la même façon :

$$\begin{aligned}
 x \in f^{-1}\left(\bigcap_{i \in I} B_i\right) &\iff f(x) \in \bigcap_{i \in I} B_i \\
 &\iff \forall i \in I, f(x) \in B_i \\
 &\iff \forall i \in I, x \in f^{-1}(B_i) \\
 &\iff x \in \bigcap_{i \in I} f^{-1}(B_i).
 \end{aligned}$$

On obtient ainsi les deux égalités annoncées.

Disjonction. Si les B_i sont deux à deux disjoints, soit $i \neq j$ dans I et $x \in f^{-1}(B_i) \cap f^{-1}(B_j)$. Alors $f(x) \in B_i \cap B_j = \emptyset$, ce qui est absurde : donc $f^{-1}(B_i) \cap f^{-1}(B_j) = \emptyset$, c'est-à-dire que les $f^{-1}(B_i)$ sont eux aussi deux à deux disjoints. ■

Remarque 4.3

Ce sont exactement ces propriétés qui font que l'image réciproque « respecte » la structure de tribu : c'est le contenu de la Proposition 4.4 « Stabilité d'une tribu par image réciproque », qui est le socle de toute la notion de mesurabilité.

Propriété 4.4 – Stabilité d'une tribu par image réciproque

Soit E un ensemble, soit $(F, \mathcal{S})$ un espace mesurable, soit $f : E \rightarrow F$. Alors

$$f^{-1}(\mathcal{S}) := \{f^{-1}(B) \mid B \in \mathcal{S}\}$$

est une tribu sur E . De plus, c'est la **plus petite tribu sur E qui rende f mesurable** comme application de E vers $(F, \mathcal{S})$.

Démonstration. On vérifie les axiomes d'une tribu en utilisant la Proposition 4.2 « Propriétés algébriques de l'image réciproque ».

Tout d'abord,

$$f^{-1}(\emptyset) = \emptyset.$$

Comme $\emptyset \in \mathcal{S}$, on a donc $\emptyset \in f^{-1}(\mathcal{S})$.

Soit ensuite $A \in f^{-1}(\mathcal{S})$. Il existe $B \in \mathcal{S}$ tel que $A = f^{-1}(B)$. Par la Proposition 4.2 « Propriétés algébriques de l'image réciproque »,

$$A^c = (f^{-1}(B))^c = f^{-1}(B^c).$$

Comme $\mathcal{S}$ est une tribu, $B^c \in \mathcal{S}$, donc $A^c \in f^{-1}(\mathcal{S})$.

Enfin, soit $(A_n)_{n \in \mathbb{N}}$ une suite d'éléments de $f^{-1}(\mathcal{S})$. Pour chaque n , il existe $B_n \in \mathcal{S}$ tel que $A_n = f^{-1}(B_n)$. Toujours d'après la Proposition 4.2 « Propriétés algébriques de l'image réciproque »,

$$\bigcup_{n \in \mathbb{N}} A_n = \bigcup_{n \in \mathbb{N}} f^{-1}(B_n) = f^{-1}\left(\bigcup_{n \in \mathbb{N}} B_n\right).$$

Or $\bigcup_{n \in \mathbb{N}} B_n \in \mathcal{S}$ puisque $\mathcal{S}$ est une tribu. Par conséquent,

$$\bigcup_{n \in \mathbb{N}} A_n \in f^{-1}(\mathcal{S}).$$

Ainsi $f^{-1}(\mathcal{S})$ contient $\emptyset$, est stable par complémentation et par réunion dénombrable. On conclut que $f^{-1}(\mathcal{S})$ est une tribu sur E .

Montrons maintenant la minimalité. Soit $\mathcal{T}$ une tribu sur E telle que

$$f : (E, \mathcal{T}) \longrightarrow (F, \mathcal{S})$$

soit mesurable. Par définition de la mesurabilité, pour tout $B \in \mathcal{S}$,

$$f^{-1}(B) \in \mathcal{T}.$$

Ainsi tous les éléments de $f^{-1}(\mathcal{S})$ appartiennent à $\mathcal{T}$, donc

$$f^{-1}(\mathcal{S}) \subseteq \mathcal{T}.$$

Par conséquent, $f^{-1}(\mathcal{S})$ est bien la plus petite tribu sur E rendant f mesurable. ■

Exemple 4.5 – La tribu minimale d’une indicatrice

Soit $A \subset E$ et $f = \mathbf{1}_A : E \rightarrow \mathbb{R}$, où $\mathbb{R}$ est muni de sa tribu borélienne. Comme f ne prend que les valeurs 0 et 1, les seules images réciproques possibles d’un borélien sont

$$\emptyset, \quad A, \quad A^c, \quad E.$$

Ainsi

$$f^{-1}(\mathcal{B}(\mathbb{R})) = \{\emptyset, A, A^c, E\}.$$

C’est donc la plus petite tribu sur E qui rend $\mathbf{1}_A$ mesurable.

Si A appartient déjà à une tribu $\mathcal{T}$ sur E , alors $\{\emptyset, A, A^c, E\} \subseteq \mathcal{T}$ et $\mathbf{1}_A$ est $\mathcal{T}/\mathcal{B}(\mathbb{R})$ -mesurable. En revanche, si $E = \mathbb{R}$ et si $V \subset [0, 1]$ est un ensemble de Vitali, le même calcul donne

$$(\mathbf{1}_V)^{-1}(\mathcal{B}(\mathbb{R})) = \{\emptyset, V, V^c, \mathbb{R}\}.$$

La construction de la tribu minimale ne change donc pas : elle ne suppose pas que V soit mesurable pour une tribu déjà fixée. Simplement, comme $V \notin \mathcal{M}(\lambda^*)$, cette tribu minimale n’est pas contenue dans la tribu de Lebesgue ; par conséquent $\mathbf{1}_V$ n’est pas Lebesgue-mesurable.

Propriété 4.6 – Tribu engendrée et image réciproque

Soient E, F deux ensembles, $f : E \rightarrow F$ une application, $\mathcal{G}$ une partie de $\mathcal{P}(F)$. Alors :

$$f^{-1}(\sigma(\mathcal{G})) = \sigma(f^{-1}(\mathcal{G})).$$

Remarque 4.7

La démonstration de cette proposition est proposée dans le TD n°3, partie 3, exercice « Tribu engendrée et image réciproque ».

Remarque 4.8

Ce résultat, bien que technique, aura une conséquence tout à fait concrète : il permettra de vérifier qu’une application est mesurable en la testant seulement sur une famille *génératrice* de la tribu d’arrivée, plutôt que sur tous les boréliens (Proposition 4.15 « Caractérisation par une famille génératrice » ci-dessous). C’est ce principe d’économie qui rend la théorie utilisable en pratique.

4.2 Définition et premières propriétés

Définition 4.9 – Fonction mesurable

Soient $(E, \mathcal{T}_E)$ et $(F, \mathcal{T}_F)$ deux espaces mesurables. Soit $f : E \rightarrow F$ une application. On dit que f est **mesurable** si

$$\forall \Sigma \in \mathcal{T}_F, \quad f^{-1}(\Sigma) \in \mathcal{T}_E.$$

Lorsque $\mathcal{T}_E$ et $\mathcal{T}_F$ sont les tribus boréliennes de E et F , on dit aussi que f est **borélienne**.

Définition 4.10 – Fonction Lebesgue-mesurable

Une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ est dite **Lebesgue-mesurable** lorsqu'elle est mesurable de

$$(\mathbb{R}, \mathcal{M}(\lambda^*)) \quad \text{dans} \quad (\mathbb{R}, \mathcal{B}(\mathbb{R})),$$

c'est-à-dire lorsque

$$\forall B \in \mathcal{B}(\mathbb{R}), \quad f^{-1}(B) \in \mathcal{M}(\lambda^*).$$

En particulier, toute fonction borélienne $f : \mathbb{R} \rightarrow \mathbb{R}$ est Lebesgue-mesurable puisque $\mathcal{B}(\mathbb{R}) \subseteq \mathcal{M}(\lambda^*)$.

Remarque 4.11 – Pourquoi cette notion est utile

La mesurabilité est la condition minimale qui permet de transformer une question sur les valeurs de f en un ensemble auquel on sait attribuer une mesure. Par exemple, pour une variable aléatoire réelle X , l'événement

$$\{X \leq a\} = X^{-1}(]-\infty, a])$$

est mesurable précisément parce que X est mesurable. Sans cette propriété, des quantités comme $\mathbb{P}(X \leq a)$ ou $\int X d\mathbb{P}$ n'ont pas de sens dans le cadre de la théorie de la mesure.

Exemple 4.12 – Un premier exemple

Soit $(E, \mathcal{T}_E)$ un espace mesurable et $A \in \mathcal{T}_E$. L'indicatrice $\mathbf{1}_A : E \rightarrow \mathbb{R}$ est alors mesurable (on le démontrera juste après, Proposition 4.19 « Mesurabilité des indicatrices ») : c'est le premier exemple, le plus simple possible, de fonction mesurable non triviale.




Figure 7: $f : E \rightarrow F$ est mesurable si l'image réciproque $f^{-1}(\Sigma)$ de tout événement $\Sigma \in \mathcal{T}_F$ est encore un événement de E , c'est-à-dire un élément de $\mathcal{T}_E$.

Propriété 4.13 – Stabilité par composition

Soient $(E, \mathcal{T}_E)$, $(F, \mathcal{T}_F)$, $(G, \mathcal{T}_G)$ trois espaces mesurables, $f : E \rightarrow F$ et $g : F \rightarrow G$ mesurables. Alors $g \circ f$ est mesurable.

Démonstration. Soit $W \in \mathcal{T}_G$. Alors $(g \circ f)^{-1}(W) = f^{-1}(g^{-1}(W))$. Or $g^{-1}(W) \in \mathcal{T}_F$ (car g est mesurable), donc $f^{-1}(g^{-1}(W)) \in \mathcal{T}_E$ (car f est mesurable). ■

Attention 4.14 – Un piège classique : « mesurable ◦ mesurable » sur $\mathbb{R}$

La Proposition 4.13 « Stabilité par composition » est un résultat abstrait sans ambiguïté : elle suppose que g est mesurable pour la tribu portée par l'espace intermédiaire. Sur $\mathbb{R}$, il faut donc distinguer la tribu borélienne $\mathcal{B}(\mathbb{R})$ de la tribu de Lebesgue $\mathcal{M}(\lambda^*)$. D'après la Définition 4.10 « Fonction Lebesgue-mesurable », une fonction Lebesgue-mesurable vérifie seulement

$$f^{-1}(\mathcal{B}(\mathbb{R})) \subseteq \mathcal{M}(\lambda^*),$$

et non, en général, $f^{-1}(\mathcal{M}(\lambda^*)) \subseteq \mathcal{M}(\lambda^*)$. Ainsi la composition de deux fonctions seulement Lebesgue-mesurables peut ne pas être Lebesgue-mesurable. Un contre-exemple guidé est proposé dans le TD n°3, partie 3, exercice « Composition de fonctions Lebesgue-mesurables : un contre-exemple ».

Propriété 4.15 – Caractérisation par une famille génératrice

Soient $(E, \mathcal{T}_E)$ et $(F, \mathcal{T}_F)$ deux espaces mesurables, $f : E \rightarrow F$, et $\mathcal{G}$ une partie de $\mathcal{T}_F$ engendrant $\mathcal{T}_F$. Alors f est mesurable si et seulement si $f^{-1}(G) \in \mathcal{T}_E$ pour tout $G \in \mathcal{G}$.

Démonstration. Le sens direct est immédiat : si f est mesurable, $f^{-1}(G) \in \mathcal{T}_E$ pour *tout* $G \in \mathcal{T}_F$, donc en particulier pour $G \in \mathcal{G} \subset \mathcal{T}_F$.

Réciproquement, supposons $f^{-1}(G) \in \mathcal{T}_E$ pour tout $G \in \mathcal{G}$, c'est-à-dire $f^{-1}(\mathcal{G}) \subset \mathcal{T}_E$. En appliquant l'opération $\sigma(\cdot)$ (tribu engendrée) aux deux membres, qui préserve l'inclusion, on obtient $\sigma(f^{-1}(\mathcal{G})) \subset \mathcal{T}_E$ (car $\mathcal{T}_E$ est déjà une tribu, elle est égale à la tribu qu'elle engendre). Or, par la Proposition 4.6 « Tribu engendrée et image réciproque », $\sigma(f^{-1}(\mathcal{G})) = f^{-1}(\sigma(\mathcal{G})) = f^{-1}(\mathcal{T}_F)$ (car $\mathcal{G}$ engendre $\mathcal{T}_F$ par hypothèse). On a donc $f^{-1}(\mathcal{T}_F) \subset \mathcal{T}_E$, c'est-à-dire exactement que f est mesurable. ■

Méthode 4.16 – Montrer qu'une fonction est mesurable

Pour montrer que $f : E \rightarrow \mathbb{R}$ (ou $\mathbb{R}^n$, ou $\overline{\mathbb{R}}$) est mesurable, il suffit, grâce à la Proposition 4.15 « Caractérisation par une famille génératrice », de vérifier que $f^{-1}(G) \in \mathcal{T}_E$ pour G parcourant une famille génératrice *simple* de la tribu borélienne, par exemple les demi-droites $] -\infty, a]$. Dans la pratique, on utilise surtout les résultats de « boîte à outils » suivants (Propositions Proposition 4.17 « Mesurabilité des fonctions continues » et Proposition 4.23 « Stabilité par opérations usuelles ») : continuité $\Rightarrow$ mesurabilité, et stabilité par les opérations usuelles $(+, \times, |\cdot|, \sup, \inf, \lim)$.

Propriété 4.17 – Mesurabilité des fonctions continues

Soient $(E, \mathcal{T}_E)$ et $(F, \mathcal{T}_F)$ deux espaces vectoriels normés munis de leur tribu borélienne. Toute application continue $f : E \rightarrow F$ est mesurable.

Démonstration. La famille des ouverts de F engendre $\mathcal{T}_F = \mathcal{B}(F)$. Or pour f continue et V ouvert de F , $f^{-1}(V)$ est un ouvert de E , donc un élément de $\mathcal{B}(E) = \mathcal{T}_E$. On conclut par la Proposition 4.15 « Caractérisation par une famille génératrice ». ■

Exemple 4.18

Les fonctions constantes, les fonctions polynomiales, $\exp$, $\sin$, $\cos$, ou encore la fonction indicatrice $\mathbf{1}_A$ d'un ouvert ou d'un fermé A , sont mesurables comme fonctions continues (ou, pour $\mathbf{1}_A$, par un argument direct, voir Proposition 4.19 « Mesurabilité des indicatrices »).

Propriété 4.19 – Mesurabilité des indicatrices

Soit $(E, \mathcal{T})$ un espace mesurable, soit $A \in \mathcal{T}$. Alors $\mathbf{1}_A$ est mesurable.

Démonstration. Soit $B \subset \mathbb{R}$. Selon que 0 et 1 appartiennent ou non à B , on trouve $\mathbf{1}_A^{-1}(B) \in \{\emptyset, A, A^c, E\}$,

qui sont tous des éléments de $\mathcal{T}$ (car $A \in \mathcal{T}$). ■

Exemple 4.20 – Une indicatrice non mesurable

La condition $A \in \mathcal{T}$ est indispensable. Soit $V \subset [0, 1]$ l'ensemble de Vitali (Chapitre 1 « Autour de la mesure extérieure de Lebesgue », Théorème 1.31 « Ensemble de Vitali »), qui n'est pas Lebesgue-mesurable. Alors $\mathbf{1}_V : \mathbb{R} \rightarrow \mathbb{R}$ n'est **pas** une fonction Lebesgue-mesurable, car

$$\{x \in \mathbb{R} : \mathbf{1}_V(x) > 1/2\} = V \notin \mathcal{M}(\lambda^*).$$

Ce contre-exemple montre que la mesurabilité d'une fonction peut authentiquement échouer : ce n'est pas une hypothèse automatiquement satisfaite.

Exemple 4.21

$\mathbb{Q}$ étant un borélien de $\mathbb{R}$ (Chapitre 2 « Espace mesurable »), $\mathbf{1}_{\mathbb{Q}}$ est une fonction borélienne – bien qu'elle ne soit continue en *aucun* point de $\mathbb{R}$! C'est un premier signe que la mesurabilité est une notion beaucoup plus souple que la continuité.

Propriété 4.22 – Caractérisation des fonctions mesurables à valeurs vectorielles

Soit $(E, \mathcal{T})$ un espace mesurable, $n \geq 1$, $f = (f_1, \dots, f_n) : E \rightarrow \mathbb{R}^n$ ($\mathbb{R}^n$ muni de sa tribu borélienne). Alors f est mesurable si et seulement si chaque $f_i : E \rightarrow \mathbb{R}$ est mesurable.

Démonstration. ($\Rightarrow$) Soit $i \in \{1, \dots, n\}$. La projection $\pi_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $(x_1, \dots, x_n) \mapsto x_i$, est linéaire entre espaces de dimension finie, donc continue, donc mesurable (Proposition 4.17 « Mesurabilité des fonctions continues »). Par composition (Proposition 4.13 « Stabilité par composition »), $f_i = \pi_i \circ f$ est mesurable. ($\Leftarrow$) Supposons chaque f_i mesurable. Les pavés $(B_1 \times \dots \times B_n)$, avec $B_i \in \mathcal{B}(\mathbb{R})$, engendrent $\mathcal{B}(\mathbb{R}^n)$ (c'est la définition de la tribu produit/borélienne sur $\mathbb{R}^n$). Or

$$f^{-1}(B_1 \times \dots \times B_n) = \{x \in E \mid f_1(x) \in B_1, \dots, f_n(x) \in B_n\} = \bigcap_{i=1}^n f_i^{-1}(B_i),$$

qui est un élément de $\mathcal{T}$ comme intersection finie d'éléments de $\mathcal{T}$ (chaque $f_i^{-1}(B_i) \in \mathcal{T}$ par mesurabilité de f_i). Par la Proposition 4.15 « Caractérisation par une famille génératrice » (caractérisation par une famille génératrice), f est donc mesurable. ■

Propriété 4.23 – Stabilité par opérations usuelles

Soit $(E, \mathcal{T})$ un espace mesurable, $\lambda \in \mathbb{R}$, $f, g : E \rightarrow \mathbb{R}$ mesurables. Alors $f + g$, fg , λf , $|f|$ sont mesurables.

Démonstration. Soit $h : E \rightarrow \mathbb{R}^2$, $h(x) = (f(x), g(x))$. Par la Proposition 4.22 « Caractérisation des fonctions mesurables à valeurs vectorielles », h est mesurable puisque ses deux coordonnées f, g le sont. Les applications $S : (x, y) \mapsto x + y$, $P : (x, y) \mapsto xy$, $m_\lambda : x \mapsto \lambda x$, $\text{abs} : x \mapsto |x|$ sont continues, donc mesurables (Proposition 4.17 « Mesurabilité des fonctions continues »). Par stabilité par composition (Proposition 4.13 « Stabilité par composition »), $S \circ h = f + g$, $P \circ h = fg$, $m_\lambda \circ f = \lambda f$ et $\text{abs} \circ f = |f|$ sont mesurables. ■

Définition 4.24 – Droite réelle achevée, tribu borélienne achevée

On appelle **droite réelle achevée** l'ensemble $\overline{\mathbb{R}} = \mathbb{R} \cup \{-\infty, +\infty\}$, notée aussi $[-\infty, +\infty]$. On appelle **tribu borélienne achevée** l'ensemble

$$\mathcal{B}(\overline{\mathbb{R}}) := \{A \subset \overline{\mathbb{R}} \mid A \cap \mathbb{R} \in \mathcal{B}(\mathbb{R})\},$$

où $\mathcal{B}(\mathbb{R})$ désigne la tribu borélienne de $\mathbb{R}$.

Propriété 4.25 – Stabilité par sup et inf dénombrables

Soit $(E, \mathcal{T})$ un espace mesurable, soit $(f_n)_{n \geq 1}$ une famille de fonctions mesurables $E \rightarrow \overline{\mathbb{R}} := \mathbb{R} \cup \{-\infty, +\infty\}$ (muni de la tribu borélienne achevée de la Définition 4.24 « Droite réelle achevée, tribu borélienne achevée »). Alors $\sup_{n \geq 1} f_n$ et $\inf_{n \geq 1} f_n$ sont mesurables.

Remarque 4.26

La démonstration détaillée de cette proposition est proposée dans le TD n°3, exercice 2.6 « Suites de fonctions mesurables : supremum, limsup et limite simple ».

Rappel de L2 4.27 – opérations dans $\overline{\mathbb{R}}$

Dans $\overline{\mathbb{R}}$, on adopte les conventions suivantes :

1. $-\infty < +\infty$;
2. pour tout $x \in \mathbb{R}$,

$$-\infty < x < +\infty, \quad (\pm\infty) = (\pm\infty) + x = x + (\pm\infty), \quad \frac{x}{\pm\infty} = 0 ;$$

$$3. \quad x \cdot (\pm\infty) = (\pm\infty) \cdot x = \begin{cases} (\pm\infty) & \text{si } x \in]0, +\infty] \\ 0 & \text{si } x = 0 \\ (\mp\infty) & \text{si } x \in [-\infty, 0[. \end{cases}$$

Attention 4.28

On évite systématiquement l'opération $\infty - \infty$, qui n'est pas définie. Les conventions choisies ci-dessus (en particulier $0 \times \infty = 0$) sont celles qui permettent, dans la suite du livret, d'étendre les calculs dans $\overline{\mathbb{R}}$ tout en gardant une cohérence : une fonction nulle en dehors d'un ensemble négligeable, mais valant $+\infty$ sur ce dernier, doit avoir une intégrale nulle.

Exercice 4.29 – Mesurabilité de la limsup de fonctions

Soit $(E, \mathcal{T})$ un espace mesurable, $(f_n)_{n \geq 1}$ une famille de fonctions mesurables sur E à valeurs dans $\overline{\mathbb{R}}$. On pose $\limsup_n f_n := \inf_{n \geq 1} \sup_{m \geq n} f_m$ et $\liminf_n f_n := \sup_{n \geq 1} \inf_{m \geq n} f_m$.

1. Montrer que $\limsup_n f_n$ et $\liminf_n f_n$ sont mesurables.
2. Montrer que si (f_n) converge simplement vers f , alors f est mesurable.

Remarque 4.30

La démonstration est renvoyée au TD n°3, exercice 2.6.

Rappel de L1 4.31 – suites réelles

On rappelle que pour une suite réelle (u_n) , $\liminf_n u_n \leq \limsup_n u_n$ toujours, et que (u_n) converge (dans $\overline{\mathbb{R}}$) si et seulement si $\liminf_n u_n = \limsup_n u_n$, cette valeur commune étant alors la limite. C'est ce résultat, appliqué point par point (x fixé), qui permet de transporter la convergence simple d'une suite de fonctions mesurables vers la mesurabilité de la limite – un résultat qui sera constamment utilisé au Chapitre 5 « Intégrale de Lebesgue ».

4.3 Complément : mesure image

Définition 4.32 – Mesure image

Soit $f : (E, \mathcal{T}_E) \rightarrow (F, \mathcal{T}_F)$ une application mesurable, μ une mesure sur $(E, \mathcal{T}_E)$. La **mesure image** de μ par f , notée $f(\mu)$ ou μ_f , est la mesure sur $(F, \mathcal{T}_F)$ définie par $f(\mu)(B) := \mu(f^{-1}(B))$ pour $B \in \mathcal{T}_F$.

Remarque 4.33

C'est exactement la construction que l'on retrouvera au Chapitre 9 « Variables aléatoires réelles » sous le nom de **loi** d'une variable aléatoire : $\mathbb{P}_X$. La définition posée ici, dans le cadre général d'une mesure quelconque (pas nécessairement une probabilité), montre que la notion de loi d'une variable aléatoire n'est qu'un cas particulier d'une construction beaucoup plus générale de théorie de la mesure.

Exercice 4.34 – Invariance par translation de la mesure de Lebesgue

Montrer que pour tout $A \in \mathcal{B}(\mathbb{R})$ et tout $x \in \mathbb{R}$, $\lambda(x + A) = \lambda(A)$.

Solution

La mesure image de λ par la translation $\sigma_x : y \mapsto y - x$ vérifie $\sigma_x(\lambda)(A) = \lambda(\sigma_x^{-1}(A)) = \lambda(x + A)$. Or $\sigma_x(\lambda)$ et λ coïncident sur tout intervalle $]a, b[$ (deux intervalles translatés ont même longueur) : la famille des intervalles ouverts étant stable par intersection finie et engendrant $\mathcal{B}(\mathbb{R})$, le Corollaire 3.13 « Unicité d'une mesure déterminée par un π -système générateur » donne $\sigma_x(\lambda) = \lambda$ sur $\mathcal{B}(\mathbb{R})$ tout entier, d'où $\lambda(x + A) = \lambda(A)$.

5 Intégrale de Lebesgue

Objectifs

- Construire l'intégrale de Lebesgue par étapes (fonctions étagées, positives, quelconques).
- Connaître les propriétés de l'intégrale (linéarité, croissance, additivité).
- Maîtriser les trois théorèmes de convergence (convergence monotone, Fatou, convergence dominée) et leurs applications.
- Savoir dériver sous le signe intégrale.

Introduction

On dispose maintenant de tout le nécessaire – une tribu, une mesure, la notion de fonction mesurable – pour construire une théorie de l'intégration extrêmement générale : l'**intégrale de Lebesgue**. On procède en trois étapes, illustrées ci-dessous : fonctions étagées, puis mesurables positives par approximation croissante, puis de signe quelconque par décomposition $f = f^+ - f^-$.




Figure 8: Plan de construction de l'intégrale de Lebesgue : on définit l'intégrale des fonctions étagées positives (combinaisons linéaires finies d'indicatrices), on l'étend aux fonctions mesurables positives par approximation croissante, puis aux fonctions de signe quelconque en séparant partie positive et partie négative.

5.1 Fonctions étagées et approximation

Définition 5.1 – Fonction étagée

Soit $(E, \mathcal{T})$ un espace mesurable, soit $f : E \rightarrow \mathbb{R}$. On dit que f est **simple** ou **étagée** s'il existe une famille $(A_k)_{1 \leq k \leq n} \in \mathcal{T}^n$ d'ensembles mesurables deux à deux disjoints et $(x_k)_{1 \leq k \leq n} \in \mathbb{R}^n$ tels que

$$f = \sum_{k=1}^n x_k \mathbf{1}_{A_k}.$$

Exemple 5.2

Les fonctions en escaliers sur $\mathbb{R}$ (à support dans une réunion finie d'intervalles) sont des fonctions étagées : c'est le pont entre l'intégrale de Riemann, vue en licence, et l'intégrale de Lebesgue que l'on construit dans ce chapitre.




Figure 9: Une fonction étagée $f = \sum_k x_k \mathbf{1}_{A_k}$: elle prend un nombre fini de valeurs, chacune sur un ensemble mesurable ; les A_k ne sont pas nécessairement des intervalles (contrairement au cas des fonctions en escaliers) – ici A_1 et A_3 sont chacun formés de deux intervalles disjoints, sur lesquels f prend bien, comme il se doit, la même valeur.

Propriété 5.3 – Mesurabilité des fonctions étagées

Toute fonction étagée est mesurable.

Démonstration. Combinaison linéaire finie de fonctions $\mathbf{1}_{A_k}$ mesurables (Proposition 4.19 « Mesurabilité des indicatrices »), donc mesurable par la Proposition 4.23 « Stabilité par opérations usuelles ». ■

Théorème 5.4 – Lemme d'approximation

Soit $(E, \mathcal{T})$ un espace mesurable, soit $f : E \rightarrow [0, +\infty]$ mesurable. Il existe une suite $(f_n)_{n \geq 1}$ de fonctions étagées **positives** qui converge simplement en croissant vers f .

Idée de preuve. On construit f_n en découpant l'intervalle $[0, n]$ en $n2^n$ tranches de largeur 2^{-n} , et en approchant f par le bas sur chaque tranche : $f_n = \sum_{0 \leq k < n2^n} \frac{k}{2^n} \mathbf{1}_{\{k2^{-n} \leq f < (k+1)2^{-n}\}} + n \mathbf{1}_{\{f \geq n\}}$. Chaque f_n est étagée, la précision 2^{-n} s'améliore quand n croît, et la troncature à hauteur n finit par ne plus jouer de rôle : on obtient bien une convergence simple croissante vers f .




Figure 10: Approximation de f par des fonctions étagées $f_0 \leq f_1 \leq f_2 \leq f_3$.

Démonstration. Pour tout $n \geq 1$ et tout entier k tel que $0 \leq k < n2^n$, posons

$$A_{n,k} := \{x \in E \mid k2^{-n} \leq f(x) < (k+1)2^{-n}\} = f^{-1}([k2^{-n}, (k+1)2^{-n}[),$$

et

$$A_n := \{x \in E \mid f(x) \geq n\} = f^{-1}([n, +\infty[).$$

D'après la Définition 4.9 « Fonction mesurable », les ensembles $A_{n,k}$ et A_n appartiennent à $\mathcal{T}$, puisque les intervalles considérés sont boréliens. Pour n fixé, ils sont deux à deux disjoints et

$$E = A_n \sqcup \bigcup_{k=0}^{n2^n-1} A_{n,k}.$$

On définit alors

$$f_n := \sum_{k=0}^{n2^n-1} \frac{k}{2^n} \mathbf{1}_{A_{n,k}} + n \mathbf{1}_{A_n}.$$

Ainsi f_n est une fonction étagée positive.

Monotonie de la suite (f_n) . Fixons $x \in E$. Nous distinguons trois cas.

Premier cas : $f(x) \geq n+1$. Alors $x \in A_n \cap A_{n+1}$, donc

$$f_n(x) = n < n+1 = f_{n+1}(x).$$

Deuxième cas : $n \leq f(x) < n+1$. On a $x \in A_n$, donc

$$f_n(x) = n.$$

Comme $f(x) < n+1$, il existe un entier k' tel que

$$0 \leq k' < (n+1)2^{n+1}, \quad \frac{k'}{2^{n+1}} \leq f(x) < \frac{k'+1}{2^{n+1}}.$$

De plus, $f(x) \geq n$ implique

$$\frac{k'+1}{2^{n+1}} > n, \quad \text{donc} \quad k' \geq n2^{n+1}.$$

Par conséquent,

$$f_{n+1}(x) = \frac{k'}{2^{n+1}} \geq \frac{n2^{n+1}}{2^{n+1}} = n = f_n(x).$$

Troisième cas : $f(x) < n$. Il existe un unique entier $k \in \{0, \dots, n2^n - 1\}$ tel que

$$\frac{k}{2^n} \leq f(x) < \frac{k+1}{2^n}, \quad \text{et donc} \quad f_n(x) = \frac{k}{2^n} = \frac{2k}{2^{n+1}}.$$

L'intervalle

$$\left[\frac{k}{2^n}, \frac{k+1}{2^n} \right[= \left[\frac{2k}{2^{n+1}}, \frac{2k+2}{2^{n+1}} \right[$$

se partage en deux intervalles de longueur $2^{-(n+1)}$.

Si

$$f(x) \in \left[\frac{2k}{2^{n+1}}, \frac{2k+1}{2^{n+1}} \right[,$$

alors

$$f_{n+1}(x) = \frac{2k}{2^{n+1}} = \frac{k}{2^n} = f_n(x).$$

Si, au contraire,

$$f(x) \in \left[\frac{2k+1}{2^{n+1}}, \frac{2k+2}{2^{n+1}} \right[,$$

alors

$$f_{n+1}(x) = \frac{2k+1}{2^{n+1}} > \frac{2k}{2^{n+1}} = \frac{k}{2^n} = f_n(x).$$

Dans tous les cas,

$$f_n(x) \leq f_{n+1}(x).$$

Comme $x \in E$ était arbitraire, on obtient

$$f_n \leq f_{n+1} \quad \text{sur } E,$$

et la suite (f_n) est croissante.

Convergence simple. Fixons à nouveau $x \in E$.

Si $f(x) = +\infty$, alors $x \in A_n$ pour tout n , donc

$$f_n(x) \xrightarrow{n \rightarrow +\infty} +\infty = f(x).$$

Si $f(x) < +\infty$, choisissons $n > f(x)$. Alors $x \notin A_n$ et il existe un unique $k \in \{0, \dots, n2^n - 1\}$ tel que $x \in A_{n,k}$, c'est-à-dire

$$\frac{k}{2^n} \leq f(x) < \frac{k+1}{2^n}.$$

Comme

$$f_n(x) = \frac{k}{2^n},$$

on en déduit

$$0 \leq f(x) - f_n(x) < \frac{k+1}{2^n} - \frac{k}{2^n} = 2^{-n} \xrightarrow{n \rightarrow +\infty} 0.$$

Ainsi

$$f_n(x) \xrightarrow{n \rightarrow +\infty} f(x).$$

Finalement, (f_n) est une suite croissante de fonctions étagées positives qui converge simplement vers f . ■

Remarque 5.5 – Une formule unique pour f_n

La construction ci-dessus, qui distingue les tranches $A_{n,k}$ de la troncature A_n , peut se réécrire en une seule formule fermée, plus maniable dans certaines preuves :

$$f_n = \min \left(n, \frac{\lfloor 2^n f \rfloor}{2^n} \right), \quad n \geq 1,$$

où $\lfloor \cdot \rfloor$ désigne la partie entière (appliquée point par point, i.e. $f_n(x) = \min(n, 2^{-n} \lfloor 2^n f(x) \rfloor)$, avec la convention $\lfloor 2^n \cdot (+\infty) \rfloor = +\infty$). On vérifie immédiatement que cette écriture coïncide avec celle de la démonstration : si $f(x) \in [k2^{-n}, (k+1)2^{-n}[$ pour un $k < n2^n$, alors $\lfloor 2^n f(x) \rfloor = k$, donc $2^{-n} \lfloor 2^n f(x) \rfloor = k2^{-n}$, qui est bien $< n$; et si $f(x) \geq n$, alors $2^{-n} \lfloor 2^n f(x) \rfloor \geq n$, donc le minimum avec n vaut n . C'est exactement la fonction f_n construite plus haut. Cette formule a l'avantage de rendre *immédiate* la mesurabilité de f_n (composée de f , mesurable, avec la fonction borélienne $t \mapsto \min(n, 2^{-n} \lfloor 2^n t \rfloor)$, continue par morceaux donc borélienne), sans avoir à vérifier séparément que les $A_{n,k}$ et A_n sont mesurables.

Exemple 5.6

Ce lemme est la clé de voûte de toute la construction de l'intégrale du paragraphe suivant : il permet de définir $\int_E f d\mu$ pour f mesurable positive quelconque comme limite (ou borne supérieure) des intégrales, déjà connues, des fonctions étagées f_n qui l'approchent.

5.2 Construction de l'intégrale de Lebesgue

Rappel de L2 5.7 – intégrale de Riemann

Soit $f : [a, b] \rightarrow \mathbb{R}$ une fonction bornée. Pour une subdivision

$$P : \quad a = x_0 < x_1 < \cdots < x_m = b,$$

on pose

$$L(f, P) := \sum_{i=1}^m \left(\inf_{[x_{i-1}, x_i]} f \right) (x_i - x_{i-1}), \quad U(f, P) := \sum_{i=1}^m \left(\sup_{[x_{i-1}, x_i]} f \right) (x_i - x_{i-1}).$$

La fonction f est dite **Riemann-intégrable** lorsque

$$\sup_P L(f, P) = \inf_P U(f, P).$$

La valeur commune est alors notée $\int_a^b f(x) dx$. De façon équivalente, pour tout $\varepsilon > 0$, il existe deux fonctions en escalier φ, ψ telles que

$$\varphi \leq f \leq \psi \quad \text{et} \quad \int_a^b (\psi(x) - \varphi(x)) dx < \varepsilon.$$

Compatibilité Riemann–Lebesgue. Toute fonction Riemann-intégrable $f : [a, b] \rightarrow \mathbb{R}$ est mesurable pour la tribu de Lebesgue, Lebesgue-intégrable, et

$$\int_a^b f(x) dx = \int_{[a,b]} f d\lambda.$$

Idée de preuve. On choisit des subdivisions de plus en plus fines et les fonctions en escalier inférieure et supérieure associées. Elles encadrent f , leurs intégrales ont le même limite, et leur écart tend vers 0. Les limites des deux approximations coïncident presque partout ; f coïncide donc presque partout avec une fonction Lebesgue-mesurable et les intégrales sont égales. La preuve détaillée est proposée au TD n°3, partie 3, exercice « Compatibilité des intégrales de Riemann et de Lebesgue ».

5.2.1 Intégrale d'une fonction étagée positive

Définition 5.8 – Intégrale d'une fonction étagée positive

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, soit $(A_1, \dots, A_n)$ une partition (finie) de Ω par des éléments de $\mathcal{T}$, soient $x_1, \dots, x_n \in \mathbb{R}^+$. On pose $f = \sum_{k=1}^n x_k \mathbf{1}_{A_k}$. L'intégrale de f est le réel positif

$$\int_{\Omega} f d\mu := \sum_{k=1}^n x_k \mu(A_k) \quad \left(\text{notée aussi } \int f d\mu \right).$$

Remarque 5.9

Cette définition appelle une vérification : une même fonction étagée peut s'écrire de plusieurs façons comme combinaison linéaire d'indicatrices (en raffinant la partition), et il faut s'assurer que la valeur de l'intégrale n'en dépend pas. Ceci se démontre en considérant la partition commune obtenue par intersection des deux partitions de départ (les $C_{i,j} = A_i \cap B_j$) : sur chaque $C_{i,j}$ non vide, les deux écritures de f imposent la même valeur, et l'égalité des deux sommes s'ensuit par regroupement des termes.




Figure 11: L'intégrale de la fonction étagée positive $f = 1,5 \mathbf{1}_{A_1} + 2,6 \mathbf{1}_{A_2} + 0,8 \mathbf{1}_{A_3}$ est la somme des aires des « rectangles généralisés » $x_k \mu(A_k)$: ici les largeurs représentent $\mu(A_1) = 1,2$, $\mu(A_2) = 2,5$ et $\mu(A_3) = 5,3$.

Exemple 5.10

Trois mesures différentes donnent trois calculs très concrets pour une fonction étagée positive.

Mesure de Lebesgue. Soit $\mu = \lambda$ la mesure de Lebesgue sur $\mathbb{R}$, et

$$f = 2\mathbf{1}_{[0,1]} + 3\mathbf{1}_{\mathbb{Q} \cap [1,4]}.$$

Alors f est étagée : elle vaut 2 sur $[0, 1[$, 5 sur $\mathbb{Q} \cap [1, 4]$, et 0 ailleurs. Ainsi

$$\int_{\mathbb{R}} f d\lambda = 2\lambda([0, 1]) + 5\lambda(\mathbb{Q} \cap [1, 4]) = 2 \times 1 + 5 \times 0 = 2,$$

car $\mathbb{Q} \cap [1, 4]$ est dénombrable, donc négligeable pour λ .

Mesure de comptage. Sur $(\mathbb{N}, \mathcal{P}(\mathbb{N}))$, soit ν la mesure de comptage et

$$g = 2\mathbf{1}_{\{0,1,2\}} + 4\mathbf{1}_{\{5\}}.$$

Comme $\nu(\{0, 1, 2\}) = 3$ et $\nu(\{5\}) = 1$, on obtient

$$\int_{\mathbb{N}} g d\nu = 2\nu(\{0, 1, 2\}) + 4\nu(\{5\}) = 2 \times 3 + 4 \times 1 = 10.$$

On retrouve ici le fait que, pour la mesure de comptage, intégrer revient à sommer les valeurs de la fonction.

Mesure de Dirac en un point. Fixons $a \in \mathbb{R}$ et considérons la mesure de Dirac δ_a . Si

$$h = \sum_{k=1}^n x_k \mathbf{1}_{A_k}$$

est étagée positive, avec $(A_1, \dots, A_n)$ une partition mesurable de $\mathbb{R}$, il existe un unique indice j tel que $a \in A_j$. Comme $\delta_a(A_j) = 1$ et $\delta_a(A_k) = 0$ pour $k \neq j$,

$$\int_{\mathbb{R}} h d\delta_a = \sum_{k=1}^n x_k \delta_a(A_k) = x_j = h(a).$$

Par exemple, pour $a = 2$ et $h = 3\mathbf{1}_{[0,1]} + 7\mathbf{1}_{[1,3]}$, on a

$$\int_{\mathbb{R}} h d\delta_2 = h(2) = 7.$$

5.2.2 Intégrale d'une fonction mesurable positive

Définition 5.11 – Intégrale d'une fonction mesurable positive

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, soit $f : \Omega \rightarrow [0, +\infty]$ mesurable. On appelle **intégrale** de f par rapport à μ :

$$\int_{\Omega} f d\mu := \sup \left\{ \int_{\Omega} S d\mu \mid 0 \leq S \leq f, S \text{ étagée} \right\} \in [0, +\infty].$$

Si $\int_{\Omega} f d\mu < +\infty$, on dit que f est μ -**intégrable**.

Remarque 5.12

Cette intégrale est toujours bien définie (dans $[0, +\infty]$), même lorsque sa valeur est $+\infty$: c'est une différence essentielle avec l'intégrale de Riemann, qui nécessite un encadrement par le haut *et* par le bas. Grâce au Théorème 5.4 « Lemme d'approximation », on peut aussi calculer cette intégrale comme une limite : si (f_n) est une suite croissante de fonctions étagées convergeant simplement vers f , alors $\int_{\Omega} f d\mu = \lim_{n \rightarrow +\infty} \int_{\Omega} f_n d\mu$ (Proposition 5.13 « Limite croissante et intégrale » ci-dessous).

Propriété – Monotonie positive

Soient $u, v : \Omega \rightarrow [0, +\infty]$ deux fonctions mesurables. Si $0 \leq u \leq v$, alors

$$\int_{\Omega} u \, d\mu \leq \int_{\Omega} v \, d\mu.$$

Démonstration. Fixons une fonction étagée positive $\varphi \leq u$. Comme $u \leq v$, on a aussi $\varphi \leq v$; ainsi φ appartient à la famille des fonctions étagées positives utilisée pour définir l'intégrale de v . Par conséquent,

$$\int_{\Omega} \varphi \, d\mu \leq \sup_{\substack{0 \leq \psi \leq v \\ \psi \text{ étagée}}} \int_{\Omega} \psi \, d\mu = \int_{\Omega} v \, d\mu.$$

Cette inégalité valant pour toute fonction étagée positive $\varphi \leq u$, on prend la borne supérieure sur toutes ces fonctions :

$$\int_{\Omega} u \, d\mu = \sup_{\substack{0 \leq \varphi \leq u \\ \varphi \text{ étagée}}} \int_{\Omega} \varphi \, d\mu \leq \int_{\Omega} v \, d\mu.$$

■

Propriété 5.13 – Limite croissante et intégrale

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, soit $(f_n)_{n \geq 1}$ une suite croissante de fonctions étagées positives convergeant simplement vers f . Alors $\lim_{n \rightarrow +\infty} \int_{\Omega} f_n \, d\mu = \int_{\Omega} f \, d\mu$.

Idée de preuve. Par monotonie positive, la suite $(\int_{\Omega} f_n \, d\mu)_n$ est croissante et, puisque $f_n \leq f$, elle est majorée par $\int_{\Omega} f \, d\mu$. Pour l'inégalité inverse, on fixe une fonction étagée positive $\varphi \leq f$ et un nombre $\alpha \in]0, 1[$. Les ensembles $E_n = \{f_n \geq \alpha\varphi\}$ croissent vers Ω ; la monotonie positive appliquée à $\alpha\varphi \mathbf{1}_{E_n} \leq f_n$, puis la continuité croissante de la mesure, permettent de faire tendre n vers l'infini, puis α vers 1.

Démonstration. Par monotonie positive,

$$f_n \leq f_{n+1} \implies \int_{\Omega} f_n \, d\mu \leq \int_{\Omega} f_{n+1} \, d\mu.$$

Ainsi la suite des intégrales est croissante ; posons

$$L := \lim_{n \rightarrow +\infty} \int_{\Omega} f_n \, d\mu \in [0, +\infty].$$

Comme $f_n \leq f$ pour tout n , la monotonie positive donne également

$$\int_{\Omega} f_n \, d\mu \leq \int_{\Omega} f \, d\mu, \quad \text{donc} \quad L \leq \int_{\Omega} f \, d\mu.$$

Montrons l'inégalité inverse. Soit

$$\varphi = \sum_{j=1}^p a_j \mathbf{1}_{A_j}$$

une fonction étagée positive telle que $0 \leq \varphi \leq f$, où $(A_j)_{1 \leq j \leq p}$ est une partition mesurable de Ω et $a_j \geq 0$. Fixons $\alpha \in]0, 1[$ et posons

$$E_n := \{f_n \geq \alpha\varphi\}.$$

Comme $f_n \uparrow f$, la suite (E_n) est croissante. De plus, pour tout $x \in \Omega$, si $\varphi(x) = 0$ alors $x \in E_n$ pour tout n ; et si $\varphi(x) > 0$, alors

$$\lim_n f_n(x) = f(x) \geq \varphi(x) > \alpha\varphi(x),$$

donc $x \in E_n$ à partir d'un certain rang. Ainsi

$$E_n \uparrow \Omega.$$

Sur E_n , on a $\alpha\varphi \leq f_n$, tandis que sur E_n^c la fonction $\alpha\varphi\mathbf{1}_{E_n}$ est nulle. Par conséquent

$$0 \leq \alpha\varphi\mathbf{1}_{E_n} \leq f_n.$$

Par monotonie positive,

$$\alpha \int_{\Omega} \varphi\mathbf{1}_{E_n} d\mu \leq \int_{\Omega} f_n d\mu \leq L.$$

Or

$$\int_{\Omega} \varphi\mathbf{1}_{E_n} d\mu = \sum_{j=1}^p a_j \mu(A_j \cap E_n).$$

Pour chaque j , $A_j \cap E_n \uparrow A_j$; par continuité croissante de la mesure,

$$\mu(A_j \cap E_n) \longrightarrow \mu(A_j).$$

La somme étant finie, on obtient

$$\int_{\Omega} \varphi\mathbf{1}_{E_n} d\mu \longrightarrow \sum_{j=1}^p a_j \mu(A_j) = \int_{\Omega} \varphi d\mu.$$

En faisant tendre n vers l'infini,

$$L \geq \alpha \int_{\Omega} \varphi d\mu.$$

Puis, comme cette inégalité vaut pour tout $\alpha \in]0, 1[$,

$$L \geq \int_{\Omega} \varphi d\mu.$$

Enfin, cette inégalité vaut pour toute fonction étagée positive $\varphi \leq f$. Le membre de gauche ne dépendant pas de φ , on prend la borne supérieure du membre de droite sur toutes les fonctions étagées positives inférieures à f :

$$L \geq \sup_{\substack{0 \leq \varphi \leq f \\ \varphi \text{ étagée}}} \int_{\Omega} \varphi d\mu = \int_{\Omega} f d\mu.$$

Avec l'inégalité opposée déjà établie, on conclut

$$\boxed{\lim_{n \rightarrow +\infty} \int_{\Omega} f_n d\mu = \int_{\Omega} f d\mu.}$$

■

Exemple 5.14

On retrouve, avec cette proposition, l'exemple du Théorème 5.4 « Lemme d'approximation » : la fonction en escalier « sous la courbe » f_n converge en croissant vers f , et son intégrale (aire des rectangles) converge vers l'aire sous la courbe de f .

5.2.3 Intégrale d'une fonction de signe quelconque

Définition 5.15 – Intégrale d'une fonction mesurable réelle

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, soit $f : \Omega \rightarrow \overline{\mathbb{R}}$ mesurable. On pose $f^+ = \max(f, 0)$, $f^- = \max(-f, 0)$ (de sorte que $f = f^+ - f^-$ et $|f| = f^+ + f^-$) : ce sont deux fonctions mesurables positives. On dit que f est μ -**intégrable** si $\int_{\Omega} f^+ d\mu < +\infty$ et $\int_{\Omega} f^- d\mu < +\infty$, et l'on définit alors

$$\int_{\Omega} f d\mu := \int_{\Omega} f^+ d\mu - \int_{\Omega} f^- d\mu.$$

On note $L^1(\Omega, \mu)$ l'ensemble des fonctions μ -intégrables sur Ω (cette notation sera reprise et généralisée aux espaces L^p , $p \geq 1$, au Chapitre 7 « Espaces L^p »).




Figure 12: Décomposition $f = f^+ - f^-$: f^+ ne retient que la partie où f est positive, f^- (ici tracée en négatif, $-f^-$) la partie où f est négative. L'intégrale de f n'a de sens que si les deux aires (positive et négative) sont finies.

Remarque 5.16

On a $|f|$ intégrable $\iff f$ intégrable (car $|f| = f^+ + f^-$ et $f^+, f^- \leq |f|$) : c'est l'analogue, pour Lebesgue, de l'intégrabilité absolue déjà rencontrée avec les séries et les intégrales impropres en licence.

Remarque 5.17 – Espérance comme intégrale de Lebesgue

Sur un espace probabilisé $(\Omega, \mathcal{T}, \mathbb{P})$, une variable aléatoire réelle est simplement une fonction mesurable $X : \Omega \rightarrow \mathbb{R}$. Dès que X est intégrable, son espérance est l'intégrale de Lebesgue de X par rapport à la mesure de probabilité :

$$\mathbb{E}(X) = \int_{\Omega} X d\mathbb{P}.$$

Cette définition contient les formules usuelles. Si X prend un nombre fini de valeurs $x_1, \dots, x_p$, alors

$$X = \sum_{k=1}^p x_k \mathbf{1}_{\{X=x_k\}} \implies \mathbb{E}(X) = \sum_{k=1}^p x_k \mathbb{P}(X = x_k).$$

Par exemple, pour un dé équilibré,

$$\mathbb{E}(X) = \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) = \frac{7}{2}.$$

Si X admet une densité f_X , on retrouvera au Chapitre 9 « Variables aléatoires réelles », grâce au Théorème 9.44 « Théorème de transfert », la formule familière

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f_X(x) dx.$$

Ainsi, le « calcul d'une espérance » est bien un cas particulier du calcul d'une intégrale de Lebesgue.

Définition 5.18 – Intégrale sur un événement, presque partout

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $f : \Omega \rightarrow \overline{\mathbb{R}}$, $A \in \mathcal{T}$. On appelle intégrale de f sur A la quantité $\int_A f d\mu := \int_{\Omega} f \cdot \mathbf{1}_A d\mu$. On dit qu'une propriété P est vraie **presque partout** (p.p.) sur Ω s'il existe $N \in \mathcal{T}$ avec $\mu(N) = 0$ tel que $P(x)$ soit vraie pour tout $x \notin N$; lorsque μ est une probabilité, on dit **presque sûrement** (p.s.).

Exemple 5.19

Sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$, la fonction $\mathbf{1}_{\mathbb{Q}}$ est nulle presque partout (puisque $\mathbb{Q}$ est négligeable pour λ), bien qu'elle ne soit égale à la fonction nulle en aucun point de $\mathbb{Q}$.

Méthode 5.20 – Calculer une intégrale de Lebesgue « à la main »

Face à une intégrale $\int_{\Omega} f d\mu$, trois cas fréquents :

1. Si f est étagée, on revient à la définition (somme finie $\sum_k x_k \mu(A_k)$).
2. Si μ est la mesure de comptage sur $\mathbb{N}$ (ou une partie de $\mathbb{R}$), $\int f d\mu$ se calcule comme une **série** $\sum_k f(k)$: l'intégrabilité de f équivaut à la convergence (absolue) de la série (cf. Exercice 5.29 « Mesure de comptage et séries »).
3. Si $\mu = \lambda$ est la mesure de Lebesgue et f est continue par morceaux, l'intégrale de Lebesgue coïncide avec l'intégrale de Riemann (généralisée) déjà connue – voir Exercice 5.21 « Riemann et Lebesgue ». On calcule alors comme en licence (primitive, IPP, changement de variable).

Exercice 5.21 – Riemann et Lebesgue

On considère $\mathbb{R}$ muni de $\mathcal{B}(\mathbb{R})$ et de la mesure de Lebesgue λ . Montrer que $\mathbf{1}_{\mathbb{Q}}$ n'est pas Riemann-intégrable sur $[0, 1]$, mais qu'elle est Lebesgue-intégrable, d'intégrale nulle.

Solution

Tout intervalle non dégénéré contenu dans $[0, 1]$ contient à la fois un rationnel et un irrationnel. Ainsi, sur chaque intervalle d'une subdivision, l'infimum de $\mathbf{1}_{\mathbb{Q}}$ vaut 0 et son supremum vaut 1. Pour toute subdivision P de $[0, 1]$,

$$L(\mathbf{1}_{\mathbb{Q}}, P) = 0, \quad U(\mathbf{1}_{\mathbb{Q}}, P) = 1.$$

Les intégrales inférieure et supérieure de Darboux sont donc respectivement 0 et 1 : $\mathbf{1}_{\mathbb{Q}}$ n'est pas Riemann-intégrable.

En revanche, $\mathbb{Q} \cap [0, 1]$ est dénombrable, donc de mesure de Lebesgue nulle. La fonction $\mathbf{1}_{\mathbb{Q}}$ est Lebesgue-mesurable et

$$\int_{[0,1]} \mathbf{1}_{\mathbb{Q}} d\lambda = \lambda(\mathbb{Q} \cap [0, 1]) = 0.$$

5.3 Propriétés de l'intégrale

Propriété 5.22 – Linéarité de l'intégrale

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré.

1. Si $f, g : \Omega \rightarrow [0, +\infty]$ sont mesurables, ou si $f, g : \Omega \rightarrow \mathbb{R}$ sont mesurables et intégrables, alors $f + g$ est respectivement positive mesurable ou intégrable, et

$$\int_{\Omega} (f + g) d\mu = \int_{\Omega} f d\mu + \int_{\Omega} g d\mu.$$

2. Si $f \geq 0$ est mesurable et $\lambda \geq 0$, ou si $f : \Omega \rightarrow \mathbb{R}$ est intégrable et $\lambda \in \mathbb{R}$, alors λf est respectivement positive mesurable ou intégrable, et

$$\int_{\Omega} \lambda f d\mu = \lambda \int_{\Omega} f d\mu.$$

3. Si $A, B \in \mathcal{T}$ sont disjoints et si f est positive mesurable, ou si $f : \Omega \rightarrow \mathbb{R}$ est intégrable, alors

$$\int_{A \cup B} f d\mu = \int_A f d\mu + \int_B f d\mu.$$

Idée de preuve. On établit d'abord les formules pour les fonctions étagées positives, par calcul direct sur une partition commune. Le Théorème 5.4 « Lemme d'approximation » et la Proposition 5.13 « Limite croissante et intégrale » permettent ensuite de passer aux fonctions mesurables positives. Enfin, pour des fonctions intégrables à valeurs réelles, on utilise $f = f^+ - f^-$; l'intégrabilité des sommes et des multiples scalaires se vérifie directement à partir des inégalités sur les parties positive et négative.

Démonstration. Traitons d'abord l'additivité.

Étape 1 : f, g étagées positives. Écrivons $f = \sum_{i=1}^p x_i \mathbf{1}_{A_i}$ et $g = \sum_{j=1}^q y_j \mathbf{1}_{B_j}$, avec $(A_i)_i$ et $(B_j)_j$ des partitions mesurables de Ω . La famille $(A_i \cap B_j)_{i,j}$ raffine les deux partitions et

$$f + g = \sum_{i,j} (x_i + y_j) \mathbf{1}_{A_i \cap B_j}.$$

Par définition de l'intégrale d'une fonction étagée positive,

$$\int_{\Omega} (f + g) d\mu = \sum_{i,j} (x_i + y_j) \mu(A_i \cap B_j) = \sum_i x_i \mu(A_i) + \sum_j y_j \mu(B_j),$$

car $\sum_j \mu(A_i \cap B_j) = \mu(A_i)$ et, symétriquement, $\sum_i \mu(A_i \cap B_j) = \mu(B_j)$. C'est exactement

$$\int_{\Omega} (f + g) d\mu = \int_{\Omega} f d\mu + \int_{\Omega} g d\mu.$$

Étape 2 : f, g mesurables positives. Par le Théorème 5.4 « Lemme d'approximation », choisissons $f_n \uparrow f$ et $g_n \uparrow g$, avec f_n, g_n étagées positives. Alors $f_n + g_n \uparrow f + g$. Par la Proposition 5.13 « Limite croissante et intégrale » et l'Étape 1,

$$\int_{\Omega} (f + g) d\mu = \lim_n \int_{\Omega} (f_n + g_n) d\mu = \lim_n \left(\int_{\Omega} f_n d\mu + \int_{\Omega} g_n d\mu \right) = \int_{\Omega} f d\mu + \int_{\Omega} g d\mu.$$

Nous utiliserons aussi la monotonie positive établie lors de la définition de l'intégrale : si $0 \leq u \leq v$ sont mesurables positives, alors

$$\int_{\Omega} u d\mu \leq \int_{\Omega} v d\mu.$$

Étape 3 : f, g intégrables à valeurs réelles. Posons $h = f + g$. Les inégalités

$$h^+ \leq f^+ + g^+, \quad h^- \leq f^- + g^-$$

et l'Étape 2 montrent que les deux fonctions de droite ont une intégrale finie. Par la comparaison précédente, $\int h^+ d\mu < +\infty$ et $\int h^- d\mu < +\infty$: h est donc intégrable. De l'identité

$$h^+ + f^- + g^- = h^- + f^+ + g^+$$

et de l'additivité déjà établie pour les fonctions positives, on déduit

$$\int h^+ d\mu + \int f^- d\mu + \int g^- d\mu = \int h^- d\mu + \int f^+ d\mu + \int g^+ d\mu.$$

Toutes ces quantités sont finies ; on peut donc les réarranger et obtenir

$$\int_{\Omega} (f + g) d\mu = \int_{\Omega} f d\mu + \int_{\Omega} g d\mu.$$

L'homogénéité se montre de la même façon. Pour une fonction étagée positive et $\lambda \geq 0$, elle est immédiate dans la somme définissant l'intégrale ; le passage aux fonctions positives mesurables se fait avec la Proposition 5.13 « Limite croissante et intégrale ». Si $f : \Omega \rightarrow \mathbb{R}$ est intégrable et $\lambda < 0$, on utilise $(\lambda f)^+ = (-\lambda)f^-$ et $(\lambda f)^- = (-\lambda)f^+$, ce qui donne à la fois l'intégrabilité de λf et la formule. Enfin, le point 3 résulte de l'additivité appliquée à $f\mathbf{1}_A$ et $f\mathbf{1}_B$. ■

Propriété 5.23 – Monotonie

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré.

1. Si $f : \Omega \rightarrow [0, +\infty]$ est mesurable, alors $\int_{\Omega} f d\mu \geq 0$.
2. Si $0 \leq g \leq f$ avec $f, g : \Omega \rightarrow [0, +\infty]$ mesurables, ou si $f, g : \Omega \rightarrow \mathbb{R}$ sont intégrables et $g \leq f$, alors

$$\int_{\Omega} g d\mu \leq \int_{\Omega} f d\mu.$$

3. Si f et g sont deux fonctions mesurables positives, ou deux fonctions intégrables, et si $f = g$ presque partout, alors

$$\int_{\Omega} f d\mu = \int_{\Omega} g d\mu.$$

Démonstration. *Point 1.* Si $f \geq 0$ est étagée, son intégrale est une somme de termes positifs. Pour $f \geq 0$ mesurable quelconque, $\int f d\mu$ est la borne supérieure d'intégrales de fonctions étagées positives : elle est donc positive.

Point 2, cas positif. C'est exactement la propriété de monotonie positive établie lors de la définition de l'intégrale des fonctions mesurables positives.

Point 2, cas intégrable réel. Si $f, g : \Omega \rightarrow \mathbb{R}$ sont intégrables et $f \geq g$, la Proposition 5.22 « Linéarité de l'intégrale » montre que $h := f - g$ est intégrable. Comme $h \geq 0$, le point 1 donne $\int h d\mu \geq 0$. Par linéarité,

$$\int_{\Omega} f d\mu - \int_{\Omega} g d\mu = \int_{\Omega} h d\mu \geq 0.$$

Point 3, cas positif. Supposons $f, g \geq 0$ et $f = g$ sur N^c , avec $\mu(N) = 0$. Soit $\varphi = \sum_{j=1}^p a_j \mathbf{1}_{A_j}$ étagée positive, $\varphi \leq f$. Alors $\varphi \mathbf{1}_{N^c} \leq g$ et

$$\int_{\Omega} \varphi \mathbf{1}_{N^c} d\mu = \sum_{j=1}^p a_j \mu(A_j \cap N^c) = \sum_{j=1}^p a_j \mu(A_j) = \int_{\Omega} \varphi d\mu,$$

car $\mu(A_j \cap N) = 0$. Posons $\psi := \varphi \mathbf{1}_{N^c}$. Pour φ fixée, ψ est étagée positive et $\psi \leq g$; en prenant d'abord la borne supérieure, dans le membre de droite, sur toutes les fonctions étagées positives inférieures à g , on obtient

$$\int_{\Omega} \varphi d\mu = \int_{\Omega} \psi d\mu \leq \sup_{\substack{0 \leq \eta \leq g \\ \eta \text{ étagée}}} \int_{\Omega} \eta d\mu = \int_{\Omega} g d\mu.$$

Cette inégalité valant pour toute fonction étagée positive $\varphi \leq f$, on prend ensuite la borne supérieure du membre de gauche sur toutes ces fonctions :

$$\int_{\Omega} f d\mu = \sup_{\substack{0 \leq \varphi \leq f \\ \varphi \text{ étagée}}} \int_{\Omega} \varphi d\mu \leq \int_{\Omega} g d\mu.$$

L'inégalité inverse s'obtient en échangeant f et g .

Si f, g sont intégrables et égales presque partout, alors $f^+ = g^+$ et $f^- = g^-$ presque partout. Le cas positif appliqué à ces quatre fonctions donne l'égalité des intégrales de leurs parties positive et négative, donc $\int f d\mu = \int g d\mu$. ■

Propriété 5.24 – Espérance et nullité presque partout

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $f : \Omega \rightarrow [0, +\infty]$ mesurable. Alors

$$\int_{\Omega} f d\mu = 0 \iff f = 0 \text{ presque partout.}$$

Démonstration. Supposons $\int_{\Omega} f d\mu = 0$. Pour $n \geq 1$, posons

$$A_n := \{f \geq 1/n\}.$$

La fonction étagée positive $\frac{1}{n}\mathbf{1}_{A_n}$ est majorée par f . Par définition de l'intégrale d'une fonction positive,

$$0 \leq \frac{1}{n}\mu(A_n) = \int_{\Omega} \frac{1}{n}\mathbf{1}_{A_n} d\mu \leq \int_{\Omega} f d\mu = 0.$$

Donc $\mu(A_n) = 0$ pour tout n . Or

$$\{f > 0\} = \bigcup_{n \geq 1} A_n,$$

donc $\mu(f > 0) = 0$ par σ -sous-additivité : $f = 0$ presque partout.

Réciproquement, si $f = 0$ presque partout, le point 3 de la Proposition 5.23 « Monotonie », appliqué à f et à la fonction nulle, donne

$$\int_{\Omega} f d\mu = \int_{\Omega} 0 d\mu = 0.$$

■

Propriété 5.25 – Intégrabilité

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $f, g : \Omega \rightarrow \overline{\mathbb{R}}$ mesurables. Alors :

1. f est μ -intégrable si et seulement si $|f|$ l'est ;
2. si f est μ -intégrable, alors f est finie presque partout ;
3. si $|f| \leq g$ avec g intégrable, alors f est intégrable ;
4. si f, g sont intégrables, elles admettent des versions à valeurs réelles presque partout ; la somme de telles versions est intégrable.

Idée de preuve. Les points 1, 3 et 4 reposent sur $|f| = f^+ + f^-$, sur l'inégalité triangulaire et sur la monotonie de l'intégrale. Pour le point 2, on applique directement la définition de l'intégrale aux fonctions étagées $n\mathbf{1}_{\{|f| \geq n\}}$.

Démonstration. *Point 1.* On a $|f| = f^+ + f^-$. Par linéarité pour les fonctions positives (Proposition 5.22 « Linéarité de l'intégrale »),

$$\int_{\Omega} |f| d\mu = \int_{\Omega} f^+ d\mu + \int_{\Omega} f^- d\mu.$$

Cette somme de deux quantités positives est finie si et seulement si chacune l'est. C'est exactement l'équivalence entre l'intégrabilité de $|f|$ et celle de f .

Point 2. Supposons f intégrable. Par le point 1,

$$C := \int_{\Omega} |f| d\mu < +\infty.$$

Pour $n \geq 1$, posons $A_n := \{|f| \geq n\}$. Comme $n\mathbf{1}_{A_n} \leq |f|$, la monotonie (Proposition 5.23 « Monotonie ») donne

$$n\mu(A_n) = \int_{\Omega} n\mathbf{1}_{A_n} d\mu \leq C, \quad \text{donc} \quad \mu(A_n) \leq \frac{C}{n}.$$

La suite (A_n) est décroissante et $\mu(A_1) \leq C < +\infty$. Par continuité décroissante de la mesure (Proposition 3.20 « Continuité croissante et décroissante »),

$$\mu(|f| = +\infty) = \mu\left(\bigcap_{n \geq 1} A_n\right) = \lim_{n \rightarrow +\infty} \mu(A_n) = 0.$$

Ainsi f est finie presque partout.

Point 3. Si $|f| \leq g$ avec g intégrable, alors $g \geq 0$ et, par monotonie,

$$\int_{\Omega} |f| d\mu \leq \int_{\Omega} g d\mu < +\infty.$$

Donc $|f|$, puis f par le point 1, est intégrable.

Point 4. Par le point 2, les ensembles où f ou g ne sont pas finis sont négligeables. En remplaçant f et g par 0 sur leur union, on obtient des versions $\tilde{f}, \tilde{g} : \Omega \rightarrow \mathbb{R}$ qui leur sont égales presque partout. Les parties positive et négative de $\tilde{f}$ sont presque partout égales à celles de f ; le cas positif du point 3 de la Proposition 5.23 « Monotonie » montre donc qu'elles ont les mêmes intégrales. Ainsi $\tilde{f}$ est intégrable et $\int \tilde{f} d\mu = \int f d\mu$; de même pour g . La Proposition 5.22 « Linéarité de l'intégrale », appliquée aux versions réelles $\tilde{f}$ et $\tilde{g}$, montre alors que $\tilde{f} + \tilde{g}$ est intégrable. On peut aussi le voir directement par

$$|\tilde{f} + \tilde{g}| \leq |\tilde{f}| + |\tilde{g}|$$

et le point 3, puisque $|\tilde{f}| + |\tilde{g}|$ est intégrable par linéarité des fonctions positives. ■

Méthode 5.26 – Justifier l'intégrabilité d'une fonction

Pour montrer que f est μ -intégrable, la démarche la plus fréquente est :

1. Majorer $|f|$ par une fonction $g \geq 0$ dont on sait déjà qu'elle est intégrable (Proposition 5.25 « Intégrabilité », point 3) : c'est le réflexe le plus rapide.
2. Sinon, calculer directement $\int |f| d\mu$ (croissances comparées pour Lebesgue, critère de Riemann ou comparaison série/intégrale pour la mesure de comptage).

Exercice 5.27 – Majoration d'une intégrale

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $f : \Omega \rightarrow \mathbb{R}$ mesurable, $A \in \mathcal{T}$ de mesure finie, $m, M \in \mathbb{R}$ tels que $m \leq f \leq M$ sur A . Montrer que $m\mu(A) \leq \int_A f d\mu \leq M\mu(A)$.

Solution

On a $m\mathbf{1}_A \leq f\mathbf{1}_A \leq M\mathbf{1}_A$; par monotonie et linéarité de l'intégrale (Propositions Proposition 5.22 « Linéarité de l'intégrale » et Proposition 5.23 « Monotonie »), et comme $\mu(A) < +\infty$, on obtient l'encadrement annoncé.

5.4 Les trois théorèmes de convergence

Cette section regroupe les trois résultats les plus utilisés de toute la théorie de l'intégration : ils permettent d'échanger limite et intégrale sous des hypothèses raisonnables. Nous en donnons ci-dessous les démonstrations complètes.

Théorème 5.28 – Théorème de convergence monotone

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, soit $(f_n)_{n \geq 1}$ une suite **croissante** de fonctions mesurables $\Omega \rightarrow [0, +\infty]$, convergeant simplement vers f . Alors f est mesurable et

$$\int_{\Omega} f \, d\mu = \lim_{n \rightarrow +\infty} \int_{\Omega} f_n \, d\mu \quad (\text{égalité dans } [0, +\infty]).$$

Version « série » : pour $(g_n)_{n \geq 1}$ mesurables positives, $\int_{\Omega} \sum_{n \geq 1} g_n \, d\mu = \sum_{n \geq 1} \int_{\Omega} g_n \, d\mu$.

Idée de preuve. On compare d'abord les intégrales de f_n à celle de f . Pour l'inégalité inverse, on fixe une fonction étagée positive $\varphi \leq f$ et $\alpha \in]0, 1[$, puis on considère les ensembles $E_n = \{f_n \geq \alpha\varphi\}$, qui croissent vers Ω . La continuité croissante de la mesure permet alors de faire tendre n vers l'infini.

Démonstration. La limite $f = \sup_n f_n$ est mesurable par la Proposition 4.25 « Stabilité par sup et inf dénombrables ». Comme $f_n \leq f$, la Proposition 5.23 « Monotonie » donne

$$\int_{\Omega} f_n \, d\mu \leq \int_{\Omega} f \, d\mu.$$

La suite des intégrales est croissante ; posons

$$L := \lim_{n \rightarrow +\infty} \int_{\Omega} f_n \, d\mu.$$

On a donc déjà

$$L \leq \int_{\Omega} f \, d\mu.$$

Montrons l'inégalité inverse. Soit

$$\varphi = \sum_{j=1}^p a_j \mathbf{1}_{A_j}$$

une fonction étagée positive telle que $0 \leq \varphi \leq f$, et fixons $\alpha \in]0, 1[$. Posons

$$E_n := \{f_n \geq \alpha\varphi\}.$$

Comme $f_n \uparrow f$, on a $E_n \uparrow \Omega$. Sur E_n ,

$$0 \leq \alpha\varphi \mathbf{1}_{E_n} \leq f_n,$$

donc, par monotonie,

$$\alpha \int_{\Omega} \varphi \mathbf{1}_{E_n} \, d\mu \leq \int_{\Omega} f_n \, d\mu \leq L.$$

Or

$$\int_{\Omega} \varphi \mathbf{1}_{E_n} \, d\mu = \sum_{j=1}^p a_j \mu(A_j \cap E_n).$$

Pour chaque j , $A_j \cap E_n \uparrow A_j$; la Proposition 3.20 « Continuité croissante et décroissante » donne donc

$$\mu(A_j \cap E_n) \longrightarrow \mu(A_j).$$

La somme étant finie,

$$\int_{\Omega} \varphi \mathbf{1}_{E_n} \, d\mu \longrightarrow \int_{\Omega} \varphi \, d\mu.$$

En faisant tendre n vers $+\infty$, puis α vers 1, on obtient

$$L \geq \int_{\Omega} \varphi \, d\mu.$$

Cette inégalité étant vraie pour toute fonction étagée positive $\varphi \leq f$, la définition de l'intégrale d'une fonction mesurable positive donne

$$L \geq \int_{\Omega} f \, d\mu.$$

Avec l'inégalité opposée, on conclut

$$\boxed{\int_{\Omega} f \, d\mu = \lim_{n \rightarrow +\infty} \int_{\Omega} f_n \, d\mu.}$$

Pour la version « série », on pose $S_N := \sum_{k=1}^N g_k$. Alors $S_N \uparrow \sum_{k \geq 1} g_k$; le résultat précédent et la Proposition 5.22 « Linéarité de l'intégrale » donnent

$$\int_{\Omega} \sum_{k \geq 1} g_k \, d\mu = \lim_{N \rightarrow +\infty} \int_{\Omega} S_N \, d\mu = \lim_{N \rightarrow +\infty} \sum_{k=1}^N \int_{\Omega} g_k \, d\mu = \sum_{k \geq 1} \int_{\Omega} g_k \, d\mu.$$

■




Figure 13: Convergence monotone : la suite (f_n) croît simplement vers f , donc l'aire sous f_n croît vers l'aire sous f (aucune hypothèse de domination n'est nécessaire, contrairement au Théorème 5.33 « Théorème de convergence dominée »).

Exercice 5.29 – Mesure de comptage et séries

On munit $(\mathbb{R}, \mathcal{P}(\mathbb{R}))$ de la mesure $\mu(A) = \text{Card}(A \cap \mathbb{N})$ (mesure de comptage sur $\mathbb{N}$).

1. Justifier que toute fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ est mesurable pour cette tribu.

2. Calculer $\int_{\mathbb{R}} e^{-x} \, d\mu$ puis $\int_{\mathbb{R}} \frac{1}{(1+x)^2} \, d\mu$.

Solution

1. Pour tout $B \subset \mathbb{R}$, $f^{-1}(B) \subset \mathbb{R}$, donc $f^{-1}(B) \in \mathcal{P}(\mathbb{R})$: toute application est mesurable pour la tribu $\mathcal{P}(\mathbb{R})$.

2. Puisque $\mathbb{R} \setminus \mathbb{N}$ est de mesure nulle pour μ , on a $\int_{\mathbb{R}} f \, d\mu = \int_{\mathbb{N}} f \, d\mu = \sum_{n \in \mathbb{N}} f(n)$ (théorème de convergence monotone, version « série », Théorème 5.28 « Théorème de convergence monotone »). Ainsi $\int_{\mathbb{R}} e^{-x} \, d\mu = \sum_{n \in \mathbb{N}} e^{-n} = \frac{1}{1 - e^{-1}}$ (série géométrique), et $\int_{\mathbb{R}} \frac{1}{(1+x)^2} \, d\mu =$

$$\sum_{n \in \mathbb{N}} \frac{1}{(n+1)^2} = \frac{\pi^2}{6}.$$

Exemple 5.30 – Sommation par paquets d’une série double

Le Théorème 5.28 « Théorème de convergence monotone » sous sa forme « série », combiné à la mesure de comptage sur $\mathbb{N}$ (Exercice 5.29 « Mesure de comptage et séries »), redonne exactement le résultat de licence : pour une famille double $(u_{n,k})$ à termes positifs, $\sum_n \sum_k u_{n,k} = \sum_k \sum_n u_{n,k}$ (sommation par paquets), sans aucune condition supplémentaire tant que les termes sont positifs.

Théorème 5.31 – Lemme de Fatou

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $(f_n)_{n \geq 1}$ mesurables à valeurs dans $[0, +\infty]$. Alors

$$\int_{\Omega} \liminf_{n \geq 1} f_n d\mu \leq \liminf_{n \geq 1} \int_{\Omega} f_n d\mu.$$

Démonstration. Pour $n \geq 1$, posons $g_n = \inf_{m \geq n} f_m \geq 0$. La suite (g_n) est croissante (l’infimum porte sur un ensemble d’indices de plus en plus petit) et converge simplement, par définition, vers $\liminf_n f_n$. De plus, pour tout $m \geq n$, $g_n \leq f_m$ (par définition de l’infimum), donc par monotonie de l’intégrale (Proposition 5.23 « Monotonie »),

$$\int_{\Omega} g_n d\mu \leq \int_{\Omega} f_m d\mu \quad \text{pour tout } m \geq n.$$

Pour n fixé, le membre de gauche ne dépend pas de m . On peut donc prendre la borne inférieure du membre de droite sur tous les $m \geq n$, ce qui donne

$$\int_{\Omega} g_n d\mu \leq \inf_{m \geq n} \int_{\Omega} f_m d\mu.$$

En passant à la limite $n \rightarrow +\infty$: le membre de gauche tend vers $\int_{\Omega} \liminf_n f_n d\mu$ par le Théorème 5.28 « Théorème de convergence monotone » (la suite (g_n) étant croissante et positive) ; le membre de droite tend, par définition, vers $\liminf_n \int_{\Omega} f_n d\mu$. On obtient bien

$$\int_{\Omega} \liminf_n f_n d\mu \leq \liminf_n \int_{\Omega} f_n d\mu.$$

■

Attention 5.32 – Le lemme de Fatou n’est qu’une inégalité

Il n’y a en général *pas* égalité dans le Théorème 5.31 « Lemme de Fatou » : une partie de la « masse » peut s’échapper à la limite. Exemple classique sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$: $f_n = \frac{1}{2n} \mathbf{1}_{[-n,n]}$. Chaque $\int_{\mathbb{R}} f_n d\lambda = 1$, donc $\lim_n \int f_n d\lambda = 1$; mais (f_n) converge simplement vers la fonction nulle (pour x fixé, $f_n(x) = 0$ dès que $n > |x|$), d’intégrale nulle. On a bien $0 = \int \liminf f_n d\lambda < \liminf \int f_n d\lambda = 1$: l’aire « part à l’infini » (masse qui s’étale de plus en plus, hauteur qui tend vers 0) sans que la limite ponctuelle ne la voie.




Figure 14: Contre-exemple à l’égalité dans le Théorème 5.31 « Lemme de Fatou » : les rectangles $f_n = \frac{1}{2n} \mathbf{1}_{[-n,n]}$ ont tous une aire égale à 1, mais s’aplatissent indéfiniment ; la limite simple est la fonction nulle.

Théorème 5.33 – Théorème de convergence dominée

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $(f_n)_{n \geq 1}$ mesurables $\Omega \rightarrow \overline{\mathbb{R}}$, telles que :

1. (f_n) converge simplement presque partout vers f ;
2. (**hypothèse de domination**) il existe $g : \Omega \rightarrow [0, +\infty]$ intégrable telle que $|f_n| \leq g$ pour tout n .

Alors f est intégrable et $\int_{\Omega} f d\mu = \lim_{n \rightarrow +\infty} \int_{\Omega} f_n d\mu$.

Démonstration. *Intégrabilité de f .* Par domination, $|f_n| \leq g$ pour tout n , donc en passant à la limite simple (p.p.), $|f| \leq g$ également. Comme g est intégrable, f l'est par la Proposition 5.25 « Intégrabilité » (point 3).

Convergence des intégrales. Les suites $(g - f_n)_{n \geq 1}$ et $(g + f_n)_{n \geq 1}$ sont positives (par domination) et mesurables. Le Théorème 5.31 « Lemme de Fatou » donne :

$$\int_{\Omega} \liminf_n (g - f_n) d\mu \leq \liminf_n \int_{\Omega} (g - f_n) d\mu, \quad \int_{\Omega} \liminf_n (g + f_n) d\mu \leq \liminf_n \int_{\Omega} (g + f_n) d\mu.$$

Comme (f_n) converge p.p. vers f , $\liminf_n (g - f_n) = g - f$ et $\liminf_n (g + f_n) = g + f$ (p.p.). En développant par linéarité (licite, g et les f_n étant intégrables) et en utilisant $\liminf_n (-a_n) = -\limsup_n a_n$ pour la première inégalité :

$$\int_{\Omega} g d\mu - \int_{\Omega} f d\mu \leq \int_{\Omega} g d\mu - \limsup_n \int_{\Omega} f_n d\mu, \quad \int_{\Omega} g d\mu + \int_{\Omega} f d\mu \leq \int_{\Omega} g d\mu + \liminf_n \int_{\Omega} f_n d\mu.$$

Comme $\int_{\Omega} g d\mu < +\infty$, on peut le simplifier des deux côtés de chaque inégalité, ce qui donne

$$\limsup_n \int_{\Omega} f_n d\mu \leq \int_{\Omega} f d\mu \leq \liminf_n \int_{\Omega} f_n d\mu.$$

Or on a toujours $\liminf_n \int_{\Omega} f_n d\mu \leq \limsup_n \int_{\Omega} f_n d\mu$ (rappel sur les suites réelles) : les trois quantités ci-dessus sont donc égales, ce qui montre à la fois que $(\int_{\Omega} f_n d\mu)_n$ converge et que sa limite vaut $\int_{\Omega} f d\mu$. ■




Figure 15: Convergence dominée : les f_n oscillent de plus en plus, mais restent toujours coincées entre $-g$ et g (aire finie) ; cette domination uniforme empêche la « fuite de masse » observée pour le Théorème 5.31 « Lemme de Fatou ».

Méthode 5.34 – Appliquer le théorème de convergence dominée

Pour calculer une limite $\lim_n \int_{\Omega} f_n d\mu$, la méthode-type est :

1. Identifier la limite simple (p.p.) f de (f_n) , souvent en fixant x et en étudiant $f_n(x)$ quand $n \rightarrow +\infty$;
2. Trouver une fonction dominante g , **indépendante de n** , intégrable, avec $|f_n| \leq g$ pour tout n (une majoration grossière suffit, du type $|f_n(x)| \leq \frac{C}{1+x^2}$ ou $|f_n| \leq \mathbf{1}_{[a,b]} \times \text{constante}$) ;
3. Conclure $\lim_n \int f_n d\mu = \int f d\mu = \int (\lim_n f_n) d\mu$.

L'étape la plus fréquemment oubliée est de vérifier que g ne dépend pas de n : une domination $|f_n| \leq g_n$ où g_n dépend de n ne permet *pas* de conclure – **sauf** si (g_n) elle-même vérifie certaines hypothèses supplémentaires (voir la Remarque 5.35 « Une hypothèse de domination plus faible : le théorème de convergence dominée généralisé »).

Remarque 5.35 – Une hypothèse de domination plus faible : le théorème de convergence dominée généralisé

On peut affaiblir l'hypothèse de domination du Théorème 5.33 « Théorème de convergence dominée » en autorisant une fonction dominante **qui dépend de n** , à condition qu'elle converge simplement (p.p.) et en intégrale vers une limite finie. Précisément : soient $(f_n)_{n \geq 1}$ mesurables convergeant p.p. vers f , et $(g_n)_{n \geq 1}$ mesurables positives, intégrables, telles que :

1. $|f_n| \leq g_n$ p.p., pour tout n ;
2. (g_n) converge p.p. vers une fonction g ;
3. $\int_{\Omega} g_n d\mu \xrightarrow{n \rightarrow +\infty} \int_{\Omega} g d\mu < +\infty$.

Alors f est intégrable et $\int_{\Omega} f_n d\mu \rightarrow \int_{\Omega} f d\mu$.

Le théorème de convergence dominée usuel (Théorème 5.33 « Théorème de convergence dominée ») est exactement le cas particulier $g_n = g$ pour tout n (auquel cas les hypothèses 2 et 3 sont triviales). La preuve de cette version généralisée reprend *mot pour mot* celle du Théorème 5.33 « Théorème de convergence dominée », en appliquant le Théorème 5.31 « Lemme de Fatou » aux suites positives $(g_n + f_n)_n$ et $(g_n - f_n)_n$: elle est proposée en exercice (TD, Chapitre 5 « Intégrale de Lebesgue »).

Exercice 5.36 – Application du théorème de convergence dominée

Pour $n \geq 1$, on pose $f_n : x \mapsto (\sin(1/x))^n \mathbf{1}_{]0,1[}(|x|)$ sur $\mathbb{R}$ (et $f_n(x) = 0$ si $|x| \geq 1$ ou $x = 0$). Montrer que $\int_{\mathbb{R}} f_n d\lambda \rightarrow 0$.

Solution

On a $|f_n| \leq \mathbf{1}_{[-1,1]}$, fonction intégrable indépendante de n : la domination est vérifiée. Pour la limite simple, si $|\sin(1/x)| < 1$ (ce qui est le cas sauf pour un ensemble dénombrable, donc négligeable, de valeurs de x), $f_n(x) \rightarrow 0$ comme suite géométrique de raison < 1 en valeur absolue. Par le Théorème 5.33 « Théorème de convergence dominée », $\int_{\mathbb{R}} f_n d\lambda \rightarrow \int_{\mathbb{R}} 0 d\lambda = 0$.

Exercice 5.37 – Une limite sans domination : le lemme de Fatou seul

On pose, sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$, $f_n = \mathbf{1}_{[n, +\infty[}$. Montrer que (f_n) converge simplement vers 0, mais que $\int_{\mathbb{R}} f_n d\lambda \not\rightarrow 0$. Pourquoi le Théorème 5.33 « Théorème de convergence dominée » ne s'applique-t-il pas ?

Solution

Pour x fixé, $f_n(x) = 0$ dès que $n > x$: la suite converge simplement vers 0. Pourtant $\int_{\mathbb{R}} f_n d\lambda = \lambda([n, +\infty[) = +\infty$ pour tout n : la suite des intégrales est constante égale à $+\infty$, elle ne tend donc pas vers 0. Il ne peut exister de fonction dominante intégrable g avec $f_n \leq g$ pour tout n , car cela forcerait $g = 1$ sur $[n, +\infty[$ pour tout n , donc sur $\mathbb{R}^+$ tout entier, ce qui rend g non intégrable.

5.5 Intégrales dépendant d'un paramètre

Ce dernier paragraphe donne deux applications très utiles du Théorème 5.33 « Théorème de convergence dominée » : elles permettent de justifier la continuité, puis la dérivabilité, d'une fonction définie comme une intégrale dépendant d'un paramètre – un outil de calcul omniprésent en analyse (transformée de Fourier, transformée de Laplace, fonction Gamma d'Euler, etc.), et que l'on retrouvera plus loin dans ce livret pour étudier les fonctions caractéristiques de variables aléatoires (Chapitre 12 « Vecteurs aléatoires gaussiens »).

Théorème 5.38 – Continuité sous le signe intégral

Soit $(E, \|\cdot\|)$ un espace vectoriel normé, $U \subset E$, $u_0 \in U$, $f : U \times \Omega \rightarrow \mathbb{R}$ telle que :

1. pour tout $u \in U$, $x \mapsto f(u, x)$ est mesurable ;
2. pour μ -presque tout x , $u \mapsto f(u, x)$ est continue en u_0 ;
3. (domination) il existe $g \in L^1(\Omega, \mu)$ positive telle que $|f(u, x)| \leq g(x)$ pour tout $u \in U$, μ -p.p.

Alors $F(u) := \int_{\Omega} f(u, x) d\mu(x)$ est bien définie pour tout $u \in U$, et continue en u_0 .

Démonstration. L'hypothèse (3) montre que $x \mapsto f(u, x)$ est intégrable pour tout u (dominée par $g \in L^1$), donc $F(u)$ est bien définie. Soit $(u_n)_{n \geq 1}$ une suite de U convergeant vers u_0 (pour la norme $\|\cdot\|$). Par l'hypothèse (2), $f(u_n, x) \rightarrow f(u_0, x)$ pour μ -presque tout x ; par l'hypothèse (3), $|f(u_n, x)| \leq g(x)$ pour tout n , avec g intégrable, indépendante de n . Le Théorème 5.33 « Théorème de convergence dominée » s'applique donc à la suite $(f(u_n, \cdot))_n$ et donne $F(u_n) = \int_{\Omega} f(u_n, x) d\mu(x) \rightarrow \int_{\Omega} f(u_0, x) d\mu(x) = F(u_0)$. Ceci étant vrai pour toute suite $u_n \rightarrow u_0$, F est continue en u_0 (caractérisation séquentielle de la continuité, valable dans tout espace vectoriel normé – ou plus généralement métrique). ■

Exemple 5.39 – Continuité de la fonction Gamma d'Euler

Pour $s > 0$, on pose $\Gamma(s) := \int_0^{+\infty} x^{s-1} e^{-x} dx$ (intégrale bien définie, cf. Chapitre 4 « Fonctions mesurables »). Montrons que Γ est continue sur $]0, +\infty[$. Fixons $s_0 > 0$ et $[a, b] \subset]0, +\infty[$ un segment contenant s_0 : pour $s \in [a, b]$ et $x > 0$, $f(s, x) := x^{s-1} e^{-x}$ vérifie $|f(s, x)| \leq g(x) := (x^{a-1} + x^{b-1})e^{-x}$, une fonction intégrable sur $]0, +\infty[$ (Chapitre 4 « Fonctions mesurables », intégrale de référence) et indépendante de s . Le Théorème 5.38 « Continuité sous le signe intégral » (avec $U = [a, b]$) donne la continuité de Γ en s_0 ; ceci pour tout $s_0 > 0$, Γ est donc continue sur $]0, +\infty[$.

Théorème 5.40 – Dérivabilité sous le signe intégral

Soit $I \subset \mathbb{R}$ un intervalle ouvert, $f : I \times \Omega \rightarrow \mathbb{R}$ telle que :

1. pour tout $u \in I$, $x \mapsto f(u, x)$ est dans $L^1(\Omega, \mu)$;
2. pour μ -presque tout x , $u \mapsto f(u, x)$ est dérivable sur I tout entier, de dérivée notée $\frac{\partial f}{\partial u}(u, x)$;
3. (domination) il existe $g \in L^1(\Omega, \mu)$ positive telle que $|\frac{\partial f}{\partial u}(u, x)| \leq g(x)$ pour tout $u \in I$, μ -p.p.

Alors $F(u) := \int_{\Omega} f(u, x) d\mu(x)$ est dérivable sur I tout entier, de dérivée $F'(u) = \int_{\Omega} \frac{\partial f}{\partial u}(u, x) d\mu(x)$ pour tout $u \in I$.

Démonstration. Fixons $u_0 \in I$ et montrons que F est dérivable en u_0 , de la dérivée annoncée. Soit $(u_n)_{n \geq 1}$ une suite de $I \setminus \{u_0\}$ convergeant vers u_0 . Posons $\varphi_n(x) := \frac{f(u_n, x) - f(u_0, x)}{u_n - u_0}$.

Par l'hypothèse (2) (dérivabilité en particulier au point u_0), $\varphi_n(x) \rightarrow \frac{\partial f}{\partial u}(u_0, x)$ pour μ -presque tout x . Par le théorème des accroissements finis appliqué à $u \mapsto f(u, x)$ sur l'intervalle d'extrémités u_0, u_n (inclus dans I), il existe $\theta_n(x)$ strictement entre u_0 et u_n tel que $\varphi_n(x) = \frac{\partial f}{\partial u}(\theta_n(x), x)$; comme $\theta_n(x) \in I$, l'hypothèse (3) donne $|\varphi_n(x)| = \left| \frac{\partial f}{\partial u}(\theta_n(x), x) \right| \leq g(x)$ pour tout n , μ -p.p., avec $g \in L^1$ indépendante de n . Le Théorème 5.33 « Théorème de convergence dominée » s'applique :

$$\lim_{n \rightarrow +\infty} \frac{F(u_n) - F(u_0)}{u_n - u_0} = \lim_{n \rightarrow +\infty} \int_{\Omega} \varphi_n(x) d\mu(x) = \int_{\Omega} \frac{\partial f}{\partial u}(u_0, x) d\mu(x).$$

Ceci étant vrai pour toute suite $u_n \rightarrow u_0$ ($u_n \neq u_0$), F est dérivable en u_0 avec la dérivée annoncée. Ceci pour tout $u_0 \in I$, F est donc dérivable sur I tout entier. ■

Remarque 5.41 – Une version affaiblie, localisée en un point

On peut affaiblir les hypothèses (2)-(3) ci-dessus, valables sur tout I , en des versions seulement **ponctuelles en un point** $u_0 \in I : u \mapsto f(u, x)$ dérivable en u_0 (sans supposer la dérivabilité ailleurs sur I), et $|f(u, x) - f(u_0, x)| \leq g(x)|u - u_0|$ pour tout $u \in I$, μ -p.p. (une domination du taux d'accroissement, plutôt que de la dérivée elle-même). La même démonstration (sans le détour par le théorème des accroissements finis, puisque cette hypothèse borne directement φ_n) montre alors que F est dérivable en ce seul point u_0 , de dérivée $F'(u_0) = \int_{\Omega} \frac{\partial f}{\partial u}(u_0, x) d\mu(x)$. C'est une hypothèse plus fine, mais aussi moins commode à vérifier en pratique : on utilisera presque toujours la version globale du Théorème 5.40 « Dérivabilité sous le signe intégral ».

Méthode 5.42 – Dériver sous le signe intégral

Pour justifier $F'(u) = \int \frac{\partial f}{\partial u}(u, x) d\mu(x)$:

1. Vérifier que $u \mapsto f(u, x)$ est dérivable (pour presque tout x), et calculer $\frac{\partial f}{\partial u}$;
2. Trouver une fonction dominante $g \in L^1$, **indépendante de u** , majorant $\left| \frac{\partial f}{\partial u}(u, x) \right|$ pour tout u dans l'intervalle considéré ;
3. Conclure par le Théorème 5.40 « Dérivabilité sous le signe intégral » (ou sa version renforcée ci-dessus).

C'est exactement cette méthode qui permettra, dans le complément sur le mouvement brownien, de dériver sous l'intégrale gaussienne, et qui justifiera plus loin (Chapitre 12 « Vecteurs aléatoires gaussiens ») la dérivabilité de la fonction caractéristique d'une variable aléatoire admettant un moment.

Exercice 5.43 – Dérivabilité d'une intégrale à paramètre

Soit $F(t) := \int_0^{+\infty} \frac{e^{-tx}}{1+x^2} dx$ pour $t \geq 0$. Montrer que F est dérivable sur $]0, +\infty[$, et exprimer $F'(t)$ sous forme intégrale.

Solution

Posons $f(t, x) := \frac{e^{-tx}}{1+x^2}$. Pour t dans un segment $[a, b] \subset]0, +\infty[$, $\left| \frac{\partial f}{\partial t}(t, x) \right| = \frac{x e^{-tx}}{1+x^2} \leq x e^{-ax} =: g(x)$, une fonction intégrable sur $]0, +\infty[$ (croissance polynomiale dominée par l'exponentielle) et indépendante de $t \in [a, b]$. Le Théorème 5.40 « Dérivabilité sous le signe intégral » (version renforcée) s'applique donc sur tout segment $[a, b] \subset]0, +\infty[$, donc sur $]0, +\infty[$ tout entier : F y est dérivable, de dérivée

$$F'(t) = - \int_0^{+\infty} \frac{x e^{-tx}}{1+x^2} dx.$$

6 Intégrales multiples

Objectifs

- Connaître et savoir appliquer les théorèmes de Tonelli et de Fubini pour calculer une intégrale multiple et changer l'ordre des intégrations.
- Savoir appliquer la formule de changement de variable dans une intégrale multiple, notamment en coordonnées polaires, cylindriques et sphériques.

Introduction

L'intégrale de Lebesgue construite au Chapitre 5 « Intégrale de Lebesgue » se généralise à $\mathbb{R}^n$ muni de la mesure de Lebesgue λ_n . Ce chapitre présente deux outils de calcul fondamentaux : les théorèmes de Tonelli–Fubini, qui permettent de ramener une intégrale multiple à des intégrales successives, et la formule de changement de variables en dimension n . Les cas polaire, cylindrique et sphérique seront traités explicitement.

6.1 Mesure produit et théorèmes de Tonelli–Fubini

On commence par formaliser l'intégration sur un produit d'espaces mesurés. Les résultats sont énoncés pour deux facteurs ; en les appliquant successivement, on obtient immédiatement les intégrales multiples sur un nombre fini de facteurs, en particulier sur $\mathbb{R}^n$.

Définition 6.1 – Tribu produit

Soient $(E, \mathcal{T}_E)$ et $(F, \mathcal{T}_F)$ deux espaces mesurables. On appelle **tribu produit** sur $E \times F$, notée $\mathcal{T}_E \otimes \mathcal{T}_F$, la tribu engendrée par les pavés $(A \times B)_{A \in \mathcal{T}_E, B \in \mathcal{T}_F}$.

Théorème 6.2 – Existence et unicité de la mesure produit

Soient $(E, \mathcal{T}_E, \mu)$ et $(F, \mathcal{T}_F, \nu)$ deux espaces mesurés σ -finis. Il existe une unique mesure $\mu \otimes \nu$ sur $(E \times F, \mathcal{T}_E \otimes \mathcal{T}_F)$ telle que

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B)$$

pour tous $A \in \mathcal{T}_E$ et $B \in \mathcal{T}_F$. Elle est appelée **mesure produit** de μ et ν .

Idée de preuve. [renvoi au TD4] La construction complète de la mesure produit et la démonstration de son unicité sont proposées dans le TD n°4, partie 3. L'idée est de construire d'abord la mesure sur les pavés, puis de l'étendre à la tribu produit en utilisant les outils d'extension et d'unicité vus précédemment.

Exemple 6.3


Pour $E = F = (\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$, on obtient ainsi la mesure de Lebesgue sur $\mathbb{R}^2$ (Théorème 3.15 « Mesure de Lebesgue sur $\mathbb{R}^n$ ») : $\mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R}) = \mathcal{B}(\mathbb{R}^2)$.

Définition 6.4 – Coupes d'un ensemble

Pour $D \subset E \times F$ et $x \in E$, on appelle **coupe verticale** de D en x l'ensemble

$$D_x := \{y \in F \mid (x, y) \in D\}.$$

De même, pour $y \in F$, on définit la coupe horizontale $D^y := \{x \in E \mid (x, y) \in D\}$.



La coupe verticale D_x est l'ensemble des y tels que $(x, y) \in D$.

Propriété 6.5 – Mesurabilité des coupes

Si $D \in \mathcal{T}_E \otimes \mathcal{T}_F$, alors $D_x \in \mathcal{T}_F$ pour tout $x \in E$ et $D^y \in \mathcal{T}_E$ pour tout $y \in F$. De plus, les applications

$$x \mapsto \nu(D_x), \quad y \mapsto \mu(D^y)$$

sont mesurables, et

$$(\mu \otimes \nu)(D) = \int_E \nu(D_x) d\mu(x) = \int_F \mu(D^y) d\nu(y).$$

Idée de preuve. [renvoi au TD4] La démonstration utilise le théorème π - λ (Dynkin) : on vérifie d'abord le résultat sur les pavés $A \times B$, puis on montre que la famille des ensembles pour lesquels il est vrai est un système de Dynkin. La construction détaillée de la mesure produit et la preuve complète de cette proposition sont proposées dans le TD n°4, partie 3.

Théorème 6.6 – Théorème de Fubini-Tonelli

Soient $(E, \mathcal{T}_E, \mu)$, $(F, \mathcal{T}_F, \nu)$ deux espaces mesurés σ -finis.

- **(Tonelli, cas positif)** Si $f : E \times F \rightarrow [0, +\infty]$ est mesurable, alors

$$\int_{E \times F} f d(\mu \otimes \nu) = \int_E \left(\int_F f(x, y) d\nu(y) \right) d\mu(x) = \int_F \left(\int_E f(x, y) d\mu(x) \right) d\nu(y).$$

- **(Fubini, cas intégrable)** Si $f : E \times F \rightarrow \mathbb{R}$ est mesurable et $\int_{E \times F} |f| d(\mu \otimes \nu) < +\infty$, alors les mêmes égalités sont vraies (les fonctions $x \mapsto \int_F f(x, y) d\nu(y)$ etc. étant définies pour presque tout x).

Idée de preuve. La partie technique est la Proposition 6.5 « Mesurabilité des coupes » : elle permet de traiter les fonctions indicatrices. Une fois ce point admis, le reste de la preuve réutilise uniquement des outils déjà vus au chapitre précédent : linéarité, approximation par fonctions étagées, convergence monotone et décomposition $f = f^+ - f^-$. La démonstration technique complète est proposée dans le TD n°4, partie 3.

Démonstration. Pour $f = \mathbf{1}_D$, la Proposition 6.5 donne

$$\int_F \mathbf{1}_D(x, y) d\nu(y) = \nu(D_x), \quad \int_E \nu(D_x) d\mu(x) = (\mu \otimes \nu)(D),$$

donc la formule de Tonelli est vraie pour les indicatrices. Par linéarité, elle est alors vraie pour toute fonction étagée positive.

Soit maintenant $f : E \times F \rightarrow [0, +\infty]$ mesurable. D'après le Théorème 5.4 « Lemme d'approximation », il existe une suite croissante (f_n) de fonctions étagées positives telle que $f_n \uparrow f$. Pour chaque x , la convergence monotone donne

$$\int_F f_n(x, y) d\nu(y) \uparrow \int_F f(x, y) d\nu(y).$$

En appliquant une seconde fois la convergence monotone à l'intégrale extérieure,

$$\int_{E \times F} f d(\mu \otimes \nu) = \lim_n \int_{E \times F} f_n d(\mu \otimes \nu) = \int_E \left(\int_F f(x, y) d\nu(y) \right) d\mu(x).$$

On échange ensuite les rôles de E et F pour obtenir l'autre ordre : c'est Tonelli.

Enfin, si f est intégrable, on écrit $f = f^+ - f^-$. Comme

$$\int |f| = \int f^+ + \int f^- < +\infty,$$

Tonelli appliqué à f^+ et f^- montre que leurs intégrales itérées sont finies presque partout. On peut donc soustraire les deux égalités de Tonelli : on obtient exactement le théorème de Fubini. Cette dernière étape explique pourquoi l'intégrabilité absolue est l'hypothèse naturelle dans le cas où f change de signe. ■

Corollaire 6.7 – Intégrales multiples en dimension finie

Par récurrence, Tonelli et Fubini s'appliquent à un produit fini d'espaces mesurés σ -finis. En particulier, pour une fonction positive sur $\mathbb{R}^n$ (ou intégrable sur $\mathbb{R}^n$), on peut calculer

$$\int_{\mathbb{R}^n} f(x_1, \dots, x_n) dx_1 \cdots dx_n$$

par n intégrations successives, dans n'importe quel ordre autorisé par Tonelli ou Fubini.

Attention 6.8 – L'hypothèse d'intégrabilité (ou de positivité) est indispensable

Sans elle, les deux intégrations successives peuvent donner des résultats différents. Exemple classique : $f(x, y) = \frac{x^2 - y^2}{(x^2 + y^2)^2}$ sur $]0, 1[^2$ vérifie $\int_0^1 \left(\int_0^1 f(x, y) dy \right) dx = \frac{\pi}{4}$ mais $\int_0^1 \left(\int_0^1 f(x, y) dx \right) dy = -\frac{\pi}{4}$: f n'étant pas intégrable sur $]0, 1[^2$ (elle change de signe et $\int |f| = +\infty$), le théorème de Fubini ne s'applique pas, et les deux ordres d'intégration ne coïncident pas.

Exemple 6.9 – Deux sommes itérées différentes

Sur $\mathbb{N}^2$ muni de la mesure de comptage, posons

$$f(m, n) = \mathbf{1}_{\{m=n\}} - \mathbf{1}_{\{m=n+1\}}.$$

Alors, pour tout n , on a $\sum_m f(m, n) = 0$, donc la somme itérée « d'abord en m » vaut 0. En revanche, pour $m = 0$, la somme en n vaut 1, et pour $m \geq 1$ elle vaut 0 ; la somme itérée « d'abord en n » vaut donc 1. Les deux sommes itérées existent, mais elles ne coïncident pas, car $\sum_{m,n} |f(m, n)| = +\infty$: Fubini ne s'applique pas.

Méthode 6.10 – Utiliser Fubini-Tonelli en pratique

Face à une intégrale multiple :

1. Si $f \geq 0$: on peut *toujours* intervertir l'ordre d'intégration (Tonelli), sans justification supplémentaire – c'est l'outil de base pour calculer la loi d'une somme de deux variables indépendantes par convolution (Chapitre 10 « Vecteurs aléatoires »), ou pour vérifier qu'une variable est bien intégrable en calculant $\iint |f|$.
2. Si f change de signe : il faut d'abord vérifier $\int |f| < +\infty$ sur le domaine produit (souvent en appliquant Tonelli à $|f|$!) avant d'intervertir.

Exemple 6.11 – Changer l’ordre d’intégration sur un domaine triangulaire

Soit

$$D = \{(x, y) \in \mathbb{R}^2 : 0 \leq x \leq y \leq 1\}.$$

Pour $f(x, y) = x + y \geq 0$, Tonelli permet d’écrire

$$\iint_D (x + y) \, dx \, dy = \int_0^1 \int_0^y (x + y) \, dx \, dy.$$

On obtient

$$\int_0^1 \left[\frac{x^2}{2} + xy \right]_{x=0}^{x=y} dy = \int_0^1 \frac{3}{2} y^2 \, dy = \frac{1}{2}.$$

Pour changer l’ordre d’intégration, on redécrit le même domaine sous la forme

$$D = \{(x, y) : 0 \leq x \leq 1, x \leq y \leq 1\}.$$

Ainsi

$$\iint_D (x + y) \, dx \, dy = \int_0^1 \int_x^1 (x + y) \, dy \, dx = \frac{1}{2}.$$

Cet exemple illustre le point essentiel : changer l’ordre d’intégration consiste d’abord à **redécrire correctement le domaine**.

Exemple 6.12 – Convolution de deux fonctions positives

Soient $f, g : \mathbb{R} \rightarrow \mathbb{R}^+$ mesurables. On définit leur **produit de convolution** par $(f * g)(z) := \int_{\mathbb{R}} f(z - y) g(y) \, dy$ (bien défini dans $[0, +\infty]$, l’intégrande étant positive). Si de plus $\int_{\mathbb{R}} f \, d\lambda = \int_{\mathbb{R}} g \, d\lambda = 1$, alors $\int_{\mathbb{R}} (f * g) \, d\lambda = 1$ également : en effet, par le théorème de Tonelli (l’intégrande $(y, z) \mapsto f(z - y)g(y)$ étant positive, mesurable par composition avec l’application $(y, z) \mapsto z - y$ continue),

$$\int_{\mathbb{R}} (f * g)(z) \, dz = \int_{\mathbb{R}} \int_{\mathbb{R}} f(z - y) g(y) \, dy \, dz = \int_{\mathbb{R}} g(y) \left(\int_{\mathbb{R}} f(z - y) \, dz \right) dy = \int_{\mathbb{R}} g(y) \left(\int_{\mathbb{R}} f(u) \, du \right) dy = 1$$

(on a utilisé le changement de variable $u = z - y$ à y fixé, puis $\int_{\mathbb{R}} g = 1$). C’est exactement cette identité qui, appliquée à deux densités de probabilité f, g , donnera au Chapitre 10 « Vecteurs aléatoires » la densité d’une somme de deux variables aléatoires indépendantes.

6.2 Changement de variables

Rappel de L3 6.13 – C^1 -difféomorphisme et jacobien

Soient U, Ω deux ouverts de $\mathbb{R}^n$. Une application

$$\Phi : U \rightarrow \Omega, \quad \Phi(u_1, \dots, u_n) = (x_1, \dots, x_n),$$

est un C^1 -difféomorphisme si elle est bijective, de classe C^1 , et si sa réciproque

$$\Psi := \Phi^{-1} : \Omega \rightarrow U$$

est encore de classe C^1 . En particulier, $\det \text{Jac}(\Phi)(u) \neq 0$ pour tout $u \in U$.

En dimension 2, si $\Phi(u, v) = (x(u, v), y(u, v))$, alors

$$\text{Jac}(\Phi)(u, v) = \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix}.$$

Par exemple,

$$\Phi(u, v) = (u + v, u - v) = (x, y)$$

est un C^1 -difféomorphisme de $\mathbb{R}^2$ dans $\mathbb{R}^2$, d'inverse

$$\Psi(x, y) = \left(\frac{x + y}{2}, \frac{x - y}{2} \right).$$

On a

$$\det \text{Jac}(\Phi) = -2, \quad \det \text{Jac}(\Psi) = -\frac{1}{2},$$

donc $dx dy = 2 du dv$ et, réciproquement, $du dv = \frac{1}{2} dx dy$.

En revanche, $\tilde{\Phi}(u, v) = (u^2, v)$ n'est pas un difféomorphisme de $\mathbb{R}^2$ dans son image, car elle n'est pas injective.




Figure 15: Schéma d'un changement de variables pour $\Phi(u, v) = (u + v, u - v)$: la droite $u = v$ correspond à l'axe $y = 0$, donc les points de U vérifiant $u < v$ sont envoyés dans la région où $y < 0$. Comme $\det \text{Jac}(\Phi) = -2 < 0$, la transformation inverse l'orientation : on peut l'interpréter comme une dilatation composée avec une symétrie.

Théorème 6.14 – Formule du changement de variable

Soient U, Ω deux ouverts de $\mathbb{R}^n$ et

$$\Phi : U \rightarrow \Omega, \quad \Phi(u_1, \dots, u_n) = (x_1, \dots, x_n),$$

un C^1 -difféomorphisme. Si $f : \Omega \rightarrow \mathbb{R}$ est mesurable, positive ou intégrable, alors

$$\int_{\Omega} f(x_1, \dots, x_n) dx_1 \cdots dx_n = \int_U f(\Phi(u_1, \dots, u_n)) |\det \text{Jac}(\Phi)(u_1, \dots, u_n)| du_1 \cdots du_n.$$

Idée de preuve. [admise] Pour une application linéaire inversible $A : \mathbb{R}^n \rightarrow \mathbb{R}^n$, le facteur $|\det A|$ est précisément le facteur de dilatation des volumes. Une application C^1 étant localement approchée par son application linéaire jacobienne, le facteur local de dilatation est donc $|\det \text{Jac}(\Phi)(u)|$. La démonstration générale consiste à rendre cette approximation locale rigoureuse sur de petits pavés, puis à passer des compacts aux boréliens grâce à la régularité de la mesure de Lebesgue rappelée aux Chapitres 1 et 2. Le TD n°4, partie 3, donne une démonstration complète guidée du théorème de changement de variables.

Rappel de L2 6.15 – changement de variable, cas $n = 1$

On rappelle la formule de licence $\int_a^b f(\varphi(t))\varphi'(t) dt = \int_{\varphi(a)}^{\varphi(b)} f(u) du$ pour φ de classe C^1 strictement monotone : c'est exactement le Théorème 6.14 « Formule du changement de variable » en dimension $n = 1$, à ceci près qu'en dimension 1 on garde le signe de φ' (il est absorbé par l'échange des bornes), alors qu'en dimension $n \geq 2$ on prend la valeur absolue du déterminant jacobien, car une mesure (un volume) est toujours positive.

Exemple 6.16 – Passage en coordonnées polaires

Pour $\Phi(r, \theta) = (r \cos \theta, r \sin \theta)$, avec $r > 0$ et $0 < \theta < 2\pi$, on a

$$\text{Jac}(\Phi)(r, \theta) = \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix},$$

donc

$$\det \text{Jac}(\Phi)(r, \theta) = r \cos^2 \theta + r \sin^2 \theta = r.$$

La formule du changement de variable donne alors, pour f intégrable ou positive sur $\mathbb{R}^2$,

$$\int_{\mathbb{R}^2} f(x, y) dx dy = \int_0^{2\pi} \int_0^{+\infty} f(r \cos \theta, r \sin \theta) r dr d\theta,$$

en négligeant le demi-axe retiré, qui est de mesure nulle. Autrement dit,

$$dx dy = r dr d\theta.$$

C'est cette formule, appliquée à $f(x, y) = e^{-(x^2+y^2)}$, qui permet de calculer élégamment l'intégrale de Gauss : si $I = \int_{\mathbb{R}} e^{-x^2} dx$, alors

$$I^2 = \int_0^{2\pi} \int_0^{+\infty} e^{-r^2} r dr d\theta = 2\pi \cdot \frac{1}{2} = \pi,$$

car une primitive de re^{-r^2} est $-\frac{1}{2}e^{-r^2}$, donc $\int_0^{+\infty} e^{-r^2} r dr = \left[-\frac{1}{2}e^{-r^2}\right]_0^{+\infty} = \frac{1}{2}$. Ainsi $I = \sqrt{\pi}$.

Exemple 6.17 – Coordonnées cylindriques dans $\mathbb{R}^3$

Les coordonnées cylindriques s'écrivent

$$\Phi(r, \theta, z) = (r \cos \theta, r \sin \theta, z).$$




Figure 16: Le rectangle $U = [r, r + dr] \times [\theta, \theta + d\theta]$ avec $r > 0$ est envoyé sur un morceau d'anneau qui ne touche pas l'origine. Son aire vaut approximativement $r \, dr \, d\theta$, d'où le facteur jacobien r .

On calcule

$$\text{Jac}(\Phi)(r, \theta, z) = \begin{pmatrix} \cos \theta & -r \sin \theta & 0 \\ \sin \theta & r \cos \theta & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad \det \text{Jac}(\Phi) = r.$$

Ainsi, pour une fonction positive ou intégrable,

$$\int_{\mathbb{R}^3} f(x, y, z) \, dx \, dy \, dz = \int_{-\infty}^{+\infty} \int_0^{2\pi} \int_0^{+\infty} f(r \cos \theta, r \sin \theta, z) \, r \, dr \, d\theta \, dz,$$

c'est-à-dire

$$\boxed{dx \, dy \, dz = r \, dr \, d\theta \, dz.}$$




Figure 17: Coordonnées cylindriques : (r, θ, z) repère un point par sa distance r à l'axe, son angle θ et sa hauteur z . Le facteur de volume est r .

Exemple 6.18 – Coordonnées sphériques dans $\mathbb{R}^3$

On utilise ici la convention

$$\rho \geq 0, \quad 0 \leq \theta < 2\pi, \quad 0 \leq \varphi \leq \pi,$$

avec

$$\Phi(\rho, \theta, \varphi) = (\rho \sin \varphi \cos \theta, \rho \sin \varphi \sin \theta, \rho \cos \varphi).$$

La matrice jacobienne vaut

$$\text{Jac}(\Phi)(\rho, \theta, \varphi) = \begin{pmatrix} \sin \varphi \cos \theta & -\rho \sin \varphi \sin \theta & \rho \cos \varphi \cos \theta \\ \sin \varphi \sin \theta & \rho \sin \varphi \cos \theta & \rho \cos \varphi \sin \theta \\ \cos \varphi & 0 & -\rho \sin \varphi \end{pmatrix}.$$

Un développement du déterminant donne

$$\det \text{Jac}(\Phi)(\rho, \theta, \varphi) = -\rho^2 \sin \varphi,$$

et comme $0 \leq \varphi \leq \pi$,

$$|\det \text{Jac}(\Phi)(\rho, \theta, \varphi)| = \rho^2 \sin \varphi.$$

Par conséquent,

$$\boxed{dx \, dy \, dz = \rho^2 \sin \varphi \, d\rho \, d\theta \, d\varphi.}$$

Ces coordonnées sont adaptées aux boules, aux sphères et aux fonctions ne dépendant que de $x^2 + y^2 + z^2 = \rho^2$.




Figure 18: Coordonnées sphériques : ρ est la distance à l'origine, φ l'angle polaire entre Oz et OP , et θ l'angle azimutal, dans le plan $z = 0$, entre Ox et le segment joignant l'origine au projeté de P . Le facteur de volume est $\rho^2 \sin \varphi$.

Exemple 6.19 – Aire d'une ellipse, changement de variable affine

Calculons $\lambda_2(E)$, l'aire de l'ellipse pleine $E := \{(x, y) \in \mathbb{R}^2 \mid \frac{x^2}{a^2} + \frac{y^2}{b^2} \leq 1\}$, pour $a, b > 0$ fixés.

Le changement de variable. Posons $\Phi : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, $\Phi(u, v) := (au, bv)$. C'est une bijection de $\mathbb{R}^2$ dans lui-même, de bijection réciproque $\Psi := \Phi^{-1}$ donnée par $\Psi(x, y) = (\frac{x}{a}, \frac{y}{b})$, et Φ envoie le disque unité fermé

$D := \{(u, v) \mid u^2 + v^2 \leq 1\}$ exactement sur E : en effet, $(x, y) = \Phi(u, v) \in E \iff \frac{(au)^2}{a^2} + \frac{(bv)^2}{b^2} \leq 1 \iff u^2 + v^2 \leq 1 \iff (u, v) \in D$.

Φ est de classe C^1 . Ses deux composantes $(u, v) \mapsto au$ et $(u, v) \mapsto bv$ sont des fonctions polynomiales (affines) de (u, v) , donc de classe C^∞ sur $\mathbb{R}^2$; en particulier $\Phi \in C^1(\mathbb{R}^2, \mathbb{R}^2)$, et il en va de même pour Ψ (mêmes raisons, avec $a, b \neq 0$).

La jacobienne. On calcule directement les dérivées partielles :

$$\text{Jac}(\Phi)(u, v) = \begin{pmatrix} \frac{\partial(au)}{\partial u} & \frac{\partial(au)}{\partial v} \\ \frac{\partial(bv)}{\partial u} & \frac{\partial(bv)}{\partial v} \end{pmatrix} = \begin{pmatrix} a & 0 \\ 0 & b \end{pmatrix},$$

de déterminant $\det \text{Jac}(\Phi)(u, v) = ab$, constant (indépendant de (u, v)) et non nul puisque $a, b > 0$: Φ est donc bien un C^1 -difféomorphisme de $\mathbb{R}^2$ dans $\mathbb{R}^2$, comme il se doit pour appliquer le Théorème 6.14 « Formule du changement de variable ».

Fin du calcul. Par la formule du changement de variable, appliquée à $f = \mathbf{1}_E$:

$$\lambda_2(E) = \int_{\mathbb{R}^2} \mathbf{1}_E(x, y) dx dy = \int_{\mathbb{R}^2} \mathbf{1}_E(\Phi(u, v)) |\det \text{Jac}(\Phi)(u, v)| du dv = \int_{\mathbb{R}^2} \mathbf{1}_D(u, v) ab du dv,$$

où l'on a utilisé $\mathbf{1}_E \circ \Phi = \mathbf{1}_{\Phi^{-1}(E)} = \mathbf{1}_D$ (car $\Phi(D) = E$ et Φ est bijective). Ainsi

$$\lambda_2(E) = ab \int_{\mathbb{R}^2} \mathbf{1}_D(u, v) du dv = ab \lambda_2(D) = \pi ab,$$

puisque $\lambda_2(D) = \pi$ (aire du disque unité, valeur classique). On retrouve la formule bien connue : **l'aire d'une ellipse de demi-axes a et b vaut πab** (qui redonne bien πa^2 pour $a = b$, l'aire du disque de rayon a).




Figure 19: Le changement affine $(u, v) \mapsto (au, bv)$ transforme le disque unité en l'ellipse de demi-axes a et b ; les aires sont multipliées par ab .

Exercice 6.20 – Un changement de variable non standard

Trouver une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ telle que, pour toute fonction φ continue bornée, $\int_{[0,1]^2} \varphi(xy) dx dy = \int_{\mathbb{R}} \varphi(u) f(u) du$.

Solution

Le changement de variable. Posons $T := \{(u, v) \in \mathbb{R}^2 \mid 0 < u \leq v \leq 1\}$, et $\Phi : T \rightarrow]0, 1]^2$, $\Phi(u, v) := (\frac{u}{v}, v)$.

Φ est bien à valeurs dans $]0, 1]^2$, et bijective sur son image. Pour $(u, v) \in T$, on a $v \in]0, 1]$ et, puisque $0 < u \leq v$, $\frac{u}{v} \in]0, 1]$: donc $\Phi(u, v) \in]0, 1]^2$. Réciproquement, pour $(x, y) \in]0, 1]^2$, l'unique antécédent possible est $u = xy$, $v = y$ (en résolvant $x = u/v$, $y = v$) ; on vérifie que $(u, v) = (xy, y) \in T$ puisque $0 < xy \leq y \leq 1$ (car $0 < x \leq 1$). Ainsi Φ est une bijection de T sur $]0, 1]^2$, de bijection réciproque $\Psi := \Phi^{-1}$ donnée par $\Psi(x, y) = (xy, y)$.

Φ est un C^1 -difféomorphisme. Sur l'ouvert $\{v > 0\} \supset T \setminus \{v = 1, u = 1\}$ (on peut ignorer le bord de mesure nulle), les deux composantes $(u, v) \mapsto u/v$ et $(u, v) \mapsto v$ sont de classe C^1 (quotient et projection de fonctions C^∞ , dénominateur non nul) ; de même pour $\Psi(x, y) = (xy, y)$, polynomiale donc C^∞ .

La jacobienne de Φ . On calcule

$$\text{Jac}(\Phi)(u, v) = \begin{pmatrix} \frac{\partial}{\partial u}(\frac{u}{v}) & \frac{\partial}{\partial v}(\frac{u}{v}) \\ \frac{\partial}{\partial u} & \frac{\partial}{\partial v} \end{pmatrix} = \begin{pmatrix} \frac{1}{v} & -\frac{u}{v^2} \\ 0 & 1 \end{pmatrix}, \quad \det \text{Jac}(\Phi)(u, v) = \frac{1}{v} \quad (\neq 0 \text{ sur } T).$$

Application du théorème de changement de variable. Pour φ continue bornée, en posant $g(x, y) := \varphi(xy)$ (mesurable bornée sur $]0, 1]^2$, donc intégrable sur le domaine borné $]0, 1]^2$) :

$$\int_{]0, 1]^2} \varphi(xy) dx dy = \int_{]0, 1]^2} g(x, y) dx dy = \int_T g(\Phi(u, v)) |\det \text{Jac}(\Phi)(u, v)| du dv$$

par le Théorème 6.14 « Formule du changement de variable » (avec $\Phi : T \rightarrow]0, 1]^2$ comme ci-dessus).

Or $g(\Phi(u, v)) = \varphi(\frac{u}{v} \cdot v) = \varphi(u)$, donc

$$\int_{]0, 1]^2} \varphi(xy) dx dy = \int_T \varphi(u) \frac{1}{v} du dv.$$

Fin du calcul, par Fubini-Tonelli. L'intégrande $(u, v) \mapsto \varphi(u)/v$ est mesurable sur T , et φ étant bornée par une constante M , $|\varphi(u)/v| \leq M/v$ est intégrable sur T (car $\int_T \frac{1}{v} du dv = \int_0^1 (\int_0^v \frac{1}{v} du) dv = \int_0^1 1 dv = 1 < +\infty$) : Fubini-Tonelli s'applique donc, et permet d'intégrer d'abord en v (pour $u \in]0, 1]$ fixé, v décrit $[u, 1]$, condition $u \leq v \leq 1$) :

$$\int_T \varphi(u) \frac{1}{v} du dv = \int_0^1 \varphi(u) \left(\int_u^1 \frac{dv}{v} \right) du = \int_0^1 \varphi(u) [\ln v]_u^1 du = \int_0^1 \varphi(u) (-\ln u) du.$$

En comparant avec l'égalité demandée $\int_{]0, 1]^2} \varphi(xy) dx dy = \int_{\mathbb{R}} \varphi(u) f(u) du$ (et puisque $-\ln u$ n'est définie et positive que sur $]0, 1[$, on prolonge par 0 ailleurs), on peut donc choisir

$$f = -\mathbf{1}_{]0, 1[} \ln.$$




Figure 20: Le changement $(u, v) \mapsto (u/v, v)$ envoie le triangle $T = \{0 < u \leq v \leq 1\}$ sur le carré $]0, 1]^2$.

7 Espaces L^p

Objectifs

- Connaître et savoir appliquer les inégalités classiques (Markov, Bienaymé-Tchebychev, Hölder, Minkowski, Jensen).
- Connaître les espaces L^p , leur norme, et savoir démontrer qu'il s'agit d'espaces vectoriels normés complets.
- Connaître les résultats de densité dans les espaces L^p .

Introduction

Ce chapitre regroupe les inégalités et les résultats fonctionnels fondamentaux associés à l'intégrale de Lebesgue, qui seront utilisés de façon constante dans la suite de ce livret – en particulier pour l'étude des modes de convergence des suites de variables aléatoires (Chapitre 13 « Convergence de suites de variables aléatoires ») et pour la construction de l'espérance conditionnelle (Chapitre 11 « Lois et espérance conditionnelles »). On travaille ici sur un espace mesuré $(\Omega, \mathcal{T}, \mu)$ *quelconque*, pas seulement probabilisé : les probabilités en seront, comme souvent dans ce livret, le cas particulier $\mu = \mathbb{P}$.

7.1 Définition et norme

Définition 7.1 – Espaces L^p

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $p \geq 1$. On note $L^p(\Omega, \mu)$ l'ensemble des fonctions mesurables $f : \Omega \rightarrow \mathbb{R}$ vérifiant $\int_{\Omega} |f|^p d\mu < +\infty$. Pour $f \in L^p$, on note $\|f\|_p := (\int_{\Omega} |f|^p d\mu)^{1/p}$.

Définition 7.2 – L^∞

$L^\infty(\Omega, \mu)$ désigne l'ensemble des fonctions mesurables bornées μ -presque partout, i.e. pour lesquelles il existe $M > 0$ avec $\mu(|f| > M) = 0$.

Remarque 7.3

$\|\cdot\|_p$ est une **semi-norme** sur L^p : l'homogénéité absolue est immédiate, et la sous-additivité (inégalité triangulaire) sera établie à la Proposition 7.14 « Inégalité de Minkowski ».

Propriété 7.4 – Séparation, ou pourquoi $\|\cdot\|_p$ n'est qu'une semi-norme

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $p \in [1, +\infty[$, $f \in L^p(\Omega, \mu)$. Alors

$$\|f\|_p = 0 \quad \Longleftrightarrow \quad f = 0 \text{ } \mu\text{-presque partout.}$$

Démonstration. ($\Leftarrow$) Si $f = 0$ μ -p.p., alors $|f|^p = 0$ μ -p.p., donc $\int_{\Omega} |f|^p d\mu = 0$ (intégrale d'une fonction nulle presque partout, Chapitre 5 « Intégrale de Lebesgue »), d'où $\|f\|_p = (\int_{\Omega} |f|^p d\mu)^{1/p} = 0$.

($\Rightarrow$) Si $\|f\|_p = 0$, alors $\int_{\Omega} |f|^p d\mu = 0$. Or $|f|^p \geq 0$; par la Proposition 5.24 « Espérance et nullité presque partout » (intégrale nulle d'une fonction positive), $|f|^p = 0$ μ -presque partout, donc $f = 0$ μ -presque partout.

Remarque 7.5

Cette proposition explique précisément pourquoi $\|\cdot\|_p$ n'est qu'une **semi-norme** sur $L^p(\Omega, \mu)$, et non une véritable norme : $\|f\|_p = 0$ n'entraîne pas $f = 0$ *partout*, seulement μ -presque partout. Deux fonctions égales μ -p.p. ont donc la même « norme » $\|\cdot\|_p$, sans être nécessairement égales. Pour obtenir un véritable espace vectoriel normé, on quotiente $L^p(\Omega, \mu)$ par la relation d'équivalence « égalité μ -presque partout » – ce que l'on fait implicitement dans toute la suite de ce livret, sans alourdir les notations.

Remarque 7.6 – Le cas probabiliste

Lorsque $\mu = \mathbb{P}$ est une mesure de probabilité, $L^p(\Omega, \mathbb{P})$ est exactement l'espace des variables aléatoires réelles admettant un **moment d'ordre p** (Chapitre 9 « Variables aléatoires réelles ») : $\mathbb{E}(|X|^p) < +\infty$, avec $\|X\|_p = \mathbb{E}(|X|^p)^{1/p}$. C'est sous cette forme que l'on retrouvera L^p dans la suite de ce livret.

7.2 Inégalités fondamentales

Propriété 7.7 – Inégalité de Markov

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $f \geq 0$ mesurable. Alors

$$\forall a > 0, \quad \mu(f \geq a) \leq \frac{1}{a} \int_{\Omega} f \, d\mu.$$

Démonstration. On a $f \geq a \mathbf{1}_{\{f \geq a\}}$ sur Ω tout entier (sur $\{f \geq a\}$ c'est l'hypothèse, ailleurs le membre de droite est nul et $f \geq 0$). Par monotonie et linéarité de l'intégrale (Proposition 5.22 « Linéarité de l'intégrale », Proposition 5.23 « Monotonie »), $\int_{\Omega} f \, d\mu \geq a \int_{\Omega} \mathbf{1}_{\{f \geq a\}} \, d\mu = a \mu(f \geq a)$, d'où le résultat en divisant par $a > 0$. ■




Figure 21: Idée de l'inégalité de Markov : la fonction (en escalier) $a \mathbf{1}_{f \geq a}$ est partout dominée par la fonction f (en trait plein là où $f \geq a$, en pointillés au-delà du point x_a où f franchit le niveau a ; l'axe des abscisses est tracé en rouge sur $\{f < a\}$, là où l'indicatrice vaut 0), ce qui donne, après intégration, $a \mu(f \geq a) \leq \int f \, d\mu$.

Propriété 7.8 – Inégalité de Bienaymé-Tchebychev

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $f \in L^2(\Omega, \mu)$, $c \in \mathbb{R}$. Alors

$$\forall \varepsilon > 0, \quad \mu(|f - c| \geq \varepsilon) \leq \frac{1}{\varepsilon^2} \int_{\Omega} (f - c)^2 \, d\mu.$$

Démonstration. On applique la Proposition 7.7 « Inégalité de Markov » à $g = (f - c)^2 \geq 0$ et $a = \varepsilon^2 > 0$: $\mu(g \geq \varepsilon^2) \leq \frac{1}{\varepsilon^2} \int_{\Omega} g \, d\mu$. Or $g \geq \varepsilon^2 \iff |f - c| \geq \varepsilon$ (les deux membres étant positifs). ■

Méthode 7.9 – Utiliser Markov ou Bienaymé-Tchebychev

1. Pour majorer $\mu(f \geq a)$ avec $f \geq 0$ et seule l'intégrale (ou l'espérance) connue : Markov.
2. Pour majorer $\mu(|f - c| \geq \varepsilon)$ (écart à une constante c , souvent la moyenne) avec la norme L^2 connue : Bienaymé-Tchebychev. C'est, en probabilités, l'outil de base pour établir une convergence en probabilité (cf. Proposition 13.14 « Convergence $L^p \Rightarrow$ convergence en probabilité ») ou une loi des grands nombres.
3. Pour des bornes plus fines (à décroissance exponentielle), on utilise en probabilités avancées les inégalités de Chernoff/Hoeffding, hors-programme ici, qui appliquent Markov à e^{tX} pour un t optimisé.

Propriété 7.10 – Inégalité de Hölder

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, f, g deux fonctions mesurables, $p, q \in]1, +\infty[$ tels que $\frac{1}{p} + \frac{1}{q} = 1$. Si $f \in L^p$ et $g \in L^q$, alors $fg \in L^1$ et

$$\int_{\Omega} |fg| d\mu \leq \|f\|_p \|g\|_q.$$

Démonstration. Si $\|f\|_p = 0$ ou $\|g\|_q = 0$, alors $f = 0$ μ -p.p. ou $g = 0$ μ -p.p. (Proposition 5.24 « Espérance et nullité presque partout »), et l'inégalité est triviale ($0 \leq 0$). Supposons $\|f\|_p, \|g\|_q > 0$ et posons $u = f/\|f\|_p$, $v = g/\|g\|_q$ (de sorte que $\int_{\Omega} |u|^p d\mu = \int_{\Omega} |v|^q d\mu = 1$). Pour $a, b \geq 0$, par concavité de $\ln$:

$$\ln\left(\frac{a^p}{p} + \frac{b^q}{q}\right) \geq \frac{1}{p} \ln(a^p) + \frac{1}{q} \ln(b^q) = \ln(ab)$$

(l'inégalité de concavité $\ln(\lambda x + (1 - \lambda)y) \geq \lambda \ln x + (1 - \lambda) \ln y$ appliquée à $x = a^p, y = b^q, \lambda = 1/p$), d'où l'**inégalité de Young** $ab \leq \frac{a^p}{p} + \frac{b^q}{q}$. En appliquant point par point avec $a = |u(\omega)|$, $b = |v(\omega)|$, puis en intégrant (croissance et linéarité de l'intégrale) :

$$\int_{\Omega} |uv| d\mu \leq \frac{\int_{\Omega} |u|^p d\mu}{p} + \frac{\int_{\Omega} |v|^q d\mu}{q} = \frac{1}{p} + \frac{1}{q} = 1.$$

En revenant à $f = \|f\|_p u$, $g = \|g\|_q v$, on obtient $\int_{\Omega} |fg| d\mu = \|f\|_p \|g\|_q \int_{\Omega} |uv| d\mu \leq \|f\|_p \|g\|_q$. ■

Corollaire 7.11 – Inclusion $L^p \subset L^q$ en mesure finie

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré **fini** (i.e. $\mu(\Omega) < +\infty$), soient $1 \leq q < p \leq +\infty$. Alors $L^p(\Omega, \mu) \subset L^q(\Omega, \mu)$.

Démonstration. Cas $p < +\infty$. Soit $f \in L^p$. Par l'inégalité de Hölder (Proposition 7.10 « Inégalité de Hölder ») appliquée à $|f|^q$ et $\mathbf{1}_{\Omega}$, avec les exposants conjugués p/q et $(p/q)' = \frac{p}{p-q}$:

$$\int_{\Omega} |f|^q d\mu = \int_{\Omega} |f|^q \cdot \mathbf{1}_{\Omega} d\mu \leq \left(\int_{\Omega} |f|^p d\mu \right)^{q/p} \left(\int_{\Omega} \mathbf{1}_{\Omega} d\mu \right)^{1-q/p} = \|f\|_p^q \mu(\Omega)^{1-q/p} < +\infty,$$

la dernière quantité étant finie car $\mu(\Omega) < +\infty$. Donc $f \in L^q$.

Cas $p = +\infty$. Soit $f \in L^{\infty}$, borné μ -p.p. par une constante M . Alors $|f|^q \leq M^q$ μ -p.p., donc $\int_{\Omega} |f|^q d\mu \leq M^q \mu(\Omega) < +\infty$ (car $\mu(\Omega) < +\infty$) : $f \in L^q$. ■

Remarque 7.12

Ce résultat est **spécifique aux mesures finies** (donc, en particulier, aux mesures de probabilité) : $\mathbf{1}_{\Omega}$ n'est intégrable que si $\mu(\Omega) < +\infty$, ce qui n'est plus vrai en général – par exemple pour la mesure de Lebesgue sur $\mathbb{R}$, où l'on peut avoir $f \in L^p \setminus L^q$ pour $q < p$ (et réciproquement).

Rappel de L1–L2 7.13 – convexité

On rappelle qu'une fonction φ est convexe sur un intervalle si son graphe est toujours situé sous ses cordes (ou, si φ est deux fois dérivable, si $\varphi'' \geq 0$). L'inégalité de Young utilisée ci-dessus est un cas particulier de convexité (celle de $x \mapsto -\ln x$, ou de $x \mapsto x^p$) ; on retrouvera ce principe de façon plus générale avec l'inégalité de Jensen (Proposition 7.17 « Inégalité de Jensen »).

Propriété 7.14 – Inégalité de Minkowski

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $p \geq 1$. Si $f, g \in L^p$, alors $f + g \in L^p$ et $\|f + g\|_p \leq \|f\|_p + \|g\|_p$.

Démonstration. Le cas $p = 1$ découle de $|f + g| \leq |f| + |g|$ par croissance et linéarité de l'intégrale. Supposons $p > 1$ et $\|f\|_p, \|g\|_p > 0$ (le cas contraire est trivial comme pour Hölder). Posons $t = \frac{\|f\|_p}{\|f\|_p + \|g\|_p} \in]0, 1[$, $u = f/\|f\|_p$, $v = g/\|g\|_p$, de sorte que $f + g = (\|f\|_p + \|g\|_p)(tu + (1 - t)v)$. La fonction $s \mapsto |s|^p$ étant convexe sur $\mathbb{R}$ (car $p > 1$) :

$$|tu + (1 - t)v|^p \leq (t|u| + (1 - t)|v|)^p \leq t|u|^p + (1 - t)|v|^p$$

(la première inégalité par l'inégalité triangulaire puis croissance de $s \mapsto s^p$ sur $\mathbb{R}^+$, la seconde par convexité de $s \mapsto s^p$). En intégrant :

$$\int_{\Omega} |tu + (1 - t)v|^p d\mu \leq t \int_{\Omega} |u|^p d\mu + (1 - t) \int_{\Omega} |v|^p d\mu = t + (1 - t) = 1$$

(car $\int_{\Omega} |u|^p d\mu = \int_{\Omega} |v|^p d\mu = 1$ par construction). Donc $\|tu + (1 - t)v\|_p \leq 1$, c'est-à-dire $\|f + g\|_p \leq \|f\|_p + \|g\|_p$. ■

Remarque 7.15 – Une autre preuve de Minkowski, à partir de Hölder

Une seconde preuve de la Proposition 7.14 « Inégalité de Minkowski », fondée directement sur l'inégalité de Hölder, est proposée en complément de cours dans le **TD n°5, partie 3, exercice 3.1**. Elle permet de voir comment Hölder entraîne presque immédiatement Minkowski une fois l'intégrabilité de $f + g$ établie.

Exemple 7.16

L'inégalité de Minkowski est précisément ce qui manquait pour affirmer que $\|\cdot\|_p$ est une (semi-)norme sur L^p : L^p devient ainsi un espace vectoriel normé (après quotient par la relation « égalité μ -presque partout »), ce qui ouvre la voie à l'analyse fonctionnelle appliquée à la théorie de la mesure et aux probabilités (espaces de Hilbert pour $p = 2$, notamment).

Propriété 7.17 – Inégalité de Jensen

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré avec $0 < \mu(\Omega) < +\infty$, $f \in L^1(\Omega, \mu)$, $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ convexe telle que $\varphi(f)$ soit également intégrable. Alors

$$\varphi\left(\frac{1}{\mu(\Omega)} \int_{\Omega} f d\mu\right) \leq \frac{1}{\mu(\Omega)} \int_{\Omega} \varphi(f) d\mu.$$

En particulier, pour $\mu = \mathbb{P}$ une mesure de **probabilité** ($\mu(\Omega) = 1$), on retrouve $\varphi\left(\int_{\Omega} f d\mathbb{P}\right) \leq \int_{\Omega} \varphi(f) d\mathbb{P}$.

Démonstration. Posons $m = \frac{1}{\mu(\Omega)} \int_{\Omega} f d\mu$. φ étant convexe, elle est dérivable à gauche et à droite en tout point, avec $\varphi'_g(m) \leq \varphi'_d(m)$; choisissons $a \in [\varphi'_g(m), \varphi'_d(m)]$. Par convexité, la droite $x \mapsto a(x - m) + \varphi(m)$ (la **tangente** à φ en m – de pente a , passant par $(m, \varphi(m))$) ; si φ est dérivable en m , $a = \varphi'(m)$ est l'unique

choix possible) minore le graphe de φ :

$$\forall x \in \mathbb{R}, \quad \varphi(x) \geq a(x - m) + \varphi(m).$$

En appliquant cette inégalité en $x = f(\omega)$ pour chaque ω :

$$\varphi(f(\omega)) \geq a(f(\omega) - m) + \varphi(m).$$

En intégrant les deux membres par rapport à μ (croissance et linéarité de l'intégrale, licites car f et $\varphi(f)$ sont intégrables par hypothèse), puis en divisant par $\mu(\Omega) \in]0, +\infty[$:

$$\frac{1}{\mu(\Omega)} \int_{\Omega} \varphi(f) d\mu \geq a \left(\frac{1}{\mu(\Omega)} \int_{\Omega} f d\mu - m \right) + \varphi(m) = a \times 0 + \varphi(m) = \varphi(m) = \varphi \left(\frac{1}{\mu(\Omega)} \int_{\Omega} f d\mu \right),$$

ce qui est exactement l'inégalité annoncée. ■




Figure 22: L'inégalité de Jensen : une fonction convexe est toujours au-dessus de n'importe laquelle de ses tangentes, en particulier celle passant par $(m, \varphi(m))$; l'espérance « efface » le terme linéaire.

Exemple 7.18

Pour $\varphi(x) = x^2$ (convexe), la Proposition 7.17 « Inégalité de Jensen » redonne $\mathbb{E}(f)^2 \leq \mathbb{E}(f^2)$, c'est-à-dire $\text{Var}(f) \geq 0$: une (re)démonstration, par un tout autre chemin, d'un fait déjà connu depuis la formule de Koenig-Huygens.

Méthode 7.19 – Reconnaître un cas d'application de Jensen

Dès qu'un énoncé demande de comparer $\varphi(\mathbb{E}(X))$ et $\mathbb{E}(\varphi(X))$ pour une fonction convexe usuelle (x^2 , $|x|$, e^x , $-\ln x$ sur $\mathbb{R}^{+*}$, etc.), il s'agit très probablement d'une application directe de l'inégalité de Jensen. Pour une fonction *concave* (comme $\ln$), l'inégalité s'inverse : $\varphi(\mathbb{E}(X)) \geq \mathbb{E}(\varphi(X))$ (appliquer Jensen à $-\varphi$, convexe).

7.3 Complétude et densité dans les espaces L^p

On établit ici que L^p , muni de $\|\cdot\|_p$, est un espace de Banach (complet) – un résultat qui sous-tend, par exemple, l'existence de la projection orthogonale utilisée pour construire l'espérance conditionnelle (Chapitre 11 « Lois et espérance conditionnelles »).

Théorème 7.20 – Riesz-Fischer

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré. Pour tout $p \in [1, +\infty]$, $(L^p(\Omega, \mu), \|\cdot\|_p)$ est un espace de Banach.

Idee de preuve. On traite $1 \leq p < +\infty$ (le cas $p = \infty$ est analogue et plus direct). L'idée est d'extraire, d'une suite de Cauchy (f_n) , une sous-suite $(g_n) = (f_{k_n})$ dont les écarts successifs décroissent géométriquement ($\|g_{n+1} - g_n\|_p \leq 2^{-n}$). La série des écarts absolus est alors dominée dans L^p , ce qui fournit une convergence presque partout puis une convergence dans L^p . Une suite de Cauchy possédant une sous-suite convergente converge ensuite tout entière vers la même limite. La **démonstration complète, y compris le cas $p = +\infty$, est donnée dans le TD n°5, partie 3, exercice 3.2.**

Remarque 7.21

La démonstration fait apparaître, comme sous-produit, un résultat utile en lui-même : **de toute suite convergente dans L^p , on peut extraire une sous-suite qui converge aussi presque partout.** La réciproque est fautive en général (convergence p.p. n'entraîne pas convergence L^p , cf. les modes de convergence, Chapitre 13 « Convergence de suites de variables aléatoires »), mais devient vraie sous une hypothèse de domination, exactement comme pour le Théorème 5.33 « Théorème de convergence dominée ».

7.4 Le cas $p = 2$: espaces de Hilbert et théorème de représentation de Riesz

Rappel de L3 7.22 – analyse fonctionnelle élémentaire

Soit E un espace vectoriel réel.

- Un **produit scalaire** sur E est une application $\langle \cdot, \cdot \rangle : E \times E \rightarrow \mathbb{R}$ bilinéaire, symétrique et définie positive : $\langle x, x \rangle \geq 0$, avec égalité si et seulement si $x = 0$. Il définit la norme

$$\|x\| := \sqrt{\langle x, x \rangle}.$$

- Une suite (x_n) d'un espace vectoriel normé est une **suite de Cauchy** si

$$\forall \varepsilon > 0, \exists N, \forall n, m \geq N, \quad \|x_n - x_m\| < \varepsilon.$$

- Un espace vectoriel normé est dit **complet** si toute suite de Cauchy y converge.
- Un **espace de Hilbert** est un espace vectoriel muni d'un produit scalaire et complet pour la norme associée.
- Si E, F sont deux espaces vectoriels normés, une application $T : E \rightarrow F$ est **linéaire** si $T(ax + by) = aT(x) + bT(y)$. Une application linéaire est **continue** si et seulement s'il existe $C \geq 0$ tel que

$$\|T(x)\|_F \leq C\|x\|_E \quad \text{pour tout } x \in E.$$

Lorsqu'elle est continue, on distingue sa **norme d'opérateur** des normes des vecteurs en la notant

$$\|T\| := \sup_{\|x\|_E \leq 1} \|T(x)\|_F.$$

- Une **forme linéaire** sur E est une application linéaire $\ell : E \rightarrow \mathbb{R}$. Si elle est continue, sa norme d'opérateur est donc

$$\|\ell\| := \sup_{\|x\|_E \leq 1} |\ell(x)|.$$

Propriété 7.23 – L^2 est un espace de Hilbert

Sur $L^2(\Omega, \mu)$, on pose

$$\langle f, g \rangle_{L^2} := \int_{\Omega} fg \, d\mu.$$

Alors $\langle \cdot, \cdot \rangle_{L^2}$ est un produit scalaire (sur les classes de fonctions égales μ -presque partout), sa norme associée est exactement $\| \cdot \|_2$, et $L^2(\Omega, \mu)$ est un espace de Hilbert.

Démonstration. Par Hölder avec $p = q = 2$ (inégalité de Cauchy–Schwarz), $fg \in L^1$, donc le produit scalaire est bien défini. La bilinéarité et la symétrie découlent de celles de l'intégrale ; de plus

$$\langle f, f \rangle_{L^2} = \int_{\Omega} |f|^2 \, d\mu \geq 0,$$

et cette quantité est nulle si et seulement si $f = 0$ μ -presque partout. Enfin,

$$\sqrt{\langle f, f \rangle_{L^2}} = \|f\|_2.$$

La complétude de L^2 est le cas $p = 2$ du Théorème 7.20 « Riesz–Fischer ». Ainsi L^2 est un espace de Hilbert. ■

Théorème 7.24 – Théorème de représentation de Riesz

Soit H un espace de Hilbert réel et $\ell : H \rightarrow \mathbb{R}$ une forme linéaire continue. Alors il existe un unique $h \in H$ tel que

$$\forall x \in H, \quad \ell(x) = \langle x, h \rangle.$$

De plus,

$$\|\ell\| = \|h\|.$$

Idée de preuve. Le théorème affirme qu'une forme linéaire continue sur un espace de Hilbert est entièrement représentée par un unique vecteur du même espace. Géométriquement, le produit scalaire permet donc d'identifier le dual continu de H avec H lui-même. La **démonstration complète est donnée dans le TD n°5, partie 3, exercice 3.3**. Ce résultat sera utilisé au Chapitre 8 « Décomposition des mesures » pour démontrer le théorème de Radon–Nikodym.

Théorème 7.25 – Densité dans L^p

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $p \in [1, +\infty[$. L'espace des fonctions étagées (intégrables) est dense dans $L^p(\Omega, \mu)$: pour tout $f \in L^p$, il existe une suite (f_n) de fonctions étagées avec $\|f_n - f\|_p \rightarrow 0$.

Démonstration. Il suffit de traiter $f \geq 0$ (cas général par différence $f = f^+ - f^-$). Par le Théorème 5.4 « Lemme d'approximation », il existe une suite (f_n) de fonctions étagées positives, $f_n \leq f$, convergeant simplement en croissant vers f . Alors $|f - f_n|^p \leq f^p$, intégrable par hypothèse ($f \in L^p$) ; par le Théorème 5.33 « Théorème de convergence dominée », $\int_{\Omega} |f - f_n|^p \, d\mu \rightarrow 0$, c'est-à-dire $\|f - f_n\|_p \rightarrow 0$. De plus, comme $0 \leq f_n \leq f$ et $f \in L^p$, on a $|f_n|^p \leq |f|^p$; donc $f_n \in L^p$. ■

Exemple 7.26

Ce théorème de densité est l'outil technique qui permet, dans de nombreuses démonstrations « par approximations successives » de ce livret (Théorème 9.44 « Théorème de transfert », propriétés de l'espérance conditionnelle, etc.), de se ramener au cas des indicatrices ou des fonctions étagées : on établit d'abord le résultat pour ces fonctions simples, puis on l'étend par densité (et un argument de continuité ou de convergence dominée) à L^p tout entier.

8 Décomposition des mesures

Objectifs

- Définir la notion de mesure absolument continue et de mesure à densité, et démontrer le théorème de Radon-Nikodym qui relie les deux.
- Construire un exemple explicite de mesure diffuse mais étrangère à la mesure de Lebesgue : la mesure de Cantor.
- Définir la notion de mesures étrangères (singulières).
- Connaître le Théorème 8.22 « Décomposition de Lebesgue » et comprendre son mécanisme ; la démonstration complète est donnée dans le TD5bis, partie 3.
- Savoir décomposer une mesure finie sur $\mathbb{R}$ en partie à densité, partie discrète et partie singulière continue.

Introduction

Jusqu'ici, les mesures de probabilité rencontrées dans ce livret étaient presque toujours de l'un des deux types suivants : **discrètes** (concentrées sur un ensemble fini ou dénombrable de points) ou **à densité** (de la forme $f \cdot \lambda$ pour une densité f). On pourrait croire que toute mesure de probabilité sur $\mathbb{R}$ est de l'un de ces deux types, ou une combinaison des deux. Ce chapitre montre qu'il n'en est rien : il existe des mesures **diffuses** (sans aucun atome) qui ne sont pourtant **la densité d'aucune fonction** par rapport à la mesure de Lebesgue – l'exemple canonique étant la mesure de Cantor, construite ci-dessous. Le **Théorème 8.22 « Décomposition de Lebesgue »**, démontré à partir du théorème de Radon-Nikodym, sépare en général une mesure en une partie absolument continue et une partie singulière. Dans le cas particulier d'une mesure finie sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, on raffinerait ensuite la partie singulière en une partie discrète et une partie singulière continue.

Rappel 8.1 – Atome et mesure diffuse

On rappelle la Définition 3.7 « Atome et mesure diffuse ». Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré. Un point $x \in \Omega$ est un **atome** de μ lorsque le singleton $\{x\}$ est mesurable et

$$\mu(\{x\}) > 0.$$

La mesure μ est dite **diffuse** lorsqu'elle ne possède aucun atome, c'est-à-dire lorsque $\mu(\{x\}) = 0$ pour tout $x \in \Omega$ tel que $\{x\} \in \mathcal{T}$.

Définition 8.2 – Mesure discrète

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré. On dit que μ est une **mesure discrète** s'il existe un ensemble au plus dénombrable $S \subset \Omega$, formé d'atomes de μ , tel que

$$\mu(\Omega \setminus S) = 0.$$

Autrement dit, toute la masse de μ est concentrée sur un nombre fini ou dénombrable d'atomes. On a alors

$$\mu = \sum_{x \in S} \mu(\{x\}) \delta_x.$$

Si l'on autorise dans cette définition un ensemble S qui n'est pas nécessairement fini ou dénombrable, on dit que μ est **purement atomique**.

Remarque 8.3 – Discrète, diffuse, ou mixte

Une mesure diffuse non nulle ne peut pas être discrète. En revanche, une mesure qui n'est pas discrète n'est pas nécessairement diffuse : elle peut posséder à la fois des atomes et une partie diffuse. Par exemple, sur $\mathbb{R}$,

$$\mu := \delta_0 + \lambda$$

possède l'atome 0, mais n'est pas concentrée sur un ensemble dénombrable ; elle n'est donc ni discrète, ni diffuse. C'est précisément ce type de coexistence que les théorèmes de décomposition permettent d'analyser.

8.1 Densité et mesures absolument continues

Avant de contraster la notion de mesures *étrangères* (ci-dessous), introduisons deux notions étroitement liées : celle de **mesure à densité**, puis celle de **mesure absolument continue**. Le théorème de Radon–Nikodym précisera ensuite, sous une hypothèse de σ -finitude, dans quelle mesure ces deux notions coïncident.

Définition 8.4 – Mesure à densité

Soit μ une mesure sur $(\Omega, \mathcal{T})$, $g : \Omega \rightarrow [0, +\infty]$ mesurable. La mesure $\nu := g \cdot \mu$, définie par $\nu(A) := \int_A g d\mu$ pour $A \in \mathcal{T}$, est appelée **mesure de densité g par rapport à μ** . On note aussi $g = \frac{d\nu}{d\mu}$.

Exemple 8.5 – Une mesure à densité qui n'est pas une probabilité

Sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, munissons-nous de la mesure de Lebesgue λ et posons

$$g(x) := 1 + x^2, \quad \nu(A) := \int_A (1 + x^2) d\lambda(x), \quad A \in \mathcal{B}(\mathbb{R}).$$

Alors $\nu = g \cdot \lambda$ est une mesure à densité par rapport à λ . Par exemple,

$$\nu([0, 1]) = \int_0^1 (1 + x^2) dx = 1 + \frac{1}{3} = \frac{4}{3}.$$

En revanche, $\nu(\mathbb{R}) = +\infty$: il s'agit donc bien d'un exemple de mesure, et non d'une mesure de probabilité.

Définition 8.6 – Mesure absolument continue

Soit $(\Omega, \mathcal{T})$ un espace mesurable, μ, ν deux mesures sur $(\Omega, \mathcal{T})$. On dit que ν est **absolument continue** par rapport à μ , et l'on note $\nu \ll \mu$, si

$$\forall A \in \mathcal{T}, \quad \mu(A) = 0 \implies \nu(A) = 0.$$

Autrement dit, ν ne peut charger un ensemble que si μ le charge déjà (au moins un peu) : ν ne peut pas être « plus précise » que μ quant à ce qui est négligeable.

Propriété 8.7 – Une mesure à densité est absolument continue

Toute mesure à densité par rapport à μ est absolument continue par rapport à μ : si $\nu = g \cdot \mu$, alors $\nu \ll \mu$.

Démonstration. Si $\mu(A) = 0$, alors $\nu(A) = \int_A g d\mu = 0$ (intégrer une fonction, même non nulle, sur un ensemble μ -négligeable donne toujours 0 – propriété déjà établie au Chapitre 5 « Intégrale de Lebesgue »). Donc $\mu(A) = 0 \implies \nu(A) = 0$, c'est-à-dire $\nu \ll \mu$. ■

Remarque 8.8 – La réciproque : le théorème de Radon-Nikodym

La Proposition 8.7 « Une mesure à densité est absolument continue » admet une réciproque remarquable, **lorsque μ et ν sont σ -finies** : si $\nu \ll \mu$, alors ν est une mesure à densité, $\nu = g \cdot \mu$ pour une certaine fonction mesurable $g \geq 0$, unique μ -presque partout. C'est le **théorème de Radon-Nikodym**. Son énoncé et son idée de preuve sont donnés plus loin dans ce chapitre (Théorème 8.21 « Théorème de Radon-Nikodym »), et sa démonstration complète est donnée dans le TD5bis, partie 3. On l'utilisera librement dès à présent : **pour deux mesures σ -finies, l'absolue continuité $\nu \ll \mu$ équivaut à l'existence d'une densité de ν par rapport à μ .**

Propriété 8.9 – Formule de transfert pour une mesure à densité

Soit $(\Omega, \mathcal{T}, \mu)$ un espace mesuré, $g : \Omega \rightarrow [0, +\infty]$ mesurable, $\nu := g \cdot \mu$ (Définition 8.4 « Mesure à densité »). Alors, pour toute fonction mesurable $\varphi : \Omega \rightarrow [0, +\infty]$,

$$\int_{\Omega} \varphi d\nu = \int_{\Omega} \varphi g d\mu.$$

Plus généralement, pour $\varphi : \Omega \rightarrow \overline{\mathbb{R}}$ mesurable, φ est ν -intégrable si et seulement si φg est μ -intégrable, et dans ce cas $\int_{\Omega} \varphi d\nu = \int_{\Omega} \varphi g d\mu$.

Démonstration. On procède par approximations successives : indicatrices, fonctions étagées positives, fonctions mesurables positives, puis fonctions intégrables.

Cas des indicatrices. Soit $A \in \mathcal{T}$, $\varphi = \mathbf{1}_A$. Par définition même de $\nu = g \cdot \mu$ (Définition 8.4 « Mesure à densité »),

$$\int_{\Omega} \mathbf{1}_A d\nu = \nu(A) = \int_A g d\mu = \int_{\Omega} \mathbf{1}_A g d\mu.$$

Cas des fonctions étagées positives. Par linéarité de l'intégrale (des deux côtés), l'égalité s'étend par combinaison linéaire finie aux fonctions étagées positives $\varphi = \sum_{k=1}^n x_k \mathbf{1}_{A_k}$.

Cas des fonctions mesurables positives. Soit $\varphi \geq 0$ mesurable. Par le lemme d'approximation (Chapitre 5 « Intégrale de Lebesgue »), il existe une suite (φ_n) de fonctions étagées positives, croissante, convergeant simplement vers φ . Par le cas précédent, $\int_{\Omega} \varphi_n d\nu = \int_{\Omega} \varphi_n g d\mu$ pour tout n . La suite (φ_n) est croissante, donc $(\varphi_n g)$ l'est également (car $g \geq 0$) ; en passant à la limite des deux côtés par convergence monotone (Théorème 5.28 « Théorème de convergence monotone »),

$$\int_{\Omega} \varphi d\nu = \lim_{n \rightarrow +\infty} \int_{\Omega} \varphi_n d\nu = \lim_{n \rightarrow +\infty} \int_{\Omega} \varphi_n g d\mu = \int_{\Omega} \varphi g d\mu.$$

Cas général. Soit $\varphi : \Omega \rightarrow \overline{\mathbb{R}}$ mesurable. En appliquant le cas positif à $|\varphi|$,

$$\int_{\Omega} |\varphi| d\nu = \int_{\Omega} |\varphi| g d\mu = \int_{\Omega} |\varphi g| d\mu$$

(car $g \geq 0$, donc $|\varphi g| = |\varphi|g$) : ainsi φ est ν -intégrable si et seulement si φg est μ -intégrable. Dans ce cas, on applique le cas positif séparément à φ^+ et φ^- (avec $(\varphi g)^+ = \varphi^+ g$ et $(\varphi g)^- = \varphi^- g$, car $g \geq 0$), puis on soustrait :

$$\int_{\Omega} \varphi d\nu = \int_{\Omega} \varphi^+ d\nu - \int_{\Omega} \varphi^- d\nu = \int_{\Omega} \varphi^+ g d\mu - \int_{\Omega} \varphi^- g d\mu = \int_{\Omega} \varphi g d\mu.$$

■

Remarque 8.10

Cette proposition est parfois appelée **formule de transfert** (« changer la mesure d'intégration contre une multiplication par la densité ») : elle est à la base de toute manipulation d'une mesure à densité (calcul d'espérances pour une loi à densité, Chapitre 9 « Variables aléatoires réelles » ; changement de mesure dans les exercices de ce chapitre). Sa version probabiliste – pour une variable aléatoire X image d'une mesure de probabilité $\mathbb{P}$, plutôt que pour une mesure à densité – sera revue au Chapitre 9 « Variables aléatoires réelles » (Théorème 9.44 « Théorème de transfert ») ; les deux résultats, bien que voisins dans l'esprit (« changer la mesure d'intégration »), portent sur des opérations différentes : ici une même mesure de base μ est simplement *repondérée* par une densité g , alors que le théorème du Chapitre 9 « Variables aléatoires réelles » change entièrement d'espace via une application mesurable X .

Exemple 8.11

La mesure de Lebesgue λ restreinte à un borélien A (i.e. $B \mapsto \lambda(A \cap B)$) est absolument continue par rapport à λ , de densité $\mathbf{1}_A$. Plus généralement, toute loi de probabilité « à densité » au sens du Chapitre 9 « Variables aléatoires réelles » ($\mathbb{P}_X = f \cdot \lambda$) est, par définition même, absolument continue par rapport à λ .

8.2 Mesures étrangères

Définition 8.12 – Mesures étrangères, ou mutuellement singulières

Soit $(\Omega, \mathcal{T})$ un espace mesurable, μ, ν deux mesures sur $(\Omega, \mathcal{T})$. On dit que μ et ν sont **étrangères** (ou **mutuellement singulières**), et l'on note $\mu \perp \nu$, s'il existe $B \in \mathcal{T}$ tel que

$$\mu(B) = 0 \quad \text{et} \quad \nu(B^c) = 0.$$

Autrement dit, μ est tout entière « portée » par B^c , et ν tout entière « portée » par B : les deux mesures vivent sur deux parties disjointes de Ω .

Remarque 8.13

La relation $\perp$ est symétrique : si $\mu(B) = 0 = \nu(B^c)$, alors en posant $B' = B^c$, on a $\nu(B') = \nu(B^c) = 0$ et $\mu((B')^c) = \mu(B) = 0$. Elle diffère radicalement de l'absolue continuité $\nu \ll \mu$ (Définition 8.6 « Mesure absolument continue ») : $\nu \ll \mu$ signifie que ν ne peut charger que ce que μ charge déjà (même « support » au sens large), alors que $\mu \perp \nu$ signifie que les deux mesures ne partagent *aucun* support commun. Une mesure ne peut être à la fois absolument continue *et* étrangère par rapport à une même mesure $\mu \neq 0$, sauf à être nulle : si $\nu \ll \mu$ et $\nu \perp \mu$, alors $\nu(B^c) = 0$ et $\mu(B) = 0 \Rightarrow \nu(B) = 0$ (absolue continuité), donc $\nu(\Omega) = \nu(B) + \nu(B^c) = 0$.

Exemple 8.14

Une mesure discrète $\mu = \sum_i p_i \delta_{x_i}$ et la mesure de Lebesgue λ sont étrangères : on peut prendre $B = \{x_i\}_i$, avec $\lambda(B) = 0$ et $\mu(B^c) = 0$ (toute la masse de μ est concentrée sur B).

8.3 La mesure de Cantor

On construit à présent un exemple de mesure de probabilité **diffuse**, mais **étrangère** à la mesure de Lebesgue – ni discrète, ni à densité. L'idée est d'approcher cette mesure par une suite de mesures à densité, de plus en plus concentrées sur l'ensemble de Cantor $C = \bigcap_k C_k$ (Chapitre 1 « Autour de la mesure extérieure de Lebesgue »), tout en gardant toujours une masse totale égale à 1.

Propriété 8.15 – Construction de la mesure de Cantor

Pour $k \in \mathbb{N}$, rappelons que C_k est une réunion de 2^k segments fermés disjoints, chacun de longueur 3^{-k} , de sorte que $\lambda(C_k) = (2/3)^k$ (Chapitre 1 « Autour de la mesure extérieure de Lebesgue », Proposition 2.27 « L'ensemble de Cantor est fermé, non dénombrable, et négligeable »). Posons

$$\mu_k(A) := \left(\frac{3}{2}\right)^k \lambda(A \cap C_k), \quad A \in \mathcal{B}(\mathbb{R}).$$

Alors chaque μ_k est une mesure de probabilité, et il existe une unique mesure de probabilité ν_C sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ telle que, pour tout intervalle $I \subset \mathbb{R}$,

$$\nu_C(I) = \lim_{k \rightarrow +\infty} \mu_k(I).$$

Démonstration. La démonstration complète est donnée dans le TD5bis, partie 3, exercice 3.2. Elle construit ν_C comme mesure image de $\lambda|_{[0,1]}$ par l'application qui remplace les chiffres binaires 0, 1 par les chiffres ternaires 0, 2, puis montre que $|\mu_k(I) - \nu_C(I)| \leq 2^{1-k}$ pour tout intervalle I . ■

Définition 8.16 – Mesure de Cantor

L'unique mesure de probabilité ν_C fournie par la Proposition 8.15 « Construction de la mesure de Cantor » est appelée **mesure de Cantor** et est notée ν_C .

Remarque 8.17

$\mu_k([0, 1]) = \left(\frac{3}{2}\right)^k \lambda(C_k) = \left(\frac{3}{2}\right)^k \left(\frac{2}{3}\right)^k = 1$: chaque μ_k est bien une mesure de probabilité, quel que soit k – c'est précisément pour cela que l'on a choisi la constante de normalisation $(3/2)^k = 1/\lambda(C_k)$.



Figure 23: Représentation schématique des trois premières mesures μ_0 , μ_1 et μ_2 associées aux étapes C_0 , C_1 et C_2 de la construction de l'ensemble de Cantor.

Théorème 8.18 – Propriétés de la mesure de Cantor

La mesure de Cantor ν_C vérifie :

1. ν_C est une mesure de probabilité sur $\mathbb{R}$, avec $\nu_C(C) = 1$;
2. ν_C est **diffuse** (elle n'a aucun atome) ;
3. ν_C est **étrangère** à la mesure de Lebesgue λ : $\nu_C \perp \lambda$.

En particulier, ν_C n'est ni une mesure discrète (par le point 2), ni la mesure à densité d'une fonction par rapport à λ (par le point 3, cf. Remarque 8.19 « Pourquoi ν_C n'a pas de densité »).

Idée de preuve. Le point clé est de calculer la masse que ν_C attribue à chacun des 2^k segments de C_k : elle vaut exactement 2^{-k} , indépendamment de k et du segment choisi (par symétrie de la construction). On en déduit $\nu_C(C_k) = 1$ pour tout k , puis $\nu_C(C) = 1$ par continuité décroissante (les C_k décroissant vers C). La même estimation, appliquée au segment de C_k contenant un point donné x , montre que $\nu_C(\{x\}) \leq 2^{-k} \rightarrow 0$: ν_C est diffuse.

Démonstration. *Masse d'un segment de C_k .* Fixons $k \in \mathbb{N}$ et notons I l'un des 2^k segments constituant C_k , de longueur 3^{-k} . Pour $m \geq k$, $I \cap C_m$ est une réunion de 2^{m-k} des 2^m segments de C_m (ceux obtenus en poursuivant la construction à l'intérieur de I), chacun de longueur 3^{-m} , donc $\lambda(I \cap C_m) = 2^{m-k} \cdot 3^{-m}$. Ainsi

$$\mu_m(I) = \left(\frac{3}{2}\right)^m \lambda(I \cap C_m) = \frac{3^m}{2^m} \cdot 2^{m-k} \cdot \frac{1}{3^m} = \frac{2^{m-k}}{2^m} = 2^{-k},$$

et ceci pour **tout** $m \geq k$: la suite $(\mu_m(I))_{m \geq k}$ est constante, égale à 2^{-k} . Par la Proposition 8.15 « Construction de la mesure de Cantor », $\nu_C(I) = \lim_{m \rightarrow +\infty} \mu_m(I) = 2^{-k}$.

1. $\nu_C(C) = 1$. C_k est la réunion disjointe de ses 2^k segments, chacun de ν_C -masse 2^{-k} par ce qui précède ; par additivité finie, $\nu_C(C_k) = 2^k \cdot 2^{-k} = 1$, pour tout $k \in \mathbb{N}$. Comme $(C_k)_k$ est une suite décroissante d'ensembles (Chapitre 1 « Autour de la mesure extérieure de Lebesgue ») d'intersection C , la continuité décroissante de la mesure (Proposition 3.20 « Continuité croissante et décroissante », applicable car $\nu_C(C_0) = 1 < +\infty$) donne

$$\nu_C(C) = \lim_{k \rightarrow +\infty} \nu_C(C_k) = \lim_{k \rightarrow +\infty} 1 = 1.$$

Par ailleurs $\nu_C(\mathbb{R}) = 1$ par la Définition 8.16 « Mesure de Cantor ».

2. *Diffuse.* Soit $x \in \mathbb{R}$. Si $x \notin C$, alors $x \notin C_k$ pour k assez grand (C_k fermé décroissant vers C), et l'on peut isoler x dans un intervalle disjoint de C_k , de ν_C -mesure nulle par construction (densité nulle hors de C_k dans la limite) – ou plus simplement, $\nu_C(\{x\}) \leq \nu_C(C^c \cap \text{voisinage})$, nul puisque $\nu_C(C) = 1$ donne $\nu_C(C^c) = 0$. Si $x \in C$, alors pour tout k , x appartient à l'un des 2^k segments I_k de C_k (les I_k étant emboîtés, $I_0 \supset I_1 \supset \dots$, de longueur $3^{-k} \rightarrow 0$), et $\{x\} \subset I_k$, donc par croissance de ν_C et le calcul ci-dessus : $\nu_C(\{x\}) \leq \nu_C(I_k) = 2^{-k}$. En faisant $k \rightarrow +\infty$, $\nu_C(\{x\}) = 0$.

3. *Étrangère à λ .* Posons $B = C \in \mathcal{B}(\mathbb{R})$ (Proposition 2.27 « L'ensemble de Cantor est fermé, non dénombrable, et négligeable », point 1). D'une part $\lambda(B) = \lambda(C) = 0$ (Proposition 2.27 « L'ensemble de Cantor est fermé, non dénombrable, et négligeable », point 3). D'autre part $\nu_C(B^c) = \nu_C(\mathbb{R} \setminus C) = 1 - \nu_C(C) = 1 - 1 = 0$ (point 1 ci-dessus). Ainsi $\lambda(B) = 0 = \nu_C(B^c)$: par la Définition 8.12 « Mesures étrangères, ou mutuellement singulières », $\nu_C \perp \lambda$. ■

Remarque 8.19 – Pourquoi ν_C n'a pas de densité

Si l'on avait $\nu_C = g \cdot \lambda$ pour une fonction $g \geq 0$, alors $\nu_C(C) = \int_C g d\lambda$. Or $\lambda(C) = 0$ entraîne $\int_C g d\lambda = 0$ quelle que soit g (intégrer sur un ensemble Lebesgue-négligeable donne toujours 0) : on aurait $\nu_C(C) = 0$, ce qui contredit $\nu_C(C) = 1$. Ainsi ν_C n'est la densité d'aucune fonction par rapport à λ .

Définition 8.20 – Mesure singulière continue

Une mesure ν sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ est dite **singulière continue** lorsqu'elle est à la fois **diffuse** et **étrangère** à la mesure de Lebesgue λ , c'est-à-dire

$$\forall x \in \mathbb{R}, \quad \nu(\{x\}) = 0, \quad \text{et} \quad \nu \perp \lambda.$$

Ainsi, par le Théorème 8.18 « Propriétés de la mesure de Cantor », la mesure de Cantor ν_C est singulière continue.

8.4 Le théorème de Radon-Nikodym

Le théorème de Radon-Nikodym ci-dessous utilisera le Théorème 7.24 « Théorème de représentation de Riesz », établi au Chapitre 7 « Espaces L^p ». Dans la démonstration, on travaillera dans l'espace de Hilbert $L^2(\Omega, \mu + \nu)$. La Proposition 3.3 « Somme et multiplication positive de mesures » garantit que $\mu + \nu$ est bien une mesure, finie lorsque μ et ν le sont.

Théorème 8.21 – Théorème de Radon-Nikodym

Soient μ et ν deux mesures σ -finies sur $(\Omega, \mathcal{T})$, avec ν **absolument continue** par rapport à μ (c'est-à-dire : $\mu(A) = 0 \Rightarrow \nu(A) = 0$). Alors il existe une fonction mesurable $h : \Omega \rightarrow [0, +\infty]$, unique à un ensemble μ -négligeable près, telle que

$$\forall A \in \mathcal{T}, \quad \nu(A) = \int_A h \, d\mu.$$

On dit que h est la **densité** de ν par rapport à μ , notée $h = \frac{d\nu}{d\mu}$.

Idée de preuve. On traite le cas où μ, ν sont *finies* (le seul dont on aura besoin, puisqu'en pratique μ sera une probabilité). L'idée, due à von Neumann, est purement hilbertienne : on introduit la forme linéaire $f \mapsto \int f \, d\nu$ sur $L^2(\Omega, \mu + \nu)$, qui est continue (par Cauchy-Schwarz, car $\mu + \nu$ est finie d'après la Proposition 3.3 « Somme et multiplication positive de mesures »), donc représentée par un produit scalaire avec une fonction $k \in L^2(\mu + \nu)$ (Théorème 7.24 « Théorème de représentation de Riesz ») ; on vérifie que $0 \leq k < 1$ ($\mu + \nu$)-p.p. (sauf sur un ensemble μ -négligeable, où l'absolue continuité entre en jeu), ce qui permet d'isoler $h = \frac{k}{1-k}$ comme densité recherchée.

Démonstration. La démonstration complète, y compris le passage du cas fini au cas σ -fini, est donnée dans le TD5bis, partie 3, exercice 3.3. ■

8.5 Le théorème de décomposition de Lebesgue

On a donc, avec la mesure de Cantor, un exemple concret d'un troisième type de mesure, au-delà du discret et du continu à densité. Le Théorème 8.22 « Décomposition de Lebesgue » montre que ces trois types épuisent, en un sens précis, toutes les possibilités.

Théorème 8.22 – Décomposition de Lebesgue

Soient μ, ν deux mesures σ -finies sur un espace mesurable $(\Omega, \mathcal{T})$. Il existe un unique couple (ν_{ac}, ν_{sing}) de mesures sur $(\Omega, \mathcal{T})$ tel que

$$\nu = \nu_{ac} + \nu_{sing}, \quad \nu_{ac} \ll \mu, \quad \nu_{sing} \perp \mu.$$

Idée de preuve. L'argument reprend, presque à l'identique, la construction hilbertienne de la densité de Radon-Nikodym (Théorème 8.21 « Théorème de Radon-Nikodym ») : on applique ce théorème non pas à ν par rapport à μ (ce qui supposerait déjà $\nu \ll \mu$, l'hypothèse que l'on cherche justement à affaiblir), mais à ν par rapport à la mesure $\mu + \nu$, qui domine toujours ν (donc $\nu \ll \mu + \nu$ sans hypothèse supplémentaire). On obtient une densité $h = \frac{d\nu}{d(\mu + \nu)} \in [0, 1]$, et l'on sépare Ω selon que $h = 1$ ou $h < 1$: sur $\{h = 1\}$, μ ne

charge rien (c'est la partie « singulière » de ν) ; sur $\{h < 1\}$, on peut réexprimer ν comme une densité par rapport à μ (c'est la partie absolument continue).

Démonstration. La démonstration complète est donnée dans le TD5bis, partie 3, exercice 3.4. Elle précise en particulier la construction de la partie absolument continue sur $\{h < 1\}$ et l'argument d'unicité. ■

Remarque 8.23 – Densité de la partie absolument continue

Une fois l'existence établie, $\nu_{ac} \ll \mu$ (μ étant σ -finie) admet, par le théorème de Radon-Nikodym lui-même, une densité $g = \frac{d\nu_{ac}}{d\mu}$: on peut donc toujours écrire $\nu = g \cdot \mu + \nu_{sing}$ avec $\nu_{sing} \perp \mu$. C'est sous cette forme que l'on utilisera le théorème dans les exemples ci-dessous, avec $\mu = \lambda$.

Corollaire 8.24 – Décomposition d'une mesure finie sur $\mathbb{R}$

Soit ν une mesure finie sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Il existe une fonction mesurable $g : \mathbb{R} \rightarrow [0, +\infty[$ intégrable par rapport à λ , une famille au plus dénombrable de points distincts $(x_i)_{i \in I}$, des coefficients $p_i > 0$ tels que $\sum_{i \in I} p_i < +\infty$, et une mesure ν_{sc} singulière continue tels que

$$\nu = \underbrace{g \cdot \lambda}_{\text{à densité}} + \underbrace{\sum_{i \in I} p_i \delta_{x_i}}_{\text{discrète}} + \underbrace{\nu_{sc}}_{\text{singulière continue}}.$$

Cette décomposition est unique, à l'égalité λ -presque partout près pour g et à une permutation près des points (x_i) .

Démonstration. Appliquons le Théorème 8.22 « Décomposition de Lebesgue » avec $\mu = \lambda$. Puisque λ est σ -finie et ν est finie, il existe un unique couple (ν_{ac}, ν_{sing}) tel que

$$\nu = \nu_{ac} + \nu_{sing}, \quad \nu_{ac} \ll \lambda, \quad \nu_{sing} \perp \lambda.$$

Par le théorème de Radon-Nikodym, il existe une fonction mesurable $g \geq 0$, unique λ -p.p., telle que $\nu_{ac} = g \cdot \lambda$. Comme ν_{ac} est finie,

$$\int_{\mathbb{R}} g d\lambda = \nu_{ac}(\mathbb{R}) < +\infty,$$

donc $g \in L^1(\lambda)$.

Considérons maintenant l'ensemble des atomes de ν_{sing} ,

$$A := \{x \in \mathbb{R} : \nu_{sing}(\{x\}) > 0\}.$$

Comme ν_{sing} est finie, A est au plus dénombrable : en effet, pour $n \geq 1$, l'ensemble

$$A_n := \left\{ x \in A : \nu_{sing}(\{x\}) \geq \frac{1}{n} \right\}$$

est fini, sans quoi l'additivité sur des singletons disjoints contredirait $\nu_{sing}(\mathbb{R}) < +\infty$, et $A = \bigcup_{n \geq 1} A_n$. Écrivons donc $A = \{x_i : i \in I\}$ et posons

$$p_i := \nu_{sing}(\{x_i\}) > 0, \quad \nu_d := \sum_{i \in I} p_i \delta_{x_i}.$$

Alors $\sum_i p_i = \nu_{sing}(A) \leq \nu_{sing}(\mathbb{R}) < +\infty$. Enfin, définissons

$$\nu_{sc}(B) := \nu_{sing}(B \setminus A), \quad B \in \mathcal{B}(\mathbb{R}).$$

C'est une mesure, et pour tout borélien B ,

$$\nu_{sing}(B) = \nu_{sing}(B \cap A) + \nu_{sing}(B \setminus A) = \sum_{i \in I} p_i \delta_{x_i}(B) + \nu_{sc}(B).$$

La mesure ν_{sc} est diffuse par construction : si $x \in A$, sa masse a été retirée, et si $x \notin A$, alors $\nu_{sing}(\{x\}) = 0$. Elle est aussi étrangère à λ , car elle est une restriction de la mesure $\nu_{sing} \perp \lambda$. Elle est donc singulière continue.

L'unicité de ν_{ac} et de ν_{sing} vient du Théorème 8.22. À l'intérieur de ν_{sing} , la partie discrète est nécessairement constituée de tous ses atomes, avec leurs masses $\nu_{sing}(\{x\})$; la partie diffuse restante est alors imposée. La décomposition annoncée est donc unique. ■

Méthode 8.25 – Décomposer une mesure de probabilité sur $\mathbb{R}$

Pour une mesure de probabilité ν sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, le Corollaire 8.24 donne directement

$$\nu = \underbrace{g \cdot \lambda}_{\text{à densité}} + \underbrace{\sum_i p_i \delta_{x_i}}_{\text{discrète}} + \underbrace{\nu_{sc}}_{\text{singulière continue}},$$

avec $g \geq 0$, $\int_{\mathbb{R}} g d\lambda < +\infty$, $p_i > 0$, $\sum_i p_i < +\infty$ et ν_{sc} singulière continue. Comme $\nu(\mathbb{R}) = 1$, les masses des trois composantes vérifient en outre

$$\int_{\mathbb{R}} g d\lambda + \sum_i p_i + \nu_{sc}(\mathbb{R}) = 1.$$

Probabilités

9 Variables aléatoires réelles

Objectifs

- Faire le lien entre le langage probabiliste (variable aléatoire, loi, espérance) et le langage de la mesure (fonction mesurable, mesure image, intégrale).
- Connaître les lois usuelles, discrètes et à densité.
- Maîtriser la notion d'indépendance et ses caractérisations.

Introduction

On dispose maintenant de tout le matériel nécessaire : une notion de mesurabilité (Chapitre 4 « Fonctions mesurables ») et une notion d'intégrale (Chapitre 5 « Intégrale de Lebesgue ») valable pour n'importe quelle mesure, en particulier une mesure de *probabilité*. On peut donc enfin retrouver, dans ce cadre unifié, les objets déjà rencontrés en licence – variable aléatoire, loi, espérance – mais en levant les limitations qui séparaient jusqu'ici le cas discret du cas à densité.

Rappel de L2–L3 9.1 – probabilités discrètes et à densité

En licence, on distinguait deux mondes disjoints : les variables aléatoires **discrètes** (loi donnée par $\mathbb{P}(X = k)$ pour k dans un ensemble dénombrable, espérance $= \sum_k k \mathbb{P}(X = k)$) et les variables aléatoires **à densité** (loi donnée par une fonction $f \geq 0$, espérance $= \int x f(x) dx$). Le formalisme qui suit unifie complètement les deux cas : dans les deux, l'espérance sera *la même formule* $\int_{\Omega} X d\mathbb{P}$, et l'on retrouvera les deux formules usuelles comme cas particuliers (Théorème 9.44 « Théorème de transfert »).

9.1 Rappels : événements, mesure de probabilité, formules classiques

Avant d'introduire la notion de variable aléatoire, il est utile de rappeler – dans le seul langage des **événements** (parties de Ω), sans encore parler de fonctions mesurables – les formules de calcul des probabilités déjà rencontrées en licence, et de bien voir qu'elles ne sont jamais que des cas particuliers des propriétés générales des mesures établies au Chapitre 3 « Mesures ».

Rappel de L1–L2 9.2 – calcul des probabilités

On rappelle qu'un **espace probabilisé** est un espace mesuré particulier $(\Omega, \mathcal{T}, \mathbb{P})$ où $\mathbb{P}(\Omega) = 1$ (Définition 3.1 « Mesure, mesure finie, mesure σ -finie, mesure de probabilité », Chapitre 3 « Mesures ») : Ω est l'**univers** (l'ensemble de toutes les issues possibles de l'expérience aléatoire), $\mathcal{T}$ la tribu des **événements** (les parties de Ω auxquelles on sait attribuer une probabilité), et $\mathbb{P}$ la probabilité elle-même. **Toute** propriété générale des mesures (Chapitre 3 « Mesures ») s'applique donc telle quelle aux probabilités – il suffit de remplacer μ par $\mathbb{P}$ et de se rappeler que $\mathbb{P}(\Omega) = 1$.

Propriété 9.3 – Probabilité de l'événement contraire

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $A \in \mathcal{T}$. Alors $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.

Démonstration. A et A^c sont incompatibles (disjoints), de réunion Ω . Par additivité finie (Proposition 3.19 « Propriétés élémentaires d'une mesure », point 1, Chapitre 3 « Mesures »), $\mathbb{P}(A) + \mathbb{P}(A^c) = \mathbb{P}(\Omega) = 1$, d'où le résultat. ■

Exemple 9.4 – Un dé, un événement et son contraire

On lance un dé à 6 faces équilibré. On modélise l'expérience par $\Omega = \{1, \dots, 6\}$, $\mathcal{T} = \mathcal{P}(\Omega)$ (toutes les

parties, Ω étant fini), $\mathbb{P}$ la probabilité uniforme ($\mathbb{P}(\{k\}) = 1/6$ pour tout k). Soit $A = \{\text{le résultat est pair}\} = \{2, 4, 6\}$. Alors $\mathbb{P}(A) = 3/6 = 1/2$, et $\mathbb{P}(A^c) = \mathbb{P}(\{\text{le résultat est impair}\}) = 1 - 1/2 = 1/2$ – ce que l'on retrouve bien sûr directement, mais la Proposition 9.3 « Probabilité de l'événement contraire » dispense de recompter.

Propriété 9.5 – Formule du crible à deux événements – rappel

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $A, B \in \mathcal{T}$. Alors

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Démonstration. C'est exactement la Proposition 3.19 « Propriétés élémentaires d'une mesure » (point 3, Chapitre 3 « Mesures »), appliquée à $\mu = \mathbb{P}$ – ici toujours de mesure finie, puisque $\mathbb{P}(A), \mathbb{P}(B) \leq \mathbb{P}(\Omega) = 1$. ■

Exemple 9.6 – Un jeu de cartes

On tire une carte au hasard dans un jeu de 32 cartes (modélisation : $\Omega =$ l'ensemble des 32 cartes, $\mathcal{T} = \mathcal{P}(\Omega)$, $\mathbb{P}$ uniforme, $\mathbb{P}(\{c\}) = 1/32$ pour chaque carte c). Soit $A = \{\text{la carte est un cœur}\}$ ($|A| = 8$) et $B = \{\text{la carte est une figure (Valet, Dame, Roi)}\}$ ($|B| = 12$). Alors $A \cap B = \{\text{cœur et figure}\}$, de cardinal 3 (Valet, Dame, Roi de cœur). Par la formule du crible :

$$\mathbb{P}(A \cup B) = \frac{8}{32} + \frac{12}{32} - \frac{3}{32} = \frac{17}{32}.$$

Méthode 9.7 – Modéliser une expérience aléatoire (sans variable aléatoire)

Avant tout calcul, il faut fixer un espace probabilisé $(\Omega, \mathcal{T}, \mathbb{P})$ adapté à l'expérience décrite :

1. **Choisir Ω** : l'ensemble de **toutes** les issues élémentaires envisageables (assez fin pour distinguer les événements dont on veut parler, mais pas plus – inutile, par exemple, de distinguer l'ordre d'apparition de deux dés si seule leur somme importe).
2. **Choisir $\mathcal{T}$** : si Ω est fini ou dénombrable, on prend en général $\mathcal{T} = \mathcal{P}(\Omega)$ (tout est mesurable) ; sinon (cf. Chapitre 2 « Espace mesurable »), on choisit la tribu adaptée au problème (souvent $\mathcal{B}(\mathbb{R})$ ou $\mathcal{B}(\mathbb{R}^n)$).
3. **Choisir $\mathbb{P}$** : la probabilité qui traduit les hypothèses de l'énoncé (équiprobabilité si les issues sont « symétriques » ; sinon, une mesure construite à partir des données du problème – densité, poids, fréquences).

Une erreur fréquente est de choisir un Ω non adapté (trop grossier, oubliant des issues ; ou surchargé de détails superflus rendant le calcul de $\mathbb{P}$ inutilement compliqué).

Exemple 9.8 – Modélisation : un contrôle qualité en aéronautique

Un atelier de maintenance inspecte des rivets sur un tronçon de fuselage. Chaque rivet inspecté peut être conforme (C) ou défectueux (D), et l'atelier en inspecte 3 sur une même journée. On souhaite calculer la probabilité qu'**au plus un** rivet soit défectueux, sachant que chaque rivet a, indépendamment des autres, une probabilité $p = 0,02$ d'être défectueux (donnée statistique du constructeur).

Modélisation. On prend $\Omega = \{C, D\}^3$ (les $2^3 = 8$ séquences possibles de conformité des 3 rivets), $\mathcal{T} = \mathcal{P}(\Omega)$. Pour $\mathbb{P}$, l'hypothèse d'indépendance des rivets suggère de définir, pour $\omega = (\omega_1, \omega_2, \omega_3) \in \Omega$,

$$\mathbb{P}(\{\omega\}) := \prod_{i=1}^3 q(\omega_i), \quad \text{où } q(D) = p = 0,02, \quad q(C) = 1 - p = 0,98$$

(ceci définit bien une probabilité : les 8 valeurs sont positives et sommables à $\prod_i (q(C) + q(D)) = 1$ par la formule du binôme, cf. Chapitre 3 « Mesures »). L'événement « au plus un défectueux » est $A = \{\omega :$

au plus une coordonnée vaut D }, de cardinal $1+3=4$ (aucun D , ou exactement un D parmi les 3 positions). On calcule

$$\mathbb{P}(A) = q(C)^3 + 3pq(C)^2 = 0,98^3 + 3 \times 0,02 \times 0,98^2 \approx 0,9412 + 0,0576 = 0,9988.$$

On reconnaîtra dans cette construction – sans le nommer encore – le début du modèle de la loi binomiale, introduit formellement plus loin dans ce chapitre.

9.2 Probabilités conditionnelles et indépendance des événements

Définition 9.9 – Probabilité conditionnelle

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $B \in \mathcal{T}$ tel que $\mathbb{P}(B) > 0$. Pour $A \in \mathcal{T}$, on appelle **probabilité conditionnelle** de A sachant B le nombre

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Remarque 9.10

On vérifie sans peine que $A \mapsto \mathbb{P}(A \mid B)$ est elle-même une mesure de probabilité sur $(\Omega, \mathcal{T})$ (positivité et σ -additivité héritées de $\mathbb{P}$, et $\mathbb{P}(\Omega \mid B) = \mathbb{P}(B)/\mathbb{P}(B) = 1$) : c'est la probabilité « mise à jour » une fois l'information B connue – **on ne considère plus que les issues compatibles avec B** , renormalisées pour que leur probabilité totale reste 1.

Exemple 9.11 – Deux dés, une somme connue

On lance deux dés équilibrés indépendants ($\Omega = \{1, \dots, 6\}^2$, $\mathbb{P}$ uniforme). Soit $B = \{\text{la somme des deux dés vaut } 8\}$ et $A = \{\text{le premier dé vaut } 6\}$. On a $B = \{(2, 6), (3, 5), (4, 4), (5, 3), (6, 2)\}$, donc $\mathbb{P}(B) = 5/36$; et $A \cap B = \{(6, 2)\}$, donc $\mathbb{P}(A \cap B) = 1/36$. Ainsi

$$\mathbb{P}(A \mid B) = \frac{1/36}{5/36} = \frac{1}{5},$$

alors que $\mathbb{P}(A) = 1/6$: savoir que la somme vaut 8 modifie (ici, augmente légèrement) la probabilité que le premier dé soit un 6.

Propriété 9.12 – Formule des probabilités totales et formule de Bayes

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $(B_i)_{i \in I}$ un système complet d'événements (partition dénombrable de Ω , $\mathbb{P}(B_i) > 0$ pour tout i). Alors, pour $A \in \mathcal{T}$:

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A \mid B_i) \mathbb{P}(B_i) \quad (\text{probabilités totales}),$$

et, si de plus $\mathbb{P}(A) > 0$, pour tout $j \in I$:

$$\mathbb{P}(B_j \mid A) = \frac{\mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}{\sum_{i \in I} \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)} \quad (\text{formule de Bayes}).$$

Démonstration. Les $(A \cap B_i)_{i \in I}$ forment une partition de A (car les B_i partitionnent Ω), donc par σ -additivité, $\mathbb{P}(A) = \sum_i \mathbb{P}(A \cap B_i) = \sum_i \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$ (Définition 9.9 « Probabilité conditionnelle », en supposant $\mathbb{P}(B_i) > 0$ pour réécrire $\mathbb{P}(A \cap B_i) = \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$). La formule de Bayes s'obtient en écrivant $\mathbb{P}(B_j \mid A) = \frac{\mathbb{P}(A \cap B_j)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}{\mathbb{P}(A)}$, puis en remplaçant $\mathbb{P}(A)$ par la formule des probabilités totales.

■

Exemple 9.13 – Modélisation : alerte de dégivrage et conditions givrantes

Un capteur de givrage embarqué se déclenche (événement A) soit parce que les conditions sont réellement givrantes (événement B , $\mathbb{P}(B) = 0,05$ sur un vol donné, statistique météorologique), soit par un défaut du capteur en l'absence de givre. On donne $\mathbb{P}(A | B) = 0,98$ (le capteur détecte le givre quand il y en a) et $\mathbb{P}(A | B^c) = 0,03$ (fausse alerte). On veut $\mathbb{P}(B | A)$: sachant que l'alerte s'est déclenchée, quelle est la probabilité que les conditions soient réellement givrantes ?

Modélisation. $\{B, B^c\}$ est un système complet d'événements (une partition en deux, $\mathbb{P}(B), \mathbb{P}(B^c) > 0$). Par la formule des probabilités totales,

$$\mathbb{P}(A) = \mathbb{P}(A | B)\mathbb{P}(B) + \mathbb{P}(A | B^c)\mathbb{P}(B^c) = 0,98 \times 0,05 + 0,03 \times 0,95 = 0,049 + 0,0285 = 0,0775.$$

Par Bayes,

$$\mathbb{P}(B | A) = \frac{0,98 \times 0,05}{0,0775} = \frac{0,049}{0,0775} \approx 0,632.$$

Ainsi, malgré une détection très fiable (98 %) en présence de givre, seulement 63 % environ des alertes correspondent à un réel danger – conséquence de la rareté du givre (5 % des vols) combinée à un taux de fausses alertes non négligeable : c'est le même phénomène, bien connu, que celui des faux positifs dans un test médical de dépistage d'une maladie rare.

Définition 9.14 – Indépendance de deux événements

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $A, B \in \mathcal{T}$ avec $\mathbb{P}(A) > 0$. On dit que A et B sont **indépendants** si

$$\mathbb{P}(B | A) = \mathbb{P}(B) :$$

autrement dit, savoir que A est réalisé ne change rien à la probabilité de B – c'est exactement l'intuition que l'on attend de l'indépendance.

Propriété 9.15 – Caractérisations équivalentes de l'indépendance

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $A, B \in \mathcal{T}$ tels que $\mathbb{P}(A) > 0$ et $\mathbb{P}(B) > 0$. Les trois propriétés suivantes sont équivalentes :

1. $\mathbb{P}(B | A) = \mathbb{P}(B)$;
2. $\mathbb{P}(A | B) = \mathbb{P}(A)$;
3. $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$.

Démonstration. (1) $\Rightarrow$ (3) : par définition de la probabilité conditionnelle, $\mathbb{P}(B | A) = \mathbb{P}(B)$ signifie $\frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \mathbb{P}(B)$, soit $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ (licite, $\mathbb{P}(A) > 0$).

(3) $\Rightarrow$ (2) : $\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A)$ (licite, $\mathbb{P}(B) > 0$).

(2) $\Rightarrow$ (1) : par symétrie du raisonnement (1) $\Rightarrow$ (3) $\Rightarrow$ (2), en échangeant les rôles de A et B (l'hypothèse (2) donne $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ comme ci-dessus, d'où (1)). ■

Remarque 9.16

La caractérisation (3), $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$, a l'avantage de rester valable **même si** $\mathbb{P}(A) = 0$ **ou** $\mathbb{P}(B) = 0$ (les deux membres sont alors nuls, sans qu'il soit besoin de diviser par quoi que ce soit) : c'est pour cette raison qu'on la retient comme définition *générale* et opérationnelle de l'indépendance dans la suite de ce livret (elle est d'ailleurs symétrique en A, B , ce qui n'est pas immédiatement visible sur les formulations (1) ou (2)). **Indépendance** et **incompatibilité** ($A \cap B = \emptyset$) sont deux notions très différentes – deux événements incompatibles de probabilités non nulles ne sont jamais indépendants (savoir que l'un est réalisé exclut totalement l'autre, ce qui est l'opposé de l'indépendance).

Méthode 9.17 – En pratique, on vérifie l'indépendance par le produit

Pour **montrer** que deux événements A, B sont indépendants (ou pour l'utiliser dans un calcul), on emploie presque toujours, en pratique, la formule du produit

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B)$$

plutôt que l'une des deux formulations conditionnelles (1) ou (2) de la Proposition 9.15 « Caractérisations équivalentes de l'indépendance » : elle ne nécessite aucune hypothèse de positivité, elle est symétrique en A, B , et elle se généralise directement à un produit de plusieurs événements (indépendance mutuelle, Chapitre 9 « Variables aléatoires réelles ») ou de plusieurs variables aléatoires (Chapitre 10 « Vecteurs aléatoires »).

Exemple 9.18 – Modélisation : deux moteurs indépendants

Un avion bimoteur ne peut pas décoller si les deux moteurs tombent en panne simultanément. On modélise les deux pannes par des événements A_1, A_2 (panne du moteur 1, resp. 2) dans un espace probabilisé $(\Omega, \mathcal{T}, \mathbb{P})$ construit de sorte que A_1, A_2 soient indépendants (hypothèse de conception : les deux moteurs sont physiquement isolés l'un de l'autre, alimentés séparément), de probabilité $\mathbb{P}(A_1) = \mathbb{P}(A_2) = 10^{-4}$ par vol. Alors $\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2) = 10^{-8}$: c'est précisément l'hypothèse d'indépendance des pannes qui permet ce gain spectaculaire de fiabilité (une probabilité de panne totale bien plus faible que celle de chaque panne individuelle) – et c'est pourquoi la conception aéronautique s'efforce, autant que possible, de rendre les systèmes redondants réellement indépendants (sources d'alimentation, circuits hydrauliques séparés, etc.).

9.3 Variable aléatoire, loi, fonction de répartition

Définition 9.19 – Variable aléatoire

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, soit $(E, \mathcal{T}_E)$ un espace mesurable. Une application $X : \Omega \rightarrow E$ est une **variable aléatoire** à valeurs dans E si elle est mesurable. Si $E = \mathbb{R}$ (muni de $\mathcal{B}(\mathbb{R})$), on dit que X est une **variable aléatoire réelle**.

Remarque 9.20

Une variable aléatoire n'est donc *rien d'autre* qu'une fonction mesurable, au sens du Chapitre 4 « Fonctions mesurables », définie sur un espace *probabilisé* : tout le vocabulaire (stabilité par composition, par opérations algébriques, par sup/inf/limites) s'applique donc immédiatement.

Exemple 9.21

On lance un dé équilibré : $\Omega = \{1, \dots, 6\}$, muni de $\mathcal{P}(\Omega)$ et de la probabilité uniforme. L'application $X : \Omega \rightarrow \mathbb{R}$, $X(\omega) = \omega$, est une variable aléatoire réelle (toute application est mesurable ici, Ω étant fini muni de $\mathcal{P}(\Omega)$) : c'est le résultat du lancer. Ici $X = \text{id}$ et $\mathbb{P}_X = \mathbb{P}$ (la loi de X est simplement la probabilité uniforme sur $\{1, \dots, 6\}$).

Mais dès que l'on considère une fonction non triviale de plusieurs résultats, la loi change de nature : pour la somme de deux dés, $\Omega = \{1, \dots, 6\}^2$, $X(\omega_1, \omega_2) = \omega_1 + \omega_2$. X prend ses valeurs dans $\{2, \dots, 12\}$, avec une loi $\mathbb{P}_X$ différente de la loi uniforme sur Ω (par exemple $\mathbb{P}_X(\{7\}) = 6/36$, la valeur la plus probable, contre $\mathbb{P}_X(\{2\}) = 1/36$ seulement) : la variable aléatoire « transporte » la structure de Ω vers $\mathbb{R}$, mais sans en garder l'uniformité.

Exemple 9.22

On attend un temps aléatoire avant qu'un phénomène ne se produise (durée de vie d'une ampoule, temps

d'attente à un guichet). On modélise cela par $\Omega = \mathbb{R}^+$, muni de $\mathcal{B}(\mathbb{R}^+)$, et $T : \Omega \rightarrow \mathbb{R}^+$, $T(\omega) = \omega$ (l'identité) : T est une variable aléatoire réelle, représentant la durée observée. Contrairement à l'exemple du dé, T prend ici ses valeurs dans un continuum, ce qui imposera de travailler avec des lois à densité plutôt que discrètes (section suivante).

Définition 9.23 – Loi d'une variable aléatoire

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $(E, \mathcal{T}_E)$ un espace mesurable, $X : \Omega \rightarrow E$ une variable aléatoire. On appelle **loi** de X , notée $\mathbb{P}_X$, la mesure image de $\mathbb{P}$ par X :

$$\forall A \in \mathcal{T}_E, \quad \mathbb{P}_X(A) := \mathbb{P}(X^{-1}(A)) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in A\}) =: \mathbb{P}(X \in A).$$

Remarque 9.24 – Notations abrégées, cas d'une variable aléatoire réelle

Lorsque X est à valeurs réelles, on utilisera systématiquement les abréviations suivantes, pour $a \in \mathbb{R}$:

$$\mathbb{P}(X \leq a) := \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \leq a\}) = \mathbb{P}_X(]-\infty, a]), \quad \mathbb{P}(X = a) := \mathbb{P}(\{\omega \in \Omega \mid X(\omega) = a\}) = \mathbb{P}_X(\{a\}).$$

Plus généralement, pour toute partie $A \subset \mathbb{R}$ décrite par une condition sur X (par exemple $\{a \leq X < b\}$, $\{X \in \mathbb{N}\}$, etc.), on note $\mathbb{P}(\text{condition sur } X)$ la probabilité de l'événement $\{\omega \mid X(\omega) \text{ vérifie la condition}\}$ – pourvu que cet événement soit bien dans $\mathcal{T}$, ce qui est automatique dès que la condition définit un borélien de $\mathbb{R}$, par mesurabilité de X .

Remarque 9.25

$\mathbb{P}_X$ est bien une mesure de probabilité sur $(E, \mathcal{T}_E)$: $\mathbb{P}_X(E) = \mathbb{P}(X^{-1}(E)) = \mathbb{P}(\Omega) = 1$, et la σ -additivité de $\mathbb{P}_X$ découle directement de celle de $\mathbb{P}$ et des propriétés de l'image réciproque (Proposition 4.2 « Propriétés algébriques de l'image réciproque »).




Figure 24: La loi $\mathbb{P}_X$ est l'image de la mesure de probabilité $\mathbb{P}$ par la variable aléatoire X : elle « transporte » la masse de probabilité de Ω vers E .

Définition 9.26 – Fonction de répartition

Soit X une variable aléatoire réelle. On appelle **fonction de répartition** de X la fonction $F_X : \mathbb{R} \rightarrow [0, 1]$ définie par $F_X(a) = \mathbb{P}(X \leq a)$.

Exemple 9.27 – Fonction de répartition d'une variable uniforme sur $\{1, \dots, 6\}$

Reprenons le dé équilibré, X uniforme sur $\{1, \dots, 6\}$. Pour $a < 1$, $F_X(a) = \mathbb{P}(X \leq a) = 0$; pour $a \geq 6$, $F_X(a) = 1$; et pour $k \in \{1, \dots, 5\}$, $k \leq a < k+1$, $F_X(a) = \mathbb{P}(X \leq k) = \frac{k}{6}$ (les issues $1, \dots, k$, chacune de probabilité $\frac{1}{6}$). F_X est donc une fonction en escalier, constante par morceaux, avec un saut de hauteur $\frac{1}{6}$ en chaque entier de 1 à 6.




Figure 25: Fonction de répartition de la variable uniforme sur $\{1, \dots, 6\}$: un escalier à 6 marches égales, chacune de hauteur $\frac{1}{6}$, avec des sauts exactement aux valeurs $1, \dots, 6$ prises par X .

Propriété 9.28 – Propriétés de la fonction de répartition

Soit X une variable aléatoire réelle. Alors F_X est :

1. croissante sur $\mathbb{R}$;
2. de limite 0 en $-\infty$ et 1 en $+\infty$;
3. continue à droite en tout point ;
4. pourvue d'une limite à gauche en tout point $a \in \mathbb{R}$, égale à $F_X(a^-) = \mathbb{P}(X < a)$;
5. discontinue en a si et seulement si a est un **atome** de X (c'est-à-dire $\mathbb{P}(X = a) > 0$), le saut valant alors exactement $F_X(a) - F_X(a^-) = \mathbb{P}(X = a)$.

Idée de preuve. Il s'agit, à chaque fois, de traduire l'énoncé en termes de la mesure $\mathbb{P}_X$ appliquée à une suite bien choisie de demi-droites $]-\infty, a]$, puis d'invoquer les propriétés déjà connues d'une mesure (croissance, continuité monotone) établies au Chapitre 3 « Mesures ».

Démonstration. *Croissance.* Si $a \leq b$, alors $]-\infty, a] \subset]-\infty, b]$, donc $F_X(a) = \mathbb{P}_X(]-\infty, a]) \leq \mathbb{P}_X(]-\infty, b]) = F_X(b)$ par croissance d'une mesure (Proposition 3.19 « Propriétés élémentaires d'une mesure »).

Limites. On a $\bigcap_{n \in \mathbb{N}}]-\infty, -n] = \emptyset$, suite décroissante d'événements de mesure finie ($\mathbb{P}_X(]-\infty, 0]) \leq 1 < +\infty$) ; par continuité décroissante (Proposition 3.20 « Continuité croissante et décroissante »), $F_X(-n) = \mathbb{P}_X(]-\infty, -n]) \rightarrow \mathbb{P}_X(\emptyset) = 0$. De même, $\bigcup_{n \in \mathbb{N}}]-\infty, n] = \mathbb{R}$; par continuité croissante, $F_X(n) \rightarrow \mathbb{P}_X(\mathbb{R}) = 1$. La monotonie de F_X permet de passer de ces limites le long des entiers aux limites usuelles en $\pm\infty$.

Continuité à droite. Soit $a \in \mathbb{R}$, (t_n) une suite décroissant vers a . La suite $(]-\infty, t_n])_n$ est décroissante, d'intersection $]-\infty, a]$, et de mesure finie ; par continuité décroissante, $F_X(t_n) \rightarrow F_X(a)$. Ceci étant vrai pour toute suite décroissant vers a , F_X est continue à droite en a .

Limite à gauche. Soit $a \in \mathbb{R}$, (t_n) une suite croissant vers a ($t_n < a$ pour tout n). La suite $(]-\infty, t_n])_n$ est croissante, de réunion $]-\infty, a[$ (tout $x < a$ appartient à $]-\infty, t_n]$ dès que $t_n \geq x$, ce qui se produit pour n assez grand puisque $t_n \rightarrow a$) ; par continuité croissante (Proposition 3.20 « Continuité croissante et décroissante »), $F_X(t_n) = \mathbb{P}_X(]-\infty, t_n]) \rightarrow \mathbb{P}_X(]-\infty, a[) = \mathbb{P}(X < a)$. La monotonie de F_X (point 1) assure que cette limite ne dépend pas de la suite (t_n) choisie, croissant vers a : c'est bien la limite à gauche de F_X en a , que l'on note $F_X(a^-)$.

Discontinuités et atomes. F_X étant continue à droite (point 3) et pourvue d'une limite à gauche (point 4) en tout point, elle est discontinue en a si et seulement si $F_X(a) \neq F_X(a^-)$. Or $F_X(a) - F_X(a^-) = \mathbb{P}(X \leq a) - \mathbb{P}(X < a) = \mathbb{P}(\{X \leq a\} \setminus \{X < a\}) = \mathbb{P}(X = a)$ (les événements $\{X < a\} \subset \{X \leq a\}$, et leur différence est exactement $\{X = a\}$). Ainsi $F_X(a) \neq F_X(a^-) \iff \mathbb{P}(X = a) > 0 \iff a$ est un atome de X , et le saut vaut alors précisément $\mathbb{P}(X = a)$. ■




Figure 26: Fonction de répartition d'une variable **mixte** : deux sauts (une masse discrète en chaque point de discontinuité, $\mathbb{P}(X = x_i) > 0$) séparés par une branche strictement croissante et continue (une partie à densité, $\mathbb{P}(X \in]c, d]) = \int_c^d f$) – le cas purement discret (uniquement des sauts) et le cas purement à densité (une seule branche continue, sans saut) en sont les deux cas extrêmes.

Exemple 9.29 – L'escalier du diable

La mesure de Cantor ν_C (Chapitre 8 « Décomposition des mesures », Définition 8.16 « Mesure de Cantor ») est une mesure de probabilité sur $\mathbb{R}$: elle possède donc, elle aussi, une fonction de répartition $F_C(x) := \nu_C([-\infty, x])$, appelée **escalier du diable**. On admet (sans démonstration à ce stade) qu'elle vérifie :

- $F_C(0) = 0$ et $F_C(1) = 1$ (toute la masse de ν_C est portée par $C \subset [0, 1]$, Chapitre 8 « Décomposition des mesures ») ;
- F_C est **continue** sur $\mathbb{R}$ (car ν_C est diffuse, sans atome – Chapitre 8 « Décomposition des mesures », Théorème 8.18 « Propriétés de la mesure de Cantor ») ;
- F_C est **constante sur chaque intervalle retiré** de la construction de l'ensemble de Cantor (car ν_C n'y charge rien) – donc constante sur un ensemble de mesure de Lebesgue totale 1, bien que (non strictement) croissante de 0 à 1 sur $[0, 1]$ tout entier !




Figure 27: À gauche, les premières étapes de l'escalier du diable F_C : une fonction continue, croissante de 0 à 1, mais constante sur chacun des intervalles retirés de la construction de l'ensemble de Cantor (les « marches » de l'escalier). À droite, le véritable escalier du diable, limite de ces approximations successives (tracé ici avec un grand nombre d'étapes de la construction) : il reste continu, croissant de 0 à 1, et constant sur un ensemble de mesure de Lebesgue totale 1 (les intervalles retirés), malgré son allure visuellement lisse. C'est exactement la fonction de répartition d'une mesure *singulière continue* (Chapitre 8 « Décomposition des mesures ») : ni discrète (pas de saut, puisque F_C est continue), ni à densité (une densité donnerait une fonction *strictement* croissante sur tout intervalle non retiré... ce qui n'est jamais le cas ici, en un sens que l'on ne détaille pas).

Propriété 9.30 – Caractérisation de la loi par la fonction de répartition

Soient X, Y deux variables aléatoires réelles. Alors $\mathbb{P}_X = \mathbb{P}_Y \iff F_X = F_Y$.

Idée de preuve. [admise] Le sens direct est immédiat ($F_X(a) = \mathbb{P}_X([-\infty, a])$). Pour la réciproque, on introduit $\mathcal{D} = \{A \in \mathcal{B}(\mathbb{R}) \mid \mathbb{P}_X(A) = \mathbb{P}_Y(A)\}$: c'est un système de Dynkin (Définition 3.10 « Système de Dynkin », Chapitre 3 « Mesures ») contenant la famille $([-\infty, a])_{a \in \mathbb{R}}$, stable par intersection finie ; le Théorème 3.12 « Théorème π - λ (Dynkin) » permet de conclure que $\mathcal{D}$ contient toute la tribu engendrée par cette famille, c'est-à-dire $\mathcal{B}(\mathbb{R})$ tout entier.

Méthode 9.31 – Montrer que deux variables ont la même loi

La Proposition 9.30 « Caractérisation de la loi par la fonction de répartition » ramène l'égalité de deux lois de probabilité sur $\mathbb{R}$ à l'égalité de leurs fonctions de répartition – un objet à une seule variable réelle, souvent bien plus simple à manipuler qu'une mesure sur $\mathcal{B}(\mathbb{R})$. Ce principe se généralise, au Chapitre 12 « Vecteurs aléatoires gaussiens », à la fonction caractéristique, qui offre un outil encore plus maniable (car linéarisant la somme de variables indépendantes).

9.4 Variables discrètes et variables à densité

Définition 9.32 – Variable aléatoire discrète

Soit X une variable aléatoire réelle. On dit que X est **discrète** s'il existe une partie dénombrable $S \subset \mathbb{R}$ telle que $\mathbb{P}(X \in S) = 1$.

Exemple 9.33

Toute variable aléatoire finie (à valeurs dans un ensemble fini) ou à valeurs dans $\mathbb{N}$ est discrète. C'est le cadre des lois usuelles appelées ci-dessous (binomiale, Poisson, géométrique, etc.).

Définition 9.34 – Variable aléatoire à densité

Soit X une variable aléatoire réelle. On dit que X est **à densité** (ou **absolument continue**) s'il existe $f : \mathbb{R} \rightarrow \mathbb{R}^+$ mesurable, avec $\int_{\mathbb{R}} f(t) dt = 1$, telle que

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}(X \in A) = \int_A f(t) dt.$$

La fonction f est appelée **densité** de X .

Démonstration. Il faut vérifier que $A \mapsto \int_A f dt$ définit bien une mesure de probabilité : $\int_{\mathbb{R}} f dt = 1$ par hypothèse (normalisation), la positivité est immédiate ($f \geq 0$ et monotonie de l'intégrale, Proposition 5.23 « Monotonie »), et la σ -additivité s'obtient en appliquant le Théorème 5.28 « Théorème de convergence monotone » (version série) à une famille de boréliens deux à deux disjoints. ■

Propriété 9.35 – Le théorème de Radon-Nikodym, en probabilités

Soit X une variable aléatoire réelle, $\mathbb{P}_X$ sa loi, λ la mesure de Lebesgue sur $\mathbb{R}$. Les deux propositions suivantes sont équivalentes :

1. X est à densité, au sens de la Définition 9.34 « Variable aléatoire à densité » ;
2. $\mathbb{P}_X \ll \lambda$ (la loi de X est absolument continue par rapport à λ).

Dans ce cas, la densité f_X de X n'est autre que la dérivée de Radon-Nikodym $\frac{d\mathbb{P}_X}{d\lambda}$: elle est unique à un ensemble λ -négligeable près (deux densités d'une même loi coïncident λ -presque partout). De plus, en tout point de continuité de f_X , la fonction de répartition F_X est dérivable, de dérivée $F'_X = f_X$ (théorème fondamental du calcul intégral).

Remarque 9.36

On ne redémontre pas cette proposition : elle n'est que la relecture, dans le cas particulier $\mu = \mathbb{P}_X$ et λ la mesure de Lebesgue sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, du théorème de Radon-Nikodym général (Chapitre 8 « Décomposition des mesures ») et de la Proposition 8.9 « Formule de transfert pour une mesure à densité » (formule de transfert pour une mesure à densité). Elle explique, en particulier, pourquoi la notion de « densité » et celle d'« absolue continuité de la loi par rapport à λ » sont une seule et même chose – un fait souvent utilisé sans être formulé explicitement.

Exemple 9.37 – Loi uniforme sur un segment

Pour $I = [a, b]$, la fonction $f = \frac{1}{b-a} \mathbf{1}_I$ est une densité de probabilité (dite **uniforme** sur I , notée $\mathcal{U}([a, b])$) : elle est positive et $\int_{\mathbb{R}} f dt = \frac{b-a}{b-a} = 1$.




Figure 28: Densité de probabilité f : la probabilité que X tombe dans $[a, b]$ est l'aire sous la courbe entre a et b , soit $\int_a^b f(t) dt$.




Figure 29: Densité de la loi uniforme $\mathcal{U}([a, b])$: constante, égale à $\frac{1}{b-a}$ sur $[a, b]$, nulle ailleurs – l'aire du rectangle vaut bien $(b-a) \times \frac{1}{b-a} = 1$.

Attention 9.38

Une variable aléatoire n'est ni nécessairement discrète, ni nécessairement à densité : il existe des lois « mixtes » (combinaison des deux) et même des lois continues mais non absolument continues (lois « singulières »), comme par exemple la mesure uniforme sur l'ensemble triadique de Cantor (Chapitre 8 « Décomposition des mesures »). On retiendra que discret et à densité sont deux cas particuliers, non exhaustifs, mais qui couvrent l'immense majorité des situations rencontrées en pratique.

Exemple 9.39 – Une loi mixte : la durée de vie d'un avion

Illustrons le cas « mixte » évoqué ci-dessus. Une cellule d'avion a une durée de vie naturelle T^* de densité f sur $]0, +\infty[$ (par exemple exponentielle), mais la réglementation impose un retrait de service forcé à 30 ans : la durée de vie *effective* est $X = \min(T^*, 30)$. Alors X n'est ni purement discrète, ni purement à densité :

$$\mathbb{P}(a < X < b) = \int_a^b f(t) dt \quad \text{si } a < b < 30, \quad \mathbb{P}(X = 30) = 1 - \int_0^{30} f(t) dt.$$

La loi de X combine ainsi une partie à densité f sur $]0, 30[$ et un atome en 30 (la probabilité que l'avion atteigne la limite réglementaire en état de fonctionnement).

9.5 Espérance, moments, variance

Définition 9.40 – Espérance, moment, variance

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, X une variable aléatoire réelle.

- Si X est $\mathbb{P}$ -intégrable, on appelle **espérance** de X le réel $\mathbb{E}(X) := \int_{\Omega} X(\omega) d\mathbb{P}$.
- Pour $k \geq 1$ entier, on dit que X admet un **moment d'ordre k** si $|X|^k$ est intégrable ; on note alors $\mathbb{E}(X^k)$ ce moment.
- Si X admet un moment d'ordre 2, on appelle **variance** de X le réel $\text{Var}(X) := \mathbb{E}((X - \mathbb{E}(X))^2)$.

Remarque 9.41 – Ce que mesurent concrètement l'espérance et la variance

L'espérance $\mathbb{E}(X)$ est la valeur **moyenne** que prend X , pondérée par sa loi : si l'on répétait l'expérience aléatoire un très grand nombre de fois et que l'on faisait la moyenne arithmétique des valeurs obtenues, on obtiendrait (loi des grands nombres, Chapitre 13 « Convergence de suites de variables aléatoires ») un résultat de plus en plus proche de $\mathbb{E}(X)$. C'est le point d'équilibre, le « centre de masse » de la loi de X .

La variance $\text{Var}(X)$ mesure, elle, la **dispersion** des valeurs de X autour de cette moyenne : c'est la moyenne des carrés des écarts à $\mathbb{E}(X)$. Une variance petite signifie que X prend, avec une forte probabilité, des valeurs proches de $\mathbb{E}(X)$; une variance grande signifie que X peut s'écarter fortement de sa moyenne (l'inégalité de Bienaymé-Tchebychev, Chapitre 7 « Espaces L^p », rend cette intuition quantitative). On élève les écarts au carré plutôt que de prendre leur valeur absolue essentiellement pour des raisons de commodité de calcul (linéarité, formule de Koenig-Huygens ci-dessous) : $\sqrt{\text{Var}(X)}$, appelé **écart-type** de X , se ramène à la même unité que X et s'interprète comme une distance typique à la moyenne.

Rappel de L3 9.42 – formule de Koenig-Huygens

On rappelle la formule $\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$, obtenue en développant le carré $(X - \mathbb{E}(X))^2 = X^2 - 2X\mathbb{E}(X) + \mathbb{E}(X)^2$ puis en utilisant la linéarité de l'espérance (elle-même linéarité de l'intégrale, Proposition 5.22 « Linéarité de l'intégrale »). Cette formule reste, comme en licence, le moyen le plus rapide de calculer une variance en pratique.

Exemple 9.43 – Espérance, variance et écart-type du lancer d'un dé

Soit X le résultat du lancer d'un dé à 6 faces équilibré : X suit la loi uniforme sur $\{1, \dots, 6\}$, $\mathbb{P}(X = k) = \frac{1}{6}$ pour $k \in \{1, \dots, 6\}$.

Espérance. $\mathbb{E}(X) = \sum_{k=1}^6 k \times \frac{1}{6} = \frac{1+2+3+4+5+6}{6} = \frac{21}{6} = 3,5$. **Interprétation :** 3,5 n'est bien sûr jamais

une valeur *observée* du dé (qui prend ses valeurs dans $\{1, \dots, 6\}$), mais c'est la valeur autour de laquelle se stabilise la moyenne d'un grand nombre de lancers (loi des grands nombres, Chapitre 13 « Convergence de suites de variables aléatoires ») – le point d'équilibre de la loi, exactement au milieu de 1 et 6 par symétrie.

Variance, par la formule directe. $\text{Var}(X) = \mathbb{E}((X-3,5)^2) = \sum_{k=1}^6 (k-3,5)^2 \times \frac{1}{6} = \frac{(-2,5)^2 + (-1,5)^2 + (-0,5)^2 + (0,5)^2 + (1,5)^2 + (2,5)^2}{6} = \frac{6,25 + 2,25 + 0,25 + 0,25 + 2,25 + 6,25}{6} = \frac{17,5}{6} = \frac{35}{12}$.

Variance, par la formule de Koenig-Huygens. $\mathbb{E}(X^2) = \sum_{k=1}^6 k^2 \times \frac{1}{6} = \frac{1+4+9+16+25+36}{6} = \frac{91}{6}$, donc

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \frac{91}{6} - (3,5)^2 = \frac{91}{6} - \frac{49}{4} = \frac{182 - 147}{12} = \frac{35}{12}$$

(même résultat que par la formule directe, comme il se doit – mais obtenu ici sans avoir à calculer les six écarts $(k - 3,5)^2$ un par un, seulement $\mathbb{E}(X^2)$: c'est tout l'intérêt pratique de Koenig-Huygens). **Interprétation**

: $\text{Var}(X) = 35/12 \approx 2,92$ mesure la dispersion *au carré* des valeurs du dé autour de 3,5 – une quantité dont l'unité (des « points au carré ») n'a pas de sens physique direct, ce qui motive de lui préférer l'écart-type pour interpréter la dispersion.

Écart-type. $\sqrt{\text{Var}(X)} = \sqrt{35/12} \approx 1,708$. **Interprétation** : un lancer de dé s'écarte typiquement de sa moyenne 3,5 d'environ 1,7 point – une grandeur exprimée dans la même unité que X (des points du dé), donc directement comparable aux valeurs observées : par exemple, l'intervalle $[\mathbb{E}(X) - \text{écart-type}, \mathbb{E}(X) + \text{écart-type}] \approx [1,79, 5,21]$ contient déjà 4 des 6 issues possibles (2, 3, 4, 5), illustrant concrètement que l'écart-type donne l'ordre de grandeur des valeurs « typiques ».

Théorème 9.44 – Théorème de transfert

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire, $g : \mathbb{R} \rightarrow \mathbb{R}$ mesurable. Alors, dès que l'un des membres est bien défini,

$$\mathbb{E}(g(X)) = \int_{\mathbb{R}} g(x) d\mathbb{P}_X(x).$$

Idee de preuve. C'est encore une démonstration « par approximations successives » : on établit l'égalité pour les indicatrices (cas immédiat, définition de la loi image), on l'étend par linéarité aux fonctions étagées, puis par convergence monotone aux fonctions positives, et enfin par différence aux fonctions de signe quelconque.

Démonstration. *Cas $g = \mathbf{1}_A$, A borélien.* $\mathbb{E}(\mathbf{1}_A(X)) = \mathbb{E}(\mathbf{1}_{X^{-1}(A)}) = \mathbb{P}(X \in A) = \mathbb{P}_X(A) = \int_{\mathbb{R}} \mathbf{1}_A d\mathbb{P}_X$ (la troisième égalité par définition de la loi image, la dernière par définition de l'intégrale d'une indicatrice).

Cas g étagée. Combinaison linéaire finie du cas précédent, par linéarité des deux membres (Proposition 5.22 « Linéarité de l'intégrale »).

Cas $g \geq 0$ mesurable. Par le Théorème 5.4 « Lemme d'approximation », on choisit (g_n) étagées positives croissant simplement vers g . Alors $g_n(X)$ croît simplement vers $g(X)$, et par le Théorème 5.28 « Théorème de convergence monotone » appliqué de part et d'autre :

$$\mathbb{E}(g(X)) = \lim_n \mathbb{E}(g_n(X)) = \lim_n \int_{\mathbb{R}} g_n d\mathbb{P}_X = \int_{\mathbb{R}} g d\mathbb{P}_X$$

(l'égalité du milieu étant le cas déjà traité des fonctions étagées).

Cas g de signe quelconque. On écrit $g = g^+ - g^-$, on applique le cas positif à g^+ et g^- séparément, puis on soustrait (licite dès que l'un des membres, donc les deux par le cas positif, est fini). ■

Remarque 9.45 – Le théorème de transfert comme changement de variable par mesure image

Le Théorème 9.44 « Théorème de transfert » n'est qu'un cas particulier d'un principe plus général de **changement de variable** : pour $f : (E, \mathcal{T}_E, \mu) \rightarrow (F, \mathcal{T}_F)$ mesurable et $h : F \rightarrow \mathbb{R}$ mesurable,

$$\int_F h d(f(\mu)) = \int_E h \circ f d\mu$$

(« intégrer sur l'espace d'arrivée contre la mesure image revient à intégrer sur l'espace de départ la fonction composée »), où $f(\mu)$ est la mesure image de μ par f (Définition 4.32 « Mesure image », Chapitre 4 « Fonctions mesurables »). La démonstration ci-dessus (par approximations successives) n'utilise à aucun moment que μ soit une mesure de *probabilité* : elle établit en réalité cette formule générale, pour μ, f, h quelconques. Le Théorème 9.44 « Théorème de transfert » en est le cas particulier $E = \Omega, \mu = \mathbb{P}, f = X, F = \mathbb{R}, h = g$, avec $f(\mu) = \mathbb{P}_X$ (Définition 4.32 « Mesure image » appliquée à X) :

$$\mathbb{E}(g(X)) = \int_{\Omega} g(X(\omega)) d\mathbb{P}(\omega) = \int_{\mathbb{R}} g d\mathbb{P}_X.$$

Si de plus X admet une densité f_X (i.e. $\mathbb{P}_X = f_X \cdot \lambda$), un *second* changement de variable – celui-ci sur les mesures à densité (Proposition 8.9 « Formule de transfert pour une mesure à densité », Chapitre 8 « Décomposition des mesures ») – donne $\int_{\mathbb{R}} g d\mathbb{P}_X = \int_{\mathbb{R}} g(x) f_X(x) dx$, ce qui redonne la formule familière avec densité. Ces deux changements de variable (mesure image, puis mesure à densité) sont d'une nature différente : le premier change entièrement d'espace via X ; le second répond à une même mesure sur un même espace – ils ne doivent pas être confondus avec le changement de variable « à la jacobienne » du Chapitre 6 « Intégrales multiples » (lequel n'intervient, lui, que si l'on souhaite en plus réexprimer une intégrale sur $\mathbb{R}^n$ dans un système de coordonnées différent).

Remarque 9.46 – On retrouve enfin les formules de licence !

C'est le Théorème 9.44 « Théorème de transfert » qui reconnecte ce formalisme aux formules apprises en licence.

- Si X est discrète à valeurs dans S dénombrable, en prenant $g(x) = x$ et en décomposant $\mathbb{P}_X$ comme somme de masses de Dirac $\sum_{k \in S} \mathbb{P}(X = k) \delta_k$, on retrouve $\mathbb{E}(X) = \sum_{k \in S} k \mathbb{P}(X = k)$.
- Si X est à densité f , alors $\mathbb{P}_X$ a pour densité f par rapport à la mesure de Lebesgue, et l'on retrouve $\mathbb{E}(g(X)) = \int_{\mathbb{R}} g(x) f(x) dx$.

Le Théorème 9.44 « Théorème de transfert » est donc l'outil que l'on utilisera, dans la quasi-totalité des exercices, pour calculer effectivement une espérance.

Exemple 9.47 – Calcul d'un moment via le transfert

Soit X de loi exponentielle de paramètre $\lambda > 0$, i.e. de densité $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{]0, +\infty[}(x)$. Le Théorème 9.44 « Théorème de transfert » donne, pour $k \geq 1$,

$$\mathbb{E}(X^k) = \int_0^{+\infty} x^k \lambda e^{-\lambda x} dx \stackrel{t=\lambda x}{=} \frac{1}{\lambda^k} \int_0^{+\infty} t^k e^{-t} dt = \frac{k!}{\lambda^k},$$

par intégrations par parties successives (ou reconnaissance de la fonction Γ d'Euler, $\Gamma(k+1) = k!$). On en déduit en particulier $\mathbb{E}(X) = 1/\lambda$ et, par Koenig-Huygens, $\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$.

Méthode 9.48 – Calculer une espérance ou une variance

1. Identifier si X est discrète ou à densité (ou utiliser directement le Théorème 9.44 « Théorème de transfert » dans le cas général) ;
2. Écrire $\mathbb{E}(g(X))$ comme une série (cas discret) ou une intégrale (cas à densité) via le Théorème 9.44 « Théorème de transfert », avec $g(x) = x$ pour l'espérance, $g(x) = x^2$ pour le moment d'ordre 2 ;
3. Pour la variance, préférer systématiquement la formule de Koenig-Huygens $\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$ plutôt que de développer directement $\mathbb{E}((X - \mathbb{E}(X))^2)$.

Exercice 9.49 – Moments d'une loi normale centrée réduite

Soit $X \sim \mathcal{N}(0, 1)$, de densité $f(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$. Montrer que $\mathbb{E}(X^{2k+1}) = 0$ pour tout $k \in \mathbb{N}$, et calculer $\text{Var}(X)$.

Solution

La fonction $x \mapsto x^{2k+1}f(x)$ est impaire (produit d'une fonction impaire par une fonction paire), donc son intégrale sur $\mathbb{R}$ (lorsqu'elle est bien définie, ce qui est le cas ici par croissances comparées) est nulle par symétrie : $\mathbb{E}(X^{2k+1}) = 0$. En particulier $\mathbb{E}(X) = 0$. Pour $\mathbb{E}(X^2)$, une intégration par parties (en dérivant $x \mapsto e^{-x^2/2}$ dont la primitive apparaît naturellement) donne $\mathbb{E}(X^2) = 1$, d'où $\text{Var}(X) = 1 - 0^2 = 1$.

9.6 Rappel : les inégalités fondamentales du Chapitre 7 « Espaces L^p », en version probabiliste

Le Chapitre 7 « Espaces L^p » a établi, pour un espace mesuré $(\Omega, \mathcal{T}, \mu)$ *quelconque*, une série d'inégalités fondamentales. Le cas particulier $\mu = \mathbb{P}$ (mesure de probabilité) de ces résultats est si constamment utilisé en probabilités qu'il est utile de le réénoncer ici, en langage probabiliste $(X, \mathbb{E}, \text{Var}, \mathbb{P})$, une fois pour toutes. **Aucune de ces propositions n'est redémontrée** : les preuves, identiques, se trouvent au Chapitre 7 « Espaces L^p » (il suffit d'y remplacer $(\Omega, \mathcal{T}, \mu)$ par $(\Omega, \mathcal{T}, \mathbb{P})$ et une fonction mesurable f par une variable aléatoire X).

Propriété 9.50 – Inégalité de Markov – version probabiliste

Soit X une variable aléatoire réelle positive, $a > 0$. Alors

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}.$$

(Cas particulier $\mu = \mathbb{P}$ de la Proposition 7.7 « Inégalité de Markov ».)

Propriété 9.51 – Inégalité de Bienaymé-Tchebychev – version probabiliste

Soit X une variable aléatoire réelle de carré intégrable, $c \in \mathbb{R}$. Alors

$$\forall \varepsilon > 0, \quad \mathbb{P}(|X - c| \geq \varepsilon) \leq \frac{1}{\varepsilon^2} \mathbb{E}((X - c)^2).$$

En particulier, pour $c = \mathbb{E}(X)$:

$$\forall \varepsilon > 0, \quad \mathbb{P}(|X - \mathbb{E}(X)| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}.$$

(Cas particulier $\mu = \mathbb{P}$ de la Proposition 7.8 « Inégalité de Bienaymé-Tchebychev ».)

Propriété 9.52 – Inégalité de Cauchy–Schwarz – version probabiliste

Soient X, Y deux variables aléatoires réelles de carré intégrable. Alors XY est intégrable et

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2)} \sqrt{\mathbb{E}(Y^2)}.$$

(Cas particulier $p = q = 2$, $\mu = \mathbb{P}$, de l'inégalité de Hölder, Proposition 7.10 « Inégalité de Hölder ».)

Propriété 9.53 – Inégalité de Hölder – version probabiliste

Soient X, Y deux variables aléatoires réelles, $p, q \in]1, +\infty[$ conjugués ($\frac{1}{p} + \frac{1}{q} = 1$). Si $\mathbb{E}(|X|^p) < +\infty$ et $\mathbb{E}(|Y|^q) < +\infty$, alors XY est intégrable et

$$\mathbb{E}(|XY|) \leq \mathbb{E}(|X|^p)^{1/p} \mathbb{E}(|Y|^q)^{1/q}.$$

(Cas particulier $\mu = \mathbb{P}$ de la Proposition 7.10 « Inégalité de Hölder ».)

Propriété 9.54 – Inégalité de Minkowski – version probabiliste

Soient X, Y deux variables aléatoires réelles admettant un moment d'ordre $p \geq 1$. Alors $X + Y$ admet un moment d'ordre p et

$$\mathbb{E}(|X + Y|^p)^{1/p} \leq \mathbb{E}(|X|^p)^{1/p} + \mathbb{E}(|Y|^p)^{1/p}.$$

(Cas particulier $\mu = \mathbb{P}$ de la Proposition 7.14 « Inégalité de Minkowski ».)

Propriété 9.55 – Inégalité de Jensen – version probabiliste

Soit X une variable aléatoire réelle intégrable, $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ convexe telle que $\varphi(X)$ soit également intégrable. Alors

$$\varphi(\mathbb{E}(X)) \leq \mathbb{E}(\varphi(X)).$$

(Cas particulier $\mu = \mathbb{P}$, donc $\mu(\Omega) = 1$, de la Proposition 7.17 « Inégalité de Jensen ».)

Corollaire 9.56 – Inclusion des espaces de moments

Soit X une variable aléatoire réelle, $1 \leq q < p \leq +\infty$. Si X admet un moment d'ordre p (ou est bornée, si $p = +\infty$), alors X admet un moment d'ordre q : $L^p(\Omega, \mathbb{P}) \subset L^q(\Omega, \mathbb{P})$. Autrement dit, en probabilités, **plus l'ordre du moment est élevé, plus l'hypothèse est forte**. (Cas particulier $\mu = \mathbb{P}$, mesure finie, du Corollaire 7.11 « Inclusion $L^p \subset L^q$ en mesure finie ».)

Méthode 9.57 – Retrouver rapidement la bonne inégalité

1. Pour majorer $\mathbb{P}(X \geq a)$ ($X \geq 0$) à partir de $\mathbb{E}(X)$ seul : Markov.
2. Pour majorer $\mathbb{P}(|X - \mathbb{E}(X)| \geq \varepsilon)$ à partir de $\text{Var}(X)$: Bienaymé-Tchebychev – l'outil de base pour établir une convergence en probabilité ou une loi des grands nombres (Chapitre 13 « Convergence de suites de variables aléatoires »).
3. Pour majorer $|\mathbb{E}(XY)|$ ou $\mathbb{E}(|XY|)$ à partir des moments séparés de X et Y : Cauchy–Schwarz (cas $p = q = 2$) ou Hölder (cas général).
4. Pour comparer $\varphi(\mathbb{E}(X))$ et $\mathbb{E}(\varphi(X))$, φ convexe usuelle (x^2 , $|x|$, $e^x \dots$) : Jensen.
5. Pour vérifier qu'un moment d'ordre plus faible existe déjà : Corollaire 9.56 « Inclusion des espaces de moments » (aucun calcul à faire).

9.7 Lois usuelles

Rappel de L1–L2 9.58 – lois discrètes usuelles

On rappelle brièvement les lois discrètes déjà rencontrées en licence ; le formalisme de ce chapitre ne change rien à leur définition, il en précise seulement le cadre (fonction mesurable sur un espace probabilisé).

Loi	$\mathbb{P}(X = k)$	Espérance	Variance
Bernoulli $\mathcal{B}(p)$	$\mathbb{P}(X = 0) = 1 - p, \mathbb{P}(X = 1) = p$	p	$p(1 - p)$
Binomiale $\mathcal{B}(n, p)$	$\binom{n}{k} p^k (1 - p)^{n-k}, 0 \leq k \leq n$	np	$np(1 - p)$
Géométrique $\mathcal{G}(p)$	$(1 - p)^{k-1} p, k \geq 1$	$1/p$	$(1 - p)/p^2$
Poisson $\mathcal{P}(\lambda)$	$e^{-\lambda} \lambda^k / k!, k \geq 0$	λ	λ





Figure 30: Diagrammes en bâtons de deux lois discrètes usuelles.

Exemple 9.59 – Loi de Poisson comme approximation

La loi de Poisson $\mathcal{P}(\lambda)$ s'obtient comme limite de lois binomiales $\mathcal{B}(n, \lambda/n)$ quand $n \rightarrow +\infty$ (« loi des événements rares ») : c'est un résultat classique de convergence en loi que l'on peut redémontrer avec les outils du Chapitre 12 « Vecteurs aléatoires gaussiens » (fonctions caractéristiques), voir Exercice 13.31 « Poisson comme limite de la loi normale ».

Rappel de L2–L3 9.60 – lois à densité usuelles

On rappelle de même les lois à densité usuelles.

Loi	Densité $f(x)$	Espérance	Variance
Uniforme $\mathcal{U}([a, b])$	$\frac{1}{b-a} \mathbf{1}_{[a,b]}(x)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponentielle $\mathcal{E}(\lambda)$	$\lambda e^{-\lambda x} \mathbf{1}_{]0,+\infty[}(x)$	$1/\lambda$	$1/\lambda^2$
Normale $\mathcal{N}(\mu, \sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$	μ	σ^2
Normale centrée réduite $\mathcal{N}(0, 1)$	$\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$	0	1



Figure 31: Densités de deux lois continues usuelles.




Figure 32: À gauche : trois lois $\mathcal{N}(\mu, 1)$ de même variance mais de moyennes différentes – la courbe se **translate** horizontalement sans changer de forme. À droite : trois lois $\mathcal{N}(0, \sigma^2)$ de même moyenne mais de variances différentes – plus σ^2 est grand, plus la courbe est **aplatie et étalée**, et plus σ^2 est petit, plus elle est **concentrée et pointue** autour de la moyenne.

Remarque 9.61 – Pourquoi la courbe s’aplatit ou se resserre

Rappelons que la variance mesure la dispersion des valeurs autour de la moyenne (Remarque 9.41 « Ce que mesurent concrètement l’espérance et la variance »). Sur le graphique de droite, les trois courbes ont la *même aire totale* sous la courbe (toujours 1, puisque f est une densité de probabilité) : si σ^2 augmente, cette aire fixe doit se répartir sur une plage de valeurs de x plus large, ce qui oblige la courbe à s’**aplatir** (baisser en hauteur) pour compenser ; si σ^2 diminue, l’aire se concentre au contraire sur une plage étroite autour de 0, ce qui force la courbe à monter en hauteur et devenir plus **pointue**. Une variance grande signifie donc concrètement : « X prend souvent des valeurs assez loin de sa moyenne » ; une variance petite signifie : « X prend presque toujours des valeurs très proches de sa moyenne ». Ainsi, la courbe σ^2 grand est plus aplatie précisément parce qu’un grand écart-type autorise, avec une probabilité non négligeable, de grands écarts à la moyenne (ici 0) : la masse de probabilité, plutôt que de rester concentrée près de 0, se répand vers des valeurs de x éloignées, ce qui abaisse mécaniquement la hauteur du pic pour que l’aire totale reste égale à 1.

Inversement, lorsque $\sigma \rightarrow 0$, la courbe se concentre de plus en plus étroitement autour de 0 : on devine que la suite de lois $\mathcal{N}(0, \sigma^2)$ converge, en un certain sens (que l’on précisera au Chapitre 13 « Convergence de suites de variables aléatoires », sous le nom de **convergence en loi**), vers une masse de Dirac δ_0 – la loi « certaine » qui vaut 0 avec probabilité 1. C’est cohérent avec l’intuition : une variance nulle correspondrait à une absence totale de dispersion, donc à une variable aléatoire constante.

Exercice 9.62 – Moments de la loi uniforme

Soit $X \sim \mathcal{U}([a, b])$. Calculer $\mathbb{E}(X^k)$ pour $k \in \mathbb{N}$, puis retrouver $\text{Var}(X) = \frac{(b-a)^2}{12}$.

Solution

Par le Théorème 9.44 « Théorème de transfert », $\mathbb{E}(X^k) = \frac{1}{b-a} \int_a^b x^k dx = \frac{b^{k+1} - a^{k+1}}{(k+1)(b-a)}$. En particulier $\mathbb{E}(X) = \frac{a+b}{2}$ et $\mathbb{E}(X^2) = \frac{a^2 + ab + b^2}{3}$. Par Koenig-Huygens : $\text{Var}(X) = \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} = \frac{(b-a)^2}{12}$ après réduction au même dénominateur.

9.8 Indépendance

Définition 9.63 – Indépendance de deux variables aléatoires

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $X_1, X_2 : \Omega \rightarrow \mathbb{R}$ deux variables aléatoires. On dit que X_1 et X_2 sont **indépendantes** si

$$\forall (A, B) \in \mathcal{B}(\mathbb{R})^2, \quad \mathbb{P}(X_1 \in A, X_2 \in B) = \mathbb{P}(X_1 \in A) \mathbb{P}(X_2 \in B).$$

Plus généralement, $(X_i)_{1 \leq i \leq n}$ sont **mutuellement indépendantes** si $\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n \mathbb{P}(X_i \in A_i)$ pour tous boréliens $A_1, \dots, A_n$.

Exemple 9.64 – Deux lancers de dés

On lance deux dés équilibrés, l'un après l'autre, sans qu'aucun n'influence l'autre : on modélise cela par $\Omega = \{1, \dots, 6\}^2$, muni de la probabilité uniforme, $X_1(\omega_1, \omega_2) = \omega_1$, $X_2(\omega_1, \omega_2) = \omega_2$. Alors X_1, X_2 sont indépendantes : pour $k, l \in \{1, \dots, 6\}$, $\mathbb{P}(X_1 = k, X_2 = l) = \frac{1}{36} = \frac{1}{6} \cdot \frac{1}{6} = \mathbb{P}(X_1 = k) \mathbb{P}(X_2 = l)$ (un seul couple (ω_1, ω_2) réalise $X_1 = k, X_2 = l$, parmi les 36 équiprobables), et cette factorisation, valable pour tout (k, l) , entraîne (Méthode 9.71 « Montrer que deux variables sont indépendantes » ci-dessous) l'indépendance de X_1 et X_2 .

Exemple 9.65 – Deux temps d'attente indépendants

Si $X \sim \mathcal{E}(\lambda)$ et $Y \sim \mathcal{E}(\mu)$ modélisent les temps d'attente de deux phénomènes physiquement sans rapport (désintégration de deux atomes distincts, pannes de deux machines indépendantes), on les suppose indépendants : $\mathbb{P}(X \leq s, Y \leq t) = \mathbb{P}(X \leq s) \mathbb{P}(Y \leq t) = (1 - e^{-\lambda s})(1 - e^{-\mu t})$ pour tous $s, t \geq 0$. C'est cette hypothèse d'indépendance, jamais automatique, qui permettra par exemple de calculer la loi de $\min(X, Y)$ ou de $X + Y$ (Chapitre 10 « Vecteurs aléatoires »).

Attention 9.66 – Indépendance mutuelle $\neq$ indépendance deux à deux

Comme en licence, l'indépendance mutuelle d'une famille est une propriété strictement plus forte que l'indépendance deux à deux : il existe des triplets de variables deux à deux indépendantes mais pas mutuellement indépendantes (construction classique à partir de deux pièces équilibrées X, Y et de $Z := \mathbf{1}_{X=Y}$, détaillée au TD, Chapitre 9 « Variables aléatoires réelles »).

Propriété 9.67 – Caractérisation de l'indépendance

Soient X_1, X_2 deux variables aléatoires réelles. Les trois propositions suivantes sont équivalentes :

1. X_1 et X_2 sont indépendantes ;
2. la loi du couple $X = (X_1, X_2)$ est le produit tensoriel $\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2}$;
3. pour toutes fonctions $\varphi, \psi : \mathbb{R} \rightarrow \mathbb{R}$ continues bornées, $\mathbb{E}(\varphi(X_1)\psi(X_2)) = \mathbb{E}(\varphi(X_1)) \mathbb{E}(\psi(X_2))$.

Idée de preuve. (1) $\Rightarrow$ (2) : les deux mesures $\mathbb{P}_X$ et $\mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2}$ coïncident sur les pavés $A \times B$ (par hypothèse),

qui engendrent $\mathcal{B}(\mathbb{R}^2)$ et forment une famille stable par intersection ; le Corollaire 3.13 « Unicité d'une mesure déterminée par un π -système générateur » étend l'égalité à toute la tribu. (2) $\Rightarrow$ (3) : c'est le Théorème 9.44 « Théorème de transfert » combiné au Théorème 6.6 « Théorème de Fubini-Tonelli », Chapitre 6 « Intégrales multiples », qui factorise l'intégrale double en produit d'intégrales simples dès que la mesure est un produit tensoriel. (3) $\Rightarrow$ (1) s'obtient en approchant $\mathbf{1}_A$ et $\mathbf{1}_B$ par des fonctions continues bornées, puis en passant à la limite via convergence monotone/dominée. Le détail complet, qui ne fait qu'exécuter ce programme, est donné ci-dessous.

Démonstration. (1) $\Rightarrow$ (2). Les deux mesures $\mathbb{P}_X$ et $\mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2}$ sur $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$ sont des mesures de probabilité ($\mathbb{P}_X(\mathbb{R}^2) = 1$ trivialement, et $(\mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2})(\mathbb{R}^2) = \mathbb{P}_{X_1}(\mathbb{R})\mathbb{P}_{X_2}(\mathbb{R}) = 1$), donc de même masse totale finie. Elles coïncident sur les pavés $A \times B$ ($A, B \in \mathcal{B}(\mathbb{R})$) : $\mathbb{P}_X(A \times B) = \mathbb{P}(X_1 \in A, X_2 \in B) = \mathbb{P}(X_1 \in A)\mathbb{P}(X_2 \in B) = \mathbb{P}_{X_1}(A)\mathbb{P}_{X_2}(B) = (\mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2})(A \times B)$, où la deuxième égalité est exactement l'hypothèse d'indépendance (1). Les pavés forment un π -système engendrant $\mathcal{B}(\mathbb{R}^2)$ (Chapitre 6 « Intégrales multiples ») : par le Corollaire 3.13 « Unicité d'une mesure déterminée par un π -système générateur », $\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2}$ sur $\mathcal{B}(\mathbb{R}^2)$ tout entier.

(2) $\Rightarrow$ (3). Soient $\varphi, \psi : \mathbb{R} \rightarrow \mathbb{R}$ continues bornées. Par le Théorème 9.44 « Théorème de transfert » appliqué au vecteur $X = (X_1, X_2)$ et à la fonction $(x_1, x_2) \mapsto \varphi(x_1)\psi(x_2)$ (mesurable bornée, donc intégrable pour une mesure de probabilité) :

$$\mathbb{E}(\varphi(X_1)\psi(X_2)) = \int_{\mathbb{R}^2} \varphi(x_1)\psi(x_2) d\mathbb{P}_X(x_1, x_2) = \int_{\mathbb{R}^2} \varphi(x_1)\psi(x_2) d(\mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2})(x_1, x_2)$$

par l'hypothèse (2). Le Théorème 6.6 « Théorème de Fubini-Tonelli », Chapitre 6 « Intégrales multiples » – applicable, l'intégrande étant bornée donc intégrable pour la mesure produit finie $\mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2}$ – factorise cette intégrale double :

$$\int_{\mathbb{R}^2} \varphi(x_1)\psi(x_2) d(\mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2}) = \left(\int_{\mathbb{R}} \varphi d\mathbb{P}_{X_1} \right) \left(\int_{\mathbb{R}} \psi d\mathbb{P}_{X_2} \right) = \mathbb{E}(\varphi(X_1)) \mathbb{E}(\psi(X_2)),$$

la dernière égalité étant à nouveau le Théorème 9.44 « Théorème de transfert », appliqué séparément à X_1 et X_2 .

(3) $\Rightarrow$ (1). Soient $A, B \in \mathcal{B}(\mathbb{R})$. On admet (résultat de régularité sur $\mathbb{R}$, analogue à celui établi sur les intervalles au Chapitre 1 « Autour de la mesure extérieure de Lebesgue ») qu'il existe des suites de fonctions continues bornées $(\varphi_n)_n, (\psi_n)_n$, à valeurs dans $[0, 1]$, convergeant simplement vers $\mathbf{1}_A, \mathbf{1}_B$ respectivement. Par (3), $\mathbb{E}(\varphi_n(X_1)\psi_n(X_2)) = \mathbb{E}(\varphi_n(X_1))\mathbb{E}(\psi_n(X_2))$ pour tout n . Les suites $(\varphi_n(X_1)\psi_n(X_2))_n, (\varphi_n(X_1))_n, (\psi_n(X_2))_n$ étant toutes dominées par 1 (intégrable, mesure de probabilité) et convergeant simplement vers $\mathbf{1}_A(X_1)\mathbf{1}_B(X_2), \mathbf{1}_A(X_1), \mathbf{1}_B(X_2)$ respectivement, le Théorème 5.33 « Théorème de convergence dominée » permet de passer à la limite dans chaque terme :

$$\mathbb{P}(X_1 \in A, X_2 \in B) = \mathbb{E}(\mathbf{1}_A(X_1)\mathbf{1}_B(X_2)) = \mathbb{E}(\mathbf{1}_A(X_1)) \mathbb{E}(\mathbf{1}_B(X_2)) = \mathbb{P}(X_1 \in A) \mathbb{P}(X_2 \in B),$$

ce qui est exactement (1). ■

Corollaire 9.68 – Espérance d'un produit, variance d'une somme de variables indépendantes

Soient X_1, X_2 deux variables aléatoires réelles indépendantes.

1. Si X_1, X_2 sont intégrables et $X_1 X_2$ est intégrable, alors $\mathbb{E}(X_1 X_2) = \mathbb{E}(X_1)\mathbb{E}(X_2)$.
2. Si X_1, X_2 sont de carré intégrable, alors $X_1 X_2$ est intégrable, $\mathbb{E}(X_1 X_2) = \mathbb{E}(X_1)\mathbb{E}(X_2)$, et

$$\text{Var}(X_1 + X_2) = \text{Var}(X_1) + \text{Var}(X_2).$$

Démonstration. 1. C'est le point (3) de la Proposition 9.67 « Caractérisation de l'indépendance », étendu de φ, ψ continues bornées à $\varphi(x) = x, \psi(x) = x$ (non bornées) : on approche φ, ψ par des fonctions continues bornées $\varphi_n(x) := \max(-n, \min(x, n))$ (troncature), qui convergent simplement vers l'identité, et on conclut par convergence dominée (Théorème 5.33 « Théorème de convergence dominée ») de part et d'autre, en utilisant l'intégrabilité de $X_1, X_2, X_1 X_2$ pour dominer.




Figure 33: Sous indépendance, la loi du couple (X_1, X_2) donne à chaque pavé $A \times B$ la masse $\mathbb{P}_{X_1}(A) \cdot \mathbb{P}_{X_2}(B)$: la loi jointe est le produit tensoriel des lois marginales.

2. Par l'inégalité de Cauchy–Schwarz (Proposition 9.52 « Inégalité de Cauchy–Schwarz – version probabiliste »), X_1, X_2 de carré intégrable entraîne $X_1 X_2$ intégrable, et le point 1 s'applique. Pour la variance, en développant (linéarité de l'espérance) :

$$\text{Var}(X_1 + X_2) = \mathbb{E}((X_1 + X_2)^2) - \mathbb{E}(X_1 + X_2)^2 = \mathbb{E}(X_1^2) + 2\mathbb{E}(X_1 X_2) + \mathbb{E}(X_2^2) - (\mathbb{E}(X_1) + \mathbb{E}(X_2))^2.$$

En développant le carré à droite et en utilisant $\mathbb{E}(X_1 X_2) = \mathbb{E}(X_1)\mathbb{E}(X_2)$ (point 1), les termes croisés $2\mathbb{E}(X_1)\mathbb{E}(X_2)$ s'annulent deux à deux, laissant

$$\text{Var}(X_1 + X_2) = (\mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2) + (\mathbb{E}(X_2^2) - \mathbb{E}(X_2)^2) = \text{Var}(X_1) + \text{Var}(X_2).$$

■

Remarque 9.69

Ce corollaire s'étend immédiatement, par récurrence, à n variables mutuellement indépendantes : $\text{Var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{Var}(X_i)$. C'est ce résultat, ainsi anticipé dès ce chapitre, que le Chapitre 10 « Vecteurs aléatoires » généralisera encore à des combinaisons linéaires quelconques (via la notion de covariance et de matrice de covariance, utile lorsque les variables ne sont plus indépendantes).

Exemple 9.70

Soient $X \sim \mathcal{E}(\lambda)$ et $Y \sim \mathcal{E}(\mu)$ indépendantes. Le couple (X, Y) a alors pour loi la mesure de densité $(x, y) \mapsto \lambda \mu e^{-\lambda x - \mu y} \mathbf{1}_{[0, +\infty[^2}(x, y)$ sur $\mathbb{R}^2$ (produit des deux densités), ce qui permet de calculer par exemple la loi de $X + Y$ par un changement de variable (cf. Exercice 13.32 « Somme de deux lois exponentielles » du Chapitre 13 « Convergence de suites de variables aléatoires »).

Méthode 9.71 – Montrer que deux variables sont indépendantes

En pratique, on utilise rarement la définition brute (portant sur *tous* les boréliens). On préfère :

1. Si les variables sont à densité, vérifier que la densité du couple se factorise : $f_{(X,Y)}(x, y) = f_X(x)f_Y(y)$;
2. Si les variables sont discrètes, vérifier que $\mathbb{P}(X = k, Y = l) = \mathbb{P}(X = k)\mathbb{P}(Y = l)$ pour tout couple (k, l) ;
3. Utiliser le point (3) de la Proposition 9.67 « Caractérisation de l'indépendance » (factorisation de l'espérance d'un produit) lorsque l'énoncé le fournit directement – c'est souvent le cas dans les exercices de construction explicite (cf. Chapitre 13 « Convergence de suites de variables aléatoires »).

Exercice 9.72 – Un couple de variables exponentielles

Soient $\lambda, \mu > 0$. On suppose que pour toute fonction $\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}$ continue bornée,

$$\mathbb{E}(\varphi(X, Y)) = \int_{]0, +\infty[^2} \varphi(x, y) \lambda e^{-\lambda x} \mu e^{-\mu y} dx dy.$$

Montrer que $X \sim \mathcal{E}(\lambda)$, $Y \sim \mathcal{E}(\mu)$, et que X, Y sont indépendantes.

Solution

En prenant $\varphi(x, y) = \varphi_1(x)$ (fonction d'une seule variable), le théorème de Fubini permet d'intégrer d'abord en y : $\int_0^{+\infty} \mu e^{-\mu y} dy = 1$, d'où $\mathbb{E}(\varphi_1(X)) = \int_0^{+\infty} \varphi_1(x) \lambda e^{-\lambda x} dx$: $X \sim \mathcal{E}(\lambda)$. On montre de même $Y \sim \mathcal{E}(\mu)$. Enfin, en prenant $\varphi(x, y) = \varphi_1(x) \varphi_2(y)$, l'hypothèse donne directement $\mathbb{E}(\varphi_1(X) \varphi_2(Y)) = \mathbb{E}(\varphi_1(X)) \mathbb{E}(\varphi_2(Y))$: c'est le point (3) de la Proposition 9.67 « Caractérisation de l'indépendance », donc X et Y sont indépendantes.

9.9 Compléments : fonction génératrice et paradoxe de Bertrand

Définition 9.73 – Fonction génératrice

Soit X une variable aléatoire à valeurs dans $\mathbb{N}$. On appelle **fonction génératrice** de X la fonction

$$G_X(s) := \mathbb{E}(s^X) = \sum_{k=0}^{+\infty} \mathbb{P}(X = k) s^k, \quad s \in [-1, 1].$$

Remarque 9.74

G_X est bien définie sur $[-1, 1]$ (série entière de rayon de convergence ≥ 1 , car $\sum_k \mathbb{P}(X = k) = 1$). C'est l'analogue, pour les variables à valeurs entières, de la fonction caractéristique – souvent plus simple à manipuler dans ce cas particulier, car elle évite le passage aux nombres complexes.

Propriété 9.75 – La fonction génératrice caractérise la loi

Soient X, Y deux variables aléatoires à valeurs dans $\mathbb{N}$. Si $G_X = G_Y$ (égalité des fonctions génératrices sur $[-1, 1]$, ou même seulement au voisinage de 0), alors X et Y ont la même loi.

Démonstration. G_X est développable en série entière au voisinage de 0 (rayon de convergence ≥ 1), de coefficients de Taylor $\mathbb{P}(X = k) = \frac{G_X^{(k)}(0)}{k!}$ pour tout $k \in \mathbb{N}$ (formule de Taylor pour les séries entières, cours d'Analyse). Si $G_X = G_Y$ au voisinage de 0, l'unicité du développement en série entière donne $G_X^{(k)}(0) = G_Y^{(k)}(0)$ pour tout k , donc $\mathbb{P}(X = k) = \mathbb{P}(Y = k)$ pour tout $k \in \mathbb{N}$: les lois de X et Y coïncident sur $\mathbb{N}$, donc partout (car $\mathbb{P}(X \in \mathbb{N}) = \mathbb{P}(Y \in \mathbb{N}) = 1$). ■

Rappel de L2 9.76 – séries entières

On rappelle qu'une série entière $\sum_k a_k s^k$ est indéfiniment dérivable à l'intérieur de son rayon de convergence R , avec dérivation terme à terme : $(\sum_k a_k s^k)^{(j)} = \sum_{k \geq j} \frac{k!}{(k-j)!} a_k s^{k-j}$. Ici $R \geq 1$ (car $\sum_k \mathbb{P}(X = k) = 1 < \infty$), ce qui justifie la dérivation de G_X sur $] -1, 1[$; en $s = 1$ (bord du disque de convergence), il faut un argument supplémentaire (convergence monotone) pour passer à la limite, d'où la formulation en termes de dérivée à gauche $G'_X(1^-)$.

Propriété 9.77 – Propriétés de la fonction génératrice

Soit X à valeurs dans $\mathbb{N}$. Alors :

1. $G_X(1) = 1$, G_X est croissante et convexe sur $[0, 1]$;
2. si X admet une espérance, G_X est dérivable en 1^- (dérivée à gauche) avec $G'_X(1^-) = \mathbb{E}(X)$; plus généralement, si X admet un moment factoriel d'ordre k , $G_X^{(k)}(1^-) = \mathbb{E}(X(X-1) \cdots (X-k+1))$;
3. si $X_1, \dots, X_n$ sont indépendantes à valeurs dans $\mathbb{N}$, $G_{X_1+\dots+X_n} = G_{X_1} \times \cdots \times G_{X_n}$.

Idée de preuve. Le point 1 découle des propriétés élémentaires des séries entières à coefficients positifs sommant à 1. Le point 2 s'obtient par dérivation terme à terme d'une série entière (licite à l'intérieur du rayon de convergence, puis passage à la limite en 1^- par convergence monotone). Le point 3 est une conséquence directe de la factorisation de l'espérance d'un produit de variables indépendantes.

Démonstration. Notons $p_k := \mathbb{P}(X = k)$, de sorte que $G_X(s) = \sum_{k \geq 0} p_k s^k$.

Point 1. $G_X(1) = \sum_k p_k = 1$ (les p_k sommant à 1). Pour $0 \leq s \leq s' \leq 1$, $s^k \leq s'^k$ pour tout $k \geq 0$, donc $G_X(s) = \sum_k p_k s^k \leq \sum_k p_k s'^k = G_X(s')$ (série à termes positifs, comparaison terme à terme) : G_X est croissante sur $[0, 1]$. Sur $] -1, 1[$ (intérieur du rayon de convergence, cf. rappel ci-dessus), G_X est deux fois dérivable terme à terme, avec $G''_X(s) = \sum_{k \geq 2} k(k-1)p_k s^{k-2} \geq 0$ pour $s \in [0, 1[$ (chaque terme est positif) : G_X est convexe sur $[0, 1[$, et par continuité (série entière) sur $[0, 1]$.

Point 2. Pour $s \in] -1, 1[$, la dérivation terme à terme (rappel ci-dessus) donne $G'_X(s) = \sum_{k \geq 1} k p_k s^{k-1}$. Pour $s \in [0, 1[$, c'est une somme de termes positifs, croissante en s (chaque terme $k p_k s^{k-1}$ croît avec $s \geq 0$) : par convergence monotone (théorème de convergence monotone, version série, Théorème 5.28 « Théorème de convergence monotone »), $\lim_{s \rightarrow 1^-} G'_X(s) = \sum_{k \geq 1} k p_k = \mathbb{E}(X)$ (cette dernière somme étant finie par hypothèse d'existence de l'espérance) : c'est exactement $G'_X(1^-) = \mathbb{E}(X)$. Le même argument, appliqué à la j -ème dérivée $G_X^{(j)}(s) = \sum_{k \geq j} \frac{k!}{(k-j)!} p_k s^{k-j}$ (rappel ci-dessus), donne $G_X^{(j)}(1^-) = \sum_{k \geq j} \frac{k!}{(k-j)!} p_k = \mathbb{E}(X(X-1) \cdots (X-j+1))$ dès que ce moment factoriel existe.

Point 3. Pour $s \in [0, 1]$ fixé, la fonction $x \mapsto s^x$ est continue bornée sur $\mathbb{R}$ (à valeurs dans $[0, 1]$). Par la Proposition 9.67 « Caractérisation de l'indépendance » (point 3, étendue à n variables par récurrence : l'indépendance mutuelle de $X_1, \dots, X_n$ entraîne celle, deux à deux, des variables $s^{X_1}, \dots, s^{X_n}$, puis la factorisation de l'espérance du produit) :

$$G_{X_1+\dots+X_n}(s) = \mathbb{E}(s^{X_1+\dots+X_n}) = \mathbb{E}(s^{X_1} \times \cdots \times s^{X_n}) = \prod_{i=1}^n \mathbb{E}(s^{X_i}) = \prod_{i=1}^n G_{X_i}(s),$$

et ceci pour tout $s \in [0, 1]$, donc $G_{X_1+\dots+X_n} = G_{X_1} \times \cdots \times G_{X_n}$. ■

Démonstration. [point 2, esquisse] Pour $s \in [0, 1[$, $G'_X(s) = \sum_{k \geq 1} k \mathbb{P}(X = k) s^{k-1}$ (dérivation terme à terme, série entière). Chaque terme est positif et croît vers $k \mathbb{P}(X = k)$ quand $s \rightarrow 1^-$; par convergence monotone (somme sur k , version série du Théorème 5.28 « Théorème de convergence monotone »), $\lim_{s \rightarrow 1^-} G'_X(s) = \sum_{k \geq 1} k \mathbb{P}(X = k) = \mathbb{E}(X)$ (dès que cette dernière quantité est finie). Le cas des moments factoriels d'ordre supérieur s'obtient de façon identique en dérivant k fois. ■

Exemple 9.78 – Fonctions génératrices usuelles

Pour $X \sim \mathcal{B}(n, p)$, $G_X(s) = \sum_{k=0}^n \binom{n}{k} p^k s^k (1-p)^{n-k} = (1-p+ps)^n$. Pour $X \sim \mathcal{P}(\lambda)$, $G_X(s) = \sum_{k \geq 0} \frac{e^{-\lambda} \lambda^k}{k!} s^k = e^{\lambda(s-1)}$. On retrouve, en dérivant en $s = 1$, $\mathbb{E}(X) = np$ (binomiale) et $\mathbb{E}(X) = \lambda$ (Poisson) – une vérification rapide des formules du tableau de la Section 9.7 « Loix usuelles » ci-dessus.

Méthode 9.79 – Utiliser la fonction génératrice

Pour une variable (ou une somme de variables indépendantes) à valeurs dans $\mathbb{N}$, la fonction génératrice offre les mêmes services que la fonction caractéristique (identification de la loi, calcul de la loi d'une somme via un produit, calcul des moments via des dérivées), mais avec des manipulations purement réelles (pas de nombres complexes). Elle est donc souvent préférée dans ce cadre restreint ; c'est en particulier l'outil de base pour l'étude des **processus de branchement** (non traités dans ce livret).

Exercice 9.80 – Paradoxe de Bertrand

On choisit une corde « au hasard » dans un cercle de rayon 1. Quelle est la probabilité que sa longueur dépasse $\sqrt{3}$ (longueur du côté du triangle équilatéral inscrit) ? On propose deux modélisations : (a) le milieu de la corde est uniforme dans le disque ; (b) les deux extrémités de la corde sont, indépendamment, uniformes sur le cercle. Calculer cette probabilité dans chacun des deux cas, et commenter.

Solution

Modélisation (a). Une corde de milieu M , à distance $r = |OM|$ du centre O , a pour longueur $2\sqrt{1-r^2}$; elle dépasse $\sqrt{3}$ ssi $r < 1/2$. Pour M uniforme dans le disque unité, $\mathbb{P}(r < 1/2) = \frac{\pi(1/2)^2}{\pi \cdot 1^2} = \frac{1}{4}$ (rapport des aires).

Modélisation (b). Par invariance par rotation, on peut fixer une extrémité A au point d'angle 0 ; l'autre extrémité B est uniforme sur le cercle, d'angle $\Theta \sim \mathcal{U}([0, 2\pi[)$. La corde AB a pour longueur $2\sin(\Theta/2)$, qui dépasse $\sqrt{3}$ ssi $\Theta/2 \in]\pi/3, 2\pi/3[$, i.e. $\Theta \in]2\pi/3, 4\pi/3[$, un arc de longueur $2\pi/3$. Donc $\mathbb{P} = \frac{2\pi/3}{2\pi} = \frac{1}{3}$.

Remarque 9.81 – Ce que révèle le paradoxe

Les deux modélisations donnent des réponses *différentes* ($1/4$ contre $1/3$) à une question qui semblait pourtant univoque (« une corde au hasard ») : il n'existe pas de notion canonique de « tirage uniforme d'une corde » sans préciser le mécanisme aléatoire sous-jacent (choix du milieu, choix des extrémités, ou d'autres paramétrisations possibles, qui donnent encore d'autres réponses). Ce paradoxe, dû à Joseph Bertrand (1889), illustre une exigence méthodologique centrale de ce livret depuis le Chapitre 3 « Mesures » : la donnée d'un espace probabilisé $(\Omega, \mathcal{T}, \mathbb{P})$ précis est indispensable avant de pouvoir parler de probabilité d'un événement – « au hasard » ne veut rien dire tant que le modèle n'est pas spécifié.

10 Vecteurs aléatoires

Objectifs

- Définir un vecteur aléatoire, sa loi jointe, ses lois marginales.
- Savoir passer de la loi jointe aux lois marginales, dans le cas discret et dans le cas à densité.
- Définir et calculer la matrice de covariance et le coefficient de corrélation d'un vecteur aléatoire.
- Caractériser l'indépendance des composantes d'un vecteur aléatoire.
- Calculer la loi d'une somme de variables aléatoires indépendantes (convolution).

Introduction

Le Chapitre 9 « Variables aléatoires réelles » a construit toute la théorie des variables aléatoires *réelles*, à valeurs dans $\mathbb{R}$. De nombreuses situations demandent cependant de considérer *plusieurs* variables aléatoires simultanément – par exemple les coordonnées d'un point aléatoire dans le plan, ou une suite $(X_1, \dots, X_n)$ de mesures répétées – et de comprendre comment elles varient *conjointement*. C'est l'objet de ce chapitre : le vecteur aléatoire $X = (X_1, \dots, X_n)$, sa loi jointe, ses lois marginales (déjà rencontrées de façon informelle au Chapitre 9 « Variables aléatoires réelles » à propos de l'indépendance), et les outils qui permettent de mesurer une dépendance entre composantes (covariance) ou de calculer la loi d'une somme.

10.1 Vecteur aléatoire et loi jointe

Définition 10.1 – Vecteur aléatoire

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $n \geq 1$. Une application $X = (X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$ est un **vecteur aléatoire** si elle est mesurable de $(\Omega, \mathcal{T})$ dans $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$. C'est équivalent à demander que chaque composante $X_i : \Omega \rightarrow \mathbb{R}$ soit une variable aléatoire réelle (Proposition 4.15 « Caractérisation par une famille génératrice », appliquée à la famille génératrice des pavés de $\mathcal{B}(\mathbb{R}^n)$).

Définition 10.2 – Loi jointe

La **loi jointe** (ou **loi du vecteur**) de $X = (X_1, \dots, X_n)$ est la mesure image de $\mathbb{P}$ par X , notée $\mathbb{P}_X$, sur $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ (Définition 4.32 « Mesure image ») : pour tout borélien $A \subset \mathbb{R}^n$,

$$\mathbb{P}_X(A) = \mathbb{P}(X \in A) = \mathbb{P}((X_1, \dots, X_n) \in A).$$

Définition 10.3 – Fonction de répartition jointe

La **fonction de répartition jointe** de $X = (X_1, \dots, X_n)$ est $F_X : \mathbb{R}^n \rightarrow [0, 1]$ définie par

$$F_X(x_1, \dots, x_n) := \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

Remarque 10.4

Exactement comme au Chapitre 9 « Variables aléatoires réelles » pour $n = 1$ (Proposition 9.30 « Caractérisation de la loi par la fonction de répartition »), les pavés $\prod_{i=1}^n]-\infty, x_i]$ engendrent $\mathcal{B}(\mathbb{R}^n)$ et forment une famille stable par intersection finie : par le Corollaire 3.13 « Unicité d'une mesure déterminée par un π -système générateur », F_X détermine entièrement $\mathbb{P}_X$. Connaître la fonction de répartition jointe, c'est donc connaître toute la loi du vecteur.

Définition 10.5 – Vecteur discret, vecteur à densité

On dit que $X = (X_1, \dots, X_n)$ est **discret** si $\mathbb{P}_X$ est portée par un ensemble dénombrable de $\mathbb{R}^n$ (loi donnée par $\mathbb{P}(X = (x_1, \dots, x_n))$ pour $(x_1, \dots, x_n)$ dans cet ensemble). On dit que X est **à densité** s'il existe $f_X : \mathbb{R}^n \rightarrow \mathbb{R}^+$ mesurable, appelée **densité jointe**, telle que

$$\forall A \in \mathcal{B}(\mathbb{R}^n), \quad \mathbb{P}(X \in A) = \int_A f_X(x_1, \dots, x_n) d\lambda_n(x_1, \dots, x_n).$$

Exemple 10.6 – Vecteur uniforme sur un triangle

Soit (X, Y) de densité jointe $f_{X,Y}(x, y) = 2 \mathbf{1}_{\{0 < x < y < 1\}}$ (on vérifie $\int_{\mathbb{R}^2} f_{X,Y} = 2 \int_0^1 (\int_0^y dx) dy = 2 \int_0^1 y dy = 1$: c'est bien une densité). C'est la loi uniforme sur le triangle $\{0 < x < y < 1\}$, d'aire $\frac{1}{2}$ (d'où le facteur $2 = 1/\text{aire}$).

10.2 Lois marginales

Définition 10.7 – Lois marginales

Soit $X = (X_1, \dots, X_n)$ un vecteur aléatoire. La **loi marginale** de X_i est simplement sa loi $\mathbb{P}_{X_i}$ en tant que variable aléatoire réelle – c'est-à-dire la mesure image de $\mathbb{P}_X$ par la i -ème projection $\pi_i : (x_1, \dots, x_n) \mapsto x_i$.

Méthode 10.8 – Calculer une loi marginale à partir de la loi jointe

1. **Cas discret** : $\mathbb{P}(X_i = x_i) = \sum_{(x_j)_{j \neq i}} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$ (on somme sur toutes les valeurs possibles des autres composantes).
2. **Cas à densité** : $f_{X_i}(x_i) = \int_{\mathbb{R}^{n-1}} f_X(x_1, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_n) d\lambda_{n-1}(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$ (on intègre la densité jointe par rapport à toutes les autres variables $x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n$, en laissant x_i fixé).

Dans les deux cas, c'est une application directe du théorème de Fubini (Chapitre 6 « Intégrales multiples »).

Exemple 10.9

Pour le couple uniforme sur le triangle de l'Exemple 10.6 « Vecteur uniforme sur un triangle » : $f_X(x) = \int_x^1 2 dy = 2(1-x)$ pour $x \in]0, 1[$ (et 0 ailleurs), et par symétrie du rôle des bornes, $f_Y(y) = \int_0^y 2 dx = 2y$ pour $y \in]0, 1[$. On vérifie que X et Y ne sont *pas* indépendantes : le produit $f_X(x)f_Y(y) = 4y(1-x)$ ne coïncide pas avec $f_{X,Y}(x, y) = 2 \mathbf{1}_{\{x < y\}}$ (en particulier, $f_X(x)f_Y(y) > 0$ même lorsque $x > y$, où $f_{X,Y}(x, y) = 0$).

Attention 10.10 – Les lois marginales ne déterminent pas la loi jointe

Il est essentiel de comprendre que la donnée des lois marginales $\mathbb{P}_{X_1}, \dots, \mathbb{P}_{X_n}$ ne suffit *en général* pas à reconstruire la loi jointe $\mathbb{P}_X$: de nombreux vecteurs différents peuvent avoir les mêmes marginales. Par exemple, si $U \sim \mathcal{U}([0, 1])$, les couples (U, U) et $(U, 1 - U)$ ont tous deux pour marginales deux lois $\mathcal{U}([0, 1])$, mais des lois jointes radicalement différentes (portées respectivement par la diagonale $\{x = y\}$ et l'anti-diagonale $\{x + y = 1\}$ du carré $[0, 1]^2$, deux boréliens disjoints). La loi jointe contient donc, en général, *strictement plus* d'information que la collection des lois marginales – sauf dans le cas particulier de l'indépendance, ci-dessous.

10.3 Indépendance des composantes

On a déjà défini, au Chapitre 9 « Variables aléatoires réelles » (Proposition 9.67 « Caractérisation de l'indépendance »), l'indépendance de deux variables aléatoires réelles, et caractérisé celle-ci par la factorisation de la loi jointe en produit tensoriel des lois marginales. La définition se généralise mot pour mot à n variables, et donc à un vecteur aléatoire.

Définition 10.11 – Composantes indépendantes

Les composantes $X_1, \dots, X_n$ du vecteur X sont dites **mutuellement indépendantes** si

$$\forall A_1, \dots, A_n \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n \mathbb{P}(X_i \in A_i),$$

c'est-à-dire, de façon équivalente (même argument qu'à la Proposition 9.67 « Caractérisation de l'indépendance »), si la loi jointe est le produit tensoriel des lois marginales : $\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_n}$.

Propriété 10.12 – Factorisation de la densité ou de la loi jointe

Si $X = (X_1, \dots, X_n)$ est à densité, ses composantes sont indépendantes si et seulement si $f_X(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$ (produit des densités marginales). Si X est discret, ses composantes sont indépendantes si et seulement si $\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \prod_i \mathbb{P}(X_i = x_i)$ pour tout n -uplet de valeurs.

Idée de preuve. Dans les deux cas, il s'agit de vérifier que deux mesures ($\mathbb{P}_X$ et le produit tensoriel des marginales) qui coïncident sur une famille génératrice stable par intersection finie (les pavés) coïncident partout – Corollaire 3.13 « Unicité d'une mesure déterminée par un π -système générateur », comme à la Proposition 9.67 « Caractérisation de l'indépendance ».

Démonstration. Traitons le cas à densité (le cas discret se traite de façon analogue, en remplaçant intégrales par sommes).

Sens direct. Si les composantes sont indépendantes, alors $\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_n}$ (Définition 10.11 « Composantes indépendantes »), c'est-à-dire, pour tout pavé $A_1 \times \dots \times A_n$:

$$\mathbb{P}(X \in A_1 \times \dots \times A_n) = \prod_{i=1}^n \mathbb{P}_{X_i}(A_i) = \prod_{i=1}^n \int_{A_i} f_{X_i}(x_i) dx_i = \int_{A_1 \times \dots \times A_n} \prod_{i=1}^n f_{X_i}(x_i) d\lambda_n$$

(la dernière égalité par le Théorème 6.6 « Théorème de Fubini-Tonelli », Chapitre 6 « Intégrales multiples », appliqué à la fonction positive $\prod_i f_{X_i}(x_i)$). Ainsi $\mathbb{P}_X$ et la mesure de densité $\prod_i f_{X_i}$ coïncident sur les pavés, un π -système engendrant $\mathcal{B}(\mathbb{R}^n)$; par le Corollaire 3.13 « Unicité d'une mesure déterminée par un π -système générateur » (les deux mesures étant finies, de masse totale 1), elles coïncident partout. Ceci signifie exactement que $f_X = \prod_i f_{X_i}$ est une densité jointe de X (l'unicité d'une densité, à un ensemble λ_n -négligeable près, étant elle-même une conséquence de cette même unicité des mesures).

Réciproque. Si $f_X(x_1, \dots, x_n) = \prod_i f_{X_i}(x_i)$, alors pour tout pavé $A_1 \times \dots \times A_n$, par le Théorème 6.6 « Théorème de Fubini-Tonelli » :

$$\mathbb{P}(X \in A_1 \times \dots \times A_n) = \int_{A_1 \times \dots \times A_n} \prod_i f_{X_i}(x_i) d\lambda_n = \prod_{i=1}^n \int_{A_i} f_{X_i}(x_i) dx_i = \prod_{i=1}^n \mathbb{P}(X_i \in A_i),$$

ce qui est exactement la définition de l'indépendance mutuelle des composantes. ■

Remarque 10.13 – Indépendance de blocs de variables

La même définition s'applique à des *blocs* de composantes : par exemple, (X_1, X_2) et (X_3, X_4, X_5) sont indépendants si $\mathbb{P}((X_1, X_2) \in A, (X_3, X_4, X_5) \in B) = \mathbb{P}((X_1, X_2) \in A) \mathbb{P}((X_3, X_4, X_5) \in B)$ pour tous boréliens $A \subset \mathbb{R}^2$, $B \subset \mathbb{R}^3$. C'est un cas particulier de la Définition 10.11 « Composantes indépendantes », appliquée aux deux vecteurs (X_1, X_2) et (X_3, X_4, X_5) plutôt qu'à leurs composantes individuelles.

Propriété 10.14 – Des fonctions de variables indépendantes sont indépendantes

Soient $X_1, \dots, X_n$ des variables aléatoires réelles mutuellement indépendantes, et $g_1, \dots, g_n : \mathbb{R} \rightarrow \mathbb{R}$ boréliennes. Alors $g_1(X_1), \dots, g_n(X_n)$ sont mutuellement indépendantes.

Démonstration. Traitons $n = 2$ (le cas général s'obtient en répétant l'argument, ou en l'appliquant directement à la définition de l'indépendance mutuelle avec des pavés $g_1^{-1}(A_1) \times \dots \times g_n^{-1}(A_n)$). Soient $A, B \in \mathcal{B}(\mathbb{R})$. Comme g_1, g_2 sont boréliennes, $g_1^{-1}(A), g_2^{-1}(B) \in \mathcal{B}(\mathbb{R})$. Par indépendance de X_1, X_2 (Définition 10.11 « Composantes indépendantes ») :

$$\mathbb{P}(g_1(X_1) \in A, g_2(X_2) \in B) = \mathbb{P}(X_1 \in g_1^{-1}(A), X_2 \in g_2^{-1}(B)) = \mathbb{P}(X_1 \in g_1^{-1}(A)) \mathbb{P}(X_2 \in g_2^{-1}(B)),$$

c'est-à-dire $\mathbb{P}(g_1(X_1) \in A) \mathbb{P}(g_2(X_2) \in B)$: c'est exactement l'indépendance de $g_1(X_1)$ et $g_2(X_2)$. ■

Remarque 10.15

Cette proposition, d'apparence anodine, est utilisée constamment et souvent implicitement dans la suite de ce livret – par exemple pour affirmer que $e^{itX_1}, \dots, e^{itX_n}$ restent mutuellement indépendantes lorsque $X_1, \dots, X_n$ le sont (Chapitre 12 « Vecteurs aléatoires gaussiens », fonction caractéristique d'une somme de variables indépendantes), ou plus généralement chaque fois que l'on transforme séparément chaque composante d'un n -uplet indépendant.

10.4 Covariance et matrice de covariance

Définition 10.16 – Covariance, corrélation

Soient $X, Y \in L^2(\Omega, \mathbb{P})$ (Chapitre 7 « Espaces L^p »). On appelle **covariance** de X et Y le réel

$$\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))] = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

Si de plus $\text{Var}(X) > 0$ et $\text{Var}(Y) > 0$, le **coefficient de corrélation (linéaire)** de X et Y est

$$\rho(X, Y) := \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}.$$

Propriété 10.17 – Propriétés élémentaires de la covariance

Pour $X, Y, Z \in L^2(\Omega, \mathbb{P})$ et $a, b \in \mathbb{R}$:

1. $\text{Cov}(X, Y)$ est bien définie (finie) ;
2. **symétrie** : $\text{Cov}(X, Y) = \text{Cov}(Y, X)$;
3. **bilinéarité** : $\text{Cov}(aX + bY, Z) = a\text{Cov}(X, Z) + b\text{Cov}(Y, Z)$;
4. $\text{Cov}(X, X) = \text{Var}(X)$.

Démonstration. *Point 1.* $|XY| \leq \frac{1}{2}(X^2 + Y^2)$ (car $(|X| - |Y|)^2 \geq 0$), et le membre de droite est intégrable dès que $X, Y \in L^2$; donc $XY \in L^1$ (Proposition 5.25 « Intégrabilité », Chapitre 5 « Intégrale de Lebesgue »), et $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$ est bien un réel fini (chaque terme étant fini : $X, Y \in L^2 \subset L^1$ en probabilité, Chapitre 7 « Espaces L^p »).

Point 2. Immédiat sur la définition : $\mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) = \mathbb{E}(YX) - \mathbb{E}(Y)\mathbb{E}(X)$ (le produit $XY = YX$ dans $\mathbb{R}$).

Point 3. Par linéarité de l'espérance (linéarité de l'intégrale, Proposition 5.22 « Linéarité de l'intégrale ») :

$$\text{Cov}(aX + bY, Z) = \mathbb{E}((aX + bY)Z) - \mathbb{E}(aX + bY)\mathbb{E}(Z) = a\mathbb{E}(XZ) + b\mathbb{E}(YZ) - (a\mathbb{E}(X) + b\mathbb{E}(Y))\mathbb{E}(Z),$$

que l'on regroupe en $a(\mathbb{E}(XZ) - \mathbb{E}(X)\mathbb{E}(Z)) + b(\mathbb{E}(YZ) - \mathbb{E}(Y)\mathbb{E}(Z)) = a\text{Cov}(X, Z) + b\text{Cov}(Y, Z)$.


Point 4. $\text{Cov}(X, X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \text{Var}(X)$ par la formule de Koenig-Huygens (Chapitre 9 « Variables aléatoires réelles »). ■

Remarque 10.18 – Ce que mesurent concrètement covariance et corrélation

La covariance $\text{Cov}(X, Y)$ mesure la tendance de X et Y à **varier ensemble** : elle est positive si X et Y ont tendance à être, *simultanément*, au-dessus ou en-dessous de leurs moyennes respectives (quand X est grand, Y tend aussi à être grand) ; elle est négative si X et Y ont tendance à varier en **sens opposés** (quand X est grand, Y tend à être petit) ; elle est nulle s'il n'y a, en moyenne, aucune tendance de ce type.

Le défaut de $\text{Cov}(X, Y)$ est de dépendre des unités et de l'échelle de X et Y (multiplier X par 100 multiplie la covariance par 100) : le **coefficient de corrélation** $\rho(X, Y) \in [-1, 1]$ (Proposition 10.19 « Cauchy-Schwarz et corrélation ») corrige ce défaut en normalisant par les écarts-types, ce qui permet de comparer la force de la liaison entre différents couples de variables, indépendamment de leur échelle :

- $\rho(X, Y)$ proche de 1 : X et Y sont presque exactement liées par une relation *affine croissante* ($Y \approx aX + b$ avec $a > 0$) ;
- $\rho(X, Y)$ proche de -1 : liaison affine *décroissante* presque exacte ($Y \approx aX + b$ avec $a < 0$) ;
- $\rho(X, Y)$ proche de 0, ou modérément non nul (par exemple 0.3) : X et Y ont une tendance *faible*, bruitée, à varier ensemble (ici plutôt dans le même sens, mais loin d'une relation déterministe) – il n'y a pas de seuil universel, mais on considère souvent $|\rho| < 0.3$ comme une corrélation faible, $|\rho| > 0.7$ comme une corrélation forte.



Trois nuages de points (X_i, Y_i) illustrant différents coefficients de corrélation. À gauche : ρ proche de 1, les points sont presque alignés sur une droite croissante. Au centre : ρ proche de -1 , droite décroissante. À droite : $\rho \approx 0.3$, une légère tendance croissante est visible, mais noyée dans un bruit important – bien loin d'un alignement parfait.

Propriété 10.19 – Cauchy-Schwarz et corrélation

Pour $X, Y \in L^2$, $|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}$; en particulier $\rho(X, Y) \in [-1, 1]$ lorsqu'il est défini. De plus, $|\rho(X, Y)| = 1$ si et seulement si Y est presque sûrement une fonction affine de X .

Idée de preuve. C'est l'inégalité de Hölder (Proposition 7.10 « Inégalité de Hölder ») pour $p = q = 2$, appliquée à $X - \mathbb{E}(X)$ et $Y - \mathbb{E}(Y)$: c'est le cas particulier $p = 2$ de Cauchy-Schwarz. Le cas d'égalité de Cauchy-Schwarz (admis, cf. cours d'algèbre bilinéaire) donne la colinéarité de $X - \mathbb{E}(X)$ et $Y - \mathbb{E}(Y)$ dans L^2 , c'est-à-dire l'affinité annoncée.

Propriété 10.20 – Indépendance et covariance

Si $X, Y \in L^2$ sont indépendantes, alors $\text{Cov}(X, Y) = 0$ (on dit qu'elles sont **décorrélées**).

Démonstration. Par indépendance et le point (3) de la Proposition 9.67 « Caractérisation de l'indépendance » (appliqué à des approximations de $x \mapsto x$, ou directement par Fubini sur la densité/loi jointe produit), $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$, donc $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) = 0$. ■

Attention 10.21 – La réciproque est fausse en général

$\text{Cov}(X, Y) = 0$ n'entraîne *pas* l'indépendance de X et Y : c'est une implication à sens unique. Exemple classique : $X \sim \mathcal{U}(\{-1, 0, 1\})$, $Y = X^2$. Alors $\mathbb{E}(X) = 0$, $\mathbb{E}(XY) = \mathbb{E}(X^3) = \frac{1}{3}((-1)^3 + 0^3 + 1^3) = 0$, donc $\text{Cov}(X, Y) = 0$; pourtant X et Y sont fortement dépendantes (Y est une fonction déterministe de X !). On verra au Chapitre 12 « Vecteurs aléatoires gaussiens » que cette implication devient une équivalence dans le cas particulier, mais important, où (X, Y) est un **vecteur gaussien**.

Définition 10.22 – Vecteur d'espérance, matrice de covariance

Soit $X = (X_1, \dots, X_n)$ un vecteur aléatoire dont chaque composante est dans L^2 . Le **vecteur d'espérance** de X est $\mathbb{E}(X) := (\mathbb{E}(X_1), \dots, \mathbb{E}(X_n)) \in \mathbb{R}^n$. La **matrice de covariance** de X est la matrice $\Sigma_X \in \mathcal{M}_n(\mathbb{R})$ de terme général $(\Sigma_X)_{i,j} := \text{Cov}(X_i, X_j)$; en particulier $(\Sigma_X)_{i,i} = \text{Var}(X_i)$.

Exemple 10.23 – Une matrice de covariance en dimension 2

Soit $X = (X_1, X_2)$ avec $\text{Var}(X_1) = 4$, $\text{Var}(X_2) = 9$, $\text{Cov}(X_1, X_2) = 3$. Alors

$$\Sigma_X = \begin{pmatrix} 4 & 3 \\ 3 & 9 \end{pmatrix}$$

(les termes diagonaux sont les variances $\text{Var}(X_1)$, $\text{Var}(X_2)$; les termes hors diagonale, la covariance $\text{Cov}(X_1, X_2) = \text{Cov}(X_2, X_1)$, d'où la symétrie). Le coefficient de corrélation associé est $\rho(X_1, X_2) = \frac{3}{\sqrt{4}\sqrt{9}} = \frac{3}{6} = \frac{1}{2}$. On note $\det \Sigma_X = 36 - 9 = 27 > 0$: conformément à la Proposition 10.24 « Propriétés de la matrice de covariance » ci-dessous, Σ_X est bien symétrique et (ici) définie positive.

Propriété 10.24 – Propriétés de la matrice de covariance

La matrice Σ_X est symétrique et **semi-définie positive** : pour tout $a = (a_1, \dots, a_n) \in \mathbb{R}^n$, $a^\top \Sigma_X a = \text{Var}\left(\sum_i a_i X_i\right) \geq 0$.

Démonstration. La symétrie découle de celle de la covariance ($\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$). Pour la forme quadratique :

$$a^\top \Sigma_X a = \sum_{i,j} a_i a_j \text{Cov}(X_i, X_j) = \text{Cov}\left(\sum_i a_i X_i, \sum_j a_j X_j\right) = \text{Var}\left(\sum_i a_i X_i\right) \geq 0,$$

où la deuxième égalité utilise la bilinéarité de la covariance, et l'inégalité est la positivité de la variance (variance d'une variable aléatoire réelle). ■

Remarque 10.25

Cette propriété n'est pas qu'une curiosité algébrique : elle jouera un rôle central au Chapitre 12 « Vecteurs aléatoires gaussiens », où l'on *part* d'une matrice symétrique semi-définie positive quelconque Σ pour *construire* un vecteur gaussien de matrice de covariance Σ .

Exercice 10.26

Soient $X_1, \dots, X_n$ deux à deux décorréelées, de même variance σ^2 . Calculer $\text{Var}\left(\frac{1}{n} \sum_i X_i\right)$.

Solution

$\Sigma_X = \sigma^2 I_n$ (diagonale, car décorréelées deux à deux). Avec $a = (\frac{1}{n}, \dots, \frac{1}{n})$, $\text{Var}\left(\frac{1}{n} \sum_i X_i\right) = a^\top \Sigma_X a = \sigma^2 \sum_i \frac{1}{n^2} = \frac{\sigma^2}{n}$: on retrouve la formule classique, ici comme cas particulier de la Proposition 10.24 « Propriétés de la matrice de covariance ».

10.5 Somme de variables aléatoires indépendantes

On termine ce chapitre par une question de calcul très fréquente : connaissant les lois de X et Y indépendantes, quelle est la loi de $X + Y$?

Propriété 10.27 – Convolution, cas discret

Soient X, Y deux variables aléatoires indépendantes, à valeurs dans $\mathbb{Z}$. Alors, pour tout $k \in \mathbb{Z}$,

$$\mathbb{P}(X + Y = k) = \sum_{j \in \mathbb{Z}} \mathbb{P}(X = j) \mathbb{P}(Y = k - j).$$

Démonstration. $\{X + Y = k\} = \bigsqcup_{j \in \mathbb{Z}} \{X = j, Y = k - j\}$ (réunion disjointe sur j , puisque X prend une unique valeur j sur chaque terme). Par σ -additivité puis indépendance (Proposition 10.12 « Factorisation de la densité ou de la loi jointe ») :

$$\mathbb{P}(X + Y = k) = \sum_{j \in \mathbb{Z}} \mathbb{P}(X = j, Y = k - j) = \sum_{j \in \mathbb{Z}} \mathbb{P}(X = j) \mathbb{P}(Y = k - j).$$

■

Exemple 10.28 – Somme de deux lois de Poisson indépendantes

Soient $X \sim \mathcal{P}(\alpha)$, $Y \sim \mathcal{P}(\beta)$ indépendantes. Pour $k \in \mathbb{N}$:

$$\mathbb{P}(X + Y = k) = \sum_{j=0}^k e^{-\alpha} \frac{\alpha^j}{j!} e^{-\beta} \frac{\beta^{k-j}}{(k-j)!} = \frac{e^{-(\alpha+\beta)}}{k!} \sum_{j=0}^k \binom{k}{j} \alpha^j \beta^{k-j} = e^{-(\alpha+\beta)} \frac{(\alpha + \beta)^k}{k!}$$

(formule du binôme de Newton) : $X + Y \sim \mathcal{P}(\alpha + \beta)$. On retrouve ainsi, par un calcul direct, un résultat déjà obtenu au Chapitre 12 « Vecteurs aléatoires gaussiens » par fonctions caractéristiques – la convolution est l’aspect « loi » de ce que le produit des fonctions caractéristiques (ou des fonctions génératrices, pour des variables à valeurs entières) exprime algébriquement.

Théorème 10.29 – Convolution, cas à densité

Soient X, Y deux variables aléatoires indépendantes, de densités respectives f_X, f_Y . Alors $X + Y$ est à densité, de densité

$$f_{X+Y}(z) = \int_{\mathbb{R}} f_X(x) f_Y(z - x) dx =: (f_X * f_Y)(z).$$

Démonstration. Soit $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ continue bornée. Par le Théorème 9.44 « Théorème de transfert » (Chapitre 9 « Variables aléatoires réelles ») appliqué au vecteur (X, Y) , de densité jointe $f_X(x)f_Y(y)$ par indépendance (Proposition 10.12 « Factorisation de la densité ou de la loi jointe ») :

$$\mathbb{E}(\varphi(X + Y)) = \int_{\mathbb{R}^2} \varphi(x + y) f_X(x) f_Y(y) dx dy.$$

Appliquons le changement de variable $\Phi(x, y) = (x, x + y) = (u, v)$ (Théorème 6.14 « Formule du changement de variable ») : Φ est un C^1 -difféomorphisme de $\mathbb{R}^2$ dans $\mathbb{R}^2$, d’inverse $(u, v) \mapsto (u, v - u)$, de jacobien $\left| \det \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \right| = 1$. Ainsi

$$\mathbb{E}(\varphi(X + Y)) = \int_{\mathbb{R}^2} \varphi(v) f_X(u) f_Y(v - u) du dv = \int_{\mathbb{R}} \varphi(v) \left(\int_{\mathbb{R}} f_X(u) f_Y(v - u) du \right) dv.$$

Ceci étant vrai pour toute φ continue bornée, la fonction entre parenthèses est, par unicité dans le Théorème 9.44 « Théorème de transfert », une densité de $X + Y$: $f_{X+Y}(v) = \int_{\mathbb{R}} f_X(u) f_Y(v - u) du = (f_X * f_Y)(v)$.

■

Exemple 10.30 – Somme de deux lois exponentielles de même paramètre

Soient $X, Y \sim \mathcal{E}(\lambda)$ indépendantes. Pour $z > 0$:

$$f_{X+Y}(z) = \int_0^z \lambda e^{-\lambda x} \cdot \lambda e^{-\lambda(z-x)} dx = \lambda^2 e^{-\lambda z} \int_0^z dx = \lambda^2 z e^{-\lambda z}$$

(et $f_{X+Y}(z) = 0$ pour $z \leq 0$, les deux densités étant nulles hors de $\mathbb{R}^+$) : on reconnaît la densité de la loi Gamma $\gamma(2, \lambda)$. Ce calcul, mené ici par convolution directe, peut se retrouver par fonctions caractéristiques (Chapitre 13 « Convergence de suites de variables aléatoires », Exercice 13.32 « Somme de deux lois exponentielles ») – les deux méthodes sont complémentaires : la convolution donne la densité explicitement, les fonctions caractéristiques identifient plus vite la *famille* de la loi lorsque celle-ci est connue à l'avance.

Méthode 10.31 – Calculer la loi d'une somme de variables indépendantes

Trois techniques, par ordre de facilité de mise en œuvre :

1. Si l'on *reconnaît* d'avance la famille de la loi somme (stabilité par somme : Poisson, binomiale de même p , Gamma de même paramètre d'échelle, gaussienne – Chapitre 12 « Vecteurs aléatoires gaussiens »), calculer directement les paramètres (souvent en identifiant l'espérance et la variance, qui s'additionnent toujours pour des variables indépendantes).
2. Sinon, la convolution (Proposition 10.27 « Convolution, cas discret » ou Théorème 10.29 « Convolution, cas à densité ») donne le résultat par un calcul direct.
3. Pour des sommes de *nombreuses* variables, ou lorsque la convolution est calculatoirement pénible, les fonctions caractéristiques (Chapitre 12 « Vecteurs aléatoires gaussiens ») transforment la convolution en simple produit : $\varphi_{X+Y} = \varphi_X \varphi_Y$.

11 Lois et espérance conditionnelles

Objectifs

- Construire l'espérance conditionnelle par rapport à une sous-tribu, et en maîtriser les propriétés.
- Définir la loi conditionnelle de X sachant Y , dans le cas discret et dans le cas à densité, et la relier à l'espérance conditionnelle.
- Savoir déterminer la droite (ou le plan) de régression linéaire de X sur $Y_1, \dots, Y_n$, et l'appliquer à des données concrètes.

Introduction

Ce chapitre franchit une étape supplémentaire dans l'abstraction : on ne conditionne plus seulement par un événement de probabilité non nulle (comme en licence), mais par toute une **sous-tribu** $\mathcal{G} \subset \mathcal{T}$, qui représente intuitivement « l'information disponible ». L'espérance conditionnelle $\mathbb{E}(X \mid \mathcal{G})$ est alors la meilleure prévision de X compatible avec cette information – un outil fondamental de la théorie des probabilités moderne (statistique, finance, théorie des processus stochastiques).

Rappel de L1–L2 11.1 – probabilité conditionnelle

On rappelle que pour A, B deux événements avec $\mathbb{P}(B) > 0$, la **probabilité conditionnelle** de A sachant B est

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Exemple. On lance un dé équilibré à 6 faces. Soit $A = \{\text{le résultat est pair}\}$, $B = \{\text{le résultat est } \geq 4\} = \{4, 5, 6\}$. Alors $A \cap B = \{4, 6\}$, donc $\mathbb{P}(A \mid B) = \frac{2/6}{3/6} = \frac{2}{3}$: sachant que le résultat est ≥ 4 , la probabilité qu'il soit pair passe de $\frac{1}{2}$ (a priori) à $\frac{2}{3}$.

Rappel de L2–L3 11.2 – espérance conditionnelle discrète

Pour Y discrète à valeurs dans un ensemble dénombrable $\{y_1, y_2, \dots\}$ et $\mathbb{P}(Y = y_i) > 0$, on rappelle que l'**espérance conditionnelle** de X sachant l'événement $\{Y = y_i\}$ est

$$\mathbb{E}(X \mid Y = y_i) := \frac{\mathbb{E}(X \mathbf{1}_{Y=y_i})}{\mathbb{P}(Y = y_i)}$$

(c'est l'espérance de X , calculée en ne retenant que les issues où $Y = y_i$, renormalisées en une vraie probabilité). On définit ensuite $\mathbb{E}(X \mid Y)$ comme la variable aléatoire valant $\mathbb{E}(X \mid Y = y_i)$ sur l'événement $\{Y = y_i\}$, pour chaque i .

Exemple. On lance deux dés équilibrés indépendants, X = somme des deux dés, Y = résultat du premier dé. Sachant $Y = 3$, le second dé reste uniforme sur $\{1, \dots, 6\}$ (indépendance), donc $\mathbb{E}(X \mid Y = 3) = 3 + \mathbb{E}(\text{second dé}) = 3 + 3,5 = 6,5$. Plus généralement, $\mathbb{E}(X \mid Y = y_i) = y_i + 3,5$ pour chaque $i \in \{1, \dots, 6\}$, d'où $\mathbb{E}(X \mid Y) = Y + 3,5$.

La construction de ce chapitre généralise ces deux idées à une tribu $\mathcal{G}$ quelconque, y compris lorsque Y est à densité (où $\mathbb{P}(Y = y) = 0$ empêche de reprendre littéralement la formule ci-dessus).

11.1 Construction de l'espérance conditionnelle

Théorème 11.3 – Existence et unicité de l'espérance conditionnelle

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $\mathcal{G}$ une sous-tribu de $\mathcal{T}$, X une variable aléatoire intégrable. Il existe une variable aléatoire Z , $\mathcal{G}$ -mesurable et intégrable, unique à l'égalité presque sûre près, telle que

$$\forall A \in \mathcal{G}, \quad \int_A Z \, d\mathbb{P} = \int_A X \, d\mathbb{P}.$$

On note $Z = \mathbb{E}(X \mid \mathcal{G})$, appelée **espérance conditionnelle** de X sachant $\mathcal{G}$.

Démonstration. Pour $X \geq 0$, on considère la mesure $\nu(A) = \int_A X \, d\mathbb{P}$ pour $A \in \mathcal{G}$: c'est une mesure finie sur $(\Omega, \mathcal{G})$ (finie car X est intégrable), absolument continue par rapport à $\mathbb{P}|_{\mathcal{G}}$ (si $\mathbb{P}(A) = 0$ alors $\nu(A) = \int_A X \, d\mathbb{P} = 0$, trivialement, car intégrer sur un ensemble négligeable donne toujours 0). Le théorème de Radon-Nikodym (Théorème 8.21 « Théorème de Radon-Nikodym »), appliqué à l'espace mesurable $(\Omega, \mathcal{G})$ muni de $\mathbb{P}|_{\mathcal{G}}$, fournit alors exactement une fonction $\mathcal{G}$ -mesurable $Z = \frac{d\nu}{d\mathbb{P}|_{\mathcal{G}}}$ vérifiant $\nu(A) = \int_A Z \, d\mathbb{P}$ pour tout $A \in \mathcal{G}$, c'est-à-dire $\int_A Z \, d\mathbb{P} = \int_A X \, d\mathbb{P}$: Z satisfait la propriété définissante recherchée.

Pour X de signe quelconque, on pose $Z = \mathbb{E}(X^+ \mid \mathcal{G}) - \mathbb{E}(X^- \mid \mathcal{G})$ (différence de deux variables construites comme ci-dessus, chacune $\mathcal{G}$ -mesurable et intégrable) : par linéarité de l'intégrale, $\int_A Z \, d\mathbb{P} = \int_A X^+ \, d\mathbb{P} - \int_A X^- \, d\mathbb{P} = \int_A X \, d\mathbb{P}$ pour tout $A \in \mathcal{G}$.

Unicité. Si Z_1, Z_2 vérifient toutes deux la propriété définissante, alors $\int_A (Z_1 - Z_2) \, d\mathbb{P} = 0$ pour tout $A \in \mathcal{G}$; en prenant $A = \{Z_1 > Z_2\} \in \mathcal{G}$ puis $A = \{Z_1 < Z_2\} \in \mathcal{G}$, on obtient $Z_1 = Z_2$ presque sûrement (même argument que pour l'unicité dans le Théorème 8.21 « Théorème de Radon-Nikodym », via la Proposition 5.24 « Espérance et nullité presque partout »). ■

Exemple 11.4 – Cas d'une tribu engendrée par une partition finie

Le cas le plus concret : $\mathcal{G} = \sigma(B_1, \dots, B_k)$, la tribu engendrée par une partition finie $\Omega = B_1 \sqcup \dots \sqcup B_k$ avec $\mathbb{P}(B_i) > 0$ pour tout i (c'est-à-dire $\mathcal{G} = \{\emptyset, \Omega, B_1, \dots, B_k, B_1 \cup B_2, \dots\}$, toutes les réunions possibles de B_i). Alors

$$\mathbb{E}(X \mid \mathcal{G}) = \sum_{i=1}^k \left(\frac{1}{\mathbb{P}(B_i)} \int_{B_i} X \, d\mathbb{P} \right) \mathbf{1}_{B_i},$$

c'est-à-dire que $\mathbb{E}(X \mid \mathcal{G})$ vaut, sur chaque bloc B_i de la partition, la **valeur moyenne** de X sur ce bloc (exactement la formule $\mathbb{E}(X \mid Y = y_i)$ du rappel ci-dessus, avec $Y = \sum_i i \mathbf{1}_{B_i}$). On vérifie directement la propriété définissante : pour $A = B_j$ (les autres éléments de $\mathcal{G}$ étant des réunions de tels blocs, on conclut

par additivité), $\int_{B_j} \mathbb{E}(X | \mathcal{G}) d\mathbb{P} = \frac{1}{\mathbb{P}(B_j)} \left(\int_{B_j} X d\mathbb{P} \right) \mathbb{P}(B_j) = \int_{B_j} X d\mathbb{P}$.

Interprétation. $\mathcal{G}$ représente ici « l'information : à quel bloc B_i appartient ω » – rien de plus fin. $\mathbb{E}(X | \mathcal{G})$ est alors la meilleure estimation de X que l'on puisse former en ne connaissant *que* cette information grossière : sachant seulement dans quel bloc on se trouve, la meilleure prévision de X est sa moyenne sur ce bloc.

Exemple 11.5 – À quoi sert l'espérance conditionnelle ?

Reprenons l'exemple du lancer de deux dés, $\Omega = \{1, \dots, 6\}^2$, et $X = \omega_1 + \omega_2$ (la somme). Soit $\mathcal{G} = \sigma(\omega_1)$, la tribu engendrée par le résultat du *premier* dé seulement (l'information « je connais le premier dé, pas le second »). Concrètement, $\mathcal{G}$ est engendrée par la partition $\{B_1, \dots, B_6\}$ avec $B_i := \{\omega_1 = i\} = \{i\} \times \{1, \dots, 6\}$: c'est exactement le cas de l'Exemple 11.4 « Cas d'une tribu engendrée par une partition finie » ci-dessus, avec ces B_i comme blocs.

Pour **calculer** $\mathbb{E}(X | \mathcal{G})(\omega)$ en un point $\omega = (\omega_1, \omega_2)$ donné, on *fixe* la valeur $i := \omega_1(\omega)$ prise par le premier dé en ce point précis ω (c'est un nombre, disons $\omega_1(\omega) = i$), puis on calcule la moyenne de X sur tout le bloc $B_i = \{\omega_1 = i\}$ – c'est-à-dire que l'on fait comme si l'on *savait* que le premier dé vaut i , et l'on moyenne sur toutes les valeurs encore possibles du second dé. Sachant que le premier dé vaut i , la meilleure prévision de la somme est $i + \mathbb{E}(\omega_2) = i + 3.5$ (le second dé restant totalement aléatoire, non observé). On a ainsi $\mathbb{E}(X | \mathcal{G})(\omega) = \omega_1(\omega) + 3.5$ pour *chaque* ω , c'est-à-dire, comme variable aléatoire, $\mathbb{E}(X | \mathcal{G}) = \omega_1 + 3.5$ (ou, avec les notations d'une variable aléatoire $D_1 : \Omega \rightarrow \{1, \dots, 6\}$, $D_1(\omega) := \omega_1$ pour le résultat du premier dé : $\mathbb{E}(X | \mathcal{G}) = D_1 + 3.5$). Plus généralement, l'espérance conditionnelle sert à formaliser l'idée de « meilleure prévision compatible avec une information partielle » : c'est l'outil de base pour les modèles de prévision et le filtrage statistique.

Remarque 11.6 – Une autre construction, plus intuitive : le cas L^2

Lorsque $X \in L^2(\Omega, \mathbb{P})$, il existe une construction alternative, plus géométrique : $L^2(\Omega, \mathcal{G}, \mathbb{P})$ (les variables $\mathcal{G}$ -mesurables de carré intégrable) est un sous-espace fermé de l'espace de Hilbert $L^2(\Omega, \mathcal{T}, \mathbb{P})$, et $\mathbb{E}(X | \mathcal{G})$ n'est autre que le **projeté orthogonal** de X sur ce sous-espace : c'est, parmi toutes les variables $\mathcal{G}$ -mesurables, celle qui approche le mieux X au sens de la norme L^2 , c'est-à-dire la meilleure prévision de X (au sens des moindres carrés) compatible avec l'information $\mathcal{G}$.




Figure 34: Pour $X \in L^2(\Omega, \mathbb{P})$, $\mathbb{E}(X | \mathcal{G})$ est le projeté orthogonal de X sur le sous-espace (représenté ici comme un « plan » incliné dans l'espace de Hilbert $L^2(\Omega, \mathcal{T}, \mathbb{P})$) des variables $\mathcal{G}$ -mesurables de carré intégrable : la variable $\mathcal{G}$ -mesurable la plus proche de X au sens quadratique – exactement comme on projette perpendiculairement un point de l'espace sur un plan.

Définition 11.7 – Espérance conditionnelle sachant une variable aléatoire

Soit Y une variable aléatoire (ou un vecteur). On note $\mathbb{E}(X | Y) := \mathbb{E}(X | \sigma(Y))$, où $\sigma(Y) = Y^{-1}(\mathcal{B}(\mathbb{R}))$ est la tribu engendrée par Y (la plus petite tribu rendant Y mesurable).

Exemple 11.8 – Les deux cas extrêmes : tribu grossière et tribu discrète

On lance un dé équilibré : $\Omega = \{1, \dots, 6\}$, $\mathcal{T} = \mathcal{P}(\Omega)$ (la tribu **discrète**, toutes les parties de Ω – ici, la tribu totale), $\mathbb{P}$ uniforme. Soit $X(\omega) := \omega$ (le résultat du dé), d'espérance $\mathbb{E}(X) = 3,5$.

Tribu totale $\mathcal{G} = \mathcal{T} = \mathcal{P}(\Omega)$. X est, par construction, $\mathcal{T}$ -mesurable (*toute* fonction sur Ω l'est, puisque $\mathcal{T} = \mathcal{P}(\Omega)$ contient déjà toutes les parties). La variable X elle-même vérifie donc trivialement la propriété définissante de $\mathbb{E}(X | \mathcal{T})$: pour tout $A \in \mathcal{T}$, $\int_A X d\mathbb{P} = \int_A X d\mathbb{P}$. Par unicité, $\mathbb{E}(X | \mathcal{T}) = X$: **connaître toute l'information disponible ne fait rien perdre**, l'espérance conditionnelle redonne X lui-même.

Tribu grossière $\mathcal{G}_0 = \{\emptyset, \Omega\}$. Une variable $\mathcal{G}_0$ -mesurable ne peut prendre qu'une seule valeur sur Ω tout entier (ses seules préimages possibles de boréliens sont $\emptyset$ ou Ω) : $\mathbb{E}(X | \mathcal{G}_0)$ est donc une constante c . En prenant $A = \Omega$ dans la propriété définissante, $\int_{\Omega} c d\mathbb{P} = \int_{\Omega} X d\mathbb{P}$, soit $c \times 1 = \mathbb{E}(X) = 3,5$. Donc $\mathbb{E}(X | \mathcal{G}_0) = 3,5 = \mathbb{E}(X)$: **ne disposer d'aucune information** (autre que « l'expérience a eu lieu ») ramène à la seule espérance globale.

On retiendra, plus généralement (pour X intégrable quelconque, sur un espace probabilisé quelconque) :

$$\mathbb{E}(X | \mathcal{T}) = X \quad (\text{p.s.}), \quad \mathbb{E}(X | \{\emptyset, \Omega\}) = \mathbb{E}(X) \quad (\text{p.s.})$$

– les deux cas extrêmes de conditionnement, entre lesquels se situe toute sous-tribu $\mathcal{G}$ intermédiaire.

Propriété 11.9 – Propriétés de l'espérance conditionnelle

Soit $(\Omega, \mathcal{T}, \mathbb{P})$, $\mathcal{G}, \mathcal{H}$ des sous-tribus avec $\mathcal{H} \subset \mathcal{G} \subset \mathcal{T}$, X, Y intégrables, $\lambda \in \mathbb{R}$. Alors :

1. (linéarité) $\mathbb{E}(X + \lambda Y | \mathcal{G}) = \mathbb{E}(X | \mathcal{G}) + \lambda \mathbb{E}(Y | \mathcal{G})$ p.s. ;
2. (positivité) si $X \geq 0$ p.s., alors $\mathbb{E}(X | \mathcal{G}) \geq 0$ p.s. ;
3. (espérance totale) $\mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X)$;
4. (tour, ou « la plus petite tribu gagne ») $\mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) = \mathbb{E}(X | \mathcal{H})$;
5. (sortie des termes connus) si Y est $\mathcal{G}$ -mesurable et XY intégrable, $\mathbb{E}(XY | \mathcal{G}) = Y \mathbb{E}(X | \mathcal{G})$;
6. (indépendance) si X est indépendante de $\mathcal{G}$ (i.e. de tout événement de $\mathcal{G}$), $\mathbb{E}(X | \mathcal{G}) = \mathbb{E}(X)$;
7. (Jensen conditionnelle) si φ est convexe et $\varphi(X)$ intégrable, $\varphi(\mathbb{E}(X | \mathcal{G})) \leq \mathbb{E}(\varphi(X) | \mathcal{G})$.

Idée de preuve. Tous ces points se démontrent selon le même principe : on propose une variable $\mathcal{G}$ -mesurable candidate (souvent évidente, comme dans les points 3, 6) et on vérifie qu'elle satisfait la propriété définissante $\int_A (\cdot) d\mathbb{P} = \int_A X d\mathbb{P}$ pour tout $A \in \mathcal{G}$; l'unicité (Théorème 11.3 « Existence et unicité de l'espérance conditionnelle ») garantit alors que c'est bien $\mathbb{E}(X | \mathcal{G})$.

Démonstration. Pour chaque point, il s'agit de vérifier la propriété définissante $\int_A (\cdot) d\mathbb{P} = \int_A X d\mathbb{P}$ pour tout $A \in \mathcal{G}$; par unicité (Théorème 11.3 « Existence et unicité de l'espérance conditionnelle »), cela suffit à conclure.

- *Points 1–2.* Linéarité et positivité découlent directement de la linéarité et de la monotonie de l'intégrale, appliquées à la propriété définissante.
- *Point 3.* Prendre $A = \Omega \in \mathcal{G}$ dans la propriété définissante : $\int_{\Omega} \mathbb{E}(X | \mathcal{G}) d\mathbb{P} = \int_{\Omega} X d\mathbb{P}$, c'est-à-dire $\mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X)$.
- *Point 4.* Pour $A \in \mathcal{H} \subset \mathcal{G}$: $\int_A \mathbb{E}(X | \mathcal{H}) d\mathbb{P} = \int_A X d\mathbb{P} = \int_A \mathbb{E}(X | \mathcal{G}) d\mathbb{P}$ (car $A \in \mathcal{G}$ aussi, et $\mathbb{E}(X | \mathcal{G})$ vérifie la propriété définissante) $= \int_A \mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) d\mathbb{P}$ (propriété définissante appliquée à $\mathbb{E}(X | \mathcal{G})$, valable pour $A \in \mathcal{H}$). Ainsi $\mathbb{E}(X | \mathcal{H})$ et $\mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H})$ vérifient la même propriété définissante sur $\mathcal{H}$: par unicité, ils coïncident.
- *Point 5.* On vérifie d'abord l'égalité pour $Y = \mathbf{1}_B$, $B \in \mathcal{G}$: pour $A \in \mathcal{G}$, $\int_A \mathbf{1}_B \mathbb{E}(X | \mathcal{G}) d\mathbb{P} = \int_{A \cap B} \mathbb{E}(X | \mathcal{G}) d\mathbb{P} = \int_{A \cap B} X d\mathbb{P} = \int_A \mathbf{1}_B X d\mathbb{P}$ (la propriété définissante appliquée à $A \cap B \in \mathcal{G}$). On étend ensuite

par linéarité aux fonctions $\mathcal{G}$ -mesurables étagées, puis par convergence monotone (pour $Y \geq 0$) et différence (cas général) aux fonctions $\mathcal{G}$ -mesurables générales.

- *Point 6.* Si X est indépendante de $\mathcal{G}$, pour tout $A \in \mathcal{G}$: $\int_A X d\mathbb{P} = \mathbb{E}(X \mathbf{1}_A) = \mathbb{E}(X) \mathbb{E}(\mathbf{1}_A) = \mathbb{E}(X) \mathbb{P}(A) = \int_A \mathbb{E}(X) d\mathbb{P}$ (la deuxième égalité par indépendance de X et $\mathbf{1}_A$, Proposition 9.67 « Caractérisation de l'indépendance ») : la constante $\mathbb{E}(X)$ vérifie la propriété définissante de $\mathbb{E}(X | \mathcal{G})$, donc lui est égale par unicité.

■

Exemple 11.10 – Le point 3 est un cas particulier du point 4, et sa réciproque

Reprenons les deux tribus extrêmes de l'Exemple 11.8 « Les deux cas extrêmes : tribu grossière et tribu discrète » : $\mathcal{T}$ (totale, ou « discrète » pour un Ω fini) et $\mathcal{G}_0 = \{\emptyset, \Omega\}$ (grossière), avec $\mathcal{G}_0 \subset \mathcal{G} \subset \mathcal{T}$ pour toute sous-tribu $\mathcal{G}$.

Le point 3 est le point 4 avec $\mathcal{H} = \mathcal{G}_0$. En prenant $\mathcal{H} = \mathcal{G}_0$ dans le point 4, et en utilisant $\mathbb{E}(X | \mathcal{G}_0) = \mathbb{E}(X)$ (Exemple 11.8 « Les deux cas extrêmes : tribu grossière et tribu discrète ») des deux côtés :

$$\mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{G}_0) = \mathbb{E}(X | \mathcal{G}_0) \iff \mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X),$$

qui est exactement le point 3. Aucune contradiction entre les points 3 et 4, donc : le premier est un cas particulier du second.

Et si l'on permute $\mathcal{G}$ et $\mathcal{H}$? Prenons cette fois $\mathcal{G} = \mathcal{T}$ dans le point 4 (au lieu de $\mathcal{H} = \mathcal{G}_0$) : pour $\mathcal{H} \subset \mathcal{T}$ quelconque,

$$\mathbb{E}(\mathbb{E}(X | \mathcal{T}) | \mathcal{H}) = \mathbb{E}(X | \mathcal{H}) \iff \mathbb{E}(X | \mathcal{H}) = \mathbb{E}(X | \mathcal{H})$$

(en utilisant $\mathbb{E}(X | \mathcal{T}) = X$, Exemple 11.8 « Les deux cas extrêmes : tribu grossière et tribu discrète ») : une tautologie, qui ne renseigne sur rien de nouveau – mais confirme au passage que $\mathbb{E}(\mathbb{E}(X | \mathcal{H}) | \mathcal{T}) = \mathbb{E}(X | \mathcal{H})$ également (car $\mathbb{E}(X | \mathcal{H})$, étant déjà $\mathcal{T}$ -mesurable comme toute variable aléatoire, est inchangée par un conditionnement supplémentaire par $\mathcal{T}$). Plus généralement, pour $\mathcal{H} \subset \mathcal{G}$ quelconques (pas seulement les deux cas extrêmes), on a dans les **deux sens** : $\mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) = \mathbb{E}(X | \mathcal{H})$ (point 4) et $\mathbb{E}(\mathbb{E}(X | \mathcal{H}) | \mathcal{G}) = \mathbb{E}(X | \mathcal{H})$ (car $\mathbb{E}(X | \mathcal{H})$ est $\mathcal{H}$ -mesurable, donc *a fortiori* $\mathcal{G}$ -mesurable, donc inchangée par un conditionnement supplémentaire par $\mathcal{G}$) – dans les deux cas, « la plus petite tribu $\mathcal{H}$ gagne ».

Attention 11.11 – $\mathbb{E}(X | Y = y)$ est un nombre, $\mathbb{E}(X | Y)$ est une variable aléatoire

Une confusion fréquente porte sur la nature de $\mathbb{E}(X | Y)$. Pour **chaque valeur fixée** y , $\mathbb{E}(X | Y = y)$ est bien un **nombre** (l'espérance de X calculée sous la loi conditionnelle sachant $\{Y = y\}$). Mais $\mathbb{E}(X | Y)$, *sans* valeur fixée pour y , désigne par convention la variable aléatoire $\varphi(Y)$, où $\varphi : y \mapsto \mathbb{E}(X | Y = y)$: c'est donc une variable aléatoire, fonction de Y (plus précisément $\sigma(Y)$ -mesurable), et non un nombre. Voir l'Exercice 11.14 « Espérance conditionnelle pour le couple uniforme sur un triangle » : on y calcule d'abord $\mathbb{E}(X | Y = y) = y/2$ (un nombre, dépendant du paramètre y), puis on en déduit $\mathbb{E}(X | Y) = Y/2$ (une variable aléatoire, en remplaçant le paramètre y par la variable aléatoire Y) – ce n'est pas une erreur, mais la convention standard : $\mathbb{E}(X | Y)$ est *par définition* $\sigma(Y)$ -mesurable, jamais un simple nombre (sauf si X et Y sont indépendantes, auquel cas $\mathbb{E}(X | Y) = \mathbb{E}(X)$ est une variable aléatoire constante – un nombre « déguisé » en variable aléatoire).

Remarque 11.12 – Que signifie « X indépendante de $\mathcal{G}$ » au point 6 ?

Dire que X est indépendante de la tribu $\mathcal{G}$ signifie : pour **tout** événement $A \in \mathcal{G}$, la variable aléatoire X est indépendante de l'événement A , au sens habituel (Définition 9.14 « Indépendance de deux événements », Chapitre 9 « Variables aléatoires réelles ») : $\mathbb{P}(X \in B, A) = \mathbb{P}(X \in B) \mathbb{P}(A)$ pour tout borélien B . Intuitivement, *aucun* événement décrit par l'information $\mathcal{G}$ ne renseigne quoi que ce soit sur X . C'est équivalent à dire que les tribus $\sigma(X)$ et $\mathcal{G}$ sont indépendantes (Définition 10.11 « Composantes indépendantes », Chapitre 10 « Vecteurs aléatoires », étendue à des tribus quelconques plutôt qu'à des tribus engendrées par des variables). Par exemple, si $\mathcal{G} = \sigma(Y)$ pour une variable Y , « X indépendante de $\mathcal{G}$ » équivaut exactement à « X et Y indépendantes » au sens usuel.

Méthode 11.13 – Calculer une espérance conditionnelle

1. **Cas discret** : si Y est discrète à valeurs dans $\{y_i\}$, $\mathbb{E}(X | Y) = \sum_i \mathbb{E}(X | Y = y_i) \mathbf{1}_{Y=y_i}$, avec $\mathbb{E}(X | Y = y_i) = \mathbb{E}(X \mathbf{1}_{Y=y_i}) / \mathbb{P}(Y = y_i)$ (rappel du paragraphe précédent).
2. **Cas à densité** : si (X, Y) a une densité jointe $f_{X,Y}$, on calcule la densité conditionnelle $f_{X|Y=y}(x) = f_{X,Y}(x, y) / f_Y(y)$ (là où $f_Y(y) > 0$), puis $\mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx$.
3. **Méthode de la « bonne devinette »** : grâce à l'unicité (Théorème 11.3 « Existence et unicité de l'espérance conditionnelle »), il suffit de deviner une variable $\mathcal{G}$ -mesurable Z et de vérifier $\int_A Z d\mathbb{P} = \int_A X d\mathbb{P}$ pour tout $A \in \mathcal{G}$ (ou, plus simplement, pour A dans une famille génératrice de $\mathcal{G}$) : c'est souvent la méthode la plus rapide pour des calculs explicites.

Exercice 11.14 – Espérance conditionnelle pour le couple uniforme sur un triangle

Reprenons le couple (X, Y) uniforme sur le triangle $\{0 < x < y < 1\}$ (Chapitre 10 « Vecteurs aléatoires », Exemple 10.6 « Vecteur uniforme sur un triangle »), de densité jointe $f_{X,Y}(x, y) = 2 \mathbf{1}_{\{0 < x < y < 1\}}$ et de densité marginale $f_Y(y) = 2y$ sur $]0, 1[$. Calculer $\mathbb{E}(X | Y = y)$, puis $\mathbb{E}(X | Y)$.

Solution

Pour $y \in]0, 1[$, la densité conditionnelle (Méthode 11.13 « Calculer une espérance conditionnelle », point 2) est $f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{2}{2y} = \frac{1}{y}$ pour $x \in]0, y[$ (et 0 ailleurs) : sachant $Y = y$, X est uniforme sur $]0, y[$ – un résultat qui se lit d'ailleurs directement sur la définition du triangle, $X < Y$, sans aucun autre biais. Donc

$$\mathbb{E}(X | Y = y) = \int_0^y x \cdot \frac{1}{y} dx = \frac{1}{y} \cdot \frac{y^2}{2} = \frac{y}{2}, \quad \text{d'où} \quad \mathbb{E}(X | Y) = \frac{Y}{2}.$$

Exemple 11.15 – Interprétation

Le résultat $\mathbb{E}(X | Y) = Y/2$ est très intuitif : sachant que $Y = y$, on sait seulement que X est uniformément répartie entre 0 et y (aucune autre information ne distingue les points de cet intervalle) ; la meilleure prévision de X est donc le milieu de cet intervalle, $y/2$. C'est un exemple de **régression** de X sur Y : ici, la régression est *linéaire* ($\mathbb{E}(X | Y = y)$ est une fonction affine de y), mais ce n'est pas systématique – on y reviendra en détail dans la section sur la régression linéaire, plus loin dans ce chapitre.

11.2 Lois conditionnelles

La Méthode 11.13 « Calculer une espérance conditionnelle » donnait des formules de calcul de $\mathbb{E}(X | Y = y)$ dans les cas discret et à densité, en faisant intervenir au passage une « probabilité conditionnelle sachant $Y = y$ » ($\mathbb{P}(X = x | Y = y)$), ou une densité conditionnelle $f_{X|Y=y}$ sans jamais définir ces objets en toute généralité. C'est l'objet de ce paragraphe : donner un sens rigoureux à *la loi de X sachant $Y = y$* , et pas seulement à son espérance.

Important. L'espérance conditionnelle $\mathbb{E}(X | Y)$ ne retient qu'un **résumé** de l'information apportée par Y sur X : sa moyenne, une fois Y connue. La **loi conditionnelle** de X sachant $Y = y$ retient, elle, *toute* l'information : elle permet de calculer non seulement $\mathbb{E}(X | Y = y)$, mais aussi $\text{Var}(X | Y = y)$, $\mathbb{P}(X \in A | Y = y)$ pour tout borélien A , ou plus généralement $\mathbb{E}(\varphi(X) | Y = y)$ pour toute fonction φ – toutes ces quantités s'obtenant en intégrant la fonction voulue contre cette même loi conditionnelle.

Définition 11.16 – Loi conditionnelle, ou noyau de transition

Soient X, Y deux variables aléatoires réelles sur $(\Omega, \mathcal{T}, \mathbb{P})$. On appelle **loi conditionnelle** de X sachant Y une famille $(\mathbb{P}_{X|Y=y})_{y \in \mathbb{R}}$ de mesures de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ telle que :

1. pour tout borélien $A \in \mathcal{B}(\mathbb{R})$ fixé, l'application $y \mapsto \mathbb{P}_{X|Y=y}(A)$ est mesurable ;
2. pour tous boréliens $A, B \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}(X \in A, Y \in B) = \int_B \mathbb{P}_{X|Y=y}(A) d\mathbb{P}_Y(y).$$

Remarque 11.17

La condition 2, appliquée à $B = \mathbb{R}$, donne $\mathbb{P}(X \in A) = \int_{\mathbb{R}} \mathbb{P}_{X|Y=y}(A) d\mathbb{P}_Y(y) = \mathbb{E}(\mathbb{P}_{X|Y=y}(A))$: la loi de X s'obtient en « moyennant » les lois conditionnelles sur toutes les valeurs de y , pondérées par la loi de Y . C'est l'analogue, pour des lois continues, de la formule des probabilités totales $\mathbb{P}(X \in A) = \sum_i \mathbb{P}(X \in A | Y = y_i) \mathbb{P}(Y = y_i)$ déjà connue pour Y discrète.

Théorème 11.18 – Existence d'une loi conditionnelle

Pour tout couple (X, Y) de variables aléatoires réelles, il existe une loi conditionnelle de X sachant Y , unique $\mathbb{P}_Y$ -presque partout (au sens où deux versions coïncident pour $\mathbb{P}_Y$ -presque tout y).

Idée de preuve. [admise] La démonstration complète, technique, repose sur le fait que $\mathbb{R}$ est un espace **polonais** (métrique, complet, séparable) : on construit d'abord $y \mapsto \mathbb{P}_{X|Y=y}([-\infty, q])$ pour q décrivant $\mathbb{Q}$ (chaque fonction étant obtenue comme une densité de Radon-Nikodym, Théorème 11.3 « Existence et unicité de l'espérance conditionnelle », appliquée à $\mathbb{P}(X \leq q, Y \in \cdot)$ par rapport à $\mathbb{P}_Y$), puis on recolle ces fonctions de répartition partielles (définies sur $\mathbb{Q}$ seulement) en une vraie fonction de répartition pour $\mathbb{P}_Y$ -presque tout y , en utilisant la continuité à droite et la croissance – un argument de théorie de la mesure hors-programme dans ce livret.

Propriété 11.19 – Formule de transfert conditionnelle

Soit $(\mathbb{P}_{X|Y=y})_y$ une loi conditionnelle de X sachant Y . Pour toute fonction $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ mesurable telle que $\varphi(X)$ soit intégrable, en posant $h(y) := \int_{\mathbb{R}} \varphi(x) d\mathbb{P}_{X|Y=y}(x)$, on a

$$\mathbb{E}(\varphi(X) | Y) = h(Y) \quad \text{presque sûrement.}$$

En particulier, $\mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x d\mathbb{P}_{X|Y=y}(x)$ et $\mathbb{P}(X \in A | Y = y) = \mathbb{P}_{X|Y=y}(A)$.

Démonstration. Soit $B \in \mathcal{B}(\mathbb{R})$. Par la formule de transfert (Théorème 9.44 « Théorème de transfert », Chapitre 9 « Variables aléatoires réelles ») appliquée à Y :

$$\int_{\{Y \in B\}} h(Y) d\mathbb{P} = \int_B h(y) d\mathbb{P}_Y(y) = \int_B \left(\int_{\mathbb{R}} \varphi(x) d\mathbb{P}_{X|Y=y}(x) \right) d\mathbb{P}_Y(y).$$

Pour $\varphi = \mathbf{1}_A$ ($A \in \mathcal{B}(\mathbb{R})$), le membre de droite vaut $\int_B \mathbb{P}_{X|Y=y}(A) d\mathbb{P}_Y(y) = \mathbb{P}(X \in A, Y \in B)$ (Définition 11.16 « Loi conditionnelle, ou noyau de transition », point 2) $= \int_{\{Y \in B\}} \mathbf{1}_A(X) d\mathbb{P}$ (par définition de la probabilité d'une intersection comme intégrale d'un produit d'indicatrices). On a donc établi, pour $\varphi = \mathbf{1}_A$, que $h(Y)$ vérifie la propriété définissante de $\mathbb{E}(\varphi(X) | Y)$; par linéarité (fonctions étagées), convergence monotone ($\varphi \geq 0$) puis différence (cas général), l'égalité $\int_{\{Y \in B\}} h(Y) d\mathbb{P} = \int_{\{Y \in B\}} \varphi(X) d\mathbb{P}$ s'étend à toute φ mesurable telle que $\varphi(X)$ soit intégrable. Par unicité de l'espérance conditionnelle (Théorème 11.3 « Existence et unicité de l'espérance conditionnelle »), $\mathbb{E}(\varphi(X) | Y) = h(Y)$ presque sûrement. ■

Méthode 11.20 – Retrouver les formules usuelles

La Proposition 11.19 « Formule de transfert conditionnelle » permet de retrouver, comme cas particuliers, les deux formules déjà rencontrées :

1. **Cas discret** : si Y est discrète à valeurs dans $\{y_i\}$, la loi conditionnelle $\mathbb{P}_{X|Y=y_i}$ est la mesure discrète de poids $\mathbb{P}_{X|Y=y_i}(\{x\}) = \mathbb{P}(X = x | Y = y_i) = \frac{\mathbb{P}(X = x, Y = y_i)}{\mathbb{P}(Y = y_i)}$ – on vérifie directement que la Définition 11.16 « Loi conditionnelle, ou noyau de transition » est satisfaite, la condition 2 se réduisant à une somme sur les $y_i \in B$.
2. **Cas à densité** : si (X, Y) a une densité jointe $f_{X,Y}$, la loi conditionnelle $\mathbb{P}_{X|Y=y}$ a pour densité $f_{X|Y=y}(x) = f_{X,Y}(x, y)/f_Y(y)$ (là où $f_Y(y) > 0$) : la condition 2 de la Définition 11.16 « Loi conditionnelle, ou noyau de transition » devient exactement le théorème de Fubini (Chapitre 6 « Intégrales multiples ») appliqué à $\iint_{A \times B} f_{X,Y}$, en écrivant $f_{X,Y}(x, y) = f_{X|Y=y}(x) f_Y(y)$.

En particulier, $h(y) = \mathbb{E}(\varphi(X) | Y = y)$ se calcule bien par $\sum_x \varphi(x) \mathbb{P}(X = x | Y = y)$ (cas discret) ou $\int_{\mathbb{R}} \varphi(x) f_{X|Y=y}(x) dx$ (cas à densité), conformément à la Proposition 11.19 « Formule de transfert conditionnelle ».

Exemple 11.21 – Une loi conditionnelle qui n'est pas de la même famille que la loi jointe

Soit (X, Y) uniforme sur le disque unité $D = \{(x, y) \in \mathbb{R}^2 : x^2 + y^2 \leq 1\}$, de densité jointe $f_{X,Y}(x, y) = \frac{1}{\pi} \mathbf{1}_D(x, y)$. La marginale de Y est $f_Y(y) = \int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} \frac{1}{\pi} dx = \frac{2\sqrt{1-y^2}}{\pi}$ pour $y \in [-1, 1]$. Donc, pour $y \in]-1, 1[$ fixé,

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{1}{2\sqrt{1-y^2}} \mathbf{1}_{[-\sqrt{1-y^2}, \sqrt{1-y^2}]}(x) :$$

la loi conditionnelle de X sachant $Y = y$ est la loi **uniforme** sur $[-\sqrt{1-y^2}, \sqrt{1-y^2}]$ – un intervalle dont la longueur *dépend de y* ! On voit ici toute la richesse de la loi conditionnelle par rapport à la seule espérance conditionnelle : $\mathbb{E}(X | Y = y) = 0$ pour tout y (par symétrie de l'intervalle), ce qui ne dit rien de la dispersion de X autour de 0, alors que la loi conditionnelle donne accès à $\text{Var}(X | Y = y) = \frac{(1-y^2)}{3}$ (variance d'une loi uniforme sur un intervalle de demi-longueur $\sqrt{1-y^2}$), qui elle *varie* avec y : X est beaucoup plus dispersée sachant $Y = 0$ (le grand axe du disque) que sachant Y proche de ± 1 (près du bord).

Propriété 11.22 – Formule de la variance totale

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $\mathcal{G}$ une sous-tribu de $\mathcal{T}$, $X \in L^2(\Omega, \mathbb{P})$. En posant $\text{Var}(X | \mathcal{G}) := \mathbb{E}(X^2 | \mathcal{G}) - \mathbb{E}(X | \mathcal{G})^2$, on a

$$\text{Var}(X) = \mathbb{E}(\text{Var}(X | \mathcal{G})) + \text{Var}(\mathbb{E}(X | \mathcal{G})).$$

Démonstration. Par la propriété de tour (Proposition 11.9 « Propriétés de l'espérance conditionnelle », point 3), $\mathbb{E}(\mathbb{E}(X^2 | \mathcal{G})) = \mathbb{E}(X^2)$ et $\mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X)$. Donc

$$\mathbb{E}(\text{Var}(X | \mathcal{G})) = \mathbb{E}(\mathbb{E}(X^2 | \mathcal{G})) - \mathbb{E}(\mathbb{E}(X | \mathcal{G})^2) = \mathbb{E}(X^2) - \mathbb{E}(\mathbb{E}(X | \mathcal{G})^2).$$

Par ailleurs, en posant $Z := \mathbb{E}(X | \mathcal{G})$,

$$\text{Var}(Z) = \mathbb{E}(Z^2) - \mathbb{E}(Z)^2 = \mathbb{E}(\mathbb{E}(X | \mathcal{G})^2) - \mathbb{E}(X)^2$$

(car $\mathbb{E}(Z) = \mathbb{E}(X)$, tour). En sommant les deux expressions, les termes $\mathbb{E}(\mathbb{E}(X | \mathcal{G})^2)$ s'annulent :

$$\mathbb{E}(\text{Var}(X | \mathcal{G})) + \text{Var}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \text{Var}(X).$$

■

Remarque 11.23 – Une formule extrêmement utile en pratique

Cette décomposition – parfois appelée « loi de la variance totale », ou *Eve's law* dans la littérature anglophone – est bien plus qu'une curiosité théorique : elle sous-tend, par exemple, l'analyse de variance (ANOVA) en statistique (décomposer la variance totale d'une mesure en une part « expliquée » par un facteur $\mathcal{G}$ et une part « résiduelle »), le compromis biais-variance en apprentissage statistique, ou encore l'analyse de la variance d'un estimateur construit en deux étapes (échantillonnage puis simulation, méthodes de Monte-Carlo hiérarchiques). Le terme $\text{Var}(\mathbb{E}(X \mid \mathcal{G}))$ mesure la part de la variabilité de X « expliquée » par l'information $\mathcal{G}$; le terme $\mathbb{E}(\text{Var}(X \mid \mathcal{G}))$ mesure la variabilité **résiduelle**, celle qui subsiste même une fois $\mathcal{G}$ connue. Elle répond d'ailleurs précisément à la question posée plus haut (Remarque sur le point 3) : c'est $\text{Var}(\mathbb{E}(X \mid \mathcal{G}))$, et non $\mathbb{E}(\mathbb{E}(X \mid \mathcal{G}))$, qui quantifie l'apport réel de $\mathcal{G}$ à la connaissance de X .

Exercice 11.24

Calculer $\text{Var}(X \mid Y = y)$ pour l'Exemple 11.21 « Une loi conditionnelle qui n'est pas de la même famille que la loi jointe », et vérifier la formule de la variance totale (Proposition 11.22 « Formule de la variance totale ») : $\text{Var}(X) = \mathbb{E}(\text{Var}(X \mid Y)) + \text{Var}(\mathbb{E}(X \mid Y))$.

Solution

Pour $U \sim \mathcal{U}([-a, a])$, $\text{Var}(U) = \frac{(2a)^2}{12} = \frac{a^2}{3}$ (rappel de licence, formule de la variance d'une loi uniforme). Ici $a = \sqrt{1 - y^2}$, donc $\text{Var}(X \mid Y = y) = \frac{1 - y^2}{3}$. Comme $\mathbb{E}(X \mid Y) = 0$ presque sûrement (Exemple 11.21 « Une loi conditionnelle qui n'est pas de la même famille que la loi jointe »), $\text{Var}(\mathbb{E}(X \mid Y)) = \text{Var}(0) = 0$, donc la formule de la variance totale donne $\text{Var}(X) = \mathbb{E}(\text{Var}(X \mid Y)) = \mathbb{E}\left(\frac{1 - Y^2}{3}\right) = \frac{1 - \mathbb{E}(Y^2)}{3}$. Par symétrie du disque, $\mathbb{E}(Y^2) = \mathbb{E}(X^2) = \frac{1}{2}\mathbb{E}(X^2 + Y^2)$; un calcul en coordonnées polaires (hors-programme dans son détail) donne $\mathbb{E}(X^2 + Y^2) = \frac{1}{2}$, donc $\mathbb{E}(Y^2) = \frac{1}{4}$, et finalement $\text{Var}(X) = \frac{1 - \frac{1}{4}}{3} = \frac{1}{4}$ – que l'on peut vérifier directement être la variance de la loi marginale (uniforme sur le disque) de X .

11.3 Régression linéaire

On termine ce chapitre par une application majeure, en statistique, de la construction de l'espérance conditionnelle comme projection orthogonale dans L^2 (Remarque 11.6 « Une autre construction, plus intuitive : le cas L^2 ») : la **régression linéaire**.

Soient $X, Y_1, \dots, Y_n$ des variables aléatoires dans $L^2(\Omega, \mathcal{A}, \mathbb{P})$. On cherche à trouver la meilleure approximation de X comme fonction **affine** de $Y_1, \dots, Y_n$. Précisément, on cherche à minimiser

$$\mathbb{E}[(X - (\beta_0 + \beta_1 Y_1 + \dots + \beta_n Y_n))^2]$$

sur tous les choix possibles du $(n+1)$ -uplet de réels $(\beta_0, \dots, \beta_n)$.

Propriété 11.25 – Droite – ou hyperplan – de régression

$$\inf_{\beta_0, \dots, \beta_n \in \mathbb{R}} \mathbb{E}[(X - (\beta_0 + \beta_1 Y_1 + \dots + \beta_n Y_n))^2] = \mathbb{E}[(X - Z)^2],$$

où

$$Z = \mathbb{E}(X) + \sum_{j=1}^n \alpha_j (Y_j - \mathbb{E}(Y_j)),$$

les coefficients α_j étant (n'importe quelle) solution du système

$$\sum_{j=1}^n \alpha_j \text{Cov}(Y_j, Y_k) = \text{Cov}(X, Y_k), \quad 1 \leq k \leq n.$$

En particulier, si la matrice de covariance $\Sigma_Y = (\text{Cov}(Y_j, Y_k))_{j,k}$ est non dégénérée, on a $\alpha = \text{Cov}(X, Y) \Sigma_Y^{-1}$ en notation matricielle (avec $\text{Cov}(X, Y) = (\text{Cov}(X, Y_1), \dots, \text{Cov}(X, Y_n))$).

Idée de preuve. Soit H le sous-espace vectoriel de $L^2(\Omega, \mathcal{A}, \mathbb{P})$ engendré par $1, Y_1, \dots, Y_n$ (un sous-espace de dimension finie, donc fermé, Chapitre 7 « Espaces L^p »). Le réel $\inf_{U \in H} \mathbb{E}[(X - U)^2] = \inf_{U \in H} \|X - U\|_2^2$ est minimal exactement lorsque U est la **projection orthogonale** de X sur H – exactement le même principe que la construction de l'espérance conditionnelle comme projection sur $L^2(\Omega, \mathcal{G}, \mathbb{P})$. On écrit cette projection sous la forme $Z = \alpha_0 + \sum_j \alpha_j (Y_j - \mathbb{E}(Y_j))$, et l'on traduit la caractérisation de la projection orthogonale ($X - Z$ orthogonal à H) en équations sur les α_j .

Démonstration. Soit $H = \text{Vect}(1, Y_1, \dots, Y_n) \subset L^2(\Omega, \mathcal{A}, \mathbb{P})$, un sous-espace vectoriel de dimension finie (donc fermé). La variable Z qui minimise $\|X - U\|_2$ pour $U \in H$ est la projection orthogonale de X sur H (propriété générale de la projection orthogonale sur un sous-espace fermé d'un espace de Hilbert, admise – c'est exactement le même argument que celui utilisé pour construire $\mathbb{E}(X | \mathcal{G})$). On peut écrire Z sous la forme

$$Z = \alpha_0 + \sum_{j=1}^n \alpha_j (Y_j - \mathbb{E}(Y_j))$$

(un $(n+1)$ -uplet $(\alpha_0, \dots, \alpha_n)$ décrivant H tout entier lorsque $1, Y_1 - \mathbb{E}(Y_1), \dots, Y_n - \mathbb{E}(Y_n)$ en forment une famille génératrice, ce qui est toujours le cas).

Par définition de la projection orthogonale, $X - Z$ est orthogonal à H (pour le produit scalaire $\langle U, V \rangle = \mathbb{E}(UV)$ de L^2), donc en particulier orthogonal à chacun des générateurs de H . Orthogonalité à 1 :

$$\mathbb{E}[(X - Z) \cdot 1] = 0,$$

d'où $\alpha_0 = \mathbb{E}(X)$ (en développant : $\mathbb{E}(X) - \alpha_0 - \sum_j \alpha_j \mathbb{E}(Y_j - \mathbb{E}(Y_j)) = \mathbb{E}(X) - \alpha_0 = 0$, le second terme étant nul par définition de $\mathbb{E}(Y_j)$). Orthogonalité à $Y_k - \mathbb{E}(Y_k)$, pour chaque $k \in \{1, \dots, n\}$:

$$\mathbb{E}[(X - Z) \cdot (Y_k - \mathbb{E}(Y_k))] = 0,$$

ce qui équivaut à $\text{Cov}(Z, Y_k) = \text{Cov}(X, Y_k)$ (en reconnaissant, dans le développement, la définition de la covariance), ou encore, par bilinéarité de la covariance (Proposition 10.17 « Propriétés élémentaires de la

covariance », Chapitre 10 « Vecteurs aléatoires ») appliquée à $Z = \alpha_0 + \sum_j \alpha_j (Y_j - \mathbb{E}(Y_j))$:

$$\sum_{j=1}^n \alpha_j \text{Cov}(Y_j, Y_k) = \text{Cov}(X, Y_k).$$

Réciproquement, si les coefficients α_j vérifient ce système d'équations, il est immédiat que la variable Z ainsi définie est un élément de H tel que $X - Z$ soit orthogonal à H , donc coïncide avec la projection orthogonale de X sur H (unicité de la projection orthogonale sur un sous-espace fermé). ■

11.3.1 Cas $n = 1$: la droite de régression

Remarque 11.26 – Cas $n = 1$

Si $n = 1$ et que Y n'est pas constante presque sûrement (i.e. $\text{Var}(Y) > 0$), le système de la Proposition 11.25 « Droite – ou hyperplan – de régression » se réduit à une seule équation, $\alpha \text{Var}(Y) = \text{Cov}(X, Y)$, d'où $\alpha = \text{Cov}(X, Y)/\text{Var}(Y)$, et la meilleure approximation affine de X par une fonction de Y est

$$Z = \mathbb{E}(X) + \frac{\text{Cov}(X, Y)}{\text{Var}(Y)}(Y - \mathbb{E}(Y)).$$

C'est ce qu'on appelle parfois la **droite de régression** de X en Y .

Exemple 11.27 – Droite de régression sur des données concrètes

Un professeur note, pour 10 étudiants, le nombre d'heures de révision Y_i et la note obtenue X_i à un examen (sur 100) :

i	1	2	3	4	5	6	7	8	9	10
Y_i (heures)	1	2	3	4	5	6	7	8	9	10
X_i (note)	52	58	55	65	68	66	75	78	80	88

On modélise ces données comme les valeurs d'un couple (X, Y) discret, uniforme sur ces 10 observations (chacune de probabilité $\frac{1}{10}$) – c'est le point de vue de la **statistique descriptive** : $\mathbb{E}$, Var , Cov désignent alors simplement les moyennes, variances et covariance *empiriques* des données.

On calcule $\mathbb{E}(Y) = \frac{1}{10} \sum_i Y_i = 5.5$, $\mathbb{E}(X) = \frac{1}{10} \sum_i X_i = 68.5$, puis

$$\text{Var}(Y) = \frac{1}{10} \sum_i (Y_i - 5.5)^2 = 8.25, \quad \text{Cov}(X, Y) = \frac{1}{10} \sum_i (X_i - 68.5)(Y_i - 5.5) = 31.05.$$

Par la Remarque 11.26 « Cas $n = 1$ », $\alpha = \text{Cov}(X, Y)/\text{Var}(Y) = 31.05/8.25 \approx 3.76$, et la droite de régression de X en Y est

$$Z = 68.5 + 3.76(Y - 5.5) \approx 3.76Y + 47.8.$$

Interprétation : chaque heure de révision supplémentaire est associée, en moyenne (au sens de cette approximation affine), à un gain d'environ 3.76 points à l'examen.




Figure 35: Le nuage de points (Y_i, X_i) (en bleu) et la droite de régression $Z = 3.76Y + 47.8$ (en rouge) : la droite passe par le point moyen $(\mathbb{E}(Y), \mathbb{E}(X)) = (5.5, 68.5)$ et minimise la somme des carrés des écarts verticaux au nuage de points.

11.3.2 Cas $n = 2$: le plan de régression

Remarque 11.28 – Cas $n = 2$

Pour $n = 2$, si la matrice de covariance $\Sigma_Y = \begin{pmatrix} \text{Var}(Y_1) & \text{Cov}(Y_1, Y_2) \\ \text{Cov}(Y_1, Y_2) & \text{Var}(Y_2) \end{pmatrix}$ est inversible (i.e. Y_1, Y_2 ne sont pas affinement liées presque sûrement), le système de la Proposition 11.25 « Droite – ou hyperplan – de régression » se résout par $\alpha = (\alpha_1, \alpha_2)^\top = \Sigma_Y^{-1} \begin{pmatrix} \text{Cov}(X, Y_1) \\ \text{Cov}(X, Y_2) \end{pmatrix}$, et

$$Z = \mathbb{E}(X) + \alpha_1(Y_1 - \mathbb{E}(Y_1)) + \alpha_2(Y_2 - \mathbb{E}(Y_2))$$

est appelé le **plan de régression** de X en (Y_1, Y_2) .

Exemple 11.29 – Plan de régression sur des données concrètes

Reprenons 10 étudiants, en relevant cette fois deux variables explicatives : le nombre d'heures de révision $Y_{1,i}$, et la note obtenue à un devoir précédent $Y_{2,i}$ (sur 10, volontairement choisie sans lien particulier avec Y_1 pour illustrer un cas bien conditionné) :

i	1	2	3	4	5	6	7	8	9	10
$Y_{1,i}$ (révision)	1	2	3	4	5	6	7	8	9	10
$Y_{2,i}$ (devoir précédent)	3	8	4	9	2	7	5	10	1	6
X_i (note)	39	59	52	80	51	78	78	96	71	93

On calcule $\mathbb{E}(Y_1) = 5.5$, $\mathbb{E}(Y_2) = 5.5$, $\mathbb{E}(X) = 69.7$. Les variances et covariances empiriques donnent

$$\Sigma_Y = \begin{pmatrix} 8.25 & 0.05 \\ 0.05 & 8.25 \end{pmatrix}, \quad \begin{pmatrix} \text{Cov}(X, Y_1) \\ \text{Cov}(X, Y_2) \end{pmatrix} = \begin{pmatrix} 40.55 \\ 31.05 \end{pmatrix}.$$

(Y_1 et Y_2 sont ici presque décorréliées, Σ_Y étant presque diagonale – un choix délibéré pour que le plan de régression soit nettement incliné dans les deux directions à la fois.) La résolution du système $\Sigma_Y \alpha = (\text{Cov}(X, Y_1), \text{Cov}(X, Y_2))^\top$ donne $\alpha_1 \approx 4.89$, $\alpha_2 \approx 3.73$, d'où le plan de régression :

$$Z \approx 69.7 + 4.89(Y_1 - 5.5) + 3.73(Y_2 - 5.5) \approx 4.89Y_1 + 3.73Y_2 + 22.25.$$

Interprétation : à note de devoir précédent fixée, chaque heure de révision supplémentaire apporte environ 4.89 points ; à révision fixée, chaque point supplémentaire au devoir précédent est associé à un gain d'environ




Figure 36: Les 10 points $(Y_{1,i}, Y_{2,i}, X_i)$ (en bleu, note divisée par 10 pour l’affichage) et le plan de régression (en rose) : nettement incliné selon les deux directions Y_1 et Y_2 , généralisation à deux variables explicatives de la droite de régression.

3.73 points à l’examen – les deux variables explicatives contribuent ici de façon comparable et substantielle.

12 Vecteurs aléatoires gaussiens

Objectifs

- Connaître la définition et les propriétés de la fonction caractéristique d'une variable aléatoire réelle, et le théorème d'unicité qui lui est associé.
- Définir un vecteur gaussien et connaître sa fonction caractéristique.
- Savoir construire un vecteur gaussien de moyenne et de matrice de covariance données.
- Connaître la densité d'un vecteur gaussien non dégénéré.
- Démontrer et utiliser l'équivalence, spécifique à la loi normale, entre indépendance et décorrélation.
- Savoir manipuler les combinaisons linéaires et les sommes de vecteurs gaussiens.

Introduction

On a rencontré, au Chapitre 10 « Vecteurs aléatoires », deux limitations de la covariance : elle ne mesure qu'une dépendance *linéaire*, et $\text{Cov}(X, Y) = 0$ n'entraîne pas, en général, l'indépendance de X et Y . Ce chapitre étudie une classe de vecteurs aléatoires – les **vecteurs gaussiens** – pour laquelle ce défaut disparaît : la décorrélation devient équivalente à l'indépendance. C'est l'une des raisons pour lesquelles la loi normale multivariée est si présente en statistique (modèles linéaires, régression, analyse en composantes principales) : la matrice de covariance Σ y résume *entièrement* la structure de dépendance.

Avant de construire les vecteurs gaussiens, il nous faut l'outil central de ce chapitre : la fonction caractéristique d'une variable aléatoire réelle. On l'introduit ici, dans le cadre le plus général (toute variable aléatoire réelle, gaussienne ou non), avant de l'appliquer aux vecteurs gaussiens dans la section suivante, puis de la retrouver au Chapitre 13 « Convergence de suites de variables aléatoires » pour l'étude de la convergence en loi et le théorème central limite.

Rappel de L1 12.1 – nombres complexes et exponentielle complexe

On rappelle que pour $\theta \in \mathbb{R}$, $e^{i\theta} = \cos \theta + i \sin \theta$ (formule d'Euler), que $|e^{i\theta}| = 1$, et que l'exponentielle complexe vérifie les mêmes règles de calcul (dérivation, développement en série entière $e^z = \sum_k z^k/k!$) que l'exponentielle réelle. Ces propriétés seront utilisées constamment dans ce chapitre, où l'on manipule des espérances de variables aléatoires complexes e^{itX} .

12.1 Définition et exemples

Définition 12.2 – Fonction caractéristique

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace probabilisé, $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire. La **fonction caractéristique** de X est $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ définie par

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \mathbb{E}(\cos(tX)) + i \mathbb{E}(\sin(tX)).$$

Remarque 12.3

φ_X est toujours bien définie sur $\mathbb{R}$ tout entier, sans aucune hypothèse d'intégrabilité sur X : en effet $|e^{itX}| = 1$ est bornée, donc intégrable pour une mesure de probabilité (Proposition 5.25 « Intégrabilité »). C'est un avantage décisif par rapport, par exemple, à la transformée de Laplace $\mathbb{E}(e^{tX})$, qui peut ne pas exister.

Propriété 12.4 – Fonction caractéristique d'une loi entière

Si $X : \Omega \rightarrow \mathbb{Z}$, alors $\varphi_X(t) = \sum_{k \in \mathbb{Z}} \mathbb{P}(X = k) e^{itk}$.

Démonstration. Application directe du Théorème 9.44 « Théorème de transfert » : $\mathbb{E}(e^{itX}) = \int_{\mathbb{R}} e^{itx} d\mathbb{P}_X(x)$, et $\mathbb{P}_X$ est concentrée sur $\mathbb{Z}$. ■

Propriété 12.5 – Fonction caractéristique d'une variable à densité

Si X a pour densité f , alors $\varphi_X(t) = \int_{\mathbb{R}} e^{itx} f(x) dx$.

Démonstration. Même principe, application du Théorème 9.44 « Théorème de transfert ». ■

Exercice 12.6 – Calcul de fonctions caractéristiques usuelles

Calculer φ_X pour $X \sim \mathcal{B}(n, p)$, $X \sim \mathcal{P}(\lambda)$, $X \sim \mathcal{E}(\lambda)$, et $X \sim \mathcal{N}(0, 1)$.

Solution

Binomiale. $\varphi_X(t) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} e^{itk} = (pe^{it} + (1-p))^n$ (formule du binôme).

Poisson. $\varphi_X(t) = \sum_{k \geq 0} \frac{e^{-\lambda} \lambda^k}{k!} e^{itk} = e^{-\lambda} \sum_{k \geq 0} \frac{(\lambda e^{it})^k}{k!} = e^{-\lambda + \lambda e^{it}} = e^{\lambda(e^{it}-1)}$.

Exponentielle. $\varphi_X(t) = \lambda \int_0^{+\infty} e^{itx} e^{-\lambda x} dx = \lambda \left[\frac{e^{(it-\lambda)x}}{it-\lambda} \right]_0^{+\infty} = \frac{\lambda}{\lambda - it}$ (le crochet aux bornes se traite comme dans $\mathbb{R}$, le module de $e^{(it-\lambda)x}$ tendant vers 0 car $\lambda > 0$).

Normale centrée réduite. $\varphi_X(t) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itx} e^{-x^2/2} dx$. En posant $u_k = \int_0^{+\infty} \frac{x^{2k}}{(2k)!} e^{-x^2/2} dx$ et en développant e^{itx} en série entière (intersion série-intégrale justifiée par convergence normale), on obtient après intégrations par parties successives ($u_k = \frac{\sqrt{2\pi}}{k! 2^k}$) : $\varphi_X(t) = e^{-t^2/2}$.

12.2 Propriétés

Propriété 12.7 – Propriétés élémentaires

Soit X une variable aléatoire réelle, φ_X sa fonction caractéristique. Alors :

1. φ_X est continue sur $\mathbb{R}$;
2. $|\varphi_X(t)| \leq \varphi_X(0) = 1$ pour tout t ;
3. pour tous $a, b \in \mathbb{R}$, $\varphi_{aX+b}(t) = e^{ibt} \varphi_X(at)$.

Idée de preuve. La continuité s'obtient par convergence dominée (la fonction $t \mapsto e^{itX}$ étant uniformément bornée par 1, intégrable pour une mesure de probabilité). Le point 2 est l'inégalité triangulaire intégrée pour une variable complexe. Le point 3 est un calcul direct sur la définition.

Démonstration. *Continuité.* Soit $t \in \mathbb{R}$, (t_n) une suite réelle convergeant vers t . Pour tout ω , $e^{it_n X(\omega)} \rightarrow e^{itX(\omega)}$ (continuité de l'exponentielle complexe), et $|e^{it_n X(\omega)}| = 1$ pour tout n : la suite $(e^{it_n X})_n$ converge simplement, dominée par la constante 1, intégrable ($\mathbb{P}$ étant une mesure de probabilité). Par le Théorème 5.33 « Théorème de convergence dominée » (qui s'applique aussi aux fonctions à valeurs complexes en traitant séparément partie réelle et imaginaire), $\varphi_X(t_n) = \mathbb{E}(e^{it_n X}) \rightarrow \mathbb{E}(e^{itX}) = \varphi_X(t)$. Ainsi φ_X est continue en t , pour tout $t \in \mathbb{R}$.

Point 2. Pour une variable aléatoire complexe intégrable Z , $|\mathbb{E}(Z)| \leq \mathbb{E}(|Z|)$ (inégalité triangulaire, valable pour l'intégrale comme pour les sommes finies). En appliquant à $Z = e^{itX}$: $|\varphi_X(t)| = |\mathbb{E}(e^{itX})| \leq \mathbb{E}(|e^{itX}|) = \mathbb{E}(1) = 1$. Par ailleurs $\varphi_X(0) = \mathbb{E}(e^{i0 \cdot X}) = \mathbb{E}(1) = 1$.

Point 3. Pour $a, b \in \mathbb{R}$, $\varphi_{aX+b}(t) = \mathbb{E}(e^{it(aX+b)}) = \mathbb{E}(e^{ibt} e^{i(at)X}) = e^{ibt} \mathbb{E}(e^{i(at)X})$ (le facteur e^{ibt} ne dépendant pas de ω , il sort de l'espérance par linéarité) $= e^{ibt} \varphi_X(at)$. ■



Figure 37: Partie réelle de la fonction caractéristique pour deux lois usuelles (calculées dans l'Exercice 12.6 « Calcul de fonctions caractéristiques usuelles »). On observe que φ_X est paire et vaut 1 en $t = 0$ dans les deux cas – exactement les propriétés générales que l'on vient d'établir (Proposition 12.7 « Propriétés élémentaires »).

Exemple 12.8

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, on écrit $X = \sigma Y + \mu$ avec $Y \sim \mathcal{N}(0, 1)$; la Proposition 12.7 « Propriétés élémentaires » (point 3) donne $\varphi_X(t) = e^{i\mu t} \varphi_Y(\sigma t) = e^{i\mu t - \sigma^2 t^2 / 2}$.

Propriété 12.9 – Fonction caractéristique d'une somme de variables indépendantes

Si $X_1, \dots, X_n$ sont mutuellement indépendantes, alors $\varphi_{\sum_{i=1}^n X_i}(t) = \prod_{i=1}^n \varphi_{X_i}(t)$.

Démonstration. Soit $t \in \mathbb{R}$. On a $e^{it \sum_{i=1}^n X_i} = \prod_{i=1}^n e^{it X_i}$ (propriété de l'exponentielle). Les variables $e^{it X_1}, \dots, e^{it X_n}$ sont des fonctions (mesurables, bornées) des variables indépendantes $X_1, \dots, X_n$ respectivement, donc sont elles-mêmes indépendantes (Proposition 10.14 « Des fonctions de variables indépendantes sont indépendantes », Chapitre 10 « Vecteurs aléatoires »). Par conséquent, l'espérance de leur produit est

le produit des espérances :

$$\varphi_{\sum_i X_i}(t) = \mathbb{E}\left(\prod_{i=1}^n e^{itX_i}\right) = \prod_{i=1}^n \mathbb{E}(e^{itX_i}) = \prod_{i=1}^n \varphi_{X_i}(t).$$

■

Attention 12.10 – Le résultat le plus important de ce chapitre

C'est cette propriété – transformer une somme en un produit – qui fait tout l'intérêt de la fonction caractéristique par rapport à la fonction de répartition (pour laquelle la loi d'une somme de variables indépendantes s'obtient par un produit de convolution, bien plus lourd à manipuler). C'est elle qui rendra possible, au Chapitre 13 « Convergence de suites de variables aléatoires », la démonstration du théorème central limite.

Exemple 12.11 – Stabilité de la loi de Poisson par somme

Si $X_1, \dots, X_n$ sont indépendantes, $X_i \sim \mathcal{P}(\lambda_i)$, alors $\varphi_{\sum_i X_i}(t) = \prod_i e^{\lambda_i(e^{it}-1)} = e^{(\sum_i \lambda_i)(e^{it}-1)}$: on reconnaît la fonction caractéristique d'une loi $\mathcal{P}(\sum_i \lambda_i)$. Par le théorème d'unicité (Théorème 12.13 « Théorème d'inversion / unicité » ci-dessous), $\sum_i X_i \sim \mathcal{P}(\sum_i \lambda_i)$: c'est ainsi que l'on redémontre, très simplement, la stabilité de la loi de Poisson par somme (un résultat qui demandait, en licence, un calcul de convolution laborieux).

Méthode 12.12 – Trouver la loi d'une somme de variables indépendantes

Pour trouver la loi de $S = \sum_{i=1}^n X_i$ (X_i indépendantes) :

1. Calculer $\varphi_S = \prod_i \varphi_{X_i}$ (Proposition 12.9 « Fonction caractéristique d'une somme de variables indépendantes ») ;
2. Reconnaître, dans l'expression obtenue, la fonction caractéristique d'une loi usuelle connue (Exercice 12.6 « Calcul de fonctions caractéristiques usuelles ») ;
3. Conclure par unicité de la loi associée à une fonction caractéristique (Théorème 12.13 « Théorème d'inversion / unicité »).

Cette méthode évite systématiquement d'avoir à calculer un produit de convolution.

12.3 Lois et fonctions caractéristiques

Théorème 12.13 – Théorème d'inversion / unicité

Soit X une variable aléatoire réelle, F_X sa fonction de répartition, φ_X sa fonction caractéristique. Pour tous $a < b$ points de continuité de F_X :

$$F_X(b) - F_X(a) = \lim_{N \rightarrow +\infty} \int_{-N}^N \frac{e^{-iat} - e^{-ibt}}{2i\pi t} \varphi_X(t) dt.$$

En particulier, si X, Y ont même fonction caractéristique, elles ont même loi.

Idée de preuve. [admise] La démonstration complète (technique, admise dans son détail) repose sur le théorème de Fubini pour échanger $\int_{-N}^N \cdots dt$ et $\mathbb{E}(\cdots)$, puis sur le calcul explicite de l'intégrale $\int_0^N \frac{\sin(ct)}{t} dt \rightarrow \frac{\pi}{2} \text{sign}(c)$ (résultat d'analyse de licence, intégrale de Dirichlet). On retient surtout la **conséquence** : la fonction caractéristique détermine entièrement la loi, exactement comme la fonction de répartition (Proposition 9.30 « Caractérisation de la loi par la fonction de répartition ») – mais avec l'avantage, pour une somme de variables indépendantes, d'un calcul en produit plutôt qu'en convolution.

Rappel de L3 12.14 – intégrale de Dirichlet

On rappelle le résultat d'analyse $\lim_{N \rightarrow +\infty} \int_0^N \frac{\sin(s)}{s} ds = \frac{\pi}{2}$ (intégrale semi-convergente, calculable par exemple via les intégrales de Fresnel ou un argument de convergence dominée sur la transformée de Laplace de sinc). C'est cette intégrale, après changement de variable $s = ct$, qui apparaît dans la démonstration du Théorème 12.13 « Théorème d'inversion / unicité ».

Théorème 12.15 – Théorème de Lévy

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires réelles. Si (φ_{X_n}) converge simplement vers une fonction φ continue en 0, alors φ est la fonction caractéristique d'une variable aléatoire X , et (X_n) converge en loi vers X .

Idée de preuve. [admise] Ce théorème, difficile, est admis dans ce livret. Il s'agit d'un résultat de compacité : la continuité en 0 de la limite φ empêche la « fuite de masse à l'infini » des lois $\mathbb{P}_{X_n}$ (un phénomène analogue à celui rencontré au Chapitre 5 « Intégrale de Lebesgue » avec le Théorème 5.31 « Lemme de Fatou »), ce qui permet d'extraire une sous-suite convergeant en loi, puis d'identifier la limite grâce au Théorème 12.13 « Théorème d'inversion / unicité ».

Remarque 12.16

Le Théorème 12.15 « Théorème de Lévy » est l'outil-clé qui permettra, au Chapitre 13 « Convergence de suites de variables aléatoires », de démontrer la loi faible des grands nombres (par une méthode alternative à la démonstration directe qui y sera donnée) et surtout le théorème central limite.




Figure 38: Théorème de Lévy : convergence simple des fonctions caractéristiques + continuité de la limite en 0 $\Rightarrow$ convergence en loi. C'est la « bonne » notion de convergence pour les fonctions caractéristiques, tout comme la convergence aux points de continuité l'était pour les fonctions de répartition.

12.4 Définition et fonction caractéristique

Définition 12.17 – Vecteur gaussien

Un vecteur aléatoire $X = (X_1, \dots, X_n)$ est un **vecteur gaussien** si, pour tout $a = (a_1, \dots, a_n) \in \mathbb{R}^n$, la variable aléatoire réelle $a^\top X = \sum_{i=1}^n a_i X_i$ suit une loi normale $\mathcal{N}(\mu_a, \sigma_a^2)$ – éventuellement **dégénérée** : on convient qu'une constante c (variance nulle) est une loi normale $\mathcal{N}(c, 0)$.

Remarque 12.18

En prenant $a = e_i$ (le i -ème vecteur de la base canonique), on voit que chaque composante X_i est elle-même gaussienne réelle. La réciproque est **fausse** : il ne suffit pas que chaque X_i soit gaussienne pour que le vecteur X soit un vecteur gaussien – voir l'Exercice 12.19 « Deux gaussiennes dont le couple n'est pas gaussien » ci-dessous. C'est bien la Définition 12.17 « Vecteur gaussien », portant sur *toutes* les combinaisons linéaires, qui est la bonne notion.

Exercice 12.19 – Deux gaussiennes dont le couple n'est pas gaussien

Soit $X \sim \mathcal{N}(0, 1)$, ε indépendante de X avec $\mathbb{P}(\varepsilon = 1) = \mathbb{P}(\varepsilon = -1) = \frac{1}{2}$, et $Y = \varepsilon X$. Montrer que $Y \sim \mathcal{N}(0, 1)$, mais que $X + Y$ n'est pas une variable gaussienne (en particulier, (X, Y) n'est pas un vecteur gaussien).

Solution

Pour φ continue bornée, $\mathbb{E}(\varphi(Y)) = \frac{1}{2}\mathbb{E}(\varphi(X)) + \frac{1}{2}\mathbb{E}(\varphi(-X)) = \mathbb{E}(\varphi(X))$ (par symétrie de la loi $\mathcal{N}(0, 1)$, qui a même loi que $-X$) : donc $Y \sim \mathcal{N}(0, 1)$. Or $\mathbb{P}(X + Y = 0) = \mathbb{P}(\varepsilon = -1) = \frac{1}{2} > 0$: $X + Y$ a un atome (en 0), donc n'est pas une variable à densité, et n'est en particulier pas gaussienne (une loi $\mathcal{N}(\mu, \sigma^2)$ avec $\sigma^2 > 0$ est diffuse ; le cas $\sigma^2 = 0$ donnerait $X + Y$ constante, ce qui n'est pas le cas ici puisque $X + Y = 2X$ sur $\{\varepsilon = 1\}$). Ainsi (X, Y) n'est pas un vecteur gaussien, bien que ses deux composantes le soient individuellement.

Théorème 12.20 – Fonction caractéristique d'un vecteur gaussien

Soit X un vecteur gaussien de vecteur d'espérance $m = \mathbb{E}(X) \in \mathbb{R}^n$ et de matrice de covariance $\Sigma = \Sigma_X$. Alors, pour tout $t \in \mathbb{R}^n$,

$$\varphi_X(t) := \mathbb{E}(e^{it^\top X}) = \exp\left(it^\top m - \frac{1}{2}t^\top \Sigma t\right).$$

En particulier, la loi de X ne dépend que de (m, Σ) : on la note $\mathcal{N}_n(m, \Sigma)$.

Démonstration. Fixons $t \in \mathbb{R}^n$ et posons $Y := t^\top X$. Par la Définition 12.17 « Vecteur gaussien »,

$Y \sim \mathcal{N}(\mu, \sigma^2)$ pour certains μ, σ^2 ; par linéarité de l'espérance, $\mu = \mathbb{E}(Y) = t^\top \mathbb{E}(X) = t^\top m$, et par la Proposition 10.24 « Propriétés de la matrice de covariance » (Chapitre 10 « Vecteurs aléatoires »), $\sigma^2 = \text{Var}(Y) = \text{Var}(t^\top X) = t^\top \Sigma t$. On a alors, en évaluant la fonction caractéristique de Y en 1 (en utilisant la formule de la fonction caractéristique d'une loi $\mathcal{N}(\mu, \sigma^2)$ établie juste avant) :

$$\varphi_X(t) = \mathbb{E}(e^{it^\top X}) = \mathbb{E}(e^{i \cdot 1 \cdot Y}) = \varphi_Y(1) = \exp\left(i\mu - \frac{\sigma^2}{2}\right) = \exp\left(it^\top m - \frac{1}{2} t^\top \Sigma t\right).$$

L'unicité s'obtient en admettant l'extension, à $\mathbb{R}^n$, du théorème d'inversion (Théorème 12.13 « Théorème d'inversion / unicité » ci-dessus) : la fonction caractéristique d'un vecteur aléatoire détermine entièrement sa loi. ■

12.5 Existence : construction d'un vecteur gaussien de paramètres donnés

Le Théorème 12.20 « Fonction caractéristique d'un vecteur gaussien » montre que la loi d'un vecteur gaussien est entièrement déterminée par le couple (m, Σ) . Reste une question : *tout* couple (m, Σ) avec Σ symétrique semi-définie positive (la seule contrainte possible, par la Proposition 10.24 « Propriétés de la matrice de covariance » du Chapitre 10 « Vecteurs aléatoires ») est-il bien atteint par un vecteur gaussien ? La réponse est oui, et la construction est explicite.

Définition 12.21 – Vecteur gaussien standard

$Z = (Z_1, \dots, Z_n)$ est un **vecteur gaussien standard** si ses composantes $Z_1, \dots, Z_n$ sont des variables $\mathcal{N}(0, 1)$ indépendantes.

Propriété 12.22

Un vecteur gaussien standard Z est bien un vecteur gaussien au sens de la Définition 12.17 « Vecteur gaussien », de loi $\mathcal{N}_n(0, I_n)$.

Démonstration. Soit $a \in \mathbb{R}^n$. Par la Proposition 12.9 « Fonction caractéristique d'une somme de variables indépendantes » et la formule de $\varphi_{\mathcal{N}(0,1)}$ (Exercice 12.6 « Calcul de fonctions caractéristiques usuelles »), $\varphi_{a^\top Z}(t) = \prod_{i=1}^n \varphi_{a_i Z_i}(t) = \prod_i \varphi_{Z_i}(a_i t) = \prod_i e^{-(a_i t)^2/2} = e^{-t^2 \sum_i a_i^2/2}$: c'est la fonction caractéristique d'une loi $\mathcal{N}(0, \|a\|^2)$ (à nouveau par la formule de la fonction caractéristique d'une loi normale établie juste avant), donc $a^\top Z \sim \mathcal{N}(0, \|a\|^2)$ par unicité. Ceci vaut pour tout a : Z est un vecteur gaussien. Enfin $\mathbb{E}(Z) = 0$ et $\Sigma_Z = I_n$ (les Z_i étant indépendantes de variance 1, Proposition 10.20 « Indépendance et covariance » du Chapitre 10 « Vecteurs aléatoires » donne $\text{Cov}(Z_i, Z_j) = 0$ pour $i \neq j$). ■

Théorème 12.23 – Construction d'un vecteur gaussien quelconque

Soit $m \in \mathbb{R}^n$, $\Sigma \in \mathcal{M}_n(\mathbb{R})$ symétrique semi-définie positive. Il existe un vecteur gaussien X de loi $\mathcal{N}_n(m, \Sigma)$.

Démonstration. Avec $A = PD^{1/2}$ comme ci-dessus, soit Z un vecteur gaussien standard et $X := m + AZ$. Pour tout $a \in \mathbb{R}^n$, $a^\top X = a^\top m + (A^\top a)^\top Z$: c'est une constante plus une combinaison linéaire des composantes du vecteur gaussien Z , donc (Définition 12.17 « Vecteur gaussien » appliquée à Z , puis translation par une constante qui ne change que la moyenne d'une loi normale) une variable gaussienne. Ainsi X est un vecteur gaussien. Son espérance est $\mathbb{E}(X) = m + A\mathbb{E}(Z) = m$ (car $\mathbb{E}(Z) = 0$). Sa matrice de covariance : pour $a, b \in \mathbb{R}^n$, en notant que Cov est bilinéaire et que $\Sigma_Z = I_n$,

$$a^\top \Sigma_X b = \text{Cov}(a^\top X, b^\top X) = \text{Cov}(a^\top AZ, b^\top AZ) = (A^\top a)^\top \Sigma_Z (A^\top b) = (A^\top a)^\top (A^\top b) = a^\top (AA^\top) b = a^\top \Sigma b,$$

et ceci pour tous a, b , donc $\Sigma_X = AA^\top = \Sigma$. Ainsi $X \sim \mathcal{N}_n(m, \Sigma)$ par le Théorème 12.20 « Fonction caractéristique d'un vecteur gaussien » (unicité de la loi à (m, Σ) donné). ■

12.6 Densité dans le cas non dégénéré

Théorème 12.24 – Densité d'un vecteur gaussien non dégénéré

Soit $X \sim \mathcal{N}_n(m, \Sigma)$ avec Σ **inversible** (on dit que X est **non dégénéré**). Alors X est à densité, de densité

$$f_X(x) = \frac{1}{(2\pi)^{n/2} \sqrt{\det \Sigma}} \exp \left(-\frac{1}{2} (x - m)^\top \Sigma^{-1} (x - m) \right), \quad x \in \mathbb{R}^n.$$

Démonstration. Reprenons $X = m + AZ$ (Théorème 12.23 « Construction d'un vecteur gaussien quelconque »), A inversible ($n \times n$). $Z = (Z_1, \dots, Z_n)$ standard a pour densité jointe (indépendance des $Z_i \sim \mathcal{N}(0, 1)$, Proposition 10.12 « Factorisation de la densité ou de la loi jointe » du Chapitre 10 « Vecteurs aléatoires ») $f_Z(z) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-z_i^2/2} = \frac{1}{(2\pi)^{n/2}} e^{-\|z\|^2/2}$.

L'application $\Phi : z \mapsto m + Az$ est un C^1 -difféomorphisme de $\mathbb{R}^n$ (linéaire inversible plus translation), d'inverse $\Phi^{-1}(x) = A^{-1}(x - m)$, de jacobien constant $|\det A|$. Pour φ continue bornée, le Théorème 9.44 « Théorème de transfert » puis le changement de variable $x = \Phi(z)$ (Théorème 6.14 « Formule du changement de variable ») donnent

$$\mathbb{E}(\varphi(X)) = \mathbb{E}(\varphi(m + AZ)) = \int_{\mathbb{R}^n} \varphi(m + Az) f_Z(z) dz = \int_{\mathbb{R}^n} \varphi(x) f_Z(A^{-1}(x - m)) \frac{dx}{|\det A|}$$

(le jacobien de Φ^{-1} vaut $1/|\det A|$). Par unicité dans le Théorème 9.44 « Théorème de transfert », $f_X(x) = \frac{f_Z(A^{-1}(x - m))}{|\det A|}$. Or $\|A^{-1}(x - m)\|^2 = (A^{-1}(x - m))^\top (A^{-1}(x - m)) = (x - m)^\top (A^{-1})^\top A^{-1} (x - m) = (x - m)^\top (AA^\top)^{-1} (x - m) = (x - m)^\top \Sigma^{-1} (x - m)$ (car $(A^{-1})^\top A^{-1} = (AA^\top)^{-1}$), et $|\det A| = \sqrt{(\det A)^2} = \sqrt{\det(AA^\top)} = \sqrt{\det \Sigma}$. En substituant :

$$f_X(x) = \frac{1}{(2\pi)^{n/2}} \exp \left(-\frac{1}{2} (x - m)^\top \Sigma^{-1} (x - m) \right) \cdot \frac{1}{\sqrt{\det \Sigma}}.$$

■

Remarque 12.25 – Le cas dégénéré n'a pas de densité

Si Σ n'est pas inversible, X ne peut pas avoir de densité par rapport à λ_n : sa loi est portée par le sous-espace affine $m + \text{Im}(A) \subsetneq \mathbb{R}^n$ (de dimension = $\text{rang}(\Sigma) < n$), qui est λ_n -négligeable (un sous-espace affine strict de $\mathbb{R}^n$ est d'intérieur vide, donc de mesure de Lebesgue nulle). La loi de X est alors un exemple, en dimension n , du phénomène de mesure **étrangère** à Lebesgue rencontré au Chapitre 8 « Décomposition des mesures » – quoique, ici, portée par un ensemble bien plus simple que l'ensemble de Cantor.




Figure 39: Densité d'un vecteur gaussien $\mathcal{N}_2(0, \Sigma)$ dans $\mathbb{R}^2$, avec $\Sigma = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$: les lignes de niveau (non représentées) sont des ellipses centrées en m , dont l'orientation et l'excentricité sont données par les vecteurs et valeurs propres de Σ .

12.7 Indépendance et décorrélation : le théorème clé

On arrive au résultat qui justifie l'importance des vecteurs gaussiens dans la pratique statistique.

Théorème 12.26 – Décorrélation $\Leftrightarrow$ indépendance, pour un vecteur gaussien

Soit $X = (X^{(1)}, X^{(2)}) \sim \mathcal{N}_n(m, \Sigma)$ un vecteur gaussien, découpé en deux blocs $X^{(1)} \in \mathbb{R}^{n_1}$, $X^{(2)} \in \mathbb{R}^{n_2}$ ($n_1 + n_2 = n$). Alors $X^{(1)}$ et $X^{(2)}$ sont indépendants si et seulement si $\text{Cov}(X_i^{(1)}, X_j^{(2)}) = 0$ pour tout i, j (c'est-à-dire si Σ est diagonale par blocs).

Démonstration. Le sens direct est déjà connu en toute généralité (Proposition 10.20 « Indépendance et covariance », Chapitre 10 « Vecteurs aléatoires »).

Pour la réciproque, supposons Σ diagonale par blocs : $\Sigma = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} \end{pmatrix}$, où Σ_{11}, Σ_{22} sont les matrices de covariance de $X^{(1)}, X^{(2)}$ respectivement (la nullité des blocs hors diagonale traduisant exactement $\text{Cov}(X_i^{(1)}, X_j^{(2)}) = 0$ pour tout i, j). Pour $t = (t^{(1)}, t^{(2)}) \in \mathbb{R}^{n_1} \times \mathbb{R}^{n_2}$, la forme quadratique se scinde :

$$t^\top \Sigma t = (t^{(1)})^\top \Sigma_{11} t^{(1)} + (t^{(2)})^\top \Sigma_{22} t^{(2)}$$

(les termes croisés impliquant les blocs nuls de Σ disparaissent). De même $t^\top m = (t^{(1)})^\top m^{(1)} + (t^{(2)})^\top m^{(2)}$. Par le Théorème 12.20 « Fonction caractéristique d'un vecteur gaussien » :

$$\varphi_X(t) = \exp\left(i t^\top m - \frac{1}{2} t^\top \Sigma t\right) = \underbrace{\exp\left(i(t^{(1)})^\top m^{(1)} - \frac{1}{2}(t^{(1)})^\top \Sigma_{11} t^{(1)}\right)}_{= \varphi_{X^{(1)}}(t^{(1)})} \cdot \underbrace{\exp\left(i(t^{(2)})^\top m^{(2)} - \frac{1}{2}(t^{(2)})^\top \Sigma_{22} t^{(2)}\right)}_{= \varphi_{X^{(2)}}(t^{(2)})}.$$

La fonction caractéristique jointe se factorise donc en le produit des fonctions caractéristiques marginales. En admettant l'extension multivariée du théorème d'unicité (Théorème 12.13 « Théorème d'inversion / unicité » ci-dessus) – selon laquelle cette factorisation caractérise l'indépendance, exactement comme au Chapitre 10 « Vecteurs aléatoires » pour la loi jointe –, on conclut que $X^{(1)}$ et $X^{(2)}$ sont indépendants. ■

Exemple 12.27 – Espérance conditionnelle pour un couple gaussien

Soit (X, Y) un vecteur gaussien centré, avec $\text{Var}(X) = \sigma_X^2$, $\text{Var}(Y) = \sigma_Y^2 > 0$, $\text{Cov}(X, Y) = c$. Montrons que $\mathbb{E}(X | Y) = \frac{c}{\sigma_Y^2} Y$. Posons $Z := X - \frac{c}{\sigma_Y^2} Y$: par la Proposition 12.29 « Image d'un vecteur gaussien par une application linéaire » (combinaison linéaire de (X, Y)), (Z, Y) est encore un vecteur gaussien, et $\text{Cov}(Z, Y) = \text{Cov}(X, Y) - \frac{c}{\sigma_Y^2} \text{Var}(Y) = c - c = 0$. Par le Théorème 12.26 « Décorrélation $\Leftrightarrow$ indépendance, pour un vecteur gaussien » (décorrélation $\Rightarrow$ indépendance, spécifique aux vecteurs gaussiens), Z et Y sont donc **indépendantes**. On a ainsi $X = \frac{c}{\sigma_Y^2} Y + Z$ avec Z indépendante de Y (donc de $\sigma(Y)$) et $\frac{c}{\sigma_Y^2} Y$ qui est $\sigma(Y)$ -mesurable. Par les points 1, 5 et 6 de la Proposition 11.9 « Propriétés de l'espérance conditionnelle » (Chapitre 11 « Lois et espérance conditionnelles ») :

$$\mathbb{E}(X | Y) = \frac{c}{\sigma_Y^2} Y + \mathbb{E}(Z | Y) = \frac{c}{\sigma_Y^2} Y + \mathbb{E}(Z) = \frac{c}{\sigma_Y^2} Y.$$

Comme au Chapitre 11 « Lois et espérance conditionnelles » (Exercice 11.14 « Espérance conditionnelle pour le couple uniforme sur un triangle »), on retrouve une espérance conditionnelle *linéaire* en Y : c'est un phénomène spécifique à la loi normale (on ne l'avait alors obtenu, pour le couple uniforme sur un triangle, que par un calcul direct de densité conditionnelle, sans lien avec la gaussianité).

Attention 12.28 – L’hypothèse « vecteur gaussien » est indispensable

Le Théorème 12.26 « Décorrélacion $\Leftrightarrow$ indépendance, pour un vecteur gaussien » peut être mis en défaut si l’on ne suppose que la nullité de la covariance sans savoir que $X = (X^{(1)}, X^{(2)})$ est un vecteur gaussien – même lorsque *chaque composante, prise isolément*, est gaussienne : c’est exactement ce que montre l’Exercice 12.19 « Deux gaussiennes dont le couple n’est pas gaussien » (où $\text{Cov}(X, Y) = \mathbb{E}(XY) = \mathbb{E}(\varepsilon)\mathbb{E}(X^2) = 0$ par indépendance de ε et X , alors que $Y = \varepsilon X$ dépend fortement de X).

12.8 Stabilité par combinaison linéaire**Propriété 12.29 – Image d’un vecteur gaussien par une application linéaire**

Soit $X \sim \mathcal{N}_n(m, \Sigma)$, B une matrice $p \times n$, $c \in \mathbb{R}^p$. Alors $BX + c$ est un vecteur gaussien de $\mathbb{R}^p$, de loi $\mathcal{N}_p(Bm + c, B\Sigma B^\top)$.

Démonstration. Pour $a \in \mathbb{R}^p$, $a^\top(BX + c) = (B^\top a)^\top X + a^\top c$: combinaison linéaire des composantes de X (vecteur gaussien) plus une constante, donc une variable gaussienne (Définition 12.17 « Vecteur gaussien », comme dans la preuve du Théorème 12.23 « Construction d’un vecteur gaussien quelconque »). Ainsi $BX + c$ est un vecteur gaussien. L’espérance $\mathbb{E}(BX + c) = Bm + c$ est immédiate par linéarité ; la matrice de covariance s’obtient comme dans la preuve du Théorème 12.23 « Construction d’un vecteur gaussien quelconque » : $\text{Cov}(a^\top(BX + c), b^\top(BX + c)) = \text{Cov}(a^\top BX, b^\top BX) = (B^\top a)^\top \Sigma (B^\top b) = a^\top (B\Sigma B^\top) b$. ■

Corollaire 12.30 – Somme de vecteurs gaussiens indépendants

Si $X \sim \mathcal{N}_n(m_1, \Sigma_1)$ et $Y \sim \mathcal{N}_n(m_2, \Sigma_2)$ sont indépendants, alors $X + Y \sim \mathcal{N}_n(m_1 + m_2, \Sigma_1 + \Sigma_2)$.

Démonstration. Le vecteur $\begin{pmatrix} X \\ Y \end{pmatrix} \in \mathbb{R}^{2n}$ est gaussien : pour $(a, b) \in \mathbb{R}^n \times \mathbb{R}^n$, $a^\top X + b^\top Y$ est une somme de deux variables gaussiennes indépendantes ($a^\top X$ et $b^\top Y$ sont chacune gaussiennes par hypothèse, et indépendantes comme fonctions de X et de Y respectivement, qui sont indépendants), donc gaussienne (Proposition 12.9 « Fonction caractéristique d’une somme de variables indépendantes » ci-dessus, appliquée aux fonctions caractéristiques : le produit de deux caractéristiques gaussiennes est encore de la forme $\exp(i\mu t - \sigma^2 t^2/2)$). Ainsi $\begin{pmatrix} X \\ Y \end{pmatrix}$ est un vecteur gaussien de $\mathbb{R}^{2n}$, et $X + Y = B \begin{pmatrix} X \\ Y \end{pmatrix}$ avec $B = \begin{pmatrix} I_n & I_n \end{pmatrix}$: par la Proposition 12.29 « Image d’un vecteur gaussien par une application linéaire », $X + Y$ est gaussien, d’espérance $m_1 + m_2$ et de covariance $B \begin{pmatrix} \Sigma_1 & 0 \\ 0 & \Sigma_2 \end{pmatrix} B^\top = \Sigma_1 + \Sigma_2$ (la covariance croisée étant nulle par indépendance, Proposition 10.20 « Indépendance et covariance » du Chapitre 10 « Vecteurs aléatoires »). ■

Exemple 12.31

On retrouve ainsi, comme cas particulier du Corollaire 12.30 « Somme de vecteurs gaussiens indépendants » en dimension $n = 1$, le résultat classique : si $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$ sont indépendantes, $X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ – un cas particulier de la stabilité par convolution évoquée au Chapitre 10 « Vecteurs aléatoires », mais obtenu ici sans aucun calcul d’intégrale.

Méthode 12.32 – Travailler avec un vecteur gaussien

Trois réflexes résument l'essentiel de ce chapitre :

1. Pour montrer qu'un vecteur (ou une combinaison de composantes) est gaussien, il suffit de l'écrire comme image *affine* d'un vecteur déjà connu pour être gaussien (Proposition 12.29 « Image d'un vecteur gaussien par une application linéaire ») – jamais besoin de calculer une densité à la main.
2. La loi d'un vecteur gaussien est entièrement résumée par le couple (m, Σ) : pour l'identifier, il suffit de calculer l'espérance et la matrice de covariance (Chapitre 10 « Vecteurs aléatoires »).
3. Pour des composantes (ou blocs) *d'un même vecteur gaussien*, indépendance et décorrélacion sont **équivalentes** (Théorème 12.26 « Décorrélacion $\Leftrightarrow$ indépendance, pour un vecteur gaussien ») : il suffit donc de calculer des covariances, jamais besoin de vérifier la factorisation complète de la loi jointe.

13 Convergence de suites de variables aléatoires

Objectifs

- Connaître les différents modes de convergence d'une suite de variables aléatoires et leurs implications.
- Savoir démontrer et utiliser les deux lois des grands nombres.
- Savoir utiliser la fonction caractéristique (Chapitre 12 « Vecteurs aléatoires gaussiens ») et le Théorème 12.15 « Théorème de Lévy » pour établir une convergence en loi.
- Démontrer et appliquer le théorème central limite.

Introduction

Ce chapitre répond à une question centrale : que signifie « une suite de variables aléatoires (X_n) converge vers X » ? Contrairement au cadre déterministe, il existe *plusieurs* notions de convergence, non équivalentes en général, mais reliées par un réseau d'implications que l'on établit précisément dans ce chapitre. Les inégalités du Chapitre 7 « Espaces L^p » sont les outils techniques qui permettent de démontrer ces implications. On utilisera aussi la fonction caractéristique, introduite au Chapitre 12 « Vecteurs aléatoires gaussiens », outil le plus puissant de ce livret pour étudier la convergence en loi : elle transforme la somme de variables *indépendantes* en un *produit* de fonctions caractéristiques, ce qui rend les calculs de convergence en loi (théorème central limite, approximation de Poisson) considérablement plus simples que via la fonction de répartition.

13.1 Modes de convergence

Définition 13.1 – Convergence en moyenne à l'ordre p

Soit $p \in [1, +\infty[$, $(X_n)_{n \geq 1}$ une suite de variables aléatoires, X une variable aléatoire. On dit que (X_n) **converge dans L^p** vers X (ou en moyenne d'ordre p) si $X_n, X \in L^p$ pour tout n et $\lim_{n \rightarrow +\infty} \mathbb{E}(|X_n - X|^p) = 0$. Pour $p = 1$ on parle de convergence en moyenne, pour $p = 2$ de convergence en moyenne quadratique.

Définition 13.2 – Convergence presque sûre

$(X_n)_{n \geq 1}$ **converge presque sûrement** vers X si $\mathbb{P}(\{\omega \in \Omega \mid \lim_{n \rightarrow +\infty} X_n(\omega) = X(\omega)\}) = 1$.

Définition 13.3 – Convergence en probabilité

$(X_n)_{n \geq 1}$ **converge en probabilité** vers X si $\forall \varepsilon > 0, \lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = 0$.

Remarque 13.4 – Rappel : lemme de Borel–Cantelli

Le Théorème 3.26 « Lemme de Borel–Cantelli » a été démontré au Chapitre 3 « Mesures » dans le cadre d'une mesure quelconque. Dans le cas particulier d'un espace probabilisé $(\Omega, \mathcal{T}, \mathbb{P})$, il affirme que si $\sum_n \mathbb{P}(A_n) < +\infty$, alors $\mathbb{P}(\limsup_n A_n) = 0$.

Rappel de L2 13.5 – séries numériques

On rappelle qu'une série $\sum u_n$ à termes positifs converge si et seulement si la suite de ses sommes partielles est majorée, et que dans ce cas le reste $\sum_{n \geq N} u_n$ tend vers 0 quand $N \rightarrow +\infty$. C'est ce fait, appliqué à la série $\sum \mathbb{P}(A_n)$, qui est le moteur de la démonstration du lemme de Borel-Cantelli.

Exemple 13.6 – Interprétation probabiliste du lemme de Borel-Cantelli

En probabilités, ce théorème s'énonce ainsi : si $\sum_n \mathbb{P}(A_n) < +\infty$, alors presque sûrement, seul un nombre fini des événements A_n se réalisent (puisque l'événement « une infinité de A_n se réalisent », c'est-à-dire $\limsup_n A_n$, est de probabilité nulle). C'est un résultat central pour les études asymptotiques et pour établir des convergences presque sûres.

Méthode 13.7 – Montrer qu'un événement asymptotique est de probabilité 0 ou 1

Pour un événement de la forme « une infinité de A_n se réalisent », deux réflexes :

1. Calculer ou majorer $\sum_n \mathbb{P}(A_n)$: si cette série converge, le Théorème 3.26 « Lemme de Borel-Cantelli » conclut directement à une probabilité nulle.
2. Si la série diverge et si les A_n sont *indépendants* (notion du Chapitre 9 « Variables aléatoires réelles »), la réciproque du lemme de Borel-Cantelli (admise, hors-programme dans ce livret) affirme que $\mathbb{P}(\limsup_n A_n) = 1$.

Définition 13.8 – Convergence en loi

$(X_n)_{n \geq 1}$ **converge en loi** vers X si, pour toute fonction $\varphi \in C_b^0(\mathbb{R})$ (continue bornée), $\lim_{n \rightarrow +\infty} \mathbb{E}(\varphi(X_n)) = \mathbb{E}(\varphi(X))$.

Rappel de L2 13.9 – convergence simple vs. uniforme

On rappelle la distinction, pour des suites de fonctions déterministes, entre convergence simple ($(\forall x, f_n(x) \rightarrow f(x))$) et convergence uniforme ($\sup_x |f_n(x) - f(x)| \rightarrow 0$). La convergence presque sûre est l'analogue probabiliste de la convergence simple (mais « à un ensemble négligeable près ») ; il n'existe en revanche pas d'analogue direct de la convergence uniforme dans ce chapitre – la convergence en probabilité et la convergence L^p jouent un rôle un peu similaire, en contrôlant l'écart de façon globale plutôt que point par point.

Propriété 13.10 – Caractérisation de la convergence en loi par la fonction de répartition

(X_n) converge en loi vers X si et seulement si $F_{X_n}(a) \rightarrow F_X(a)$ en tout point a de continuité de F_X .

Idée de preuve. [admise] On encadre $\mathbf{1}_{]-\infty, a]}$ par des fonctions continues bornées $\varphi_\delta \leq \mathbf{1}_{]-\infty, a]} \leq \psi_\delta$ (rampes linéaires de largeur δ centrées en $a - \delta/2$ et $a + \delta/2$), on applique la convergence en loi à $\varphi_\delta, \psi_\delta$, puis on fait tendre $\delta \rightarrow 0$ en utilisant la continuité de F_X en a . La réciproque s'obtient en approchant une fonction continue bornée quelconque par une fonction en escalier dont les points de subdivision sont des points de continuité de F_X (denses dans $\mathbb{R}$ car F_X est croissante, donc n'a qu'un nombre dénombrable de discontinuités).

Attention 13.11

On restreint la convergence des $F_{X_n}(a)$ aux points de continuité de F_X : aux points de discontinuité (les « sauts »), rien ne garantit la convergence, et ce n'est d'ailleurs pas nécessaire pour la convergence en loi. C'est un piège classique d'exercice.

Propriété 13.12 – Inclusion des espaces L^p

Soit $1 \leq p < q \leq +\infty$. Si X admet un moment d'ordre q , alors X admet un moment d'ordre p (autrement dit $L^q \subset L^p$, pour une mesure de probabilité).

Démonstration. On a $|X|^p \leq |X|^q + 1$ (immédiat en distinguant $|X| \leq 1$ et $|X| > 1$) ; or le membre de droite est intégrable ($\mathbb{P}$ étant finie), donc $X \in L^p$ par la Proposition 5.25 « Intégrabilité ». ■

Attention 13.13

Ce résultat est **spécifique aux mesures finies** (donc aux probabilités) : 1 est intégrable pour une mesure finie, ce qui n'est plus vrai en général (par exemple pour la mesure de Lebesgue sur $\mathbb{R}$). C'est pour cette raison que $L^q \subset L^p$ pour $p < q$ en probabilités, alors qu'aucune inclusion de ce type n'est vraie en général pour la mesure de Lebesgue.

Propriété 13.14 – Convergence $L^p \Rightarrow$ convergence en probabilité

Si (X_n) converge dans L^1 vers X , alors (X_n) converge en probabilité vers X .

Démonstration. Par l'inégalité de Markov (Proposition 7.7 « Inégalité de Markov ») appliquée à $|X_n - X| \geq 0$: $\mathbb{P}(|X_n - X| \geq \varepsilon) \leq \mathbb{E}(|X_n - X|)/\varepsilon \rightarrow 0$. ■

Propriété 13.15 – Convergence presque sûre $\Rightarrow$ convergence en probabilité

Si (X_n) converge presque sûrement vers X , alors (X_n) converge en probabilité vers X .

Démonstration. Soit $\varepsilon > 0$. Posons $A_n = \{|X_n - X| \geq \varepsilon\}$. Si $X_n(\omega) \rightarrow X(\omega)$, alors ω n'appartient qu'à un nombre fini des A_n (sinon $|X_n(\omega) - X(\omega)| \geq \varepsilon$ pour une infinité de n , contredisant la convergence) : ainsi $\limsup_n A_n \subset \{\omega \mid X_n(\omega) \not\rightarrow X(\omega)\}$, ce dernier ensemble étant de probabilité nulle par hypothèse de convergence p.s. Donc $\mathbb{P}(\limsup_n A_n) = 0$.

Soit $\delta > 0$. Par continuité décroissante de la mesure (Proposition 3.20 « Continuité croissante et décroissante ») appliquée à la suite décroissante $(\bigcup_{n \geq N} A_n)_{N \geq 0}$, d'intersection $\limsup_n A_n$ (de mesure finie car $\mathbb{P}$ est une probabilité) :

$$\mathbb{P}\left(\bigcup_{n \geq N} A_n\right) \xrightarrow{N \rightarrow +\infty} \mathbb{P}(\limsup_n A_n) = 0.$$

Il existe donc N tel que $\mathbb{P}(\bigcup_{n \geq N} A_n) \leq \delta$. Par inclusion, $\mathbb{P}(A_n) \leq \delta$ pour tout $n \geq N$. Ceci étant valable pour tout $\delta > 0$, $\mathbb{P}(A_n) = \mathbb{P}(|X_n - X| \geq \varepsilon) \rightarrow 0$. ■

Propriété 13.16 – Convergence en probabilité $\Rightarrow$ convergence en loi

Si (X_n) converge en probabilité vers X , alors (X_n) converge en loi vers X .

Démonstration. Soit a un point de continuité de F_X , $\varepsilon > 0$. On a les inclusions (élémentaires, par contraposée) :

$$(X_n \leq a) \subset (X \leq a + \varepsilon) \cup (|X_n - X| \geq \varepsilon), \quad (X \leq a - \varepsilon) \subset (X_n \leq a) \cup (|X_n - X| \geq \varepsilon).$$

En effet, si $X_n(\omega) \leq a$ et $|X_n(\omega) - X(\omega)| < \varepsilon$, alors $X(\omega) < X_n(\omega) + \varepsilon \leq a + \varepsilon$; et si $X(\omega) \leq a - \varepsilon$ et $|X_n(\omega) - X(\omega)| < \varepsilon$, alors $X_n(\omega) < X(\omega) + \varepsilon \leq a$. En passant aux probabilités (sous-additivité) :


$$\mathbb{P}(X_n \leq a) \leq \mathbb{P}(X \leq a + \varepsilon) + \mathbb{P}(|X_n - X| \geq \varepsilon), \quad \mathbb{P}(X \leq a - \varepsilon) \leq \mathbb{P}(X_n \leq a) + \mathbb{P}(|X_n - X| \geq \varepsilon).$$

Autrement dit, $F_X(a - \varepsilon) - \mathbb{P}(|X_n - X| \geq \varepsilon) \leq F_{X_n}(a) \leq F_X(a + \varepsilon) + \mathbb{P}(|X_n - X| \geq \varepsilon)$. En faisant tendre $n \rightarrow +\infty$ (la convergence en probabilité donnant $\mathbb{P}(|X_n - X| \geq \varepsilon) \rightarrow 0$) :

$$F_X(a - \varepsilon) \leq \liminf_n F_{X_n}(a) \leq \limsup_n F_{X_n}(a) \leq F_X(a + \varepsilon).$$

En faisant enfin tendre $\varepsilon \rightarrow 0$, la continuité de F_X en a (point de continuité par hypothèse) donne $F_X(a - \varepsilon), F_X(a + \varepsilon) \rightarrow F_X(a)$, d'où $\lim_n F_{X_n}(a) = F_X(a)$. Ceci étant vrai pour tout point de continuité a de F_X ,

on conclut par la Proposition 13.10 « Caractérisation de la convergence en loi par la fonction de répartition » que (X_n) converge en loi vers X . ■



Les quatre flèches correspondent respectivement à la Proposition 13.12 « Inclusion des espaces L^p », à la Proposition 13.14 « Convergence $L^p \Rightarrow$ convergence en probabilité », à la Proposition 13.15 « Convergence presque sûre $\Rightarrow$ convergence en probabilité » et à la Proposition 13.16 « Convergence en probabilité $\Rightarrow$ convergence en loi ».

Figure 40: Récapitulatif des implications entre modes de convergence (aucune réciproque n'est vraie en général – voir les contre-exemples dans le texte). La convergence dans L^q entraîne celle dans L^p pour $q > p$ exactement comme l'inclusion $L^q \subset L^p$ des espaces eux-mêmes (Proposition 13.12 « Inclusion des espaces L^p ») : converger au sens d'une norme plus exigeante (q grand) entraîne la convergence au sens d'une norme plus faible (p petit). La convergence en loi est la plus faible de toutes ; c'est néanmoins la seule dont on aura besoin pour le théorème central limite.

Attention 13.17 – Aucune réciproque n'est vraie en général

- Convergence en loi $\nRightarrow$ convergence en probabilité : si $X \sim \mathcal{N}(0, 1)$ et $X_n = -X$ pour tout n , alors X_n converge en loi vers X (même loi pour tout n , par symétrie de la loi normale), mais $|X_n - X| = 2|X|$ ne tend pas vers 0 en probabilité.
- Convergence en probabilité $\nRightarrow$ convergence presque sûre, ni convergence L^p : l'exemple classique est la suite des « bosses balladeuses » $X_n = \mathbf{1}_{[\frac{k}{2^m}, \frac{k+1}{2^m}]}$ (où $n = 2^m + k$, $0 \leq k < 2^m$), sur $([0, 1], \mathcal{B}([0, 1]), \lambda)$, qui converge en probabilité vers 0 (la longueur de l'intervalle où $X_n \neq 0$ tend vers 0) mais ne converge en aucun point (chaque $\omega \in [0, 1]$ est visité une infinité de fois par des intervalles de plus en plus fins, donc $X_n(\omega)$ vaut 1 une infinité de fois et 0 une infinité de fois).

Méthode 13.18 – Identifier le bon mode de convergence à démontrer

1. Pour montrer une convergence **en probabilité**, l'outil quasi-systématique est l'inégalité de Bienaymé-Tchebychev (ou Markov) : majorer $\mathbb{P}(|X_n - X| \geq \varepsilon)$ par une quantité qui tend vers 0.
2. Pour montrer une convergence **presque sûre**, on passe souvent par le Théorème 3.26 « Lemme de Borel–Cantelli » : majorer $\sum_n \mathbb{P}(|X_n - X| \geq \varepsilon_n)$ pour une suite $\varepsilon_n \rightarrow 0$ bien choisie, afin de conclure que l'événement limite est de probabilité nulle.
3. Pour montrer une convergence **en loi**, on calcule (ou on encadre) la fonction de répartition (Proposition 13.10 « Caractérisation de la convergence en loi par la fonction de répartition »), ou – de façon souvent bien plus maniable pour les sommes de variables indépendantes – la fonction caractéristique (Chapitre 12 « Vecteurs aléatoires gaussiens », Théorème 12.15 « Théorème de Lévy »).

13.2 Loïs des grands nombres

Théorème 13.19 – Loi faible des grands nombres

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires indépendantes, de même loi, admettant une espérance μ et une variance V finies. On pose $S_n = \sum_{i=1}^n X_i$. Alors $\frac{S_n}{n}$ converge en probabilité vers μ .

Démonstration. Par indépendance, $\text{Var}(S_n) = \sum_{i=1}^n \text{Var}(X_i) = nV$ (la variance d'une somme de variables indépendantes est la somme des variances – résultat de licence, qui se retrouve directement en développant le carré et en utilisant l'indépendance pour annuler les termes croisés). Donc $\text{Var}(S_n/n) = V/n$. L'inégalité de Bienaymé-Tchebychev (Proposition 7.8 « Inégalité de Bienaymé-Tchebychev ») donne, pour tout $\varepsilon > 0$:


$$\mathbb{P}\left(\left|\frac{S_n}{n} - \mu\right| \geq \varepsilon\right) \leq \frac{V}{n\varepsilon^2} \xrightarrow{n \rightarrow +\infty} 0.$$


Figure 41: Illustration de la loi des grands nombres : la moyenne empirique S_n/n oscille de moins en moins autour de μ à mesure que n grandit (convergence en probabilité).

Exemple 13.20

C'est ce théorème qui justifie l'interprétation *fréquentiste* des probabilités : si l'on répète n fois une expérience de Bernoulli de paramètre p (par exemple un sondage), la fréquence observée $\hat{p}_n = S_n/n$ se rapproche, en probabilité, de p quand n croît – ce qui justifie l'estimation de p par $\hat{p}_n$ dans la pratique statistique.

Théorème 13.21 – Loi forte des grands nombres

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires mutuellement indépendantes, de même loi, admettant un moment d'ordre 4. On pose $\mu = \mathbb{E}(X_1)$, $S_n = \sum_{i=1}^n X_i$. Alors $\frac{S_n}{n}$ converge **presque sûrement** vers μ .

Idée de preuve. On centre les variables et on majore $\mathbb{P}(|S_n/n - \mu| \geq \varepsilon)$ non pas via la variance (moment d'ordre 2, qui ne donnerait qu'un $O(1/n)$, insuffisant pour Borel-Cantelli) mais via le moment d'ordre 4, dont le développement se simplifie grandement grâce à l'indépendance et au centrage : il ne reste que les termes « tous égaux » et « deux paires égales », ce qui donne une croissance en $O(n^2)$ au lieu de $O(n^4)$, et donc un $O(1/n^2)$ pour la probabilité recherchée – une série qui converge, ce qui permet de conclure par Borel-Cantelli.

Démonstration. Posons $Y_i = X_i - \mu$ (centrées, i.i.d., moment d'ordre 4 fini), $A = \mathbb{E}(Y_1^4)$, $B = \text{Var}(Y_1) = \mathbb{E}(Y_1^2)$. Développons $\mathbb{E}\left(\left(\sum_{i=1}^n Y_i\right)^4\right) = \sum_{i,j,k,l=1}^n \mathbb{E}(Y_i Y_j Y_k Y_l)$:

- si un indice apparaît une seule fois parmi $\{i, j, k, l\}$ (disons i , différent des trois autres), alors par indépendance $\mathbb{E}(Y_i Y_j Y_k Y_l) = \mathbb{E}(Y_i) \mathbb{E}(Y_j Y_k Y_l) = 0$ (car $\mathbb{E}(Y_i) = 0$) ;
- si les quatre indices sont égaux ($i = j = k = l$), $\mathbb{E}(Y_i^4) = A$: il y a n tels quadruplets ;
- si les indices se répartissent en exactement deux paires distinctes (par exemple $i = j \neq k = l$), $\mathbb{E}(Y_i^2 Y_k^2) = \mathbb{E}(Y_i^2) \mathbb{E}(Y_k^2) = B^2$ par indépendance : il y a $3 \binom{n}{2} \cdot 2 = 3n(n-1)$ tels quadruplets (le facteur 3 = $\binom{4}{2}/1$ comptant les façons de regrouper 4 positions en 2 paires).

Donc $\mathbb{E}\left(\left(\sum_{i=1}^n Y_i\right)^4\right) = nA + 3n(n-1)B^2$.

Par l'inégalité de Markov appliquée à la puissance 4 :

$$\mathbb{P}\left(\left|\frac{S_n}{n} - \mu\right| \geq \varepsilon\right) = \mathbb{P}\left(\left(\sum_{i=1}^n Y_i\right)^4 \geq (n\varepsilon)^4\right) \leq \frac{nA + 3n(n-1)B^2}{n^4\varepsilon^4} \leq \frac{A + 3B^2}{n^2\varepsilon^4}$$

(en majorant $n-1$ par n puis $1/n^3$ par $1/n^2$). En posant $K = A + 3B^2$, on a donc $\mathbb{P}(|S_n/n - \mu| \geq \varepsilon) \leq K/(n^2\varepsilon^4)$ pour tout $n \geq 1$, $\varepsilon > 0$.

Fixons $\varepsilon > 0$ et posons $C_n = \{|S_n/n - \mu| \geq \varepsilon\}$. La série $\sum_n \mathbb{P}(C_n) \leq \sum_n K/(n^2\varepsilon^4) < +\infty$ (série de Riemann convergente). Par le Théorème 3.26 « Lemme de Borel–Cantelli », $\mathbb{P}(\limsup_n C_n) = 0$, c'est-à-dire : presque sûrement, $|S_n/n - \mu| < \varepsilon$ pour tout n assez grand. En appliquant ceci successivement à $\varepsilon = 1/p$ pour chaque $p \geq 1$ entier (et en prenant l'intersection dénombrable des événements de probabilité 1 obtenus), on conclut que, presque sûrement, $S_n/n \rightarrow \mu$. ■

Remarque 13.22

La loi forte des grands nombres reste vraie sous la seule hypothèse $\mathbb{E}(|X_1|) < +\infty$ (résultat de Kolmogorov, admis, hors-programme dans ce livret), mais la démonstration ci-dessus, plus simple, se contente d'un moment d'ordre 4 – suffisant pour l'écrasante majorité des applications.

Méthode 13.23 – Loi faible ou loi forte ?

Face à un énoncé demandant d'étudier S_n/n :

1. Si l'on ne connaît que l'espérance et la variance (moment d'ordre 2), on ne peut établir *que* la convergence en probabilité (loi faible), via Bienaymé-Tchebychev.
2. Si un moment d'ordre 4 (ou davantage) est fourni par l'énoncé, c'est en général le signal qu'il faut établir la convergence **presque sûre** (loi forte), via un développement de $\mathbb{E}((\sum Y_i)^4)$ suivi de Borel-Cantelli.

Exercice 13.24 – Application : estimation d'une proportion

Un sondage interroge n personnes indépendamment, chacune répondant « oui » avec probabilité p inconnue. Soit $\hat{p}_n$ la proportion de « oui » observée. Donner, à l'aide de l'inégalité de Bienaymé-Tchebychev, une taille d'échantillon n garantissant $\mathbb{P}(|\hat{p}_n - p| \geq 0.02) \leq 0.05$.

Solution

On modélise par $X_i \sim \mathcal{B}(p)$ i.i.d., $\hat{p}_n = S_n/n$. On a $\text{Var}(\hat{p}_n) = \frac{p(1-p)}{n} \leq \frac{1}{4n}$ (car $p(1-p) \leq 1/4$). Bienaymé-Tchebychev donne $\mathbb{P}(|\hat{p}_n - p| \geq 0.02) \leq \frac{1}{4n \times 0.02^2} = \frac{625}{n}$. Il suffit donc de prendre $n \geq \frac{625}{0.05} = 12\,500$ pour garantir la borne demandée (une borne volontairement pessimiste, typique de Bienaymé-Tchebychev ; le théorème central limite, plus loin dans ce chapitre, permettra d'obtenir des tailles d'échantillon bien plus réalistes).

13.3 Applications aux théorèmes limites

Théorème 13.25 – Loi faible des grands nombres, redémontrée

Soit $(X_n)_{n \geq 1}$ i.i.d. (indépendantes et de même loi), $\mathbb{E}(|X_1|) < +\infty$, $\mu = \mathbb{E}(X_1)$. Alors $\frac{1}{n} \sum_{i=1}^n X_i$ converge en loi (donc, la limite étant une constante, également en probabilité) vers μ .

Démonstration. Fixons $t \in \mathbb{R}$. Par indépendance et identique distribution (Proposition 12.9 « Fonction caractéristique d'une somme de variables indépendantes »), $\varphi_{S_n/n}(t) = \mathbb{E}(e^{itS_n/n}) = \varphi_{X_1}(t/n)^n$. Comme X_1 est intégrable, φ_{X_1} est dérivable en 0 (résultat admis, obtenu par dérivation sous le signe intégral, dans le même esprit que la Proposition 12.7 « Propriétés élémentaires ») avec $\varphi'_{X_1}(0) = i\mu$; un développement limité donne, quand $n \rightarrow +\infty$ (donc $t/n \rightarrow 0$) :

$$\varphi_{X_1}(t/n) = 1 + i\mu \frac{t}{n} + o\left(\frac{1}{n}\right).$$

Pour n assez grand, $\varphi_{X_1}(t/n) \neq 0$ (car $\varphi_{X_1}(0) = 1$ et φ_{X_1} continue), et l'on peut écrire :

$$n \ln \varphi_{X_1}(t/n) = n \ln \left(1 + i\mu \frac{t}{n} + o\left(\frac{1}{n}\right)\right) = n \left(i\mu \frac{t}{n} + o\left(\frac{1}{n}\right)\right) = i\mu t + o(1)$$

(en utilisant $\ln(1+z) = z + o(z)$ au voisinage de 0, valable ici pour l'exponentielle complexe par le même développement que dans $\mathbb{R}$). En passant à l'exponentielle :

$$\varphi_{S_n/n}(t) = \exp(n \ln \varphi_{X_1}(t/n)) \xrightarrow{n \rightarrow +\infty} e^{i\mu t}.$$

Or $t \mapsto e^{i\mu t}$ est la fonction caractéristique de la variable constante (presque sûrement) égale à μ : $\varphi_{X_1}(t/n)^n \rightarrow \varphi_\mu(t)$ pour tout t , avec φ_μ continue (en particulier en 0). Par le théorème de Lévy (Théorème 12.15 « Théorème de Lévy »), S_n/n converge en loi vers la constante μ . ■

Remarque 13.26

Une variable aléatoire en loi vers une **constante** μ (au sens : la loi limite est un Dirac en μ) équivaut à la convergence en probabilité vers μ : c'est un cas particulier où convergence en loi et en probabilité coïncident (car il n'y a plus d'aléa dans la limite). C'est ce qui permet, ici, de redémontrer la loi faible des grands nombres.

Remarque 13.27 – Quelle est la taille du « zoom » nécessaire pour voir les fluctuations ?

La loi des grands nombres affirme que $S_n/n \rightarrow \mu$, mais ne dit rien de la **vitesse** de cette convergence : à quel point faut-il « zoomer » sur $S_n/n - \mu$ pour voir apparaître un comportement aléatoire non trivial (ni 0, ni $\pm\infty$) ? Sous l'hypothèse supplémentaire que les X_i sont dans L^2 , on devine la réponse en calculant, comme dans la preuve de la loi faible des grands nombres :

$$\mathbb{E}[(S_n - n\mu)^2] = \text{Var}(S_n) = nV.$$

Ce calcul indique que la valeur moyenne de $(S_n - n\mu)^2$ croît **linéairement** avec n : l'ordre de grandeur typique de $S_n - n\mu$ est donc $\sqrt{n}$ (racine carrée d'une quantité d'ordre n), ou, de façon équivalente, l'ordre de grandeur de $\frac{S_n}{n} - \mu$ est $\frac{1}{\sqrt{n}}$. C'est exactement ce que représente le rectangle rouge de la Figure ci-dessous : sa largeur, fixée arbitrairement sur le dessin, correspond en réalité à une fenêtre qui doit se rétrécir en $1/\sqrt{n}$ pour continuer à capturer les fluctuations de S_n/n autour de μ – ni plus vite (sous peine de ne plus rien voir, la fenêtre devenant trop étroite), ni moins vite (sous peine de voir une fenêtre qui reste « pleine » de façon triviale). C'est précisément ce facteur $1/\sqrt{n}$ qui suggère de considérer, pour en apprendre davantage sur la nature de ces fluctuations, la variable renormalisée $\sqrt{n}(\frac{S_n}{n} - \mu) = \frac{S_n - n\mu}{\sqrt{n}}$ – ce que rend précis le théorème central limite, ci-dessous.




Figure 42: La même illustration de la loi des grands nombres, avec cette fois un rectangle rouge bien visible : sa largeur matérialise l'échelle typique des fluctuations restantes de S_n/n autour de μ , de l'ordre de $1/\sqrt{n}$ – c'est précisément ce facteur d'échelle que le théorème central limite, ci-dessous, rend précis.

Théorème 13.28 – Théorème central limite

Soit $(X_n)_{n \geq 1}$ i.i.d., $\mathbb{E}(X_1^2) < +\infty$, $\mu = \mathbb{E}(X_1)$, $\sigma^2 = \text{Var}(X_1) > 0$. Alors

$$\frac{\sum_{i=1}^n (X_i - \mu)}{\sigma\sqrt{n}} \xrightarrow[n \rightarrow +\infty]{\text{loi}} \mathcal{N}(0, 1).$$

Démonstration. Posons $S_n^* = \frac{\sum_{i=1}^n (X_i - \mu)}{\sigma\sqrt{n}}$ et $Y_i = X_i - \mu$ (centrées, i.i.d., de variance σ^2). Fixons $t \in \mathbb{R}$. Par indépendance et identité distribution (Proposition 12.9 « Fonction caractéristique d'une somme de variables indépendantes ») :

$$\varphi_{S_n^*}(t) = \mathbb{E}\left(\exp\left(it \frac{\sum_{i=1}^n Y_i}{\sigma\sqrt{n}}\right)\right) = \varphi_{Y_1}\left(\frac{t}{\sigma\sqrt{n}}\right)^n.$$

Comme $Y_1 \in L^2$, φ_{Y_1} admet un développement limité à l'ordre 2 en 0 (résultat admis, par dérivation sous le signe intégral appliquée deux fois) :

$$\varphi_{Y_1}(s) = 1 + is \mathbb{E}(Y_1) - \frac{s^2}{2} \mathbb{E}(Y_1^2) + o(s^2) = 1 - \frac{s^2}{2} \sigma^2 + o(s^2)$$

(le terme d'ordre 1 disparaît car $\mathbb{E}(Y_1) = 0$). En prenant $s = t/(\sigma\sqrt{n}) \rightarrow 0$:

$$\varphi_{Y_1}\left(\frac{t}{\sigma\sqrt{n}}\right) = 1 - \frac{t^2}{2\sigma^2 n} \sigma^2 + o\left(\frac{1}{n}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

Comme pour la loi des grands nombres (Théorème 13.25 « Loi faible des grands nombres, redémontrée »), on en déduit, pour n assez grand :

$$n \ln \varphi_{Y_1}\left(\frac{t}{\sigma\sqrt{n}}\right) = n \left(-\frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right) = -\frac{t^2}{2} + o(1),$$

donc $\varphi_{S_n^*}(t) = \exp\left(n \ln \varphi_{Y_1}\left(\frac{t}{\sigma\sqrt{n}}\right)\right) \xrightarrow[n \rightarrow +\infty]{} e^{-t^2/2}$. Or $t \mapsto e^{-t^2/2}$ est la fonction caractéristique de $\mathcal{N}(0, 1)$ (Exercice 12.6 « Calcul de fonctions caractéristiques usuelles »), continue en 0. Par le théorème de Lévy (Théorème 12.15 « Théorème de Lévy »), S_n^* converge en loi vers $\mathcal{N}(0, 1)$. ■

Remarque 13.29 – Portée du théorème

Le théorème central limite explique l'omniprésence de la loi normale dans la nature et les sciences expérimentales : dès qu'une grandeur observée résulte de l'accumulation d'un grand nombre de petites perturbations indépendantes et de même distribution, sa loi se rapproche d'une gaussienne – *quelle que soit* la loi individuelle des perturbations (pourvu qu'elle ait un moment d'ordre 2). C'est aussi la base théorique des intervalles de confiance en statistique inférentielle.




Figure 43: Illustration du théorème central limite : quelle que soit la loi de départ (ici une loi discrète quelconque), la loi de la somme centrée-réduite se rapproche d'une loi $\mathcal{N}(0, 1)$ quand n croît.

Méthode 13.30 – Utiliser le théorème central limite en pratique

Pour une somme $S_n = \sum_{i=1}^n X_i$ de variables i.i.d. de moyenne μ et de variance σ^2 connues, et n « grand » :

$$S_n \approx \mathcal{N}(n\mu, n\sigma^2) \quad (\text{approximation en loi}),$$

ce qui permet d'approcher $\mathbb{P}(a \leq S_n \leq b)$ par $\Phi(\frac{b-n\mu}{\sigma\sqrt{n}}) - \Phi(\frac{a-n\mu}{\sigma\sqrt{n}})$, où Φ est la fonction de répartition de $\mathcal{N}(0, 1)$ – une approximation bien plus précise, pour n grand, que celle fournie par l'inégalité de Bienaymé-Tchebychev (cf. l'exercice du sondage plus haut dans ce chapitre, où Bienaymé-Tchebychev donnait $n \geq 12\,500$; le TCL donnerait typiquement n de l'ordre de quelques centaines pour la même précision).

Exercice 13.31 – Poisson comme limite de la loi normale

Pour $\lambda > 0$, soit $X_\lambda \sim \mathcal{P}(\lambda)$. Montrer que $\frac{X_\lambda - \lambda}{\sqrt{\lambda}}$ converge en loi, quand $\lambda \rightarrow +\infty$, vers $\mathcal{N}(0, 1)$.

Solution

Pour $t \in \mathbb{R}$ fixé, $\varphi_{(X_\lambda - \lambda)/\sqrt{\lambda}}(t) = \exp(-it\sqrt{\lambda} + \lambda(e^{it/\sqrt{\lambda}} - 1))$ (Proposition 12.7 « Propriétés élémentaires », point 3, appliquée à la fonction caractéristique de Poisson). Un développement limité de $e^{it/\sqrt{\lambda}} - 1$ à l'ordre 2 en $1/\sqrt{\lambda}$ donne, après simplification, $-it\sqrt{\lambda} + \lambda(\frac{it}{\sqrt{\lambda}} - \frac{t^2}{2\lambda} + o(\frac{1}{\lambda})) = -\frac{t^2}{2} + o(1)$.

Donc $\varphi_{(X_\lambda - \lambda)/\sqrt{\lambda}}(t) \rightarrow e^{-t^2/2}$: on conclut par le théorème de Lévy.

Exercice 13.32 – Somme de deux lois exponentielles

Soient $X_1, \dots, X_n$ i.i.d. de loi $\mathcal{E}(\lambda)$. Reconnaître la loi de $\sum_{i=1}^n X_i$ à l'aide de sa fonction caractéristique.

(On admettra que la fonction caractéristique d'une loi Gamma(p, λ), de densité $\frac{\lambda}{\Gamma(p)} e^{-\lambda x} (\lambda x)^{p-1} \mathbf{1}_{[0, +\infty[}(x)$

pour p entier, est $t \mapsto (\frac{\lambda}{\lambda - it})^p$.)

Solution

Par indépendance (Proposition 12.9 « Fonction caractéristique d'une somme de variables indépendantes ») et l'Exercice 12.6 « Calcul de fonctions caractéristiques usuelles », $\varphi_{\sum_{i=1}^n X_i}(t) = \left(\frac{\lambda}{\lambda - it}\right)^n$. On reconnaît la fonction caractéristique d'une loi Gamma(n, λ) ; par le théorème d'unicité (Théorème 12.13 « Théorème d'inversion / unicité »), $\sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$ – un résultat qui, par changement de variable direct (convolution), demanderait un calcul nettement plus long.

13.4 Vecteurs gaussiens et convergence

Les notions de convergence de ce chapitre s'étendent naturellement aux **vecteurs** aléatoires de $\mathbb{R}^d$ (convergence en loi : $\mathbb{E}(\varphi(X_n)) \rightarrow \mathbb{E}(\varphi(X))$ pour toute $\varphi : \mathbb{R}^d \rightarrow \mathbb{R}$ continue bornée ; convergence en probabilité et p.s. : mêmes définitions, avec $|\cdot|$ remplacé par $\|\cdot\|$). On admet, sans démonstration, la généralisation suivante du théorème de Lévy (Théorème 12.15 « Théorème de Lévy »), dont la preuve (également difficile) suit le même principe.

Théorème 13.33 – Théorème de Lévy, cas vectoriel – admis

Soit $(X_n)_{n \geq 1}$ une suite de vecteurs aléatoires de $\mathbb{R}^d$. Si (φ_{X_n}) converge simplement sur $\mathbb{R}^d$ vers une fonction φ continue en 0, alors φ est la fonction caractéristique d'un vecteur aléatoire X , et (X_n) converge en loi vers X .

Théorème 13.34 – Théorème de Cramér-Wold

Soit $(X_n)_{n \geq 1}$ une suite de vecteurs aléatoires de $\mathbb{R}^d$, X un vecteur aléatoire de $\mathbb{R}^d$. Alors

$$X_n \xrightarrow[n \rightarrow +\infty]{\text{loi}} X \iff \forall u \in \mathbb{R}^d, u^\top X_n \xrightarrow[n \rightarrow +\infty]{\text{loi}} u^\top X \quad (\text{convergence en loi dans } \mathbb{R}).$$

Autrement dit, une suite de vecteurs aléatoires converge en loi si et seulement si **toutes ses combinaisons linéaires réelles** convergent en loi.

Démonstration. ($\Rightarrow$) Si $X_n \rightarrow X$ en loi dans $\mathbb{R}^d$, alors pour $u \in \mathbb{R}^d$ fixé, $\varphi : x \mapsto e^{iu^\top x}$ n'est pas bornée en tant que fonction à valeurs complexes au sens strict de la définition, mais en séparant parties réelle et imaginaire (toutes deux continues bornées de $\mathbb{R}^d$ dans $\mathbb{R}$), la convergence en loi de (X_n) donne $\mathbb{E}(e^{iu^\top X_n}) \rightarrow \mathbb{E}(e^{iu^\top X})$, c'est-à-dire $\varphi_{X_n}(u) \rightarrow \varphi_X(u)$. En particulier, pour $t \in \mathbb{R}$, $\varphi_{u^\top X_n}(t) = \varphi_{X_n}(tu) \rightarrow \varphi_X(tu) = \varphi_{u^\top X}(t)$: les fonctions caractéristiques (réelles, en la variable t) de $u^\top X_n$ convergent simplement vers celle de $u^\top X$, continue en 0. Par le théorème de Lévy (Théorème 12.15 « Théorème de Lévy »), $u^\top X_n \rightarrow u^\top X$ en loi.

($\Leftarrow$) Supposons $u^\top X_n \rightarrow u^\top X$ en loi pour tout $u \in \mathbb{R}^d$. En particulier, pour u fixé, en évaluant en $t = 1$ les fonctions caractéristiques (convergence en loi $\Rightarrow$ convergence des fonctions caractéristiques, par définition même appliquée aux fonctions $\omega \mapsto \cos(\omega)$, $\omega \mapsto \sin(\omega)$, continues bornées) :

$$\varphi_{X_n}(u) = \varphi_{u^\top X_n}(1) \xrightarrow[n \rightarrow +\infty]{} \varphi_{u^\top X}(1) = \varphi_X(u).$$

Ceci vaut pour tout $u \in \mathbb{R}^d$: (φ_{X_n}) converge simplement vers φ_X sur $\mathbb{R}^d$, qui est continue (en particulier en 0, comme toute fonction caractéristique d'un vecteur aléatoire). Par le Théorème 13.33 « Théorème de Lévy, cas vectoriel – admis », $X_n \rightarrow X$ en loi. ■

Corollaire 13.35 – Convergence d'une suite de vecteurs gaussiens

Soit $(X_n)_{n \geq 1}$ une suite de vecteurs gaussiens, $X_n \sim \mathcal{N}_d(m_n, \Sigma_n)$. Si $m_n \rightarrow m$ et $\Sigma_n \rightarrow \Sigma$ (convergence coordonnée par coordonnée), alors X_n converge en loi vers $X \sim \mathcal{N}_d(m, \Sigma)$.

Démonstration. Par le Théorème 12.20 « Fonction caractéristique d'un vecteur gaussien » (Chapitre 12 « Vecteurs aléatoires gaussiens »), pour tout $t \in \mathbb{R}^d$,

$$\varphi_{X_n}(t) = \exp\left(it^\top m_n - \frac{1}{2} t^\top \Sigma_n t\right).$$

Comme $m_n \rightarrow m$ et $\Sigma_n \rightarrow \Sigma$ (coordonnée par coordonnée), et que $t \mapsto t^\top m_n$, $t \mapsto t^\top \Sigma_n t$ sont des fonctions continues des coefficients de m_n, Σ_n , on a, à t fixé, $t^\top m_n \rightarrow t^\top m$ et $t^\top \Sigma_n t \rightarrow t^\top \Sigma t$. Par continuité de l'exponentielle (complexe),

$$\varphi_{X_n}(t) \xrightarrow{n \rightarrow +\infty} \exp\left(it^\top m - \frac{1}{2} t^\top \Sigma t\right) = \varphi_X(t),$$

où $X \sim \mathcal{N}_d(m, \Sigma)$ (Théorème 12.23 « Construction d'un vecteur gaussien quelconque », Chapitre 12 « Vecteurs aléatoires gaussiens », un tel vecteur existe car Σ , limite de matrices de covariance, est symétrique semi-définie positive). Cette convergence a lieu pour tout $t \in \mathbb{R}^d$, et φ_X est continue (en particulier en 0) : par le Théorème 13.33 « Théorème de Lévy, cas vectoriel – admis », $X_n \rightarrow X$ en loi. ■

Remarque 13.36

La réciproque du Corollaire 13.35 « Convergence d'une suite de vecteurs gaussiens » est également vraie (si $X_n \rightarrow X$ en loi et tous les X_n sont gaussiens, alors X est gaussien et $m_n \rightarrow m$, $\Sigma_n \rightarrow \Sigma$), mais sa preuve, un peu plus délicate, est hors-programme ici : elle repose sur le fait qu'une limite en loi de variables gaussiennes réelles est encore gaussienne (éventuellement dégénérée), combinée au Théorème 13.34 « Théorème de Cramér-Wold ».

Théorème 13.37 – Théorème central limite multidimensionnel

Soit $(X_i)_{i \geq 1}$ une suite de vecteurs aléatoires de $\mathbb{R}^d$, i.i.d., de carré intégrable (chaque coordonnée admet un moment d'ordre 2), d'espérance $m \in \mathbb{R}^d$ et de matrice de covariance Σ . Alors

$$\sqrt{n}(\bar{X}_n - m) \xrightarrow[n \rightarrow +\infty]{\text{loi}} \mathcal{N}_d(0, \Sigma), \quad \text{où } \bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i.$$

Démonstration. Soit $u \in \mathbb{R}^d$. Posons $Y_i := u^\top X_i$, variables aléatoires réelles i.i.d. (fonctions des vecteurs i.i.d. X_i , cours Chapitre 10 « Vecteurs aléatoires »), de carré intégrable, d'espérance $\mathbb{E}(Y_i) = u^\top m$ et de variance $\text{Var}(Y_i) = u^\top \Sigma u$ (Proposition 10.24 « Propriétés de la matrice de covariance », Chapitre 10 « Vecteurs aléatoires », qui exprime précisément la variance d'une combinaison linéaire à l'aide de la matrice de covariance).

Cas $u^\top \Sigma u > 0$. Par le théorème central limite réel (Théorème 13.28 « Théorème central limite ») appliqué à (Y_i) ,

$$\frac{\sum_{i=1}^n (Y_i - u^\top m)}{\sqrt{u^\top \Sigma u} \sqrt{n}} \xrightarrow[n \rightarrow +\infty]{\text{loi}} \mathcal{N}(0, 1),$$

c'est-à-dire, en multipliant par la constante $\sqrt{u^\top \Sigma u}$ (fonction continue, cf. Exercice sur la transformation continue d'une convergence en loi) :

$$\sqrt{n}(\bar{Y}_n - u^\top m) = u^\top \left(\sqrt{n}(\bar{X}_n - m) \right) \xrightarrow[n \rightarrow +\infty]{\text{loi}} \mathcal{N}(0, u^\top \Sigma u).$$

Cas $u^\top \Sigma u = 0$. Alors $\text{Var}(Y_i) = 0$, donc $Y_i = u^\top m$ presque sûrement (une variable de variance nulle est constante p.s., égale à son espérance) ; ainsi $\bar{Y}_n = u^\top m$ p.s. pour tout n , donc $u^\top (\sqrt{n}(\bar{X}_n - m)) = \sqrt{n}(\bar{Y}_n - u^\top m) = 0$ p.s. pour tout n : la suite (constante, nulle) converge trivialement en loi vers 0, qui est bien la loi $\mathcal{N}(0, 0) = \mathcal{N}(0, u^\top \Sigma u)$ (dégénérée).

Dans les deux cas, $u^\top (\sqrt{n}(\bar{X}_n - m)) \rightarrow \mathcal{N}(0, u^\top \Sigma u)$ en loi, pour tout $u \in \mathbb{R}^d$. Or, si $Z \sim \mathcal{N}_d(0, \Sigma)$, on a $u^\top Z \sim \mathcal{N}(0, u^\top \Sigma u)$ (Définition 12.17 « Vecteur gaussien » du vecteur gaussien, Chapitre 12 « Vecteurs aléatoires gaussiens »). Ainsi, pour tout $u \in \mathbb{R}^d$, $u^\top (\sqrt{n}(\bar{X}_n - m))$ et $u^\top Z$ ont la même loi limite : par le théorème de Cramér-Wold (Théorème 13.34 « Théorème de Cramér-Wold »), $\sqrt{n}(\bar{X}_n - m) \rightarrow Z \sim \mathcal{N}_d(0, \Sigma)$ en loi. ■

Remarque 13.38

Ce théorème central limite multidimensionnel est l'outil de base de l'inférence statistique multivariée (construction de régions de confiance, tests du χ^2 pour des vecteurs de fréquences, etc.). Sa preuve illustre bien l'intérêt du théorème de Cramér-Wold : elle ramène un énoncé sur des vecteurs aléatoires (a priori délicat) à une simple application, direction par direction, du théorème central limite **réel** déjà démontré – sans aucun nouvel argument analytique.

Exercice 13.39 – Application : ellipse de confiance asymptotique

Soit $(X_i)_{i \geq 1}$ i.i.d. dans $\mathbb{R}^2$, de moyenne m et de matrice de covariance $\Sigma = I_2$ (identité). Montrer que $n \|\bar{X}_n - m\|^2$ converge en loi vers une loi du χ^2 à 2 degrés de liberté (i.e. la loi de $Z_1^2 + Z_2^2$ pour $Z_1, Z_2 \sim \mathcal{N}(0, 1)$ i.i.d.).

Solution

Par le Théorème 13.37 « Théorème central limite multidimensionnel », $\sqrt{n}(\bar{X}_n - m) \rightarrow \mathcal{N}_2(0, I_2)$ en loi. Or $x \mapsto \|x\|^2$ est continue sur $\mathbb{R}^2$; par le théorème de transformation continue d'une convergence en loi (cf. TD13), $\|\sqrt{n}(\bar{X}_n - m)\|^2 = n\|\bar{X}_n - m\|^2$ converge en loi vers $\|Z\|^2 = Z_1^2 + Z_2^2$, pour $Z = (Z_1, Z_2) \sim \mathcal{N}_2(0, I_2)$ (donc Z_1, Z_2 i.i.d. $\mathcal{N}(0, 1)$, par indépendance des composantes d'un vecteur gaussien standard) – c'est-à-dire une loi du χ^2 à 2 degrés de liberté.